

블록 디퓨전: 자기회귀와 디퓨전 언어모델 사이를 보간하기

(Block Diffusion: Interpolating Between Autoregressive and Diffusion Language Models —
한국어 번역본)

Marianne Arriola^{†*} Aaron Kerem Gokaslan[‡] Justin T. Chiu[‡] Zhihan Yang[‡]
Zhixuan Qi[†] Jiaqi Han[¶] Subham Sekhar Sahoo[‡] Volodymyr Kuleshov[‡]

한국어 번역: Compendium (<https://yoon-gu.github.io/compendium/>)

Abstract

디퓨전 언어모델은 병렬 생성과 제어 가능성의 잠재력 덕분에 자기회귀 (autoregressive) 모델 대비 고유한 장점을 제공하지만, 가능도 (likelihood) 모델링에서 뒤처지고 고정된 길이의 생성에만 한정된다는 한계가 있다. 본 연구는 이산(discrete) 디노이징 디퓨전과 자기회귀 모델 사이를 보간하는 블록 디퓨전(block diffusion) 언어모델 부류를 도입한다. 블록 디퓨전은 가변 길이 생성을 지원하고 KV 캐싱(KV caching) 및 병렬 토큰 샘플링으로 추론 효율을 높여, 두 접근법의 핵심 한계를 극복한다. 효과적인 블록 디퓨전 모델 구축을 위해 효율적인 학습 알고리즘, 경사 분산(gradient variance) 추정량, 분산을 최소화하는 데이터 주도(data-driven) 노이즈 스케줄을 포함하는 레시피를 제안한다. 블록 디퓨전은 언어모델링 벤치마크에서 디퓨전 모델 가운데 새로운 최첨단 성능을 달성하며, 임의 길이의 시퀀스 생성을 가능하게 한다. 코드¹와 모델 가중치, 블로그 포스트는 프로젝트 페이지에서 제공한다:

<https://m-arriola.com/bd3lms>

역자 주. 본 문서는 ICLR 2025에 발표된 *Block Diffusion: Interpolating Between Autoregressive and Diffusion Language Models* (Arriola, Gokaslan, Chiu 외, Cornell · Cohere · Stanford) 논문의 한국어 번역이다. 원문 LaTeX 소스의 구조·매크로(BD3-LMs = BD3-LMs, BD3-LM = BD3-LM 등)와 인용·수식·그림은 그대로 유지하고, 자연어 본문·캡션·표 헤더만 한국어로 옮겼다. 부록의 모델 생성 텍스트 샘플은 영어 그대로 둔다(영어 토큰 시퀀스 자체가 평가 대상). 약어·모델명·평가지표는 영문을 살린다.

*Correspondence to Marianne Arriola: marriola@cs.cornell.edu

[†]Cornell Tech, NY, USA. [¶]Stanford University, CA, USA. [‡] Cohere, NY, USA.

¹코드: <https://github.com/kuleshov-group/bd3lms>

1 서론

디퓨전 모델은 이미지 (Ho et al., 2020; Dhariwal & Nichol, 2021; Sahoo et al., 2024b)와 비디오 (Ho et al., 2022; Gupta et al., 2023) 생성에 널리 사용되며, 텍스트 (Lou et al., 2024; Sahoo et al., 2024a)나 생물학적 시퀀스 (Avdeyev et al., 2023; Goel et al., 2024) 같은 이산 데이터 생성에서도 점차 효과적으로 자리잡고 있다. 자기회귀 모델과 비교해, 디퓨전 모델은 생성 속도를 가속하고 모델 출력의 제어 가능성을 높일 잠재력이 있다 (Schiff et al., 2024; Nisonoff et al., 2024; Li et al., 2024; Sahoo et al., 2024c).

이산 디퓨전 모델은 현재 적어도 세 가지 한계를 안고 있다. 첫째, 챗 시스템과 같은 응용에서 모델은 임의 길이의 출력 시퀀스를 생성해야 한다(예: 사용자 질문에 대한 응답). 그러나 최근 대부분의 디퓨전 아키텍처는 고정 길이 벡터만 생성한다 (Austin et al., 2021; Lou et al., 2024). 둘째, 이산 디퓨전은 생성 시 양방향 문맥(bidirectional context)을 사용하므로 KV 캐싱으로 이전 계산을 재사용할 수 없고, 따라서 추론 효율이 떨어진다 (Israel et al., 2025). 셋째, perplexity 같은 표준 지표로 측정한 이산 디퓨전 모델의 품질은 자기회귀 접근에 뒤처져 있어 적용성이 제한된다 (Gulrajani & Hashimoto, 2024; Sahoo et al., 2024a).

본 논문은 이산 디퓨전과 자기회귀 모델 사이를 보간하는 Block Discrete Denoising Diffusion Language Models (BD3-LMs)을 도입하여 이러한 한계를 다루는 방향으로 진전을 이룬다. 구체적으로, 블록 디퓨전 모델(반자기회귀(semi-autoregressive) 모델로도 알려져 있음)은 이산 확률변수의 블록에 대한 자기회귀 확률 분포를 정의하며 (Si et al., 2022; 2023), 이전 블록들이 주어졌을 때의 한 블록의 조건부 확률은 이산 디노이징 디퓨전 모델로 명시된다 (Austin et al., 2021; Sahoo et al., 2024a).

효과적인 BD3-LMs 개발에는 두 가지 난제가 있다. 첫째, 블록 디퓨전 모델의 학습 목적함수를 신경망의 표준 정방향 패스(forward pass) 한 번으로 효율적으로 계산하는 것은 불가능하며, 특화된 알고리즘 개발이 필요하다. 둘째, 학습은 디퓨전 목적함수 경사의 높은 분산으로 방해받으며, 그 결과 블록 크기가 1일 때(두 모델이 동치여야 함)조차 BD3-LMs가 자기회귀에 못 미친다. 우리는 경사 분산 추정량을 유도하고, 이것이 자기회귀와 디퓨전 사이 perplexity 격차의 핵심 기여 요인임을 보인다. 이어서 경사 분산을 최소화하는 맞춤 노이즈 과정을 제안하여 perplexity 격차를 좁히는 방향으로 진전을 이룬다.

언어모델링 벤치마크에서 BD3-LMs를 평가하여, 학습 문맥 길이를 초과하는 길이를 포함해 임의 길이의 시퀀스를 생성할 수 있음을 시연한다. 또한 BD3-LMs는 이산 디퓨전 모델 가운데 새로운 최첨단 perplexity를 달성한다. 임베딩에 대한 가우시안 디퓨전을 수행하는 다른 반자기회귀 정식화 (Han et al., 2022; 2023)와 비교해, 우리의 이산 접근은 다루기 쉬운 기능도 추정치를 제공하고, 한 자릿수 더 적은 생성 단계로 향상된 생성 perplexity의 샘플을 만들어 낸다. 요약하자면, 본 연구의 기여는 다음과 같다.

- 토큰 블록 단위로 자기회귀이며 각 블록의 조건부가 이산 디퓨전에 기반한 블록 이산 디퓨전 언어모델을 도입한다. 기존 디퓨전 모델과 달리, 블록 디퓨전은 가변 길이 생성과 KV 캐싱을 지원한다.
- 모델에 입력된 토큰 배치 전체를 효율적으로 활용할 수 있게 하는, 블록 디퓨전 모델 전용 학습 알고리즘을 도입한다.

Autoregression:	✓ High quality	✓ Arbitrary-length	✓ KV caching	✗ Not Parallelizable
Generation steps	There are three categories of the average There are three categories of the average rate There are three categories of the average rate of...			
Diffusion:	✗ Lower quality	✗ Fixed-length	✗ No KV caching	✓ Parallelizable
	the reusability will continue to the Repeal the reusability cuts and the law will continue to reduce the Repeal the reusability cuts and prove the law will continue to reduce the deficit.			
Block Diffusion (Ours):	✓ High quality	✓ Arbitrary-length	✓ KV caching	✓ Parallelizable
	On September 17, we be On September 17, 2016, we will be giving the release of On September 17, 2016, we will be giving the beta-release of the to our server testing ...			

그림 1: 블록 디퓨전은 각 블록 안에서 디퓨전을 수행하고 이전 블록들에 조건화함으로써 토큰 블록을 순차적으로 생성한다. 자기회귀와 디퓨전 모델의 강점을 결합한 블록 디퓨전은 가변 길이의 더 높은 품질의 생성을 지원하고, KV 캐싱과 병렬 샘플링으로 추론 효율을 높여 두 접근의 한계를 극복한다.

- 디퓨전 모델 성능의 제약 요인으로 경사 분산을 식별하고, 경사 분산을 줄이는 맞춤 데이터 주도 노이즈 스케줄을 제안한다.
- 본 연구의 결과는 이산 디퓨전의 새로운 최첨단 perplexity를 확립하며, 자기회귀 모델과의 격차를 줄이는 방향으로 진전을 이룬다.

2 배경: 언어모델링 패러다임

표기법 V 개의 범주를 가지는 스칼라 이산 확률변수를, 단순체(simplex) Δ^V 의 부분집합인 공간 $\mathcal{V} = \{\mathbf{x} \in \{0, 1\}^V : \sum_i \mathbf{x}_i = 1\} \subset \Delta^V$ 위의 “원-핫(one-hot)” 열벡터로 본다. V 번째 범주는 특수 [MASK] 토큰을 나타내며, $\mathbf{m} \in \mathcal{V}$ 는 그 원-핫 벡터이다. $\mathbf{x}^{1:L}$ 를 L 개의 토큰 시퀀스로 정의하며, 모든 토큰 $\ell \in \{1, \dots, L\}$ 에 대해 $\mathbf{x}^\ell \in \mathcal{V}$ 이고, 그러한 모든 시퀀스의 집합을 $\mathcal{V}^L$ 로 표기한다. 본 논문 전반에서 표기를 단순화하여 토큰 시퀀스를 $\mathbf{x}$, 개별 토큰을 $\mathbf{x}^\ell$ 로 부른다. 끝으로, $\text{Cat}(\cdot; p)$ 를 확률 $p \in \Delta^V$ 인 범주 분포(categorical distribution)로 둔다.

2.1 자기회귀 모델

데이터 분포 $q(\mathbf{x})$ 에서 추출된 L 개의 토큰 시퀀스 $\mathbf{x} = [\mathbf{x}^1, \dots, \mathbf{x}^L]$ 를 고려하자. 자기회귀 (autoregressive, AR) 모델은 다음 형태로 인수분해된 분포를 정의한다.

$$\log p_\theta(\mathbf{x}) = \sum_{\ell=1}^L \log p_\theta(\mathbf{x}^\ell \mid \mathbf{x}^{<\ell}), \quad (1)$$

여기서 각 $p_\theta(\mathbf{x}^\ell \mid \mathbf{x}^{<\ell})$ 은 신경망으로 직접 매개변수화된다. 따라서 AR 모델은 다음 토큰 예측(next token prediction)을 통해 효율적으로 학습될 수 있다. 그러나 순차 의존성 때문에 AR 모델은 L 개의 토큰을 생성하는 데 L 단계가 필요하다.

2.2 이산 디노이징 디퓨전 확률 모델

디퓨전 모델은 정방향 손상 과정 q 를 역행하도록 모델 $p_\theta(\mathbf{x})$ 를 적합시킨다 (Sohl-Dickstein et al., 2015; Ho et al., 2020; Sahoo et al., 2024b). 이 과정은 깨끗한 데이터 $\mathbf{x}$ 에서 시작하여, $\mathbf{x}$ 의 점점 더 노이즈가 많은 버전을 나타내는 잠재변수 $\mathbf{x}_t = [\mathbf{x}_t^1, \dots, \mathbf{x}_t^L]$ 를 $t \in [0, 1]$ 에 대해 정의한다. T 단계로 이산화하면, $s(j) = (j-1)/T$, $t(j) = j/T$ 로 정의한다. 간결성을 위해 이하에서는 $t(j)$ 와 $s(j)$ 의 j 를 생략한다. 일반적으로 s 는 t 직전의 시간 단계를 나타낸다.

D3PM 프레임워크 (Austin et al., 2021)는 q 를 각 토큰 $\mathbf{x}^\ell$ 에 대해 독립적으로 작용하는 마르코프 정방향 과정으로 정의한다. $q(\mathbf{x}_t^\ell | \mathbf{x}_s^\ell) = \text{Cat}(\mathbf{x}_t^\ell; Q_t \mathbf{x}_s^\ell)$ 여기서 $Q_t \in \mathbb{R}^{V \times V}$ 는 디퓨전 행렬이다. 행렬 Q_t 는 마스킹, 무작위 토큰 변경, 관련 단어 치환 등 다양한 변환을 모델링할 수 있다.

이상적인 디퓨전 모델 p_θ 는 과정 q 의 역과정이다. D3PM 프레임워크는 p_θ 를 다음과 같이 정의한다.

$$p_\theta(\mathbf{x}_s | \mathbf{x}_t) = \prod_{\ell=1}^L p_\theta(\mathbf{x}_s^\ell | \mathbf{x}_t) = \sum_{\mathbf{x}} \left[\prod_{\ell=1}^L q(\mathbf{x}_s^\ell | \mathbf{x}_t^\ell, \mathbf{x}^\ell) p_\theta(\mathbf{x}^\ell | \mathbf{x}_t) \right], \quad (2)$$

여기서 디노이징 기반 모델 $p_\theta(\mathbf{x}^\ell | \mathbf{x}_t)$ 는 노이즈 시퀀스 $\mathbf{x}_t$ 가 주어졌을 때 깨끗한 토큰 $\mathbf{x}^\ell$ 을 예측하며, 역 사후 $q(\mathbf{x}_s^\ell | \mathbf{x}_t^\ell, \mathbf{x})$ 은 Austin et al. (2021)을 따라 Suppl. B.3에 정의되어 있다.

디퓨전 모델 p_θ 는 변분 추론(variational inference)으로 학습된다. $\text{KL}[\cdot]$ 이 쿨백-라이블러 발산(Kullback-Leibler divergence)을 나타낸다고 하자. 그러면 음의 ELBO(NELBO)는 다음과 같이 주어진다 (Sohl-Dickstein et al., 2015).

$$\mathcal{L}(\mathbf{x}; \theta) = \mathbb{E}_q \left[-\log p_\theta(\mathbf{x} | \mathbf{x}_{t(1)}) + \sum_{j=1}^T D_{\text{KL}}[q(\mathbf{x}_{s(j)} | \mathbf{x}_{t(j)}, \mathbf{x}) \| p_\theta(\mathbf{x}_{s(j)} | \mathbf{x}_{t(j)})] + D_{\text{KL}}[q(\mathbf{x}_{t(T)} | \mathbf{x}) \| p_\theta(\mathbf{x}_{t(T)})] \right] \quad (3)$$

이 형식은 연속 시간 마르코프 사슬(CTMC) 이론을 통해 연속 시간으로 확장되며, 점수 기반(score-based) 일반화를 허용한다 (Song & Ermon, 2019; Lou et al., 2024; Sun et al., 2022). 추가적인 단순화 (Sahoo et al., 2024a; Shi et al., 2024; Ou et al., 2025)는 ELBO를 더 조이고 성능을 향상시킨다.

3 블록 디퓨전 언어모델링

우리는 토큰 블록에 대한 자기회귀 분포를 정의하고 각 블록 내부에서 디퓨전을 수행함으로써 자기회귀와 디퓨전 모델 사이를 보간하는 Block Discrete Denoising Diffusion Language Models (BD3-LMs) 부류를 탐구한다. 최대 가능성도 추정을 위한 블록 디퓨전 목적함수와 효율적인 학습·표집 알고리즘을 제시한다. 블록 크기가 1일 때 디퓨전 목적함수는 기댓값에서는 자기회귀 가능성도와 동치이지만 분산이 높다는 점을 보인다. 높은 학습 분산을 디퓨전 모델의 제약으로 식별하고, 학습 시 경사 갱신의 분산을 줄이는 데이터 주도 노이즈 스케줄을 제안한다.

3.1 블록 디퓨전 분포와 모델 아키텍처

Section 2의 언어모델링 패러다임을, 토큰 블록을 자기회귀적으로 모델링하면서 각 블록 내부에서 디퓨전을 수행하도록 결합할 것을 제안한다. $\mathbf{x}$ 의 토큰을 길이 L' 의 B 개 블록으로 묶으며

$B = L/L'$ 이다(B 가 정수라 가정). 위치 $(b-1)L'$ 부터 bL' 까지의 각 블록 $\mathbf{x}^{(b-1)L':bL'}$ ($b \in \{1, \dots, B\}$)을 단순히 $\mathbf{x}^b$ 로 표기한다. 우리의 가능성은 블록에 대해 다음과 같이 인수분해된다.

$$\log p_\theta(\mathbf{x}) = \sum_{b=1}^B \log p_\theta(\mathbf{x}^b | \mathbf{x}^{<b}), \quad (4)$$

그리고 각 $p_\theta(\mathbf{x}^b | \mathbf{x}^{<b})$ 는 L' 개 토큰의 블록에 대한 이산 디퓨전으로 모델링된다. 구체적으로, (2)처럼 정의된 블록 b 로 제한된 역 디퓨전 과정을 정의한다.

$$p_\theta(\mathbf{x}_s^b | \mathbf{x}_t^b, \mathbf{x}^{<b}) = \sum_{\mathbf{x}^b} q(\mathbf{x}_s^b | \mathbf{x}_t^b, \mathbf{x}^b) p_\theta(\mathbf{x}^b | \mathbf{x}_t^b, \mathbf{x}^{<b}) \quad (5)$$

(4)의 각 항에 (3)의 NELBO를 적용하여 다음과 같은 원칙적인 학습 목적함수를 얻는다.

$$-\log p_\theta(\mathbf{x}) \leq \mathcal{L}_{\text{BD}}(\mathbf{x}; \theta) := \sum_{b=1}^B \mathcal{L}(\mathbf{x}^b, \mathbf{x}^{<b}; \theta), \quad (6)$$

여기서 각 $\mathcal{L}(\mathbf{x}^b, \mathbf{x}^{<b}; \theta)$ 는 $\log p_\theta(\mathbf{x}^b | \mathbf{x}^{<b})$ 에 적용한 (3)의 한 사례이다. 모델이 $\mathbf{x}^{<b}$ 에 조건화 되므로, $\mathcal{L}$ 에서 $\mathbf{x}^{<b}, \theta$ 에 대한 의존을 명시한다. 이 항들의 합을 $\mathcal{L}_{\text{BD}}(\mathbf{x}; \theta)$ 로 표기한다(그 자체로 유효한 NELBO이다).

모델 아키텍처 결정적으로, B 개의 기반 디노이저 모델 $p_\theta(\mathbf{x}^b | \mathbf{x}_t^b, \mathbf{x}^{<b})$ 를 단일 신경망 $\mathbf{x}_\theta$ 로 매개변수화한다. 신경망 $\mathbf{x}_\theta$ 는 확률 $p_\theta(\mathbf{x}^b | \mathbf{x}_t^b, \mathbf{x}^{<b})$ 뿐 아니라 효율적인 학습을 위한 계산 산출 물도 출력한다. 이는 모든 B 개 블록에 대한 손실 $\mathcal{L}_{\text{BD}}(\mathbf{x}; \theta)$ 를 메모리 효율적으로 병렬 계산할 수 있게 해 준다. 구체적으로, 블록-인과(block-causal) 어텐션 마스크를 사용하는 트랜스포머 (Vaswani et al., 2017)로 $\mathbf{x}_\theta$ 를 매개변수화한다. 트랜스포머 $\mathbf{x}_\theta$ 는 L 개 토큰에 적용되며, 블록 b 의 토큰들은 블록 1부터 b 까지의 토큰들에만 주의를 기울인다. $\mathbf{x}_\theta$ 가 학습되면, $\mathbf{x}_\theta^b(\mathbf{x}_t^b, \mathbf{x}^{<b})$ 는 노이즈 $\mathbf{x}_t^b$ 와 깨끗한 $\mathbf{x}^{<b}$ 를 바탕으로 블록 b 안 디노이즈된 토큰에 대한 L' 개의 예측을 만들어 낸다.

자기회귀 생성에서는 이전에 생성된 토큰의 키와 값을 캐싱해 매 단계 재계산을 피하는 것이 일반적이다. 마찬가지로, 블록 b 의 키와 값을 K^b, V^b 로 표기하고, $\mathbf{x}_\theta$ 가 이를 입력·출력으로 지원하도록 정의한다. $\mathbf{x}_\theta$ 의 전체 시그니처는 다음과 같다.

$$\mathbf{x}_{\text{logits}}^b, K^b, V^b \leftarrow \mathbf{x}_\theta^b(\mathbf{x}_t^b, K^{1:b-1}, V^{1:b-1}) := \mathbf{x}_\theta^b(\mathbf{x}_t^b, \mathbf{x}^{<b}), \quad (7)$$

여기서 $\mathbf{x}_{\text{logits}}^b$ 는 깨끗한 $\mathbf{x}^b$ 에 대한 예측이고, K^b, V^b 는 $\mathbf{x}_\theta$ 의 정방향 패스에서 만들어진 키-값 캐시이며, $K^{1:b-1}, V^{1:b-1}$ 은 $\mathbf{x}^{<b}$ 에 대한 $\mathbf{x}_\theta$ 정방향 패스에서 캐시된 키와 값이다(따라서 입력 $\mathbf{x}^{<b}$ 와 $K^{1:b-1}, V^{1:b-1}$ 는 동치이다).

3.2 효율적 학습·표집 알고리즘

이상적으로는 손실 $\mathcal{L}_{\text{BD}}(\mathbf{x}; \theta)$ 를 $\mathbf{x}_\theta$ 의 한 번의 정방향 패스로 계산하고 싶다. 그러나 $\mathbf{x}_t^b$ 를 디노이징하려면 이 노이즈 입력에 대한 정방향 패스가 필요하고, 다음 블록을 디노이징하려면 $\mathbf{x}_\theta$ 를 깨끗한 버전 $\mathbf{x}^b$ 에 대해 실행해야 한다. 따라서 모든 블록은 모델을 최소 두 번 통과해야 한다.

학습 이 관찰을 바탕으로, 위의 최소 계산 요구를 가진 학습 알고리즘을 제안한다 (Alg. 1). 구체적으로, 첫 번째 정방향 패스 $(\emptyset, K^{1:B}, V^{1:B}) \leftarrow \mathbf{x}_\theta(\mathbf{x})$ 에서 전체 시퀀스 $\mathbf{x}$ 의 키와 값 $K^{1:B}, V^{1:B}$ 를 미리 계산한다. 그런 다음 모든 블록에 대한 디노이즈 예측을 $\mathbf{x}_\theta^b(\mathbf{x}_t^b, K^{1:b-1}, V^{1:b-1})$ 로 계산한다. 각 토큰은 $\mathbf{x}_\theta$ 를 두 번 통과한다.

벡터화 학습 단순한 방법으로는 $\mathbf{x}_\theta^b(\mathbf{x}_t^b, \mathbf{K}^{1:b-1}, \mathbf{V}^{1:b-1})$ 를 B 번 반복 적용해 logits를 계산할 것이다. 우리는 깨끗한 데이터 $\mathbf{x}$ 와, 각 블록 $\mathbf{x}^b$ 에 노이즈 수준 t_b 를 적용해 얻은 노이즈 데이터 $\mathbf{x}_{\text{noisy}} = \mathbf{x}_{t_1}^1 \oplus \dots \oplus \mathbf{x}_{t_B}^B$ 의 결합 $\mathbf{x}_{\text{noisy}} \oplus \mathbf{x}$ 에 대해 한 번의 정방향 패스로 $\mathcal{L}_{\text{BD}}(\mathbf{x}; \theta)$ 를 계산하는 벡터화 구현을 제안한다. 노이즈 토큰들이 같은 블록 안 다른 노이즈 토큰들과 이전 블록 안 모든 깨끗한 토큰들에 주의를 기울이도록 $\mathbf{x}_{\text{noisy}} \oplus \mathbf{x}$ 에 대한 어텐션 마스크를 설계한다(Suppl. B.6 참조). 본 방법은 BD3-LMs 학습의 오버헤드를 다루기 좋게 유지하며, 사전학습과 결합해 비용을 더 줄인다.

표집 한 번에 한 블록씩 이전에 표집된 블록들에 조건화하여 표집한다(Alg. 2). 조건부 분포 $p_\theta(\mathbf{x}_s^b | \mathbf{x}_t^b, \mathbf{x}^{<b})$ 로부터 표집하기 위해 어떤 표집 절차 $\text{Sample}(\mathbf{x}_\theta^b, \mathbf{K}^{1:b-1}, \mathbf{V}^{1:b-1})$ 이든 사용할 수 있으며, 문맥 조건화는 미리 계산된 키와 값 $\mathbf{K}^{1:b-1}, \mathbf{V}^{1:b-1}$ 을 활용한 크로스 어텐션으로 생성된다. AR 모델처럼, 새 블록을 표집할 때 키와 값을 다시 계산하지 않고 캐싱하면 계산을 절약할 수 있다.

특히 우리의 블록 디퓨전 디코딩 알고리즘은 임의 길이의 시퀀스를 표집할 수 있게 해 주는 반면, (일반) 디퓨전 모델은 고정 길이 생성으로 제한된다. 또한 우리의 샘플러는 각 블록 안에서 병렬 생성을 허용하지만, AR 샘플러는 토큰 단위 생성으로 제한된다.

Algorithm 1 블록 디퓨전 학습

입력: 데이터 $\mathbf{x}$, 블록 수 B , 정방향 노이즈 과정 $q_t(\cdot | \mathbf{x})$, 모델 $\mathbf{x}_\theta$, 손실 $\mathcal{L}_{\text{BD}}$

repeat

$t_1, \dots, t_B \sim \mathcal{U}[0, 1]$ 표집

$\forall b \in \{1, \dots, B\} : \mathbf{x}_{t_b}^b \sim q_{t_b}(\cdot | \mathbf{x}^b)$

$\emptyset, \mathbf{K}^{1:B}, \mathbf{V}^{1:B} \leftarrow \mathbf{x}_\theta(\mathbf{x})$ ▷ KV 캐시

$\forall b: \mathbf{x}_{\text{logit}}^b, \emptyset, \emptyset \leftarrow \mathbf{x}_\theta^b(\mathbf{x}_{t_b}^b, \mathbf{K}^{1:b-1}, \mathbf{V}^{1:b-1})$

$\mathbf{x}_{\text{logit}} \leftarrow \mathbf{x}_{\text{logit}}^1 \oplus \dots \oplus \mathbf{x}_{\text{logit}}^B$ 로 뭉

$\nabla_\theta \mathcal{L}_{\text{BD}}(\mathbf{x}_{\text{logit}}; \theta)$ 로 경사 단계 수행

until 수렴

Algorithm 2 블록 디퓨전 표집

입력: 블록 수 B , 모델 $\mathbf{x}_\theta$, 디퓨전 표집 알고리즘 Sample

$\mathbf{x}, \mathbf{K}, \mathbf{V} \leftarrow \emptyset$ ▷ 출력 & KV 캐시

for $b = 1$ to B **do**

$\mathbf{x}^b \leftarrow \text{Sample}(\mathbf{x}_\theta^b, \mathbf{K}^{1:b-1}, \mathbf{V}^{1:b-1})$

$\emptyset, \mathbf{K}^b, \mathbf{V}^b \leftarrow \mathbf{x}_\theta^b(\mathbf{x}^b)$

$\mathbf{x} \leftarrow \mathbf{x}^{1:b-1} \oplus \mathbf{x}^b$

$(\mathbf{K}, \mathbf{V}) \leftarrow (\mathbf{K}^{1:b-1} \oplus \mathbf{K}^b, \mathbf{V}^{1:b-1} \oplus \mathbf{V}^b)$

end for

return $\mathbf{x}$

4 디퓨전과 AR 모델 사이 가능도 격차의 이해

4.1 마스크 BD3-LMs

가장 효과적인 디퓨전 언어모델은 토큰이 점진적으로 특수 마스크 토큰으로 치환되는 마스크 노이즈 과정을 활용한다 (Austin et al., 2021; Lou et al., 2024; Sahoo et al., 2024a). 여기서는 마스크 디퓨전 언어모델링 프레임워크 (Sahoo et al., 2024a; Shi et al., 2024; Ou et al., 2025)에 기반한 블록 디퓨전 모델의 특수 부류인 마스크 BD3-LMs를 도입한다.

보다 형식적으로, 토큰 $\ell \in \{1, \dots, L\}$ 에 대해 토큰별 노이즈 과정 $q(\mathbf{x}_t^\ell | \mathbf{x}^\ell) = \text{Cat}(\mathbf{x}_t^\ell; \alpha_t \mathbf{x}^\ell + (1 - \alpha_t) \mathbf{m})$ 을 채택한다. 여기서 $\mathbf{m}$ 은 마스크 토큰의 원-핫 인코딩이고, $\alpha_t \in [0, 1]$ 은 $\alpha_0 = 1, \alpha_1 = 0$ 을 만족하는 t 에 대한 엄격히 감소 함수이다. 시간 t 에서 토큰이 마스크될 확률이 $1 - \alpha_t$ 인 선형 스케줄을 사용한다. Sahoo et al. (2024a); Shi et al. (2024); Ou et al. (2025)의 단순화된

목적함수를 채택한다(전체 유도는 Suppl. B.3에 있다).

$$-\log p_\theta(\mathbf{x}) \leq \mathcal{L}_{\text{BD}}(\mathbf{x}; \theta) := \sum_{b=1}^B \mathbb{E}_{t \sim [0,1]} \mathbb{E}_q \frac{\alpha'_t}{1 - \alpha_t} \log p_\theta(\mathbf{x}^b | \mathbf{x}_t^b, \mathbf{x}^{<b}) \quad (8)$$

여기서 α'_t 은 $T \rightarrow \infty$ 로 보내는 (3)의 연속 시간 확장 하에서 α_t 의 순간 변화율이다. NELBO는 $L' = 1$ 에서 타이트(tight)하지만, $L' \rightarrow L$ 로 갈수록 참 음의 로그가능도에 대한 더 느슨한 근사가 된다(Suppl. B.5 참조).

4.2 사례 연구: 단일 토큰 생성

우리의 블록 디퓨전 매개변수화 (8)은 $L' = 1$ 의 극한에서 자기회귀 NLL (1)과 기댓값에서 동치이다(Suppl. B.4 참조). 놀랍게도, LM1B 데이터셋으로 두 모델을 학습하면 $L' = 1$ 의 블록 디퓨전 모델과 AR 사이에 perplexity 격차가 약 2 포인트 있음을 발견한다.

목적함수가 기댓값에서는 동치이지만, 남은 perplexity 격차는 높은 학습 분산의 결과임을 보인다. AR은 L 개 토큰의 교차 엔트로피로 학습되는 반면, $L' = 1$ 의 우리 블록 디퓨전 모델은 마스크 토큰 $\mathbf{x}_t^\ell = \mathbf{m} \forall \ell \in \{1, \dots, L\}$ 에 대해서만 교차 엔트로피를 계산하여 $\mathbb{E}_{t \sim \mathcal{U}[0,1]} q(\mathbf{x}_t^\ell = \mathbf{m} | \mathbf{x}^\ell) = 0.5$ 가 된다. 따라서 디퓨전 목적함수로 학습하면 손실 경사를 2배 더 적은 토큰으로 추정하게 되어 AR 대비 학습 분산이 커진다.

표 1: LM1B에서 16B 토큰에 대한 단일 토큰 생성의 테스트 perplexity(PPL; ↓).

	PPL (↓)
AR	22.88
+ random batch size	24.37
BD3-LM $L' = 1$	≤ 25.56
+ tuned schedule	22.88

가능도 격차를 닫기 위해, 정방향 과정을 토큰을 완전히 마스크하도록(즉, $q(\mathbf{x}_t^\ell = \mathbf{m} | \mathbf{x}^\ell) = 1$) 설계하여 $L' = 1$ 인 BD3-LM를 학습한다. 이 스케줄에서 디퓨전 목적함수는 AR 목적함수와 동치가 된다(Suppl. B.4). 표 1에서, 블록 디퓨전 목적함수로 학습한 결과 perplexity가 AR 학습과 같음을 보인다. 경험적으로 이는 그림 2처럼 학습 손실의 분산을 줄여 준다. 노이즈 스케줄 튜닝이 목적함수의 분산을 줄임은 328M 토큰 학습 후 $\text{Var}_{\mathbf{x},t} [\mathcal{L}_{\text{BD}}(\mathbf{x}; \theta)]$ 를 측정하여 검증한다. NELBO로 학습하면 분산이 1.52인 반면, 완전 마스크 학습으로는 분산이 0.11로 감소한다.

4.3 높은 분산 학습이 만드는 디퓨전 격차

다음으로, 디퓨전 모델 학습에서 경사 분산 문제를 형식적으로 기술한다. 단일 토큰 생성에 대한 경험적 관찰을 바탕으로, $L' \geq 1$ 의 디퓨전 모델 학습 분산을 최소화하기 위해 사용할 경사 분산 추정량을 제안한다. NELBO는 노이즈 스케줄 선택에 불변이지만(Suppl. B.3), 이 불변성은 학습 시 사용하는 손실의 몬테카를로(Monte Carlo) 추정량에는 성립하지 않는다. 따라서 추정량과 그 경사의 분산은 스케줄에 의존한다. 먼저 배치 크기 K 에서의 NELBO 추정량을 표현한다. 시퀀스 배치를 $\mathbf{X} = [\mathbf{x}^{(1)}, \mathbf{x}^{(2)}, \dots, \mathbf{x}^{(K)}]$ 로 표기하고, 각 $\mathbf{x}^{(k)} \stackrel{\text{iid}}{\sim} q(\mathbf{x})$ 이다. 배치 NELBO 추정량은 아래와 같으며, $t(k, b)$ 는 시퀀스 k 와 블록 b 에서 표집된다.

$$\mathcal{L}_{\text{BD}}(\mathbf{X}; \theta) := l(\mathbf{X}; \theta) = \frac{1}{K} \sum_{k=1}^K \sum_{b=1}^B \frac{\alpha'_{t(k,b)}}{1 - \alpha_{t(k,b)}} \log p_\theta(\mathbf{x}^{(k),b} | \mathbf{x}_{t(k,b)}^{(k),b}, \mathbf{x}^{(k),<b}) \quad (9)$$




그림 2: LM1B에서 토큰별 가능도 모델링의 학습 NLL. 모델은 16B 토큰으로 학습된다. 배치 안 토큰의 평균 절반이 마스킹되는 이산 디퓨전 NELBO로 학습할 때, 무작위 배치 크기를 가진 AR 모델과 비슷한 학습 분산을 가진다.

각 배치 $X^m \forall m \in \{1, \dots, M\}$ 에 대한 M 개 배치에 걸친 경사 추정량의 분산은 다음과 같다.

$$\text{Var}_{X,t} [\nabla_{\theta} l(X; \theta)] \approx \frac{1}{M-1} \sum_{m=1}^M \left\| \nabla_{\theta} l(X^m; \theta) - \frac{1}{M} \sum_{m=1}^M \nabla_{\theta} l(X^m; \theta) \right\|_2^2 \quad (10)$$

5 BD3-LMs를 위한 저분산 노이즈 스케줄

5.1 직관: 극단적 마스크율을 피하기

경사 추정량의 분산을 최소화하고 학습을 가장 효율적으로 만드는 스케줄을 찾는 것이 목표이다. 마스크 환경에서는 무작위 수의 토큰을 마스킹하여, 모델이 다양한 수준의 노이즈를 되돌리는 법을 학습하게 하고자 한다. 이는 표집 시 중요하다. 그러나 너무 적은 토큰만 마스킹하면 재구성 이 쉽고 유용한 학습 신호를 주지 못한다. 모든 것을 마스킹하면 최적 재구성은 데이터 분포에서 각 토큰의 주변(marginals)이며, 학습이 쉽지만 다시 유용하지 않다. 이러한 극단적 마스크율은 분산이 큰 나쁜 경사로 이어진다. 우리는 단순하고 효과적인 새로운 스케줄 부류로 이를 클리핑(clipping)하는 법을 학습하고자 한다.

5.2 저분산 경사를 위한 클리핑 스케줄

마스크율 $1 - \alpha_t \sim \mathcal{U}[\beta, \omega] (0 \leq \beta, \omega \leq 1)$ 에서 표집하는 “클리핑(clipped)” 노이즈 스케줄 부류를 제안한다. 몬테카를로 경사 추정의 관점에서 이러한 스케줄은, 지정된 범위 이전에는 마스크 확률이 약 0이고($1 - \alpha_{<\beta} \approx \epsilon$), 지정된 범위 이후에는 약 1인($1 - \alpha_{>\omega} \approx 1 - \epsilon$) 연속 스케줄과 동치임을 주장한다. 그 결과 범위 안에서는 α'_t 이 선형이다: $\alpha'_t \approx 1/(\beta - \omega)$.

5.3 블록 크기별 데이터 주도 클리핑 스케줄

최적 마스크율은 블록 크기 L' 에 따라 다를 수 있으므로, 학습 중에 스케줄을 적응적으로 학습한다. Kingma et al. (2021)는 제곱 디퓨전 손실로 분산 항을 분리해 분산 최소화를 수행하지만, 이

전략은 식 10의 우리 분산 추정량에 직접 적용되지 않는다. 우리는 무작위 t_b 뿐 아니라 무작위 배치 전반에서도 분산을 줄이고자 하기 때문이다.

대신, 학습 분산을 직접 최소화하도록 파라미터 β, ω 를 최적화한다. 최적화의 계산 부담을 줄이기 위해, 경사 추정량의 대리값(proxy)으로 디퓨전 ELBO 추정량의 분산을 사용해 β, ω 를 최적화한다: $\min_{\beta, \omega} \text{Var}_{X,t} [\mathcal{L}(X; \theta, \beta, \omega)]$. 학습 중 정기적인 간격으로 격자 탐색(grid search)을 수행하여 최적 β, ω 를 찾는다(실험 세부 사항은 Section 6).

표 2에서 디퓨전 NELBO의 분산이 테스트 perplexity와 상관관계가 있음을 보인다. 다양한 “클리핑” 노이즈율 분포 하에서, 블록 크기 $L' \in \{4, 16, 128\}$ 각각에 대해 NELBO의 분산과 테스트 perplexity를 모두 최소화하는 고유한 분포가 존재함을 확인한다.

표 2: Perplexity(PPLs; ↓)와 NELBO 분산 $\text{Var}_{X,t} [\mathcal{L}_{\text{BD}}(X; \theta)]$ (Var. NELBO; ↓). 모델은 선형 스케줄로 LM1B에서 65B 토큰을 학습한 뒤 10B 토큰으로 파인튜닝된다.

L'	$\mathcal{U}[0, .5]$		$\mathcal{U}[,3, .8]$		$\mathcal{U}[,5, 1]$		$\mathcal{U}[0, 1]$	
	PPL	Var. NELBO	PPL	Var. NELBO	PPL	Var. NELBO	PPL	Var. NELBO
128	31.72	1.03	31.78	1.35	31.92	1.83	31.78	3.80
16	31.27	7.90	31.19	3.62	31.29	3.63	31.33	7.39
4	29.23	32.68	29.37	10.39	29.16	8.28	29.23	23.65

6 실험

BD3-LMs를 표준 언어모델링 벤치마크에서 평가하고, 비조건적으로 임의 길이의 시퀀스를 생성할 수 있는 능력을 시연한다. One Billion Words 데이터셋(LM1B; Chelba et al. (2014))과 OpenWeb-Text(OWT; Gokaslan et al. (2019))에서 최대 블록 크기 $L' = L$ 로 850K 경사 단계 동안 기반 BD3-LM를 사전학습하고, 다양한 L' 로 150K 경사 단계 동안 파인튜닝한다. 학습과 추론 세부 사항은 Suppl. C에 있다.

디퓨전 NELBO 학습의 분산을 줄이기 위해, Section 5.3에 기술한 대로 파라미터 β, ω 를 최적화하여 마스킹율의 범위를 적응적으로 학습한다. 실제로는 매 검증 에포크마다(약 5K 경사 갱신 후) β, ω 를 찾기 위한 격자 탐색을 수행한다: $\min_{\beta, \omega} \text{Var}_{X,t} [\mathcal{L}(X; \theta, \beta, \omega)]$. 평가 시에는 Austin et al. (2021); Sahoo et al. (2024a)을 따라 균일 표집 마스킹율 하에서의 가능도(8)를 보고한다.

표 3: LM1B에서 65B 토큰으로 학습한 모델들의 테스트 perplexity(PPL; ↓). 디퓨전 모델 중 최고값은 굵게 표시.

	PPL (↓)
Autoregressive	
Transformer-X Base (Dai et al., 2019)	23.5
Transformer (Sahoo et al., 2024a)	22.83
Diffusion	
D3PM (absorb) (Austin et al., 2021)	≤ 82.34
SEDD (Lou et al., 2024)	≤ 32.68
MDLM (Sahoo et al., 2024a)	≤ 31.78
Block diffusion (Ours)	
BD3-LMs $L' = 16$	≤ 30.60
$L' = 8$	≤ 29.83
$L' = 4$	≤ 28.23

6.1 가능도 평가

LM1B에서 BD3-LMs는 표 3의 모든 기존 디퓨전 방법을 능가한다. MDLM (Sahoo et al., 2024a)과 비교해 BD3-LMs는 perplexity에서 최대 13%의 개선을 달성한다. 표 4의 OpenWebText에서도 비슷한 경향을 관찰한다.

또한 Radford et al. (2019)의 벤치마크를 따라 본 적 없는 데이터셋에 대한 BD3-LMs의 제로샷(zero-shot) 일반화 능력을 평가한다. OWT로 학습한 모델의 가능도를 Penn Tree Bank (PTB; (Marcus et al., 1993)), Wikitext (Merity et al., 2016), LM1B, Lambada (Paperno et al., 2016), AG News (Zhang et al., 2015), Scientific Papers (Pubmed, Arxiv 부분집합; (Cohan et al., 2018)) 데이터셋에서 평가한다. 표 5에서 BD3-LM는 Pubmed에서 AR을 넘어 최고 제로샷 perplexity를 달성하고, Wikitext, LM1B, AG News에서는 디퓨전 모델 중 최고를 달성한다.

표 5: OWT에서 524B 토큰으로 학습한 모델들의 제로샷 검증 perplexity($\downarrow$). 디퓨전 모델의 모든 perplexity는 상한이다.

	PTB	Wikitext	LM1B	Lambada	AG News	Pubmed	Arxiv
AR	81.07	25.32	51.14	52.13	52.11	48.59	41.22
SEDD	96.33	35.98	68.14	48.93	67.82	45.39	40.03
MDLM	90.96	33.22	64.94	48.29	62.78	43.13	37.89
BD3-LM $L' = 4$	96.81	31.31	60.88	50.03	61.67	42.52	39.20

6.2 샘플 품질과 가변 길이 시퀀스 생성

기존 많은 디퓨전 언어모델(예: Austin et al. (2021); Lou et al. (2024))의 핵심 단점 중 하나는 학습 시 선택한 출력 문맥 길이보다 긴 전체 길이의 시퀀스를 생성할 수 없다는 점이다. OWT 데이터셋은 1024 토큰의 학습 문맥 길이보다 긴 문서가 많아서 이 한계를 살펴보기에 유용하다.

표 6에 500개 가변 길이 샘플의 생성 길이 통계를 기록한다. 시퀀스 종료 토큰 [EOS]가 생성되거나 샘플 품질이 크게 저하될 때까지(샘플 엔트로피로 측정) 토큰 표집을 계속한다. BD3-LMs는 학습 문맥 크기로 제한된 SEDD (Lou et al., 2024)보다 약 10배까지 긴 시퀀스를 생성한다.

또한 정량·정성적 분석으로 BD3-LMs의 샘플 품질을 살펴본다. 표 7에서 길이 $L = 1024, 2048$ 의 시퀀스를 생성하고 GPT2-Large 하에서의 생성 perplexity를 측정한다. MDLM에서 $L = 2048$ 토큰을 표집하기 위해 그들의 블록 단위 디코딩 기법을 사용한다(이 기법에는 BD3-LMs와 같은 블록 디퓨전 학습이 포함되지 않는다).

표 4: 524B 토큰으로 학습한 모델들의 OWT 테스트 perplexity(PPL; $\downarrow$). 디퓨전 모델 중 최고값은 굵게 표시.

	PPL ($\downarrow$)
AR (Sahoo et al., 2024a)	17.54
SEDD (Lou et al., 2024)	≤ 24.10
MDLM (Sahoo et al., 2024a)	≤ 22.98
BD3-LMs $L' = 16$	≤ 22.27
$L' = 8$	≤ 21.68
$L' = 4$	≤ 20.73

표 6: OWT로 학습한 모델에서 500개 문서를 표집했을 때의 생성 길이 통계.

	중앙값 토큰 수	최댓값 토큰 수
OWT 학습 셋	717	131K
AR	4008	131K
SEDD	1021	1024
BD3-LM $L' = 16$	798	9982

또한 다른 블록 디퓨전 정식화인 SSD-LM (Han et al., 2022)과 비교한다. 우리의 이산 디퓨전 프레임워크와 달리 SSD-LM은 가우시안 디퓨전을 사용하며 가능도 추정을 지원하지 않는다. 더불어 BD3-LM는 마스크 디퓨전의 효율적인 샘플러를 채택하므로, 토큰이 다시 마스킹되지 않기 때문에 생성 단계 수(NFEs)는 L 로 상한이다 (Sahoo et al., 2024a; Ou et al., 2025). SSD-LM에 대해서는 그들의 실험 설정인 블록당 $T = 1K$ 디퓨전 단계로 샘플 품질을 비교하고($\geq 40K$ NFEs), 방법 간 NFEs가 비슷한 $T = 25$ 도 보고한다.

표 7: 길이 $L = 1024, 2048$ 의 300개 샘플에 대한 생성 perplexity(Gen. PPL; $\downarrow$)와 함수 평가 횟수(NFEs; $\downarrow$). 모든 모델은 OWT에서 학습된다. AR, SEDD, MDLM, BD3-LMs는 110M 파라미터로 524B 토큰에서 학습되었고, SSD-LM은 400M 파라미터로 122B 토큰에서 사전 학습되었다. 디퓨전 모델 중 최고값은 굵게 표시. 자세한 내용은 Suppl. C.5에 있다.

Model	$L = 1024$		$L = 2048$	
	Gen. PPL	NFEs	Gen. PPL	NFEs
AR	14.1	1K	13.2	2K
Diffusion				
SEDD	52.0	1K	–	–
MDLM	46.8	1K	41.3	2K
Block Diffusion				
SSD-LM $L' = 25$	37.2	40K	35.3	80K
	281.3	1K	281.9	2K
BD3-LMs $L' = 16$	33.4	1K	31.5	2K
$L' = 8$	30.4	1K	28.2	2K
$L' = 4$	25.7	1K	23.6	2K

BD3-LMs는 기존 디퓨전 방법 대비 가장 좋은 생성 perplexity를 달성한다. SSD-LM 대비 우리의 이산 접근은 한 자릿수 더 적은 생성 단계로 향상된 생성 perplexity의 샘플을 만들어 낸다. 또한 OWT 데이터셋에서 학습한 BD3-LM와 기준선(AR, MDLM)의 샘플을 정성적으로도 살펴본다. 샘플은 Suppl. D에 있다. BD3-LM 샘플이 MDLM 샘플보다 일관성이 높고 AR의 품질에 근접함을 관찰한다.

6.3 어블레이션

제안한 블록 디퓨전 레시피의 설계 선택, 즉 1) 노이즈 스케줄 선택과 2) 단순 구현 대비 제안 학습 알고리즘의 효율 향상이 미치는 영향을 평가한다.

학습 분산을 줄이기 위한 노이즈 스케줄 선택

Lou et al. (2024); Sahoo et al. (2024a)에서 사용된 선형 스케줄과 비교해, “클리핑” 노이즈 스케줄로 학습하는 것이 테스트 perplexity와 상관 있는 학습 분산을 가장 효과적으로 줄인다. 표 8에서 학습 중 최적화되는 이상적인 “클리핑” 마스킹율은 블록 크기에 특화되어 있으며, 이는 우리의 최적화 동기를 더해 준다.

다른 표준 노이즈 스케줄 (Chang et al., 2022) 대비 “클리핑” 마스크가 가장 좋은 성능을 달성한다. 더 무거운 마스크가 더 작은 블록 크기 $L' = 4$ 에 효과적이므로, 무거운 마스크를 권장하는 로그·제곱근 스케줄과 비교한다. 더 가벼운 마스크가 $L' = 16$ 에 최적이므로 제곱·코사인 스케줄과 비교한다.

학습 알고리즘의 효율

BD3-LM 학습 알고리즘 (Section 3.2)에서 $x_{\logit}$ 를 두 가지 방식으로 계산한다. 신경망을 두 번 정방향 패스(전체 시퀀스 x 의 키·값 미리 계산 후 디노이즈 예측 계산)할 수도 있고, 두 입력을 같은 어텐션 커널에 결합해 한 번에 처리할 수도 있다.

효율적인 어텐션 커널 (Dao et al., 2022; Dong et al., 2024)을 활용하면 메모리 대역폭 병목이 줄어들어 단일 정방향 패스가 더 효율적임을 확인했다 (Suppl. B.7 참고). 신경망을 두 번 통과하는 비용 대신 더 비싼 어텐션 연산의 비용만 지불한다. 우리의 벡터화 접근은 두 번의 정방향 패스 대비 학습 시 20–25% 속도 향상을 가진다.

표 8: 노이즈 스케줄이 가중도 추정에 미치는 영향. LM1B에서 3B 토큰으로 BD3-LMs를 파인튜닝하고 선형 스케줄로 평가한다. 클리핑 스케줄에 대해서는 $L' = 4, 16$ 의 최적 클리핑을 비교한다.

노이즈 스케줄	PPL	Var. NELBO
$L' = 4$		
Clipped		
$\mathcal{U}[0.45, 0.95]$	29.21	6.24
$\mathcal{U}[0.3, 0.8]$	29.38	10.33
Linear $\mathcal{U}[0, 1]$	30.18	23.45
Logarithmic	30.36	23.53
Square root	31.41	26.43
$L' = 16$		
Clipped		
$\mathcal{U}[0.45, 0.95]$	31.42	3.60
$\mathcal{U}[0.3, 0.8]$	31.12	3.58
Linear $\mathcal{U}[0, 1]$	31.72	7.62
Square	31.43	13.03
Cosine	31.41	13.00

7 논의와 선행 연구

D3PM과의 비교 블록 디퓨전은 D3PM (Austin et al., 2021)에서 출발해 이를 각 자기회귀 조건부에 적용한다. D3PM 대비 세 가지 측면에서 개선한다: (1) D3PM을 고정 시퀀스 길이를 넘어 확장하고, (2) D3PM과 AR 모델의 perplexity 격차를 연구하여 경사 분산을 그 기여 요인으로 식별하고 분산 최소화 스케줄을 설계하며, (3) D3PM 모델의 perplexity를 개선한다. 본 연구는 연속 시간의 확장 (Campbell et al., 2022; Sun et al., 2022)을 포함한 D3PM의 확장 (He et al., 2022; Lou et al., 2024)에 적용된다.

MDLM과의 비교 BD3-LMs는 MDLM (Sahoo et al., 2024a; Shi et al., 2024; Ou et al., 2025)의 perplexity 향상 개선을 한층 더 활용한다. MDLM 위에 다음과 같이 쌓아 올린다: (1) Sahoo et al. (2024a)는 그들의 NELBO가 노이즈 스케줄에 불변이라고 지적하지만, 우리는 노이즈 스케줄이 경사 분산에 상당한 영향을 미침을 보인다. (2) MDLM 너머로 perplexity의 최첨단을 끌어올린다. 우리의 perplexity 향상은 블록 디퓨전뿐 아니라 최적화된 스케줄에서도 비롯되며, 표준 MDLM과 D3PM 모델도 개선할 수 있다.

가우시안 디퓨전과의 비교 대안적으로, 이산 토큰의 연속 임베딩에 대해 디퓨전을 수행할 수 있다 (Li et al., 2022; Dieleman et al., 2022; Chen et al., 2022). 이는 연속 데이터용 알고리즘 (Song et al., 2020; Ho & Salimans, 2022)을 사용할 수 있게 해주지만 perplexity는 더 나쁘다 (Graves et al., 2023; Gulrajani & Hashimoto, 2024).

반자기회귀 디퓨전과의 비교 Han et al. (2022; 2023)는 가우시안 디퓨전의 블록 정식화를 도입했다. 반면 BD3-LMs는 Austin et al. (2021)을 확장하며 다음 특성을 가진다: (1) 원칙적 평가를 위한 다루기 쉬운 가늡도 추정치, (2) 모델 호출 횟수가 생성 토큰 수로 상한이라 더 빠른 생성(SSD-LM은 한 자릿수 이상 더 많은 호출 수행), (3) 향상된 샘플 품질. AR-Diffusion (Wu et al., 2023)은 SSD-LM을 좌→우 노이즈 스케줄로 확장한다. Chen et al. (2025); Ye et al. (2024)은 의사결정 트레이스와 비디오에, Hao et al. (2024); Kong et al. (2025)은 잠재 추론에 적용한다. PARD (Zhao et al., 2024)는 이산 블록 디퓨전을 그래프에 적용한다. 이에 비해 우리는 (1) AR/디퓨전 성능 사이를 보간하고, (2) KV 캐싱을 지원하며, (3) 노이즈 블록 안에서 어텐션을 수행한다(반면 PARD는 새 빈 블록을 주입한다).

자기회귀 디퓨전 모델 (Hoogeboom et al., 2021b;a)은 임의 순서 AR 모델(any-order AR models; AO-ARMs; Uria et al. (2014))을 확장하여 병렬 표집을 지원한다. Zheng et al. (2024)는 MDLM과 AO-ARM 학습 사이의 동치성을 증명한다. 디퓨전과 경쟁하는 AR 모델의 확장에는 반복 편집 (Gu et al., 2019), 병렬·추측 디코딩 (Gu et al., 2017; Santilli et al., 2023; Cai et al., 2024; Gloeckle et al., 2024), 일관성 학습 (Kou et al., 2024), 유도 (Sanchez et al., 2023), 교차 모달 확장 (Liu et al., 2023; Tian et al., 2025) 등이 있다.

한계 BD3-LMs 학습은 일반 디퓨전 학습보다 비용이 크다. 우리는 학습 속도를 디퓨전 학습 속도의 2배 미만으로 유지하는 벡터화 알고리즘을 제안하며, 실험에서는 속도 격차를 더 줄이기 위해 표준 디퓨전 손실로 사전학습도 한다. 또한 BD3-LMs는 블록을 순차적으로 생성하므로 블록이 작을 때는 AR과 같은 속도·제어성 제약을 겪을 수 있다. 최적 블록 크기는 과제에 따라 다르다(예: 더 큰 제어를 위해 더 큰 블록). BD3-LMs는 환각(hallucinations) (Achiam et al., 2023), 저작권 침해 (Gokaslan et al., 2024), 제어성 (Schiff et al., 2024; Wang et al., 2023), 해로운 출력 (Bai et al., 2022) 등 생성 모델 고유의 한계를 공유한다.

8 결론

본 연구는 블록 디퓨전을 탐구하며, 임의 길이의 시퀀스 생성 필요성과 자기회귀 모델 대비 perplexity 격차라는 기존 이산 디퓨전의 두 문제에서 동기를 얻는다. D3PM 프레임워크 (Austin et al., 2021)의 블록 단위 확장에 해당하는 BD3-LMs를 도입하고, 성능을 더 끌어올리는 특화 학습 알고리즘과 맞춤 노이즈 스케줄을 활용한다. 이 모델들이 장문 문서를 생성할 수 있을 뿐 아니라 perplexity도 개선해, 이산 디퓨전 모델 중 새로운 최첨단을 세움을 관찰한다.

감사의 말 및 펀딩 공개

본 연구는 미국 국립과학재단(National Science Foundation)의 DGE-1922551, CA-REER 2046760·2145577 상과 미국 국립보건원(National Institute of Health)의 MIRA R35GM151243 상의 부분적인 지원을 받았다. Marianne Arriola는 NSF Graduate Research Fellowship(DGE-2139899)과 Hopper-Dean/Bowers CIS Deans Excellence Fellowship의 지원을 받는다. 계산 자원 사용을 제공한 Databricks MosaicML에 감사드린다.

References

- Josh Achiam, Steven Adler, Sandhini Agarwal, Lama Ahmad, Ilge Akkaya, Florencia Leoni Aleman, Diogo Almeida, Janko Altschmidt, Sam Altman, Shyamal Anadkat, et al. Gpt-4 technical report. *arXiv preprint arXiv:2303.08774*, 2023.
- Jacob Austin, Daniel D Johnson, Jonathan Ho, Daniel Tarlow, and Rianne Van Den Berg. Structured denoising diffusion models in discrete state-spaces. *Advances in Neural Information Processing Systems*, 34:17981 – 17993, 2021.
- Pavel Avdeyev, Chenlai Shi, Yuhao Tan, Kseniia Dudnyk, and Jian Zhou. Dirichlet diffusion score model for biological sequence generation. In *International Conference on Machine Learning*, pp. 1276 – 1301. PMLR, 2023.
- Yuntao Bai, Saurav Kadavath, Sandipan Kundu, Amanda Askell, Jackson Kernion, Andy Jones, Anna Chen, Anna Goldie, Azalia Mirhoseini, Cameron McKinnon, et al. Constitutional ai: Harmlessness from ai feedback. *arXiv preprint arXiv:2212.08073*, 2022.
- Tianle Cai, Yuhong Li, Zhengyang Geng, Hongwu Peng, Jason D Lee, Deming Chen, and Tri Dao. Medusa: Simple llm inference acceleration framework with multiple decoding heads. *arXiv preprint arXiv:2401.10774*, 2024.
- Andrew Campbell, Joe Benton, Valentin De Bortoli, Thomas Rainforth, George Deligiannidis, and Arnaud Doucet. A continuous time framework for discrete denoising models. *Advances in Neural Information Processing Systems*, 35:28266 – 28279, 2022.
- Huiwen Chang, Han Zhang, Lu Jiang, Ce Liu, and William T Freeman. Maskgit: Masked generative image transformer. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pp. 11315 – 11325, 2022.
- Ciprian Chelba, Tomas Mikolov, Mike Schuster, Qi Ge, Thorsten Brants, Phillipp Koehn, and Tony Robinson. One billion word benchmark for measuring progress in statistical language modeling, 2014.
- Boyuan Chen, Diego Martı Monso, Yilun Du, Max Simchowitz, Russ Tedrake, and Vincent Sitzmann. Diffusion forcing: Next-token prediction meets full-sequence diffusion. *Advances in Neural Information Processing Systems*, 37:24081 – 24125, 2025.
- Ting Chen, Ruixiang Zhang, and Geoffrey Hinton. Analog bits: Generating discrete data using diffusion models with self-conditioning. *arXiv preprint arXiv:2208.04202*, 2022.
- Arman Cohan, Franck Dernoncourt, Doo Soon Kim, Trung Bui, Seokhwan Kim, Walter Chang, and Nazli Goharian. A discourse-aware attention model for abstractive summarization of long documents. *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 2 (Short Papers)*, 2018. doi: 10.18653/v1/n18-2097. URL <http://dx.doi.org/10.18653/v1/n18-2097>.

- Zihang Dai, Zhilin Yang, Yiming Yang, Jaime Carbonell, Quoc V Le, and Ruslan Salakhutdinov. Transformer-xl: Attentive language models beyond a fixed-length context. *arXiv preprint arXiv:1901.02860*, 2019.
- Tri Dao, Dan Fu, Stefano Ermon, Atri Rudra, and Christopher Re. Flashattention: Fast and memory-efficient exact attention with io-awareness. *Advances in Neural Information Processing Systems*, 35:16344–16359, 2022.
- Prafulla Dhariwal and Alex Nichol. Diffusion models beat gans on image synthesis, 2021. URL <https://arxiv.org/abs/2105.05233>.
- Sander Dieleman, Laurent Sartran, Arman Roshannai, Nikolay Savinov, Yaroslav Ganin, Pierre H Richemond, Arnaud Doucet, Robin Strudel, Chris Dyer, Conor Durkan, et al. Continuous diffusion for categorical data. *arXiv preprint arXiv:2211.15089*, 2022.
- Juechu Dong, Boyuan Feng, Driss Guessous, Yanbo Liang, and Horace He. Flex attention: A programming model for generating optimized attention kernels. *arXiv preprint arXiv:2412.05496*, 2024.
- Fabian Gloeckle, Badr Youbi Idrissi, Baptiste Roziere, David Lopez-Paz, and Gabriel Synnaeve. Better & faster large language models via multi-token prediction. *arXiv preprint arXiv:2404.19737*, 2024.
- Shrey Goel, Vishrut Thoutam, Edgar Mariano Marroquin, Aaron Gokaslan, Arash Firouzbakht, Sophia Vincoff, Volodymyr Kuleshov, Huong T Kratochvil, and Pranam Chatterjee. Memdlm: De novo membrane protein design with masked discrete diffusion protein language models. *arXiv preprint arXiv:2410.16735*, 2024.
- Aaron Gokaslan, Vanya Cohen, Ellie Pavlick, and Stefanie Tellex. Openwebtext corpus. <http://Skyllion007.github.io/OpenWebTextCorpus>, 2019.
- Aaron Gokaslan, A Feder Cooper, Jasmine Collins, Landan Seguin, Austin Jacobson, Mihir Patel, Jonathan Frankle, Cory Stephenson, and Volodymyr Kuleshov. Commoncanvas: Open diffusion models trained on creative-commons images. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 8250–8260, 2024.
- Alex Graves, Rupesh Kumar Srivastava, Timothy Atkinson, and Faustino Gomez. Bayesian flow networks. *arXiv preprint arXiv:2308.07037*, 2023.
- Jiatao Gu, James Bradbury, Caiming Xiong, Victor OK Li, and Richard Socher. Non-autoregressive neural machine translation. *arXiv preprint arXiv:1711.02281*, 2017.
- Jiatao Gu, Changan Wang, and Junbo Zhao. Levenshtein transformer. *Advances in neural information processing systems*, 32, 2019.
- Ishaan Gulrajani and Tatsunori B Hashimoto. Likelihood-based diffusion language models. *Advances in Neural Information Processing Systems*, 36, 2024.

- Agrim Gupta, Lijun Yu, Kihyuk Sohn, Xiuye Gu, Meera Hahn, Li Fei-Fei, Irfan Essa, Lu Jiang, and Jose Lezama. Photorealistic video generation with diffusion models, 2023. URL <https://arxiv.org/abs/2312.06662>.
- Xiaochuang Han, Sachin Kumar, and Yulia Tsvetkov. Ssd-lm: Semi-autoregressive simplex-based diffusion language model for text generation and modular control. *arXiv preprint arXiv:2210.17432*, 2022.
- Xiaochuang Han, Sachin Kumar, Yulia Tsvetkov, and Marjan Ghazvininejad. David helps goliath: Inference-time collaboration between small specialized and large general diffusion lms. *arXiv preprint arXiv:2305.14771*, 2023.
- Shibo Hao, Sainbayar Sukhbaatar, DiJia Su, Xian Li, Zhiting Hu, Jason Weston, and Yuan-dong Tian. Training large language models to reason in a continuous latent space. *arXiv preprint arXiv:2412.06769*, 2024.
- Zhengfu He, Tianxiang Sun, Kuanning Wang, Xuanjing Huang, and Xipeng Qiu. Diffusion-bert: Improving generative masked language models with diffusion models. *arXiv preprint arXiv:2211.15029*, 2022.
- Jonathan Ho and Tim Salimans. Classifier-free diffusion guidance. *arXiv preprint arXiv:2207.12598*, 2022.
- Jonathan Ho, Ajay Jain, and Pieter Abbeel. Denoising diffusion probabilistic models. *Advances in neural information processing systems*, 33:6840–6851, 2020.
- Jonathan Ho, Tim Salimans, Alexey Gritsenko, William Chan, Mohammad Norouzi, and David J Fleet. Video diffusion models. *arXiv:2204.03458*, 2022.
- Emiel Hoogeboom, Alexey A Gritsenko, Jasmijn Bastings, Ben Poole, Rianne van den Berg, and Tim Salimans. Autoregressive diffusion models. *arXiv preprint arXiv:2110.02037*, 2021a.
- Emiel Hoogeboom, Didrik Nielsen, Priyank Jaini, Patrick Forre, and Max Welling. Argmax flows and multinomial diffusion: Learning categorical distributions. *Advances in Neural Information Processing Systems*, 34:12454–12465, 2021b.
- Daniel Israel, Aditya Grover, and Guy Van den Broeck. Enabling autoregressive models to fill in masked tokens. *arXiv preprint arXiv:2502.06901*, 2025.
- Diederik Kingma, Tim Salimans, Ben Poole, and Jonathan Ho. Variational diffusion models. *Advances in neural information processing systems*, 34:21696–21707, 2021.
- Deqian Kong, Minglu Zhao, Dehong Xu, Bo Pang, Shu Wang, Edouardo Honig, Zhangzhang Si, Chuan Li, Jianwen Xie, Sirui Xie, et al. Scalable language models with posterior inference of latent thought vectors. *arXiv preprint arXiv:2502.01567*, 2025.
- Siqi Kou, Lanxiang Hu, Zhezhi He, Zhijie Deng, and Hao Zhang. CLLMs: Consistency large language models. In *Forty-first International Conference on Machine Learning*, 2024. URL <https://openreview.net/forum?id=8uzB0Vmh8H>.

- Xiang Li, John Thickstun, Ishaan Gulrajani, Percy S Liang, and Tatsunori B Hashimoto. Diffusion-lm improves controllable text generation. *Advances in Neural Information Processing Systems*, 35:4328 – 4343, 2022.
- Xiner Li, Yulai Zhao, Chenyu Wang, Gabriele Scalia, Gokcen Eraslan, Surag Nair, Tommaso Biancalani, Shuiwang Ji, Aviv Regev, Sergey Levine, et al. Derivative-free guidance in continuous and discrete diffusion models with soft value-based decoding. *arXiv preprint arXiv:2408.08252*, 2024.
- Haotian Liu, Chunyuan Li, Qingyang Wu, and Yong Jae Lee. Visual instruction tuning. *Advances in neural information processing systems*, 36:34892 – 34916, 2023.
- Aaron Lou, Chenlin Meng, and Stefano Ermon. Discrete diffusion modeling by estimating the ratios of the data distribution. In *Forty-first International Conference on Machine Learning*, 2024. URL <https://openreview.net/forum?id=CNicRIVIPA>.
- Mitch Marcus, Beatrice Santorini, and Mary Ann Marcinkiewicz. Building a large annotated corpus of english: The penn treebank. *Computational linguistics*, 19(2):313 – 330, 1993.
- Stephen Merity, Caiming Xiong, James Bradbury, and Richard Socher. Pointer sentinel mixture models, 2016.
- Hunter Nisonoff, Junhao Xiong, Stephan Allenspach, and Jennifer Listgarten. Unlocking guidance for discrete state-space diffusion and flow models. *arXiv preprint arXiv:2406.01572*, 2024.
- Jingyang Ou, Shen Nie, Kaiwen Xue, Fengqi Zhu, Jiacheng Sun, Zhenguo Li, and Chongxuan Li. Your absorbing discrete diffusion secretly models the conditional distributions of clean data. In *The Thirteenth International Conference on Learning Representations*, 2025. URL <https://openreview.net/forum?id=sMyXP8Tanm>.
- Denis Paperno, German Kruszewski, Angeliki Lazaridou, Ngoc Quan Pham, Raffaella Bernardi, Sandro Pezzelle, Marco Baroni, Gemma Boleda, and Raquel Fernandez. The LAMBADA dataset: Word prediction requiring a broad discourse context. In *Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pp. 1525 – 1534, Berlin, Germany, August 2016. Association for Computational Linguistics. URL <http://www.aclweb.org/anthology/P16-1144>.
- William Peebles and Saining Xie. Scalable diffusion models with transformers. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pp. 4195 – 4205, 2023.
- Alec Radford, Jeffrey Wu, Rewon Child, David Luan, Dario Amodei, Ilya Sutskever, et al. Language models are unsupervised multitask learners. *OpenAI blog*, 1(8):9, 2019.
- Subham Sekhar Sahoo, Marianne Arriola, Aaron Gokaslan, Edgar Mariano Marroquin, Alexander M Rush, Yair Schiff, Justin T Chiu, and Volodymyr Kuleshov. Simple and effective masked diffusion language models. In *The Thirty-eighth Annual Conference on Neural Information Processing Systems*, 2024a. URL <https://openreview.net/forum?id=L4uaAR4ArM>.

- Subham Sekhar Sahoo, Aaron Gokaslan, Christopher De Sa, and Volodymyr Kuleshov. Diffusion models with learned adaptive noise. In *The Thirty-eighth Annual Conference on Neural Information Processing Systems*, 2024b. URL <https://openreview.net/forum?id=IoMa99A4p8>.
- Subham Sekhar Sahoo, John Xavier Morris, Aaron Gokaslan, Srijeeta Biswas, Vitaly Shmatikov, and Volodymyr Kuleshov. Zero-order diffusion guidance for inverse problems, 2024c. URL <https://openreview.net/forum?id=JBgBrnhLLL>.
- Guillaume Sanchez, Honglu Fan, Alexander Spangher, Elad Levi, Pawan Sasanka Ammanamanchi, and Stella Biderman. Stay on topic with classifier-free guidance. *arXiv preprint arXiv:2306.17806*, 2023.
- Andrea Santilli, Silvio Severino, Emilian Postolache, Valentino Maiorca, Michele Mancusi, Riccardo Marin, and Emanuele Rodola. Accelerating transformer inference for translation via parallel decoding. In Anna Rogers, Jordan Boyd-Graber, and Naoaki Okazaki (eds.), *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pp. 12336–12355, Toronto, Canada, July 2023. Association for Computational Linguistics. doi: 10.18653/v1/2023.acl-long.689. URL <https://aclanthology.org/2023.acl-long.689>.
- Yair Schiff, Subham Sekhar Sahoo, Hao Phung, Guanghan Wang, Sam Boshar, Hugo Dalla-torre, Bernardo P de Almeida, Alexander Rush, Thomas Pierrot, and Volodymyr Kuleshov. Simple guidance mechanisms for discrete diffusion models. *arXiv preprint arXiv:2412.10193*, 2024.
- Jiaxin Shi, Kehang Han, Zhe Wang, Arnaud Doucet, and Michalis Titsias. Simplified and generalized masked diffusion for discrete data. In *The Thirty-eighth Annual Conference on Neural Information Processing Systems*, 2024. URL <https://openreview.net/forum?id=xcqS0fHt4g>.
- Phillip Si, Allan Bishop, and Volodymyr Kuleshov. Autoregressive quantile flows for predictive uncertainty estimation. In *International Conference on Learning Representations*, 2022.
- Phillip Si, Zeyi Chen, Subham Sekhar Sahoo, Yair Schiff, and Volodymyr Kuleshov. Semi-autoregressive energy flows: exploring likelihood-free training of normalizing flows. In *International Conference on Machine Learning*, pp. 31732–31753. PMLR, 2023.
- Jascha Sohl-Dickstein, Eric Weiss, Niru Maheswaranathan, and Surya Ganguli. Deep unsupervised learning using nonequilibrium thermodynamics. In *International conference on machine learning*, pp. 2256–2265. PMLR, 2015.
- Jiaming Song, Chenlin Meng, and Stefano Ermon. Denoising diffusion implicit models. *arXiv preprint arXiv:2010.02502*, 2020.
- Yang Song and Stefano Ermon. Generative modeling by estimating gradients of the data distribution. *Advances in neural information processing systems*, 32, 2019.

- Jianlin Su, Yu Lu, Shengfeng Pan, Ahmed Murtadha, Bo Wen, and Yunfeng Liu. Roformer: Enhanced transformer with rotary position embedding. *arXiv preprint arXiv:2104.09864*, 2021.
- Haoran Sun, Lijun Yu, Bo Dai, Dale Schuurmans, and Hanjun Dai. Score-based continuous-time discrete diffusion models. *arXiv preprint arXiv:2211.16750*, 2022.
- Keyu Tian, Yi Jiang, Zehuan Yuan, Bingyue Peng, and Liwei Wang. Visual autoregressive modeling: Scalable image generation via next-scale prediction. *Advances in neural information processing systems*, 37:84839–84865, 2025.
- Benigno Uria, Iain Murray, and Hugo Larochelle. A deep and tractable density estimator. In *International Conference on Machine Learning*, pp. 467–475. PMLR, 2014.
- Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. *Advances in neural information processing systems*, 30, 2017.
- Yingheng Wang, Yair Schiff, Aaron Gokaslan, Weishen Pan, Fei Wang, Christopher De Sa, and Volodymyr Kuleshov. InfoDiffusion: Representation learning using information maximizing diffusion models. In Andreas Krause, Emma Brunskill, Kyunghyun Cho, Barbara Engelhardt, Sivan Sabato, and Jonathan Scarlett (eds.), *Proceedings of the 40th International Conference on Machine Learning*, volume 202 of *Proceedings of Machine Learning Research*, pp. 36336–36354. PMLR, 23–29 Jul 2023. URL <https://proceedings.mlr.press/v202/wang23ah.html>.
- Tong Wu, Zhihao Fan, Xiao Liu, Hai-Tao Zheng, Yeyun Gong, yelong shen, Jian Jiao, Juntao Li, zhongyu wei, Jian Guo, Nan Duan, and Weizhu Chen. AR-diffusion: Auto-regressive diffusion model for text generation. In *Thirty-seventh Conference on Neural Information Processing Systems*, 2023. URL <https://openreview.net/forum?id=0EG6qUQ4xE>.
- Jiacheng Ye, Shansan Gong, Liheng Chen, Lin Zheng, Jiahui Gao, Han Shi, Chuan Wu, Xin Jiang, Zhenguo Li, Wei Bi, et al. Diffusion of thoughts: Chain-of-thought reasoning in diffusion language models. *arXiv preprint arXiv:2402.07754*, 2024.
- Xiang Zhang, Junbo Jake Zhao, and Yann LeCun. Character-level convolutional networks for text classification. In *NIPS*, 2015.
- Lingxiao Zhao, Xueying Ding, and Leman Akoglu. Pard: Permutation-invariant autoregressive diffusion for graph generation. In *The Thirty-eighth Annual Conference on Neural Information Processing Systems*, 2024. URL <https://openreview.net/forum?id=x4Kk4FxLs3>.
- Kaiwen Zheng, Yongxin Chen, Hanzi Mao, Ming-Yu Liu, Jun Zhu, and Qinsheng Zhang. Masked diffusion models are secretly time-agnostic masked models and exploit inaccurate categorical sampling. *arXiv preprint arXiv:2409.02908*, 2024.

Contents

1	서론	2
2	배경: 언어모델링 패러다임	3
2.1	자기회귀 모델	3
2.2	이산 디노이징 디퓨전 확률 모델	4
3	블록 디퓨전 언어모델링	4
3.1	블록 디퓨전 분포와 모델 아키텍처	4
3.2	효율적 학습·표집 알고리즘	5
4	디퓨전과 AR 모델 사이 가능도 격차의 이해	6
4.1	마스크 BD3-LMs	6
4.2	사례 연구: 단일 토큰 생성	7
4.3	높은 분산 학습이 만드는 디퓨전 격차	7
5	BD3-LMs를 위한 저분산 노이즈 스케줄	8
5.1	직관: 극단적 마스크율을 피하기	8
5.2	저분산 경사를 위한 클리핑 스케줄	8
5.3	블록 크기별 데이터 주도 클리핑 스케줄	8
6	실험	9
6.1	가능도 평가	9
6.2	샘플 품질과 가변 길이 시퀀스 생성	10
6.3	어블레이션	11
7	논의와 선행 연구	12
8	결론	13
A	블록 디퓨전 NELBO	21
B	마스크 BD3-LMs	22
B.1	정방향 과정	22
B.2	역방향 과정	22

B.3	마스크 디퓨전 과정의 단순화 NELBO	22
B.4	단일 토큰 생성에서 NELBO로부터 NLL 복원	24
B.5	NELBO의 타이트함	24
B.6	특화 어텐션 마스크	25
B.7	FlexAttention을 이용한 최적화 어텐션 커널	26
C	실험 세부 사항	29
C.1	데이터셋	29
C.2	아키텍처	29
C.3	학습	29
C.4	가능도 평가	30
C.5	추론	30
D	샘플	32

A 블록 디퓨전 NELBO

이하에서는 블록 디퓨전 매개변수화의 음의 ELBO(NELBO)를 제시한다. 데이터 분포 $q(\mathbf{x})$ 에서 추출된 시퀀스 $\mathbf{x}^{1:L} = [\mathbf{x}^1, \dots, \mathbf{x}^L]$ 이 B 개의 블록으로 인수분해되며, 단순화를 위해 이를 $\mathbf{x}$ 로 부른다. 구체적으로 가능도를 길이 L' 의 B 개 블록에 대해 인수분해한 뒤, 각 블록에서 T 이산화 단계의 디퓨전을 수행한다. $D_{\text{KL}}[\cdot]$ 을 쿨백-라이블러 발산으로, t, s 를 모든 $i \in [1, T]$ 에 대한 $t(i) = i/T, s(i) = (i-1)/T$ 의 약어로 두자. NELBO를 다음과 같이 유도한다.

$$\begin{aligned}
-\log p_{\theta}(\mathbf{x}) &= -\sum_{b=1}^B \log p_{\theta}(\mathbf{x}^b | \mathbf{x}^{<b}) \\
&= -\sum_{b=1}^B \log \mathbb{E}_q \frac{p_{\theta}(\mathbf{x}_{t(1):t(T)}^b | \mathbf{x}^{<b})}{q(\mathbf{x}_{t(1):t(T)}^b | \mathbf{x}^b)} \\
&= -\sum_{b=1}^B \log \mathbb{E}_q \frac{p_{\theta}(\mathbf{x}_{t(T)}^b | \mathbf{x}^{<b}) \prod_{i=1}^T p_{\theta}(\mathbf{x}_{s(i)}^b | \mathbf{x}_{t(i)}^b, \mathbf{x}^{<b})}{\prod_{i=1}^T q(\mathbf{x}_{t(i)}^b | \mathbf{x}_{s(i)}^b)} \\
&\leq \sum_{b=1}^B \left[\underbrace{-\mathbb{E}_q \log p_{\theta}(\mathbf{x}^b | \mathbf{x}_{t=\frac{1}{T}}^b, \mathbf{x}^{<b})}_{\mathcal{L}_{\text{recons}}} \right. \\
&\quad \left. + \underbrace{\mathbb{E}_{t \in \{\frac{2}{T}, \dots, \frac{T-1}{T}, 1\}} \mathbb{E}_q T D_{\text{KL}}(q(\mathbf{x}_s^b | \mathbf{x}_t^b, \mathbf{x}^b) \parallel p_{\theta}(\mathbf{x}_s^b | \mathbf{x}_t^b, \mathbf{x}^{<b}))}_{\mathcal{L}_{\text{diffusion}}} \right. \\
&\quad \left. + \underbrace{D_{\text{KL}}(q(\mathbf{x}_{t=1}^b | \mathbf{x}^b) \parallel p_{\theta}(\mathbf{x}_{t=1}^b))}_{\mathcal{L}_{\text{prior}}} \right] \tag{11}
\end{aligned}$$

B 마스크 BD3-LMs

마스크 디퓨전 언어모델링 프레임워크 위에 쌓아 올린 블록 디퓨전 모델의 특정 부류를 탐구한다. 특히 Austin et al. (2021)이 도입한 마스크 디퓨전 과정에 초점을 맞추고, Sahoo et al. (2024a); Shi et al. (2024); Ou et al. (2025)이 제안한 대로 이 프레임워크 하에서 단순화된 NELBO를 유도한다.

먼저 상태 $i \in \{1, \dots, V\}$ 에 대한 디퓨전 행렬 Q_t 를 정의한다. $\alpha_0 = 1, \alpha_1 = 0$ 을 만족하는 t 에 대한 엄격히 감소 함수인 노이즈 스케줄 함수 $\alpha_t \in [0, 1]$ 를 고려하자. 마스크 인덱스를 $m = V$ 로 표기한다. Austin et al. (2021)은 디퓨전 행렬을 다음과 같이 정의한다:

$$[Q_t]_{ij} = \begin{cases} 1 & \text{if } i = j = m \\ \alpha_t & \text{if } i = j \neq m \\ 1 - \alpha_t & \text{if } j = m, i \neq m \end{cases} \quad (12)$$

정방향 주변 분포에 대한 디퓨전 행렬 $Q_{t|s}$ 는 다음과 같다:

$$[Q_{t|s}]_{ij} = \begin{cases} 1 & \text{if } i = j = m \\ \alpha_{t|s} & \text{if } i = j \neq m \\ 1 - \alpha_{t|s} & \text{if } j = m, i \neq m \end{cases} \quad (13)$$

where $\alpha_{t|s} = \alpha_t / \alpha_s$.

B.1 정방향 과정

D3PM 프레임워크 (Austin et al., 2021) 하에서, 각 토큰 $\ell \in \{1, \dots, L\}$ 에 독립적으로 적용되는 정방향 노이즈 과정은 디퓨전 행렬 $Q_t \in \mathbb{R}^{V \times V}$ 를 사용해 다음과 같이 정의된다.

$$q(\mathbf{x}_t^\ell | \mathbf{x}^\ell) = \text{Cat}(\mathbf{x}_t^\ell; \bar{Q}_t \mathbf{x}^\ell), \quad \text{with} \quad \bar{Q}_{t(i)} = Q_{t(1)} Q_{t(2)} \dots Q_{t(i)} \quad (14)$$

B.2 역방향 과정

$Q_{t|s}$ 를 정방향 주변 분포에 대한 디퓨전 행렬이라 하자. 디퓨전 행렬을 사용해 역 사후 $q(\mathbf{x}_s^\ell | \mathbf{x}_t^\ell, \mathbf{x}^\ell)$ 를 얻는다.

$$q(\mathbf{x}_s^\ell | \mathbf{x}_t^\ell, \mathbf{x}^\ell) = \frac{q(\mathbf{x}_t^\ell | \mathbf{x}_s^\ell, \mathbf{x}^\ell) q(\mathbf{x}_s^\ell | \mathbf{x}^\ell)}{q(\mathbf{x}_t^\ell | \mathbf{x}^\ell)} = \text{Cat}\left(\mathbf{x}_s^\ell; \frac{Q_{t|s} \mathbf{x}_t^\ell \odot Q_s^\top \mathbf{x}^\ell}{(\mathbf{x}_t^\ell)^\top Q_t^\top \mathbf{x}^\ell}\right) \quad (15)$$

여기서 $\odot$ 은 두 벡터 간 아다마르(Hadamard) 곱을 나타낸다.

B.3 마스크 디퓨전 과정의 단순화 NELBO

Sahoo et al. (2024a); Shi et al. (2024); Ou et al. (2025)을 따라, 마스크 디퓨전 과정의 경우에 NELBO를 단순화한다. 이하에서 NELBO 유도의 개요를 제공하며, 전체 유도는 Sahoo et al. (2024a); Shi et al. (2024); Ou et al. (2025)을 참고하라.

먼저 식 11의 디퓨전 손실 항 $\mathcal{L}_{\text{diffusion}}$ 의 단순화에 집중한다. 마스크 디퓨전을 위한 디노이즈 모델 p_θ 를 단순화하는 Sahoo et al. (2024b)의 SUBS-매개변수화를 사용한다. 구체적으로, 디퓨전 과정에서 가능한 상태가 $\mathbf{x}_t^\ell \in \{\mathbf{x}^\ell, \mathbf{m}\} \forall \ell \in \{1, \dots, L\}$ 둘뿐이라는 사실을 이용해 p_θ 의 설계에 다음 제약을 부과한다.

1. 영(0) 마스크 확률. $p_\theta(\mathbf{x}^\ell = \mathbf{m} | \mathbf{x}_t^\ell) = 0$ 으로 둔다(깨끗한 시퀀스 $\mathbf{x}$ 에는 마스크가 없으므로).
2. 언마스크 캐리 오버(carry-over unmasking). $\mathbf{x}_t^\ell \neq \mathbf{m}$ 인 경우의 참 사후는 $q(\mathbf{x}_s^\ell = \mathbf{x}_t^\ell | \mathbf{x}_t^\ell \neq \mathbf{m}) = 1$ 이다(역방향 과정에서 언마스크된 토큰은 다시 마스크되지 않는다). 따라서 디노이징 모델을 $p_\theta(\mathbf{x}_s^\ell = \mathbf{x}_t^\ell | \mathbf{x}_t^\ell \neq \mathbf{m}) = 1$ 로 단순화한다.

결과적으로, 사후 $p_\theta(\mathbf{x}_s^\ell = \mathbf{x}^\ell | \mathbf{x}_t^\ell = \mathbf{m})$ 만 근사하면 된다. $\mathbf{x}^{b,\ell}$ 을 블록 $b \in \{1, \dots, B\}$ 의 ℓ 번째 위치의 토큰을 나타내는 표기로 두자. 디퓨전 손실 항은 다음과 같다.

$$\begin{aligned}
 \mathcal{L}_{\text{diffusion}} &= \sum_{b=1}^B \mathbb{E}_t \mathbb{E}_q T [\text{D}_{\text{KL}} [q(\mathbf{x}_s^b | \mathbf{x}_t^b, \mathbf{x}^{<b}) \| p_\theta(\mathbf{x}_s^b | \mathbf{x}_t^b, \mathbf{x}^{<b})]] \\
 &= \sum_{b=1}^B \mathbb{E}_t \mathbb{E}_q T \left[\sum_{\ell=1}^{L'} \text{D}_{\text{KL}} [q(\mathbf{x}_s^{b,\ell} | \mathbf{x}_t^{b,\ell}, \mathbf{x}^{b,<\ell}) \| p_\theta(\mathbf{x}_s^{b,\ell} | \mathbf{x}_t^{b,\ell}, \mathbf{x}^{b,<\ell})] \right] \\
 &\text{D}_{\text{KL}} \text{는 단순히 블록 } b \text{에 대한 이산 시간 디퓨전 손실이다. 따라서 Sahoo et al. (2024a) (Suppl. B.1)로부터 다음을 얻는다:} \\
 &= \sum_{b=1}^B \mathbb{E}_t \mathbb{E}_q T \left[\sum_{\ell=1}^{L'} \frac{\alpha_t - \alpha_s}{1 - \alpha_t} \log p_\theta(\mathbf{x}^{b,\ell} | \mathbf{x}_t^{b,\ell}, \mathbf{x}^{b,<\ell}) \right] \\
 &= \sum_{b=1}^B \mathbb{E}_t \mathbb{E}_q T \left[\frac{\alpha_t - \alpha_s}{1 - \alpha_t} \log p_\theta(\mathbf{x}^b | \mathbf{x}_t^b, \mathbf{x}^{<b}) \right] \tag{16}
 \end{aligned}$$

끝으로, 디퓨전 단계를 $T \rightarrow \infty$ 로 보내 가능도에 대한 더 타이트한 근사를 얻는다 (Sahoo et al., 2024a). 이때 $T(\alpha_t - \alpha_s) = \alpha'_t$ 이다.

$$\mathcal{L}_{\text{diffusion}} = \sum_{b=1}^B \mathbb{E}_{t \sim [0,1]} \mathbb{E}_q \left[\frac{\alpha'_t}{1 - \alpha_t} \log p_\theta(\mathbf{x}^b | \mathbf{x}_t^b, \mathbf{x}^{<b}) \right] \tag{17}$$

연속 시간의 경우, Sahoo et al. (2024a) (Suppl. A.2.4)는 $\mathbf{x}_{t(1)}^b \sim \lim_{T \rightarrow \infty} \text{Cat}(\cdot; \mathbf{x}_{t=\frac{1}{T}}^b) = \text{Cat}(\cdot; \mathbf{x}^b)$ 이므로 재구성 손실이 0으로 줄어들음을 보인다. 이를 사용하면 다음을 얻는다.

$$\begin{aligned}
 \mathcal{L}_{\text{recons}} &= -\mathbb{E}_q \log p_\theta(\mathbf{x}^b | \mathbf{x}_{t(1)}^b, \mathbf{x}^{<b}) \\
 &= -\log p_\theta(\mathbf{x}^b | \mathbf{x}_{t(1)}^b = \mathbf{x}^b, \mathbf{x}^{<b}) \\
 &= 0 \tag{18}
 \end{aligned}$$

사전 손실 $\mathcal{L}_{\text{prior}} = \text{D}_{\text{KL}}(q(\mathbf{x}_{t=1}^b | \mathbf{x}^b) \| p_\theta(\mathbf{x}_{t=1}^b))$ 또한 0으로 줄어드는데, 이는 $\alpha_{t=1} = 0$ 이어서 $q(\mathbf{x}_{t=1}^b | \mathbf{x}^b) = \text{Cat}(\cdot; \mathbf{m})$, $p_\theta(\mathbf{x}_{t=1}^b) = \text{Cat}(\cdot; \mathbf{m})$ 이 되기 때문이다 (Sahoo et al. (2024a) (Suppl. A.2.4) 참고).

마지막으로 교차 엔트로피 항의 가중 평균인 간단한 목적함수를 얻는다.

$$\mathcal{L}_{\text{BD}}(\mathbf{x}; \theta) = \sum_{b=1}^B \mathbb{E}_{t \sim [0,1]} \mathbb{E}_q \left[\frac{\alpha'_t}{1 - \alpha_t} \log p_\theta(\mathbf{x}^b | \mathbf{x}_t^b, \mathbf{x}^{<b}) \right] \tag{19}$$

위 NELBO는 노이즈 스케줄 α_t 의 선택에 불변이다 (Sahoo et al. (2024a) (Suppl. E.1.1) 참고).

B.4 단일 토큰 생성에서 NELBO로부터 NLL 복원

$L' = 1, B = L$ 인 블록 크기 1의 블록 디퓨전 NELBO를 고려하자. 단일 토큰 모델링 시 블록 디퓨전 NELBO는 AR NLL과 동치이다.

$$\begin{aligned}
-\log p(\mathbf{x}) &\leq \sum_{b=1}^L \mathbb{E}_{t \sim [0,1]} \mathbb{E}_q \left[\frac{\alpha'_t}{1 - \alpha_t} \log p_\theta(\mathbf{x}^b \mid \mathbf{x}_t^b, \mathbf{x}^{<b}) \right] \\
&\because \alpha'_t = -1 \text{ and } \alpha_t = 1 - t, \\
&= - \sum_{b=1}^L \mathbb{E}_{t \sim [0,1]} \mathbb{E}_q \left[\frac{1}{t} \log p_\theta(\mathbf{x}^b \mid \mathbf{x}_t^b, \mathbf{x}^{<b}) \right] \\
&= - \sum_{b=1}^L \mathbb{E}_{t \sim [0,1]} \frac{1}{t} \mathbb{E}_q [\log p_\theta(\mathbf{x}^b \mid \mathbf{x}_t^b, \mathbf{x}^{<b})] \\
&\text{Expanding } \mathbb{E}_q[\cdot], \\
&= - \sum_{b=1}^L \mathbb{E}_{t \sim [0,1]} \frac{1}{t} \left[q(\mathbf{x}_t^b = \mathbf{m} \mid \mathbf{x}^b) \log p_\theta(\mathbf{x}^b \mid \mathbf{x}_t^b = \mathbf{m}, \mathbf{x}^{<b}) \right. \\
&\quad \left. + q(\mathbf{x}_t^b = \mathbf{x}^b \mid \mathbf{x}^b) \log p_\theta(\mathbf{x}^b \mid \mathbf{x}_t^b = \mathbf{x}^b, \mathbf{x}^{<b}) \right] \quad (20)
\end{aligned}$$

우리의 디노이징 모델은 [Sahoo et al. \(2024b\)](#)의 SUBS-매개변수화를 사용함을 떠올리자. “언 마스크 캐리 오버” 성질에 의해 언마스크 토큰은 디노이징 모델의 입력에서 출력으로 단순히 복사되므로 $\log p_\theta(\mathbf{x}^b \mid \mathbf{x}_t^b = \mathbf{x}^b, \mathbf{x}^{<b}) = 0$ 이다. 따라서 (20)은 다음으로 환원된다.

$$\begin{aligned}
-\log p_\theta(\mathbf{x}) &\leq - \sum_{b=1}^L \mathbb{E}_{t \sim [0,1]} \frac{1}{t} q(\mathbf{x}_t^b = \mathbf{m} \mid \mathbf{x}^b) \log p_\theta(\mathbf{x}^b \mid \mathbf{x}_t^b = \mathbf{m}, \mathbf{x}^{<b}) \\
&\because q(\mathbf{x}_t^b = \mathbf{m} \mid \mathbf{x}^b) = t, \text{ we get:} \\
&= - \sum_{b=1}^L \mathbb{E}_{t \sim [0,1]} \log p_\theta(\mathbf{x}^b \mid \mathbf{x}_t^b = \mathbf{m}, \mathbf{x}^{<b}) \\
&= - \sum_{b=1}^L \log p_\theta(\mathbf{x}^b \mid \mathbf{m}, \mathbf{x}^{<b}) \quad (21)
\end{aligned}$$

단일 토큰 생성($L' = 1$)에서 자기회귀 NLL을 복원한다.

B.5 NELBO의 타이트함

블록 크기 $1 \leq K \leq L$ 에 대해 $-\log p(\mathbf{x}) \leq \mathcal{L}_K \leq \mathcal{L}_{K+1}$ 을 보인다. 자기회귀 NLL을 복원하는 $K = 1$ 을 고려하자(Suppl. B.4 참조).

$$\begin{aligned}
\mathcal{L}_1 &= \sum_{b=1}^L \log \mathbb{E}_{t \sim [0,1]} \mathbb{E}_q \frac{\alpha'_t}{1 - \alpha_t} p_\theta(\mathbf{x}^b \mid \mathbf{x}_t^b, \mathbf{x}^{<b}) \\
&= - \sum_{b=1}^L \log p_\theta(\mathbf{x}^b \mid \mathbf{m}, \mathbf{x}^{<b}) \quad (22)
\end{aligned}$$

블록 크기 $K = 2$ 에 대한 ELBO를 고려하자.

$$\mathcal{L}_2 = \sum_{b=1}^{L/2} \log \mathbb{E}_{t \sim [0,1]} \mathbb{E}_q \frac{\alpha'_t}{1 - \alpha_t} p_\theta(\mathbf{x}^b \mid \mathbf{x}_t^b, \mathbf{x}^{<b}) \quad (23)$$

$\mathcal{L}_1 \leq \mathcal{L}_2$ 를 보이며, 귀납에 의해 모든 $1 \leq K \leq L$ 에 대해 성립한다. $\mathbf{x}^{b,\ell}$ 이 블록 b 의 위치 $\ell \in [1, L']$ 의 토큰에 대응한다고 하자. 다음 부등식을 유도한다.

$$\begin{aligned}
-\sum_{b=1}^L \log p_\theta(\mathbf{x}^b \mid \mathbf{m}, \mathbf{x}^{<b}) &= -\sum_{b=1}^{L/2} \log \mathbb{E}_{t \sim [0,1]} \mathbb{E}_q \frac{1}{1 - \alpha_t} p_\theta(\mathbf{x}^b \mid \mathbf{x}_t^b, \mathbf{x}^{<b}) \\
&= -\sum_{b=1}^{L/2} \log \mathbb{E}_{t \sim [0,1]} \mathbb{E}_q \prod_{i=1}^2 \frac{1}{1 - \alpha_t} p_\theta(\mathbf{x}^{b,\ell} \mid \mathbf{x}_t^b, \mathbf{x}^{<b}) \\
&= -\sum_{b=1}^{L/2} \log \prod_{i=1}^2 \mathbb{E}_{t \sim [0,1]} \mathbb{E}_q \frac{1}{1 - \alpha_t} p_\theta(\mathbf{x}^{b,\ell} \mid \mathbf{x}_t^b, \mathbf{x}^{<b}) \\
&\leq -\sum_{b=1}^{L/2} \sum_{i=1}^2 \log \mathbb{E}_{t \sim [0,1]} \mathbb{E}_q \frac{1}{1 - \alpha_t} p_\theta(\mathbf{x}^{b,\ell} \mid \mathbf{x}_t^b, \mathbf{x}^{<b}) \quad (24)
\end{aligned}$$

B.6 특화 어텐션 마스크

우리의 트랜스포머 백본으로 효율적인 학습 알고리즘을 설계하여, 모든 블록 $b \in [1, B]$ 에 대한 조건부 확률 $p_\theta(\mathbf{x}^b \mid \mathbf{x}_t^b, \mathbf{x}^{<b})$ 을 동시에 모델링하는 것이 목표이다. 그러나 B 개 조건부 항을 모두 모델링하려면 모든 b 에 대해 노이즈 시퀀스 $\mathbf{x}_t^b$ 와 조건부 문맥 $\mathbf{x}^{<b}$ 를 모두 처리해야 한다.

디노이징 네트워크를 B 번 호출하는 대신, 두 시퀀스를 결합 $\mathbf{x}_{\text{full}} \leftarrow \mathbf{x}_t \oplus \mathbf{x}$ 하여 한 번에 트랜스포머의 입력으로 처리한다. 효율적인 학습을 위해 길이 $2L$ 토큰의 시퀀스 $\mathbf{x}_{\text{full}}$ 을 맞춤 어텐션 마스크 $\mathcal{M}_{\text{full}} \in \{0, 1\}^{2L \times 2L}$ 로 갱신한다.

전체 어텐션 마스크는 네 개의 $L \times L$ 더 작은 어텐션 마스크로 구성된다.

$$\mathcal{M}_{\text{full}} = \begin{bmatrix} \mathcal{M}_{BD} & \mathcal{M}_{OBC} \\ \mathbf{0} & \mathcal{M}_{BC} \end{bmatrix}$$

여기서 $\mathcal{M}_{BD}$ 와 $\mathcal{M}_{OBC}$ 는 $\mathbf{x}_t$ 의 표현을 갱신하는 데, $\mathcal{M}_{BC}$ 는 $\mathbf{x}$ 의 표현을 갱신하는 데 사용된다. 이 마스크들은 다음과 같이 정의한다.

- $\mathcal{M}_{BD}$ (블록 대각 마스크): 노이즈 블록 $\mathbf{x}_t^b$ 안의 셀프 어텐션 마스크

$$[\mathcal{M}_{BD}]_{ij} = \begin{cases} 1 & i, j \text{가 같은 블록에 있을 때} \\ 0 & \text{그 외} \end{cases}$$

- $\mathcal{M}_{OBC}$ (오프셋 블록-인과 마스크): 조건부 문맥 $\mathbf{x}^{<b}$ 로의 크로스 어텐션

$$[\mathcal{M}_{OBC}]_{ij} = \begin{cases} 1 & j \text{가 } i \text{보다 앞 블록에 속할 때} \\ 0 & \text{그 외} \end{cases}$$

- $\mathcal{M}_{BC}$ (블록-인과 마스크): $\mathbf{x}^b$ 갱신용 어텐션 마스크

$$[\mathcal{M}_{BC}]_{ij} = \begin{cases} 1 & j \text{가 } i \text{와 같은 블록 또는 } i \text{보다 앞 블록에 속할 때} \\ 0 & \text{그 외} \end{cases}$$

$L = 6$, 블록 크기 $L' = 2$ 인 어텐션 마스크의 예시를 그림 3에 시각화한다.




그림 3: 특화 어텐션 마스크의 예

B.7 FlexAttention을 이용한 최적화 어텐션 커널

Figure 3이 보이듯, 우리의 어텐션 행렬은 매우 희소(sparse)하다. 이 희소성을 활용해 BD3-LMs의 효율을 크게 개선할 수 있다.

FlexAttention (Dong et al., 2024)은 PyTorch에서 구조화된 희소성을 가진 어텐션 메커니즘을 효율적으로 구현할 수 있게 해 주는 컴파일러 기반 프로그래밍 모델이다. 수작업 최적화 어텐션 커널과 비등한 고성능을 유지하면서, 맞춤 어텐션 마스크를 정의할 유연한 인터페이스를 제공한다.

아래 Fig. 4에서, Suppl. B.6의 $M_{full} \in \{0, 1\}^{2L \times 2L}$ 정의에 기반한 블록 단위 어텐션 마스크 `block_diff_mask`를 정의한다. 어텐션 연산을 단일 FlexAttention 커널로 융합하여 어텐션 행렬의 희소성을 이용해 계산 효율을 높인다. 이를 통해 다음 최적화를 수행한다.

- **사전 계산 블록 마스킹:** `create_block_mask` 유틸리티가 컴파일 시점에 희소 어텐션 마스크를 생성하여, 매 단계 유효하지 않은 어텐션 항을 계산하는 일을 피한다. 희소성을 인지하는 실행을 통해 FlexAttention 커널은 어텐션 계산의 FLOPs 수를 줄인다.
- **줄어든 메모리 사용량:** 블록 수준의 희소성을 활용하여, 어텐션 메커니즘이 대규모 어텐션 행렬을 전부 구체화하지 않도록 함으로써 메모리 오버헤드를 크게 줄인다. FlexAttention은 완전히 마스킹된 블록을 건너뛰어 메모리 접근을 최소화한다.
- **torch.compile을 통한 계산 최적화:** `torch.compile` 통합은 최적화된 Triton 기반 커널을 생성해 GPU에서 커널 융합과 효율적 실행을 가능하게 한다. 이는 최적화된 GPU 실행 경로로 마스크 어텐션 계산을 효율적으로 병렬화한다.

이 구현은 제공된 희소 패턴에 기반해 실행을 동적으로 최적화하는 FlexAttention의 능력을 활용한다. 블록 수준 희소성을 사전 계산하고 효율적인 커널 융합을 활용함으로써, 긴 시퀀스에 대한 확장 가능한 어텐션 계산을 가능하게 한다.

전체적으로 이 접근은 구조화된 의존 제약을 보존하면서 어텐션 계산을 가속하는 원칙적 방법을 제공한다. 중단간으로, 맞춤 마스크를 사용하는 FlashAttention 커널을 FlexAttention


```

def block_diff_mask(b, h, q_idx, kv_idx, block_size, n):
    """
    Constructs the specialized block diffusion attention mask composed of
        three masks:
    - Block Diagonal Mask (MBD): Self-attention within noised blocks
    - Offset Block Causal Mask (MOBC): Cross-attention for
        conditional context
    - Block Causal Mask (MBC): Attention to update x0

    Args:
        b, h: Batch and head indices (ignored for mask logic).
        q_idx, kv_idx: Query and Key indices.
        block_size: Defines the block structure.
        n: Sequence length of x0 and xt

    Returns:
        A boolean attention mask.
    """

    # Indicate whether token belongs to xt (0) or x0 (1)
    x0_flag_q = (q_idx >= n)
    x0_flag_kv = (kv_idx >= n)

    # Compute block indices
    block_q = torch.where(x0_flag_q == 1,
                          (q_idx - n) // block_size,
                          q_idx // block_size)
    block_kv = torch.where(x0_flag_kv == 1,
                          (kv_idx - n) // block_size,
                          kv_idx // block_size)

    # 1. Block Diagonal Mask (MBD)
    block_diagonal = (block_q == block_kv) & (x0_flag_q == x0_flag_kv)

    # 2. Offset Block-Causal Mask (MOBC)
    offset_block_causal = (
        (block_q > block_kv)
        & (x0_flag_q == 0)
        & (x0_flag_kv == 1)
    )

    # 3. Block-Causal Mask (MBC)
    block_causal = (
        (block_q >= block_kv)
        & (x0_flag_q == 1)
        & (x0_flag_kv == 1)
    )

    # 4. Combine Masks
    return block_diagonal | offset_block_causal | block_causal

```

```

from torch.nn.attention.flex_attention import flex_attention,
                                         create_block_mask

from functools import partial

# Define block-wise attention mask
my_block_diff_mask = partial(block_diff_mask, seq_len=seq_len, block_size
                             =block_size)

# Generate optimized sparse block mask
block_mask = create_block_mask(my_block_diff_mask, None, None, seq_len*2,
                              seq_len*2, device=device)

# Compute attention using FlexAttention
# Use no-cudagraphs to avoid an extra copy on small compile graphs.
# Use max-autotune if compiling a larger model all at once.
@torch.compile(fullgraph=True, mode="max-autotune-no-cudagraphs")
def single_pass_block_diff_attn(q, k, v, block_mask):
    return flex_attention(q, k, v, block_mask=block_mask)

```

그림 5: 우리가 제안한 맞춤 마스크를 FlexAttention과 함께 사용해 어텐션을 계산.

커널로 대체하면 모델 정방향 패스에서 약 15%의 속도 향상이 있다. A5000 1장, $L = 1024$, 배치 크기 $B = 16$ 를 사용한다.

C 실험 세부 사항

Sahoo et al. (2024a)의 학습·평가 설정을 거의 그대로 따른다.

C.1 데이터셋

두 데이터셋에서 실험한다: One Billion Word Dataset(LM1B; Chelba et al. (2014))과 OpenWebText(OWT; Gokaslan et al. (2019)). LM1B에서 학습한 모델은 bert-base-uncased 토크나이저와 문맥 길이 128을 사용한다. LM1B의 테스트 분할에서 perplexity를 보고한다. OWT에서 학습한 모델은 GPT2 토크나이저 Radford et al. (2019)와 문맥 길이 1024를 사용한다. OWT에는 검증 분할이 없으므로 마지막 100k 문서를 검증용으로 남긴다.

LM1B 예시 준비에서, Sahoo et al. (2024a)는 각 예시를 $L = 128$ 토큰의 문맥 길이에 맞도록 패딩한다. 그러나 대부분 예시가 단일 문장으로만 구성되어 있어 더 큰 블록 크기 $L' > 4$ 의 블록 디퓨전 모델링은 학습에 유용하지 않다. 대신 시퀀스를 결합·랩핑(wrap)하여 길이 128로 만든다. 그 결과 LM1B에서 자기회귀 기준선, SEDD, MDLM을 랩핑한 데이터로 재학습한다.

OWT에서도 마찬가지로 시퀀스를 패딩·자르지 않고, LM1B처럼 결합해 길이 1024로 랩핑한다. Section 6.2의 비조건 생성 실험에서는 학습 시 본 문맥 길이보다 긴 시퀀스를 생성하고자 한다. 그러나 Sahoo et al. (2024a)는 학습 문맥의 시작·끝에 시작·끝 토큰([BOS], [EOS])을 주입한다. 따라서 Sahoo et al. (2024a)의 기준선은 학습 문맥 크기에 일치하는 시퀀스를 생성한다. Section 6.2에서 다양한 길이의 모델 생성을 살펴보기 위해 예시에 [BOS]·[EOS] 토큰을 주입하지 않고 AR, SEDD, MDLM 기준선을 재학습한다. OWT에서 모든 BD3-LMs를 학습할 때도 같은 전처리 관례를 사용한다.

C.2 아키텍처

모델 아키텍처는 디퓨전 트랜스포머 (Peebles & Xie, 2023)에 회전 위치 임베딩(rotary positional embedding) (Su et al., 2021)을 더한 것이다. 자기회귀 기준선, SEDD, MDLM, BD3-LMs는 Sahoo et al. (2024a)의 트랜스포머 아키텍처(12 레이어, 은닉 차원 768, 어텐션 헤드 12)로 매개변수화한다. 이는 110M 파라미터에 해당한다. Sahoo et al. (2024a)이 시간 단계 조건화(timestep conditioning)가 성능에 영향을 주지 않음을 보였으므로 우리도 포함하지 않는다. 배치 크기 512와 $3e-4$ 까지의 일정 학습률 워밍업(2.5K 경사 갱신)으로 AdamW 옵티마이저를 사용한다.

C.3 학습

최대 문맥 길이 $L' = L$ 로 850K 경사 단계 동안 기반 BD3-LM를 학습한다. 그런 다음 노이즈 스케줄 최적화를 사용해 다양한 L' 로 150K 경사 단계 동안 LM1B와 OpenWebText에서 파인 튜닝한다. 이는 LM1B에서 65B 토큰, 73 에포크, OWT에서 524B 토큰, 60 에포크에 해당한다. 3090, A5000, A6000, A100 GPU를 사용한다.

C.4 가 능 도 평 가

토큰 블록의 가 능 도 평 가에 t 표 집 을 위 한 단 일 몬테카를로 추 정 을 사 용 한 다. [Sahoo et al. \(2024a\)](#)을 따라, 시 간 단 계 가 $[0, 1]$ 구 간 에 더 고 르 게 분 포 하 도 록 보 장 하 여 추 정 분 산 을 줄 이 는 [Kingma et al. \(2021\)](#)의 저-불일치 샘플러(low-discrepancy sampler)를 채 택 한 다. 구 체 적 으 로, 각 블 록 $b \in \{1, \dots, B\}$ 와 시퀀스 $k \in \{1, \dots, K\}$ 의 시 간 단 계 를 균 일 구 간 의 다 른 분 할 $t(k, b) \sim \mathcal{U}[\frac{(k-1)B+b-1}{KB}, \frac{(k-1)B+b}{KB}]$ 로 부 터 표 집 한 다.

이 저-불일치 샘플러는 평 가 에 사 용 된 다. 학 습 에 서 는 각 마 스 킵 확 률 을 “클리핑” 범 위 $1 - \alpha_t \sim \mathcal{U}[\beta, \omega]$ 로 부 터 표 집 할 수 있 다. 학 습 중 저-불일치 샘플러로 $t \in [0, 1]$ 을 균 일 표 집 한 뒤, 마 스 킵 확 률 이 원 하 는 범 위 안 에 서 선 형 이 되 도 록 선 형 보 간 을 적 용 한 다: $1 - \alpha_t = \beta + (\omega - \beta)t$.

OWT로 학 습 한 모 델 로 [Radford et al. \(2019\)](#)의 벤치마크 데이터셋에서 제로샷 가 능 도 를 보 고 할 때, [Sahoo et al. \(2024a\)](#)을 따라 모 든 시퀀스 를 1024 토큰 으로 램 평 하 고 시퀀스 사 이 에 [EOS]를 추 가 하 지 않 는 다.

C.5 추 론

생 성 perplexity OWT에서 1024 토큰의 문맥 길이로 학 습 한 모 델 의 생 성 perplexity를 GPT2-Large 하에서 보 고 한 다. GPT2-Large가 문맥 크기 1024를 사 용 하 므 로, 1024 토큰 보다 긴 샘플 의 생 성 perplexity는 보 폭 512 토큰 의 슬라이딩 윈 도 우 로 계 산 한 다.

뉴 클리 어 스 샘플링 SSD-LM ([Han et al., 2022](#))을 따라, BD3-LMs와 기 준 선 들 에 뉴 클리 어 스 샘플링 을 사 용 한 다. SSD-LM의 경 우 블 록 크 기 $L' = 25$ 에 그 들 의 기 본 하 이 퍼 파 라 미 터 $p = 0.95$ 를 사 용 한 다. BD3-LMs, AR, MDLM에는 $p = 0.9$ 를 사 용 하 고, SEDD는 $p = 0.99$ 가 가 장 잘 동 작 함 을 확 인 했 다.

디퓨전 단 계 수 표 7에서 BD3-LMs와 MDLM은 $T = 5K$ 디퓨전 단 계 를 사 용 한 다. BD3-LMs와 MDLM은 [Sahoo et al. \(2024a\)](#); [Ou et al. \(2025\)](#)이 제 안 한 대 로 디 노 이 징 네 트 워 크 출 령 을 캐 시 게 효 율 적 으 로 표 집 하 며, 이 로 인 해 생 성 단 계 수 가 샘플 길 이 L 을 초 과 하 지 않 는 다. 단 순 화 된 디 노 이 징 모 델 (Suppl. B.3)에 의 해 일 단 토큰 이 언 마 스 크 되 면 다 시 마 스 킵 되 지 않 는 다. 가 변 길 이 시퀀스 생 성 에 는 MDLM의 블 록 단 위 디 코 디ంగ 알 고 리 즈 м 을 사 용 한 다 (다 만 이 모 델 들 은 블 록 디퓨전 으 로 학 습 되 지 않 았 다). 그 들 의 기 본 보 폭 512 토큰 을 채 택 한 다.

SSD-LM(표 7의 첫 행)과 SEDD는 $T = 1K$ 디퓨전 단 계 를 사 용 한 다. 블 록 디퓨전은 각 블 록 $b \in \{1, \dots, B\}$ 에 대 해 T 디퓨전 단 계 를 수 행 하 므 로 SSD-LM은 BT 생 성 단 계 를 거 친 다. SSD-LM과 공 정 하 게 비 교 하 기 위 해, 생 성 단 계 수 가 시퀀스 길 이 를 넘 지 않 는 $T = 25$ 디퓨전 단 계 의 생 성 perplexity도 보 고 한 다 (표 7의 두 번 째 행).

디퓨전 모 델 의 개 선 된 범 주 표 집 [Zheng et al. \(2024\)](#)이 제 안 한 디퓨전 모 델 의 검 벨 (Gumbel) 기 반 범 주 표 집 의 두 가 지 개 선 을 사 용 한 다.

첫 째, [Zheng et al. \(2024\)](#)의 보 정 된 검 벨 기 반 범 주 표 집 을 사 용 하 여 64비트 검 벨 변 수 를 표 집 한 다. 정 밀 도 를 32비트 로 낮 추 면 검 벨 변 수 가 크 게 잘 려 온 도 가 낮 아 지 고 문 장 엔 트 로 피 가 줄 어 들 이 보 고 되 었 다.

둘째, Zheng et al. (2024)는 생성 단계 수가 시퀀스 길이로 상한이지만 MDLM 표집 시간이 디퓨전 단계 T 에 따라 늘어남을 보인다. 샘플 길이 L , 어휘 크기 V 에서 샘플러는 $\mathcal{O}(TLV)$ 개의 균일 변수를 표집하고 그 위에 로그 연산을 수행해야 한다.

$\mathcal{O}(LV)$ 개의 균일 변수만 표집하는 Zheng et al. (2024)의 first-hitting 샘플러를 채택한다. 이는 특히 $T \gg L$ 일 때 표집 속도를 크게 향상시킨다. first-hitting 샘플러는 이론적으로 MDLM 샘플러와 동치이며, 두 가지 관찰을 활용한다: (1) 전이 확률은 디노이징 네트워크와 무관하다, (2) 주어진 t 에 대해 모든 마스크 토큰의 전이 확률이 동일하다. 따라서 토큰이 언마스크되는 첫 시간 단계는 다음과 같이 해석적으로 표집할 수 있다(선형 스케줄 $\alpha_t = 1 - t$ 가정).

$$t_{n-1} = t_n u^{1/n}, \quad (25)$$

여기서 $n \in \{L, \dots, 1\}$ 은 마스크된 토큰 수, $u_n \sim \mathcal{U}[0, 1]$, t_{n-1} 은 $n-1$ 개의 토큰이 마스크된 첫 시간 단계에 해당한다.

가변 길이 시퀀스 생성 표 6에서 BD3-LMs와 AR로 임의 길이 시퀀스를 생성할 때, 다음 정지 기준을 만족할 때까지 토큰을 계속 표집한다.

EOS 토큰이 표집됨

1. 마지막 256-토큰 청크의 평균 엔트로피가 4 미만

기준 2는 (예: 반복 토큰 시퀀스 같은) 도주성(run-on) 샘플이 누적 오류를 일으키는 것을 막기 위해 필요하다. 낮은 엔트로피의 퇴화 샘플이 GPT2 하에서 매우 낮은 perplexity를 유발해 보고된 생성 perplexity를 떨어뜨림을 확인했다. 따라서 표 7의 생성 perplexity 보고 시, 기준 2를 만족하는 샘플은 다시 생성한다.

D 샘플

<endofx>'s architect, lawyer and San Giovanni concerto art critic Paolo Capacotti, gained attention from fellow gallery members and even invited him to present a retrospective, publishing issues and newspaper interviews.[10] On 6 September, Kissi and his assistants agreed to move to Angelo's Marcus Collection,[10] which included Giorgio Avolivo Arth and Moscolliso (later owned by the artist Belzina Massingolo) and Pan Giazoglio Romeam-Guessle. The businessman, Giovanni Paletti, an outstanding collector, owned the museum and the painting. The level of criminal activity around the museum has continued to increase, which is part of several attempts to counter centennial rumors including the possibility that museum staff and visitors are tortured and even exposed to del Cavello for the only full year of Francesco Belzina's life (1999).[4] On the evening of 22 October 2005 it was reported that earlier that evening, guards had come on duty and began flinging an electric field with umbrellas from the balcony. As the fire continued, some of the guards sparked an apparent spat from the window of the cathedral. They remained idly watched by a pile of trash left after a piano key by Pietro Jolla, who died on 21 October 2005.[10] Just before 3:00 to 3pm on Monday, 27 October 2005, strong winds brought the trash on to the residence that opened on 17 October. Some ruined books and statues were hurled in front from every direction of the window. Some claimed that a customer Jacques Monet had beaten the hand of photographer Franco Campetti and in some cases had stuck a broken candle in the doorway of the museum. Andr Romeam-Guessle responded by laughing when he spoke. Giancio Giuliano, the artistic director of the Museum, even tried to told journalists and press that 'the patient in the trisomy machine [sic] carried some corpses four hours into the museum, but the whole time it was the guy who stroked the young man who who broke him'. In 2008, Giuliano told the same press that the hours of the destruction are truly "wrong for their morality" and further stated that 'We are never satisfied with our decision. We made an informed decision to build the museum after destruction.[5] Deaths [edit] A little after 12:00 am 17 October 2005, Giuliano and his partner Monica Concerta, noticed that the trash was being thrown by passers-by. Captain Iamienowska leaned over to his film camera and said, in a joking manner, that Iannorello, the chair of the Musceei, was a thief that director Frank Nolan said "he would later be arrested." When Iamienowska arrived, the people in question were interviewed by Captain Anderson Tulaqyuk, a co-man who was initially lying on the scene and whom Iamienowska said was able to stop them from passing in the vicinity. Iguano proceeded to collect the trash and the police arrived, and closed the door of the museum.[6] During the war, the statue structure was partially removed and its cannons damaged. On the eve of the war, the U.S. Army and Canadian Air Company, who once owned a lot on the Coopers of Paris near Leopold Street, sheltered the POWs, who were briefly overworked. This following years led to condemnation of the organization and artists, including John DiDione,[7] returned to the compound to sell the museum items (including many of them originally stolen over the years-more than a million returned); on 12 October, the sculptor Jack Uellein installed a temporary dome on Del Cavella.[10] Among the changes over the years, Diena featured the lion in the middle of the other two halves of the dome and the lion in the back of the Viduccio.[11] In March 2008, Arvnzo Cissino announced that seven studio studios were built between the summer of 1985 and the last one was completed on November 17, 2005.[10] In the fourth quarter of the mid-2000s, a number of new structures were constructed by various museums, but most notably by Arvnzo Cissino, the brothers-soldier, as portrayed by architect Duvois Mayaven in the illusion of the El Valleratas Humanities and Cultural Center, reconstructed by architect Duvois Benjamin. Just as the very significant additions to the current management masts of the del Museum are such private three-bedroom rooms as Tradello's cabin, as well as the architectural aspect from the museum's south wall. Also new are the rockings performed by MC Urquhart, Aiba Ruiz and March Flez, during a music festival held in the US in 2006. Urquhart was later credited with establishing record label Empire Records as an influence on his music. In<endofx>|

그림 6: MDLM (Sahoo et al., 2024a)에서 길이 $L = 1024$, $T = 5K$ 디퓨전 단계의 샘플. GPT2-Large 하에서 이 샘플의 생성 perplexity는 69.26, 엔트로피는 5.6이다. (생성된 영어 텍스트는 평가 대상이므로 원문 그대로 둔다.)

When her child was planning to travel to Mexico, she thought it could be easy for her to find money to pay the trip. But that didn't happen, either. The girl arrived on her doorstep the day before after they were scheduled to return to home and – despite her own passport blocked. It wasn't easy. Even her mother reported a bad visit. A gate to the airport – the gate and flight instructions – were locked at nine a.m. "I had no way to the gate," she told The Local. "I feel like I should keep my passport and their fees." At first the police arrived, a British man told an e-mail that parents should only have money for themselves to be fine, but could never explain the situation. Later, she told her daughter that her passport had been detained because she wanted to visit her family at a hotel. She felt embarrassed and confused. Nearly two months later, she said, she lost 35(40) on rent and imagined that the traffic-police and customs agents in Bangkok would end up delaying flights and forcing her to stay home. She was worried that her father would refuse allowing her daughter to spend a few days in the country. Meanwhile, the police were sent to search. "It wasn't easy for them when a child feels like home for the first time," said Mahavram Kaas, a spokesman for the Ministry of Foreign Affairs. He's referring to a tour arranged by the French and French foreign ministry, known as Courage in the Child. That tour cost the region 2 million worth of tickets, and cost the Calais family about \$25 million in lodging expenses, according to a statement by both the ministry's behalf (he told the Portuguese police agents) and London's Embassy in London (he told the French ambassador they provided a payment for 70,000, which would be used to pay the travel costs for their visits). In 2011, a family from Calais had moved to the UK aged 15. Their sister left to remain in France at 5 years old. Her brother tried to answer that question. He explained it to reporters at his service station at Calais airport. "You take the morning. It's named after you and your little girls," he said. The last mother was having a 19-month stay with her daughter that night, the police said. The first time she was back her husband took their daughter on a boat to the UK, said the mayor of the British Transport Agency. That meant she had plenty of cash-to-go and no money to borrow when she opened an account at Kathmandu Airport a few hours after booking her flight. She panicked. She called the was a Daley's Nessie (small cash register), saying she was getting better. Her doctors visited her when she returned and her boyfriend quit his job for four months after the visit, she said. "How do you feel like you are safe?" A text from a friend left her to the police. "She says I must go get my wallet," said Ajaz. Soon after, she booked a plane ticket to Paris and took a metro train to Calais. One night, a French policeman would knock on the door of a local council building, open the mailman and the phone and tell her she knew that she could not leave at least one week without food. The four months her daughter spent in the UK was exhausting and hard, and it reached the stage where she realized she could barely stay in Britain. "Now no choice but to go home. Then we regret having a daughter," he said. He thought for a minute. "You've broken your heart." "Today, my daughter and my boyfriend decided to stay in this country for over two months," he wrote in an email with his daughter in his hand. "All our flights cancelled and no security. Shame." Caines' family were also put on leave. The French police paid for her car after she rented it, and her female officer used it for the opening ceremony of her press conference in Thailand. The police are still arranging for her family to have their official visit. Although her son is back at work now and his old job, her daughter needs to stay in a hospital in Algiers to continue her education. But, finally, her parents will be making their girl home. The daughter was 18 when they opened her case. She was born two months ago. She doesn't talk about it because it feels like she was still a child, living in Thailand with a small child. Her mother, Anza Gurdon, came to England as a three-year-old after her brother, Ehab Rahman, was working as a British worker in Calais while living in London and studying abroad in Dubai. As a mother earns 2,000 pounds a month, they receive a well-paid living in secure accommodation, some even with public transport buses. If they make money, their child stays in the UK, they can set up companies with kids to take care of their children. Other countries sometimes also give birth to parents forced to provide child care. The parents are often refugees from their home countries, they're left without family, and have forced to leave families. As one former refugee fled Syria, his family was in detention, because when and if their child had arrived, they would be living somewhere. The detention centers in Western Europe often have a higher rate for asylum seekers. Often there are higher "safe houses" for young people, and then the people in the center get older when their child comes to stay, but the only family that is a year older is not allowed to have children, and usually only if they stay six months. Children are also detained and are asked to show identification. Because in most cases the refugees ask only about their identity, they don't have access to their own documents, and have no other documentation. An activist working for Ireland says he's against offshore processing. He thinks the charity problem here is like diseases which don't sufficiently seek out international funding. I think too many countries want to employ "humanitarian" children. Now the job Before the refugee crisis in Calais, 1,823 children were living in the UK, the UNHCR website shows. A good chunk of those children had landed in refugee camps in Africa, where mostly African migrants were sending children from Syria and Libya to their camps, but those numbers didn't fare so well. "At the moment when I met the French, it was horrific, they wanted me to put my children in a van. But I was only kidding. It's something called 10-year vans," Aakaz said during an interview. "I want to keep my children for 10 years. That's something. It's like Christmas. The dream of 10 years. . . . For me, the idea that this is a good opportunity, here's a chance," is that she can sleep with her children. At this point, it's much more than just about "alternatives". They now have to decide, at some point, whether they want to take the chance. Is it a big deal or not? Only in Calais She explained what's agreed to so the children can go home and can have a better future. "I'm very determined. My children want to go home but it's my life's personal decision," she said. "Five months. I want them to be home, 5 months. If they're not getting jobs properly, I also want to stay home. But I feel good about what I've got. She is from a poor country. I don't owe anything to anyone. But I have to work for them. I feel like I can just go to the road and provide accommodation for my children and their children." But they all don't work well because their families have her as a head. "They want me to have a job in England, but I feel like it's my home, and I'm not scared of work," she said. "And I feel that the opposite would be possible. I think in the future that I can have a job or two there." A Second World Friday event will be held outside Calais on Saturday, donating 100 euros to the coming week in the money brought up to them by UNHCR through the King Wahab Samba Global Fund. Friends and family expressed their "weakness" like many survivors in many countries. "We just don't want to accept what has to happen. We want to put the people back there as soon as possible," said one man. Her brother, who is the son of a long term migrant, said: "The story of the refugee is not a mother's story. The story of the refugee is children's story." "In Calais it's too young for these kids. They play outside or work outside, they just eat, right? I don't think much has changed. This child with all her food and sleep, she's too young for life without any protection. We don't need any protection at all. We need anything that would be safer."

그림 7: 블록 크기 $L' = 16$ 의 BD3-LM에서 길이 $L = 2031$ 의 샘플($T = 5K$ 디퓨전 단계, 문맥 길이 $L = 1024$ 로 학습). GPT2-Large 하에서 이 샘플의 생성 perplexity는 24.3, 엔트로피는 5.5이다. (생성된 영어 텍스트는 평가 대상이므로 원문 그대로 둔다.)

<endofxt>|), but Wilson took over the program and turned it around. "He's done a tremendous job," Caldwell said. "He's done a fantastic job." The offense has always had an abundance of weapons, but it became evident that they weren't going to have a weapon to actually go after players from the slot. Now they're in two different weapons sets. The top group features Dez Bryant and Mohamed Sanu, and the bottom group features an assortment of weapons and pass rushers. The job has become far more complex. The other players can make plays on the ball and get those targets at a higher rate. Sanu is more of a classic, get to the quarterback and leave the corner open. Dontari Poe got the job done this year and became one of the more effective players at the position, even in the passing game. However, Dallas has got to figure out how to get their franchise wideouts to contribute on the field. That can be tough. Adding Poe can help get the receiving corps going. C.J. Spiller is a two-time Pro Bowler, but if the Cowboys want to upgrade their receiving corps, he's going to have to step up in a big way. "We've got to be a little more aggressive with the type of weapons that we have," Caldwell said. "I think that's part of the reason why our last two games, especially when you're playing in Washington, D.C., you've got to be aggressive, make sure you're hitting at every catch. When you are, you're giving up a lot of yards." Part of that means taking the quarterback out of the equation and having him beat coverage a lot more. In the NFC West, you want your offensive weapons to do a better job of running through coverage. The biggest threat that Dallas has is a QB in Ben Roethlisberger. Roethlisberger is far and away the best quarterback in the league, but a lot of the credit has to go to his receiver group. Martavis Bryant and Antonio Brown are both big-time receivers, and last year they were in the top 10 of yards per catch and receiving yards in the league. That production will never be sustainable, but if you're going to be an elite offense, it's going to take a lot of catching up. Roethlisberger is an All-Pro receiver, and he's not the most dynamic option. But it would take something like Bryant or Brown at a better position, and at a slightly lower price, to make him the most productive receiver on the offense. The truth is that Roethlisberger isn't going to be great. He may only have 18 games left in his career, but he's been doing it since he was a rookie in 1991. But that's not the worst thing in the world. Roethlisberger's ability to hit guys on the outside with good movement, vision and running ability is what the Cowboys need in order to keep up with the competition. If he keeps getting better, he could become the best receiver in the league. Follow @walterfootball for updates. Like our Facebook page for more Cowboys news, commentary and conversation.

The owner of 1H10 Tree in Charlotte Gardens is taking legal action against the city. Derek Jarman says he's been forced to evict his neighbour, Bob, after he took to social media to threaten to burn down his neighbor's house. "I'm incredibly furious with the city," Jarman told 7.30. "I've been trying to keep my eyes on the prize." Tree in Charlotte Gardens saying it had seen '9,000+ people' enjoying a great weekend. The company that owns 1H10 named Bob after a bee and said the tree was frequently targeted because of its unusual location. Bob said he had his concerns about the tree when he was contacted in October. He said they had had 'an ongoing conversation about my neighbor. He called, hung up and he was very threatening' in the 30 days before they turned the tree over to him. A neighbour posted the following online message on 8 October. "I am shocked about the serious problems you are having with your neighbour that has caused you all (sic). You and the 2 of you are making money at the expense of the good people of Charlotte Gardens." Bob says he was furious and said he'd just got off the phone with the city manager. "I told her, 'no, I'm going to bring a lawsuit', and I called the solicitor and tried to get my phone, just hoping the solicitor would help me out. I called again, and I asked if I could go to court and to try and get an injunction. "They told me 'you cannot', and they said, 'we can't, we can't' because you're sending people to the police'." Tree in Charlotte Gardens (Facebook) He also said he'd threatened the city attorney if he didn't stop the building from burning down. The internet user tweeted: "It's on the tree, but after I said 'threw this away, here's a spot to burn', the building started to burn." Tree in Charlotte Gardens (Facebook) Bob said the neighbour had threatened to burn down the tree, the windows, the living room and his entire backyard. "It was more than a threat," he said. "He was a very strong person. He's already damaged so many people in this building. It's not going to go away." Tree in Charlotte Gardens (Facebook) Jarman says he tried to talk the building owner out of the move, but the building owner's behaviour had "deleted him." "I'm going to stop him by letter telling him not to come to my house any more," he said. "I have three kids, and if Bob is going to be in my house, I need to make sure I have someone who can go in there and protect me. "My son does a really good job of protecting me, and I'm not going to let that get in the way of that." Tree in Charlotte Gardens (Facebook) Jarman said Bob had pulled him up on social media, calling him a "white nut" and saying: "For God's sake, stop calling me a white nut. "I should have shut him up on Facebook." He said he sent Bob the letter and thanked him for the support. "He should have done it because he's a real artist and he's a real artist," he said. He declined to name the architect of the new tree, but says the firm is the same one that designs buildings. "The building is burning down", neighbour says Bob's neighbour, Michael Banks, says the fire is an insult to his daughter. "There are two black women that live next door to me and they told me 'you can't do that', and then the fire went up and then the building burnt down," he said. "You can't burn down a house if you don't burn down the house." Coun-Pete Lawrence, the Northumberland MP for Wood Green, says he has concerns about Bob's neighbours. "It's a very, very sad commentary on the state of society and democracy in general," he said. "It's interesting in a community that's 50,000-plus people, you've got your regular residents and well-meaning neighbours who are apparently oblivious to the destruction of their own home. "To me, that's appalling and it is probably a shocking amount of devastation that it's left behind. "I would expect there to be outrage as well." Bob Jarman fears for his life after the tree was torched Bob says he has told the Northumberland Council that he had already received \$1,000 in legal action from the building owner, when he told them about the incident. The building owner has declined to comment on the situation. The builder is currently assessing its legal options. "We've got to sort this out and have an understanding with the builder, Mr Banks," he said. "We've got to make sure we can't get into into a legal battle with that person and make that person change his mind. "We don't want to do anything to cause a scene or anybody in the street to be upset." Bob Jarman hopes to have an understanding with the builder on its legal options, who have refused to comment. Topics: state-parliament, smoking-and-doubt, black-wales-6168, united-kingdom, england First posted When the other guys are away playing, do a short commercial to get you fired up for the next work day. Once you make it home, get a few junkies for them. They'll be very happy to have you, for at least a day. They might not be so happy after a couple of days. Have a bunch of friends and get ready to keep it going. What are you waiting for? Make this long, one-off<endofxt>

그림 8: AR 모델 (Sahoo et al., 2024a)에서 길이 $L = 2003$ 의 샘플(문맥 길이 $L = 1024$ 로 학습). GPT2-Large 하에서 이 샘플의 생성 perplexity는 10.6, 엔트로피는 5.5이다. (생성된 영어 텍스트는 평가 대상이므로 원문 그대로 둔다.)