

오픈소스 합성 데이터 SDK를 통한 테이블형 데이터 접근의 민주화

Ivona Krchova*, Mariana Vargas Vieyra*, Mario Scriminaci, Andrey Sidorenko
MOSTLY AI

Abstract—기계 학습 개발은 고품질 데이터에 대한 액세스에 결정적으로 달려 있습니다. 그러나 개인 정보 보호, 독점 이익 및 윤리적 문제로 인해 제한이 증가하면서 데이터 접근성에 심각한 장벽이 생겼습니다. 합성 데이터는 민감한 정보를 손상시키지 않으면서 안전하고 광범위한 데이터 사용을 가능하게 하여 실행 가능한 솔루션을 제공합니다. 이 문서에서는 대부분의 AI 합성 데이터 소프트웨어를 제시합니다. SDK(개발 키트)는 고품질 표 형식 데이터를 합성하기 위해 특별히 설계된 오픈 소스 도구 키트입니다. SDK는 차등 개인 정보 보호 보장, 공정성 인식 데이터 생성, 자동화된 품질 보증과 같은 강력한 기능을 유연하고 접근 가능한 Python 인터페이스에 통합합니다. SDK는 TabularARGN 자동 회귀 프레임워크를 활용하여 다양한 데이터 유형과 복잡한 다중 테이블 및 순차 데이터 세트를 지원하여 속도와 유용성이 크게 향상되어 경쟁력 있는 성능을 제공합니다. 현재 클라우드 서비스와 로컬 설치 가능한 소프트웨어로 배포된 SDK는 실제 데이터 병목 현상을 해결하고 광범위한 데이터 민주화를 촉진하는 실용성을 강조하면서 빠르게 채택되고 있습니다.

Index Terms—소프트웨어 개발 키트, 합성 데이터 생성, 표 형식 생성 모델.

I. 소개

기계 학습 애플리케이션을 개발하려면 교육 데이터에 대한 광범위한 액세스가 필요합니다. 이러한 필요성은 최근 몇 년 동안 모델을 효과적으로 훈련하기 위해 대규모 데이터 세트가 필요한 딥 러닝의 출현으로 더욱 중요해졌습니다. 동시에 기업과 기관이 사용자 상호 작용과 배포된 애플리케이션을 통해 정기적으로 방대한 양의 데이터를 수집함에 따라 생성되는 데이터의 양이 급격히 증가했습니다. 그러나 이러한 기하급수적인 성장은 동등한 접근성으로 해석되지 않았습니다. 개인 정보 보호 규정, 독점 제한 및 윤리적 고려 사항으로 인해 개발을 위한 실제 데이터 세트의 가용성과 사용이 점점 더 제한되고 있습니다. 데이터 병목 현상 [1]라고 하는 이 현상은 테이블 형식 데이터 세트도 예외가 아닌 여러 도메인 및 데이터 양식에 영향을 미칩니다.

이러한 맥락에서 합성 데이터는 데이터 가용성 격차를 메우고 고품질 데이터 세트에 안전하게 액세스할 수 있는 수단을 제공하고 유용성을 보장하며 데이터 공유 [2], [3], [4], [5]와 관련된 개인 정보 보호 위험을 최소화하는 유망한

솔루션으로 부상합니다. 합성 데이터 세트는 다용도 도구로 등장하며 개인 정보 보호 이외의 수많은 문제에 대한 솔루션도 제공합니다. 예를 들어 데이터 볼륨 확장, 클래스 불균형 해결, 누락된 데이터 대체 또는 공정성 인식 평가 활성화 [6]가 있습니다. 이러한 문제를 전체적으로 해결하면 합성 데이터 [7]의 유용성과 실용성이 크게 향상됩니다. 그러나 테이블 형식 데이터 합성을 위해 딥 러닝을 활용하는 문헌이 늘어나고 있음에도 불구하고 많은 방법은 특히 데이터 이질성, 충실도 및 개인 정보 보호 [8], [9]와 같은 문제를 고려할 때 데이터 합성의 여러 측면을 동시에 처리하는 전체적인 솔루션을 제공하는 데 부족합니다.

데이터 가용성과 접근성 사이의 격차를 해소하기 위해 우리는 포괄적인 기능 세트를 통합하고 합성 데이터 생성의 여러 중요한 측면을 동시에 해결하는 오픈 소스 툴킷인 MOSTLY AI 합성 데이터 소프트웨어 개발 키트(SDK)를 소개합니다. 이 라이브러리는 현재의 데이터 가용성 격차를 메우고 데이터 민주화를 촉진하는 것을 목표로 다양한 분야의 광범위한 연구자 및 실무자에게 접근할 수 있도록 특별히 맞춤화되었습니다. 유연성을 위해 설계된 SDK는 API 호출을 통해 맞춤형으로 개발된 클라우드 기반 서비스에 액세스하여 로컬 또는 '클라이언트 모드'에서 실행할 수 있습니다. 그러나 이 작업에서는 로컬 배포 시나리오에 전적으로 초점을 맞춰 데이터 수집, 교육 및 생성 기능을 심층적으로 제시합니다.

A. 기여

SDK는 다음과 같은 주요 기여를 제공합니다.

- **단순한 디자인으로 높은 데이터 품질:** TabularARGN [10]를 기반으로 하는 SDK는 단순성을 저하시키지 않으면서 최첨단(SOTA) 모델과 동등한 합성 데이터 품질을 제공합니다. 또한 현재 벤치마크에 비해 훈련 및 생성 시간이 크게 향상되었습니다.
- **개인 정보 보호 및 공정성 기능:** 프레임워크는 샘플링을 위해 개인 정보 보호 값 범위를 고려하고, 내장된 정규화 레이어와 교육을 위한 조기 중지 기능을 갖추고 있으며 차등 개인 정보 보호(DP)가 [11]를 보장하는 교육 메커니즘을 제공합니다. 세대에서는 민감한 속성 [12] 전반에 걸쳐 공정성 통합을 지원합니다.

- **자동 품질 보증:** SDK는 내장된 품질 보증 모듈 [13]를 제공하여 합성 데이터 세트의 개인 정보 보호와 데이터 충실도를 정량적으로 평가하는 표준화된 심층 보고서를 생성합니다.
- **오픈 소스 패키지:** Python으로 완전히 작성된 SDK는 pip를 통해 로컬로 설치할 수 있습니다. 패키지는 완전히 허용되는 Apache 버전 2.0 오픈 소스 라이선스¹에 따라 오픈 소스로 제공됩니다.
- **사용자 커뮤니티:** 사용자 및 기여자 커뮤니티가 성장함에 따라 SDK는 고품질 데이터 합성 서비스를 제공할 뿐만 아니라 실제 피드백의 이점을 활용하여 실제 요구 사항을 더 잘 충족할 수 있도록 툴킷을 지속적으로 개선할 수 있습니다.

이 문서의 나머지 부분은 다음과 같이 구성됩니다. 섹션 II는 SDK 아키텍처를 설명합니다. 섹션 III에서는 데이터 수집 및 처리 기능을 제시합니다. 섹션 IV에서는 교육 및 생성 기능을 자세히 설명합니다. 섹션 V에서는 실증적 성과 결과를 보고합니다. 섹션 VI에서는 커뮤니티 채택에 대해 논의합니다. 섹션 VII는 결론을 내립니다.

II. 아키텍처 개요 및 워크플로

이 섹션에서는 SDK의 개요를 제시합니다. 다양한 사용 시나리오를 지원하도록 구축된 SDK를 사용하면 학술 연구자부터 데이터 과학 실무자에 이르기까지 다양한 배경을 가진 사용자가 프로그래밍 방식으로 고품질 합성 데이터 세트를 생성, 공유 및 조작할 수 있습니다. 툴킷은 명확하게 구조화된 인터페이스를 제공합니다. 허용되는 Apache 버전 2.0 라이선스에 따라 오픈 소스 패키지로 무료로 사용할 수 있습니다. `pip install -U 'mostlyai[local]'`을 통해 쉽게 설치할 수 있습니다. (Python ≥ 3.10 필요)

SDK의 아키텍처는 전용 품질 보증 구성 요소와 함께 커넥터, 생성기 및 합성 데이터 세트의 세 가지 주요 구성 요소를 중심으로 구성됩니다. 그림 1은 이 파이프라인을 보여주며 각 구성 요소와 관련된 주요 기능을 강조합니다. 이러한 아티팩트는 데이터 수집부터 생성 모델 교육 및 공유, 합성 데이터 세트 생성 및 평가까지 사용자를 안내하는 직관적인 워크플로를 형성합니다. SDK는 로컬 모드와 클라이언트 모드를 모두 지원하지만, 이 작업에서는 둘 다 동일한 기능과 특성을 공유하므로 로컬 모드에만 중점을 둡니다.

다음에서는 먼저 주요 구성 요소와 품질 보증에 대해 자세히 소개합니다. 그런 다음 SDK의 실제 사용법을 설명하기 위해 간결한 작업 흐름 예제가 제공됩니다.

A. SDK의 핵심 구성요소

a) **커넥터:** 파이프라인의 첫 번째 단계로 SDK는 다양한 유형의 데이터 소스와 대상을 구성하기 위한 인터페이스

를 제공합니다. 이는 훈련 세트를 가져오기 위해 데이터 소스에 액세스하거나 생성된 합성 데이터 세트를 저장할 대상을 지정하는 데 필요한 모든 정보를 캡슐화하는 컨테이너인 *connectors*를 통해 관리됩니다.

커넥터는 널리 사용되는 다양한 데이터베이스 및 클라우드 제공자와의 직접적인 통합을 가능하게 하는 아티팩트입니다. Figure 1에는 SDK가 현재 지원하는 다양한 유형의 커넥터가 나열되어 있습니다. 가장 간단한 수준에서 커넥터는 사용자가 수동으로 업로드한 파일에 대한 로컬 데이터 경로만 지정할 수 있는 반면, 더 복잡한 커넥터에는 키 파일, 비밀번호 및 SSL 인증서와 같은 인증을 위한 자격 증명도 포함될 수 있습니다.

b) **생성기:** 교육 데이터를 가져온 후 다음 단계에는 생성 모델을 교육하는 작업이 포함됩니다. 이 단계는 모델 자체의 학습뿐만 아니라 이후에 합성 데이터를 생성하는 데 필요한 데이터 세트에 대한 모든 관련 정보를 캡슐화하는 아티팩트인 *generator*에 의해 처리됩니다.

생성기에는 여러 데이터 유형 지원, 텍스트 모델링을 위한 LLM(대형 언어 모델) 통합, 구성 가능한 교육 설정과 같은 기능이 포함되어 있습니다. 또한 시계열 데이터와 다중 데이터 토폴로지를 처리합니다. 또한 사용자는 추가 개발을 위해 발전기를 가져오고 내보낼 수 있습니다.

c) **합성 데이터세트:** 합성 데이터세트 구성요소는 훈련된 생성기를 사용하여 합성 데이터를 생성하는 것으로 구성된 파이프라인의 마지막 단계를 처리합니다. 여기에는 데이터 통찰력 및 합성 데이터의 품질 평가를 포함한 여러 추가 아티팩트와 함께 생성된 데이터가 포함됩니다. 또한 재현성을 촉진하기 위해 전체 구성 세부 정보도 제공합니다. 사용자는 레코드를 다시 샘플링하고 다양한 전략으로 데이터를 생성하는 옵션을 사용하여 훈련된 단일 생성기에서 여러 데이터 세트를 생성할 수 있습니다.

d) **합성 데이터 품질 보증 보고서:** SDK는 모든 합성 데이터 생성기에 대해 자동 품질 보증(QA) 보고서를 제공하여 사용자가 생성된 합성 데이터의 충실도와 개인 정보 보호를 모두 평가할 수 있도록 합니다. 각 합성 데이터 생성기에는 포괄적이고 해석 가능한 분석을 위해 표준화된 품질 지표와 대화형 HTML 시각화를 모두 제공하는 상세한 QA 보고서가 함께 제공됩니다.

평가 프레임워크 [13]는 홀드아웃 기반 접근 방식을 사용하여 합성 데이터와 원본 데이터를 비교하며 분포 유사성, 임베딩 기반 측정값, 최근접 이웃 거리 등 다양한 정량적 측정항목을 포괄합니다. 순차 및 상황별 기능을 포함하여 다양한 데이터 유형을 지원합니다.

B. 기본 작업 재미있는

SDK는 고품질 합성 데이터에 대한 액세스를 민주화하여 연구자와 실무자에게 힘을 실어줌으로써 광범위한 청중에게

¹<https://github.com/mostly-ai/mostlyai>

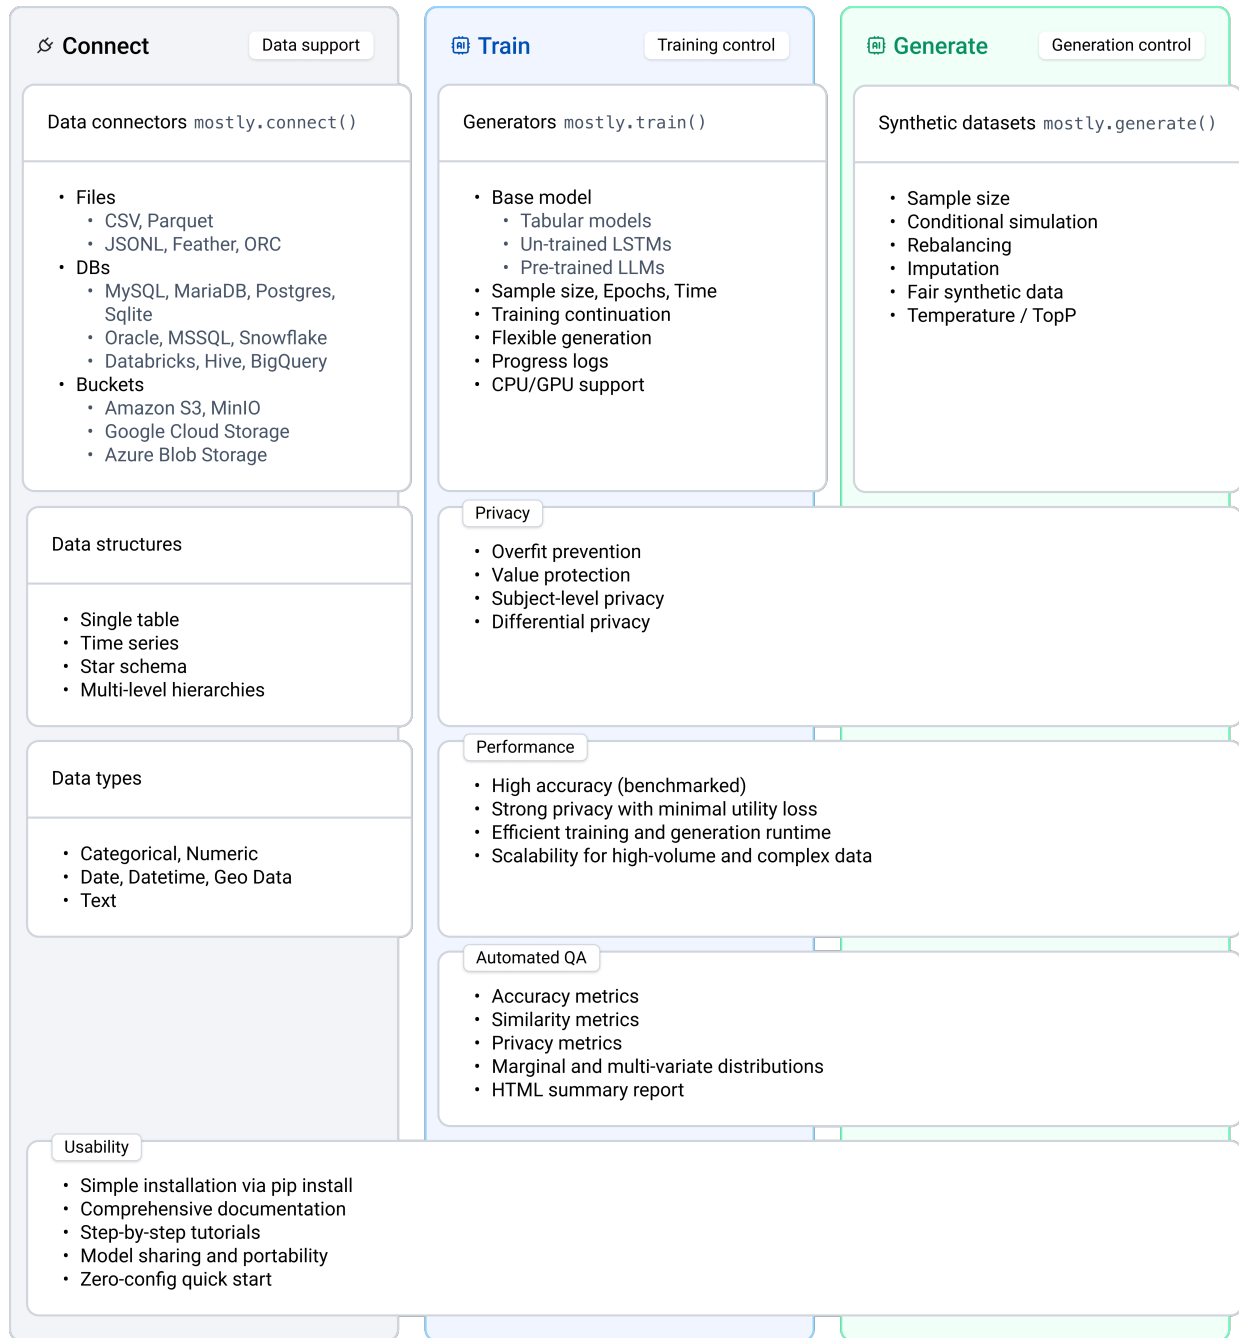


그림 1. MOSTLY AI 합성 데이터 SDK의 주요 기능 및 기능에 대한 개요입니다. SDK는 커넥터, 생성기 및 합성 데이터 세트의 세 가지 주요 아티팩트를 중심으로 구성됩니다. 커넥터는 데이터 수집 및 스키마 정의를 포함한 데이터 지원을 담당합니다. 생성기는 훈련 제어를 처리하며 주로 `mostly.train()` 기능을 통해 조작됩니다. 생성은 `mostly.generate()` 함수를 통해 합성 데이터 세트 아티팩트에 의해 제어됩니다. 마지막으로 SDK는 합성 데이터의 안전을 보장하기 위한 개인 정보 보호 메커니즘과 결과 모델 및 데이터 세트의 품질을 평가하기 위한 품질 보증 도구 키트를 통합합니다.

```

1 import pandas as pd
2 from mostlyai.sdk import MostlyAI
3 mostly = MostlyAI()
4
5 original_df = pd.read_csv(
6     "https://github.com/mostly-ai/public-demo-data/raw
7     /dev/titanic/titanic.csv"
8 )
9 g = mostly.train(
10     name="QuickStartDemoTitanic",
11     data=original_df,
12 )
13 g.reports(display=True)
14 sd = mostly.generate(g)
15 df = sd.data()

```

그림 2. 기본적인 작업 예시

```

1 g = mostly.generators.get('GENERATORID')
2 path_to_generator = g.export_to_file()
3 g = mostly.generators.import_from_file(
4     path_to_generator)

```

그림 3. 발전기 공유

다가가는 것을 목표로 합니다. 이는 사용 편의성, 명확성 및 운영 효율성을 위해 특별히 설계되었습니다.

Figure 2는 합성 데이터 생성을 위한 최소한의 엔드투엔드 워크플로를 보여줍니다. 먼저 SDK가 초기화되고(3행) 예를 들어 Titanic 데이터셋이 Pandas DataFrame(라인 5-7). 그런 다음 생성기는 `mostly.train()`을 사용하여 이 데이터에 대해 훈련됩니다. 방법(8-11행). 워크플로는 최종 합성 데이터 세트(13 14행)를 생성하고 액세스하기 전에 QA 보고서(12행)를 표시하여 마무리됩니다.

원본 데이터에 대한 훈련 후 생성기를 내보내고 공유할 수 있으므로 다른 사람들이 원본 데이터를 노출하지 않고도 합성 데이터를 생성하고 생성 설정을 자신의 요구 사항에 맞게 조정할 수 있습니다. 이 기능은 Figure 3에 나와 있습니다. 생성기가 생성되면 고유 ID가 할당됩니다. 특정 생성기에 액세스할 수 있는 권한이 있는 사용자는 1행에 표시된 대로 모델 가중치를 로드할 수 있습니다. SDK를 사용하면 생성기를 ZIP로 가져오고 내보낼 수도 있습니다. 파일은 2행과 3행에 표시된 대로입니다.

III. 데이터 수집 및 처리

실제 데이터셋은 크기와 모양이 다양한 경우가 많고, 다양한 데이터 형식에 걸쳐 있으며, 복잡한 관계가 있는 여러 테이블로 구성되는 경우가 많습니다. SDK는 이러한 다양성을 처리하도록 정밀하게 설계되어 다양한 데이터 형식과 스키마를 수용할 수 있는 효과적이고 강력한 메커니즘을 제공합니다. 이 섹션에서는 먼저 SDK가 특화된 전략을 통해 광범위한 데이터 유형을 지원하는 방법에 대해 자세히 설명

합니다. 그런 다음 지원되는 데이터 스키마에 대한 세부정보를 제공합니다.

A. 데이터 준비

훈련 전에 원시 입력 데이터는 자동 유형 감지, 인코딩 할당, 개인 정보 보호 값 보호 메커니즘을 포함하는 포괄적인 전처리 파이프라인을 거칩니다. SDK는 [10]에서 제안한 데이터 인코딩 프로토콜을 따릅니다. 여기서 원본 데이터셋의 모든 열은 하나 이상의 범주형 하위 열로 변환됩니다. 결과적으로 인코딩된 데이터 세트는 원래 데이터 세트의 도메인에 관계없이 범주형 변수로만 구성됩니다. Table I에는 지원되는 모든 표 형식 인코딩 유형이 요약되어 있습니다.

텍스트 기능의 경우 고유한 모델링 전략이 사용됩니다. 텍스트 열은 별도로 처리되므로 사용자는 먼저 적용할 언어 모델 유형을 선택할 수 있습니다. 기본적으로 맞춤형 토큰라이저가 사용되며 LSTM 기반 시퀀스 모델이 처음부터 학습됩니다. 이 모델은 표 형식 열의 상황별 정보를 통합하면서 토큰 시퀀스와 동시 발생을 캡처합니다. 또는 사용자가 사전 훈련된 LLM을 선택할 수 있으며, 이 경우 모델의 토큰라이저가 적용되어 텍스트 데이터를 토큰화합니다. 그런 다음 선택된 사전 훈련된 LLM은 LoRA(Low-Rank Adaptation)를 사용하여 데이터셋에서 미세 조정되며, 표 형식 기능의 추가 컨텍스트를 텍스트 생성 프로세스에 다시 통합합니다.

누락된 값은 자동으로 별도의 범주로 처리되어 결과 합성 데이터에서 다른 기능과의 상관 관계를 유지합니다. 값 보호 메커니즘은 각 열에 적용되어(표 II 참조) 민감하거나 이상치인 정보가 합성 데이터에서 제외되도록 보장합니다.

B. 다중 테이블 관계 관리

SDK는 주제 테이블 및 연결된 테이블이라는 두 가지 주요 테이블 유형이 있는 여러 테이블로 구성된 데이터 세트를 구성합니다. 주제 테이블에는 주제당 정확히 하나의 레코드가 포함되어 있으며 학습 시 개인 정보 보호 메커니즘이 적용될 세분성 수준을 정의합니다. 반면에 연결된 테이블은 주제와 관련된 이벤트, 시퀀스 또는 시간 인덱스 데이터를 나타내는 레코드로 구성됩니다.

데이터 세트가 SDK로 처리되면 잠재적으로 두 가지 유형의 외래 키(컨텍스트 외래 키 및 비컨텍스트 외래 키)를 통해 설정된 테이블 간의 관계와 함께 두 유형의 여러 테이블로 구성될 수 있습니다. 주제와 연결된 테이블이 컨텍스트 외래 키를 통해 연결된 경우 구현된 알고리즘은 두 테이블의 레코드 간의 상관 관계가 생성 중에 모델링되고 유지되도록 보장합니다. 반면, 비컨텍스트 외래 키를 사용하면 연결된 두 테이블이 독립적으로 모델링되더라도 참조 무결성이 유지됩니다. 톨킷은 이러한 빌딩 블록을 사용하여 지정된 데이터 세트 내의 테이블을 연결하고 복잡한 계층 구조와 중첩 관계가 있는 임의의 데이터 스키마를 처리합니다.

표 I
현재 SDK에서 지원하는 테이블 형식이 존재합니다.

인코딩 유형	설명
범주형	미리 정의된 고정된 값 집합으로 변수를 인코딩합니다(예: 티셔츠 크기).
숫자: 자동	데이터 유틸리티를 기반으로 최상의 숫자 인코딩 전략을 자동으로 선택합니다.
숫자: 이산형	숫자 데이터를 범주형(예: 우편번호, 이진 값)으로 처리합니다.
숫자: 구간화	숫자 값을 100개의 개별 간격으로 구간화하고 각 구간 내에서 샘플링하여 합성 값을 생성합니다.
숫자: 숫자	숫자 값을 숫자의 각 숫자를 나타내는 여러 범주형 열로 분할합니다.
문자	일관된 형식 지정 패턴을 사용하는 짧은 문자열을 문자열의 각 문자를 나타내는 여러 범주형 열로 분할합니다.
Datetime	datetime 값을 연도, 월, 일, 시, 분, 초를 나타내는 범주형 하위 열로 분할합니다.
날짜/시간: 상대	순차적 이벤트 간의 정확한 간격을 모델링합니다.
위도, 경도	위도/경도 쌍을 계층적 사분위수로 변환하고 이를 점점 더 미세한 수준의 해상도를 나타내는 범주형 하위 열로 인코딩합니다.

표 II
데이터 유형별 가치 보호 전략 요약

컬럼 유형	개인정보 보호 전략
범주형	고유 값을 "_RARE_" 범주로 통합하거나 보다 일반적인 범주에서 대체 값을 샘플링하여 고유 값으로 인한 재식별 위험을 줄입니다.
숫자	값을 백분위수로 분류하거나 숫자로 분해하여 정확한 숫자를 모호하게 하고 값을 잘라내어 이상값 식별을 제한합니다.
Datetime	타임스탬프(연도, 월, 일)와 클립 범위를 분해하여 일반적이지 않은 날짜를 마스크합니다.
지리 공간적	위도-경도 쌍을 로컬 데이터 밀도에 맞게 해상도가 조정된 사분위수로 변환합니다.
텍스트	구문 누출을 방지하려면 데이터 독립적인 어휘가 포함된 표준 토큰라이저를 적용하세요.

IV. 생성 모델 훈련

데이터 세트가 로드되고 데이터 스키마가 정의되면 SDK는 모델 교육을 진행합니다. 이 단계에서 SDK는 데이터세트 크기와 사용 가능한 메모리를 기반으로 배치 크기와 학습률을 자동으로 선택하고 학습률 스케줄러를 사용하여 수렴을 더욱 최적화합니다. 사용자는 CPU와 GPU 하드웨어를 모두 활용하여 훈련을 가속화할 수 있으며, 훈련 실행을 투명하게 추적하고 관리할 수 있도록 실시간 진행 상황 모니터링이 제공됩니다.

다음에서는 먼저 핵심 모델 접근 방식에 대한 개요를 제공한 다음 지원되는 LLM에 대한 세부 정보를 제공합니다.

마지막으로 SDK에 구현된 개인정보 보호 메커니즘이 제시됩니다.

A. 자동 배열 테이블 형식 개요

생성기 아티팩트는 [10]에 자세히 설명된 TabularARGN(Tabular Auto-Regressive Generative Network)을 사용하여 훈련됩니다. 해당 아키텍처는 이산화된 기능에서 작동하고 범주형 교차 엔트로피 손실을 사용하여 최적화되는 얇은 임의 차수 자동 회귀 모델을 제공합니다. 기본적으로 TabularARGN은 생성 프로세스를 자동 회귀 프레임워크에 매핑하여 데이터의 결합 확률 분포를 더 간단한 조건부 확률의 산물로 추정합니다. 다중 테이블 데이터 세트를 처리하기 위해 모델은 자동 회귀 조건부 확률 프레임워크를 확장하여 데이터 스키마에 정의된 관련 테이블 간의 종속성을 캡처합니다. 이러한 시나리오에서 SDK는 테이블이 처리되는 순서를 명시적으로 정의하여 테이블 간의 상위-하위 관계를 설정합니다. 이런 방식으로 상위 테이블의 레코드는 *context* 임베딩으로 압축된 다음 하위 테이블의 조건부 생성에 사용됩니다.

TabularARGN의 중요한 측면은 테이블 내의 열이 모델링되는 순서입니다. SDK에서 `mostly.train()`를 호출할 때 사용자는 훈련을 위한 두 가지 열 순서 전략, 즉 고정 순서와 유연한 순서(또는 임의 순서) 중에서 선택할 수 있습니다. 기본적으로 유연한 옵션이 활성화되어 있습니다. 이 모드에서 SDK는 각 훈련 배치에 대한 열 순서를 무작위로 섞습니다. 이 접근 방식을 통해 모델은 기능의 하위 집합에 따라 조건이 지정된 데이터를 생성하는 방법을 학습할 수 있으므로 데이터 배치, 조건부 시뮬레이션 또는 공정성 조정과 같은 작업에 다용도로 사용할 수 있습니다. 유연한 교육을 통해 더 폭넓은 생성 기능을 사용할 수 있지만 학습 작업도 더욱 복잡해집니다. 이러한 추가적인 복잡성으로 인해 결과 합성 데이터의 정확성이 저하될 수 있습니다. 고정 열 순서를 선택하면 학습이 단순화되고 경우에 따라 정확도가 향상될 수 있습니다. 그러나 일단 고정 순서 모드로 훈련되면 모델은 임의의 기능 하위 집합에서 유연하게 데이터를 생성하는 기능을 잃게 됩니다. 이는 생성 시 더 높은 정확성과 더 많은 유연성 사이의 절충안을 제시하며, 의도한 애플리케이션에 따라 최적의 선택이 가능합니다.

B. LLM 절단 지원

HuggingFace 플랫폼에서 호스팅되는 LLM 미세 조정을 지원합니다. 섹션 2에서 설명한 대로 텍스트 열 모델링을 위해 사전 훈련된 LLM을 활용하도록 선택할 수 있습니다. 이 경우 사용자는 처음부터 훈련되는 기본 LSTM 모델에 의존하는 대신 데이터를 미세 조정하기 위해 원하는 LLM을 선택합니다. 이 옵션은 사용자에게 읽기 권한이 있는 HuggingFace 액세스 토큰이 있는 한 SDK에서 사용할 수

있습니다. 현재 HuggingFace에서 사용 가능한 모든 텍스트 생성 LLM을 지원합니다.

C. 개인 정보 보호

TabularARGN 훈련 절차는 훈련 데이터의 개별 기록을 보호하기 위한 강력한 개인 정보 보호 장치로 설계되었습니다. 민감한 정보를 기억하게 될 수 있는 과적합의 위험을 최소화하기 위해 모델은 전용 개인 정보 보호 중심 전략을 사용합니다.

- **조기 중지:** 훈련 중 데이터 세트의 최대 10%를 검증 세트로 따로 둡니다. 각 epoch가 끝날 때 검증 손실을 계산합니다. 검증 손실이 연속 N epoch 동안 개선되지 않으면(기본값: 5) 훈련을 조기에 중단합니다. 관측된 검증 손실이 가장 낮았던 모델 가중치를 최종 모델로 유지합니다.
- **드롭아웃 정규화:** 각 네트워크 계층에는 25%의 드롭아웃 비율이 포함되어, 훈련 중 뉴런의 일부를 무작위로 비활성화함으로써 과적합 위험을 줄입니다.

a) **차등 개인 정보 보호:** SDK는 DP 보장을 통해 합성 데이터 생성기를 교육하는 옵션을 제공합니다. DP가 활성화되면 훈련 절차는 원본 데이터 세트의 개별 레코드가 개인 정보 보호 예산 매개변수 ϵ 로 정량화되는 것처럼 훈련된 모델에 수학적으로 제한된 영향을 미치도록 보장합니다. 개인 정보 보호 예산은 훈련 전반에 걸쳐 모니터링되며, 이 임계값에 도달하면 자동으로 훈련을 중단하도록 상한 ϵ 제한을 설정할 수 있습니다.

SDK의 차등 개인 정보 보호는 그라데이션 클리핑, 노이즈 추가, 무작위 데이터 로딩 및 개인 정보 계정을 통해 개인 정보 보호를 보장하는 Opacus 라이브러리를 사용하여 구현됩니다. 사용자는 요구 사항에 따라 개인 정보 보호와 모델 유틸리티의 균형을 맞추기 위해 노이즈 수준과 클리핑 매개변수를 구성할 수 있습니다.

비DP 훈련은 효율성과 정확성을 극대화하기 위한 기본값이지만, DP 옵션은 모델 성능과 계산 효율성에 영향을 미칠 수 있다는 점을 이해하고 엄격한 수학적 개인 정보 보호를 요구하는 사용자에게 제공됩니다.

V. 합성 데이터 생성

훈련이 완료되면 생성기는 원본 데이터세트의 통계적 속성과 일치하는 합성 데이터를 생성합니다. 합성 데이터 생성은 훈련된 생성기를 입력으로 사용하는 `mostly.generate()` 함수를 사용하여 수행됩니다.

두 개의 관련 테이블(예: 플랫폼 주제 테이블과 순차 연결 테이블)이 포함된 설정에서는 생성이 계층적으로 진행됩니다. 플랫폼 테이블이 먼저 샘플링되어 순차 테이블 모델에 필요한 컨텍스트를 제공합니다. 그런 다음 순차 테이블이 조건부로 생성되어 플랫폼 테이블의 종합 레코드를 상황별 입력으로 활용합니다.

a) **다중 테이블 생성:** 다중 테이블 스키마의 경우 생성 프로세스는 학습 중에 학습된 종속성과 상황별 관계에 따라 결정됩니다. 스키마 계층 구조는 샘플링 순서를 지정합니다. 즉, 상위 테이블과 상위 테이블이 먼저 합성되어 모든 다운스트림 테이블에 대한 컨텍스트를 제공합니다. 대상 테이블을 생성할 때 단일 홑 컨텍스트 테이블뿐만 아니라 컨텍스트 체인에 있는 모든 테이블의 합성 값에 대한 처리 조건입니다. 형제 순차 테이블의 경우 SDK는 조건부 생성을 지원하므로 한 시퀀스의 출력을 다른 시퀀스의 컨텍스트로 사용하여 관련 시퀀스 간의 상관 관계를 캡처할 수 있습니다. 컨텍스트 체인에 포함되지 않거나 단일 홑 컨텍스트로 포함되지 않은 테이블은 독립적으로 생성됩니다. 그러나 참조 무결성은 엄격하게 유지됩니다. 한 홑 이상 떨어진 테이블의 경우에도 모든 외래 키 관계는 합성 데이터 세트에 보존됩니다. 이를 통해 레코드 간의 모든 링크가 유효하고 현실적인 다중 테이블 데이터에 필요한 구조적 일관성을 유지하도록 보장됩니다.

A. 유연한 시리즈

유연한 생성을 통해 모델은 단순히 훈련 데이터의 통계적 패턴을 재현하는 것 이상을 수행할 수 있습니다. 유연한 순서 열 순서로 학습된 모델에 사용할 수 있는 이 기능에는 소규모 샘플부터 대규모 데이터 세트까지 원하는 양의 합성 데이터를 생성하는 기능이 포함됩니다. 유연한 조건부 시뮬레이션을 통해 사용자는 선택한 열에 특정 값을 제공하고 나머지 열에 대해 생성된 합성 콘텐츠를 사용하여 특정 시나리오에 맞게 출력을 조정할 수 있습니다. 다양한 고급 변환(예: 재조정, 대치, 공정성 조정)의 경우 사용자는 대상 열만 지정하면 되며 SDK는 각 시나리오에 대한 최적의 열 순서를 자동으로 관리합니다.

a) **조건부 시뮬레이션:** 조건부 시뮬레이션을 사용하면 초기 속성에 따라 여러 합성 시나리오를 생성하여 단순한 예측을 뛰어넘을 수 있습니다. 단일 기대값만 제공하는 대신 모델은 가능한 결과의 범위와 가능성을 정량화하는 경험적 분포를 생성합니다. 예를 들어, 의료 분석에서는 사용 가능한 환자 데이터를 컨텍스트로 사용하고 그럴듯한 회복 시나리오를 샘플링하여 다양한 치료 계획에 따라 환자 회복 궤적을 시뮬레이션할 수 있습니다. 이러한 유연한 접근 방식은 불확실성과 가능한 미래에 대한 더 깊은 통찰력을 제공하여 더 많은 정보를 바탕으로 한 데이터 기반 의사 결정을 지원 합니다.

b) **재조정:** 재조정을 통해 사용자는 데이터의 소수 그룹에 대한 추가 합성 샘플을 생성하여 클래스 불균형을 해결할 수 있습니다. 원하는 클래스 비율을 지정함으로써 사용자는 나머지 기능이 일관되고 현실적으로 유지되도록 하면서 과소대표된 결과의 표현을 늘릴 수 있습니다. [14] 비교 평가에서 TabularARGN 기반 업샘플링은 순진한 오버샘플링 [15] 및 SMOTE-NC [16]와 같은 기존 기술에 비해

장점을 보여주었습니다. 기존 레코드를 복제하거나 레코드 간에 보간하는 이러한 방법과 달리 TabularARGN은 기본 데이터 분포를 보다 정확하게 반영하는 다양한 현실적인 합성 샘플 세트를 생성하여 특히 소수 클래스가 매우 작은 경우 이러한 균형 잡힌 데이터 세트에서 훈련된 기계 학습 모델의 성능을 향상시킵니다.²

c) **대치**: 대치(Imputation)를 통해 사용자는 훈련 중에 학습한 통계적 관계를 활용하여 데이터의 누락된 값을 채울 수 있습니다. 예를 들어 데이터 세트에서 직업과 같은 범주형 열의 값이 누락된 경우 생성기는 교육, 연령, 소득과 같은 사용 가능한 기능을 사용하여 해당 개인에 대한 그럴듯한 직업을 추론할 수 있습니다. 누락된 패턴을 복제하는 대신 생성기는 누락된 범주를 마스크하고 그럴듯한 값을 샘플링하여 사용 가능한 모든 컨텍스트를 사용하도록 대치된 열을 마지막에 배치합니다. 조건부 대치의 경우 사용자는 누락된 항목과 관찰된 기능이 포함된 시드를 컨텍스트로 제공합니다. 그런 다음 SDK는 그에 따라 누락된 값을 채웁니다.³

d) **공정성**: 공정성 조정을 통해 사용자는 통계적 페리티 기준을 충족하는 합성 데이터를 생성하여 민감한 그룹 간에 균형 잡힌 결과를 보장할 수 있습니다. 예를 들어 원본 데이터에서 여성은 고소득층 사이에서 과소 대표될 수 있으며 이로 인해 불공정한 다운스트림 모델 예측이 발생할 수 있습니다. SDK의 공정성 조정 기능은 데이터 생성 프로세스를 수정하여 민감한 그룹이 원래 데이터세트의 기존 편견에 관계없이 긍정적인 결과를 할당받을 수 있는 동일한 기회를 갖도록 합니다.

이는 대상 열을 마지막으로 샘플링하고 이전에 생성된 민감한 속성을 기반으로 조건부 확률을 조정하여 통계적 페리티를 적용함으로써 달성됩니다. 결과적으로 사용자는 공정성을 인식하는 데이터 세트를 생성하여 실제 편향된 데이터를 평가할 때에도 다운스트림 모델이 더 공정하고 균형 잡힌 예측을 생성할 수 있습니다. 이러한 제약 조건은 생성 중에 동적으로 적용되므로 생성기를 재교육하지 않고도 공정성과 정확성 간의 균형을 유연하게 관리할 수 있습니다. [12]⁴

e) **유연한 샘플링**: 유연한 생성 순서 외에도 엔진을 사용하면 온도 및 top-p 매개변수를 조정하여 샘플링 프로세스를 추가로 제어할 수 있습니다. 온도를 낮추면(예: < 1) 모델이 공통 값을 생성할 가능성이 높아집니다. 이는 사용자가 알려진 규칙이나 비즈니스 논리를 엄격하게 따르는 출력을 원할 때 유용합니다(예: 유효한 제품 코드만 생성하거나 일반적인 사용자 행동을 밀접하게 준수). 온도 상승(예: > 1)

은 생성된 데이터의 다양성을 증가시키며, 이는 스트레스 테스트 모델이나 드문 시나리오 탐색에 유용할 수 있습니다.

top-p 매개변수는 샘플링 중에 고려되는 누적 확률 질량에 대한 임계값을 설정합니다. top-p 값을 낮게 설정하면 가능성이 가장 높은 결과에 초점을 맞추고, 값을 높이면 가능성이 낮은 옵션을 포함하여 다양성을 높일 수 있습니다. 이러한 제어 기능을 통해 사용자는 일상적인 작업을 위한 현실적인 기록 생성 또는 강력한 모델 평가를 위한 엣지 케이스 생성과 같은 특정 요구 사항에 맞게 합성 데이터의 다양성과 대표성을 미세 조정할 수 있습니다.

VI. 실증적 성과 및 커뮤니티 채택

SDK는 개인정보를 보호하는 합성, 왜곡된 데이터세트의 재조정, 누락된 값의 대치, 공정한 합성 데이터 등 다양한 데이터 문제에 대한 실용적인 솔루션을 제공합니다. SDK의 실제 영향을 종합적으로 평가하기 위해 우리 작업의 두 가지 보완적인 측면을 자세히 설명합니다. 한편으로는 [10]가 제시한 실증적 증거가 요약되어 SDK의 핵심 모델인 TabularARGN의 생성 정확성, 강력한 개인 정보 보호 보장 및 효율적인 런타임 측면에서 강력한 성능을 강조합니다. 한편, 2025년 1월 SDK 공개 출시 이후 관찰된 커뮤니티 채택 증가에 대해 논의하여 실용성, 유용성 및 관련성을 입증합니다.

A. 합성 데이터 품질

우리 접근 방식의 효율성을 입증하기 위해 이전에 [10]에서 보고된 주요 경험적 결과를 요약합니다. 여기서 TabularARGN은 평면 및 순차 테이블 형식 데이터 세트 모두에 대한 최첨단 방법에 대해 벤치마킹되었습니다. 평가는 일변량 및 이변량 정확도와 같은 저차 한계 통계를 통해 측정된 통계적 충실도와 DCR(Distance to Closest Record) 공유와 같은 측정항목을 통해 정량화된 개인정보 보호 품질 측면에서 합성 데이터의 품질을 평가하는 [17]가 제안한 프로토콜에 따라 수행되었습니다. 이 평가 프로토콜은 [18]에서 사용할 수 있는 오픈 소스 패키지 [13]에서 구현됩니다. SDK는 이 패키지를 활용하여 앞서 섹션 2에서 설명한 포괄적인 품질 보증 보고서를 생성합니다.

플랫 테이블의 경우 모델을 CTGAN [19], STaSy [20], TabSyn [21], TabMT [22] 및 Unmasking Trees [23]와 같은 방법과 비교했습니다. 순차 데이터의 경우 벤치마크에는 REalTabFormer [24], RC-TGAN [25] 및 ClavaDDPM [26]가 포함되었습니다. 여러 데이터세트를 조사했지만 이 섹션에서는 중단적 플레이어 성능 통계로 구성된 성인 인구 조사 데이터세트와 야구 데이터세트의 각 데이터 체계에 대해 하나의 데이터세트 결과만 제시합니다. Figure 4는 DP를 사용하여 교육할 때에도 벤치마크에 비해 상당한 속도 향상을 제공하면서 최첨단 성능을 달성하는 TabularARGN의 능력을 강조하는 주요 결과를 보여줍니다. 이는 정확도와 런타임에 부정적인 영향을 미칠 수 있습니다.

²재균형에 대한 지침은 SDK 사용 튜토리얼 참조: <https://github.com/mostly-ai/mostlyai/tree/main/docs/tutorials/rebalancing>

³리밸런싱 기능 사용에 대한 자세한 지침은 <https://github.com/mostly-ai/mostlyai/tree/main/docs/tutorials/smart-imputation>의 SDK 사용 튜토리얼을 참조하세요.

⁴공정성 기능 사용에 대해 자세히 알아보려면 <https://github.com/mostly-ai/mostlyai/tree/main/docs/tutorials/fairness>에서 SDK 튜토리얼을 확인하세요.




그림 4. 플랫폼 Adult(왼쪽) 및 순차 Baseball(오른쪽) 데이터 세트에 대한 훈련 시간(상단) 및 정확도(하단). 값은 3회 이상의 실행에 대한 평균입니다. 오류 막대는 최소/최대를 나타냅니다. DP 훈련 유무에 관계없이 TabularARGN이 표시됩니다.




그림 5. GitHub는 2025년 1월 23일까지 등장합니다. 이후 2025년 7월 31일까지 SDK의 역사를 기록합니다.




그림 6. 등장일부터 6월까지 MOSTLY AI 조직 외부 사용자가 생성한 주당 생성기 수입니다.

B. 확장성 및 응용 프로그램 처리

해당 분야의 상당한 발전에도 불구하고 딥 러닝 기반 표형식 데이터 생성기의 대부분은 유연성, 확장성 또는 실제 데이터베이스 토폴로지에 대한 지원을 희생하면서 개인 정보 보호 또는 충실도와 같은 문제의 하위 집합만 해결하는 데 여전히 초점을 맞추고 있습니다. 대표적인 예가 DataCebo에서 개발하여 널리 사용되는 비즈니스 소스 Python 라이브러리인 SDV(Synthetic Data Vault) [27]입니다. 이 라이브러리는 GAN 및 VAE를 포함한 다양한 생성 모델링 기술을 활용하여 단일 테이블, 다중 테이블 및 시계열 데이터 합성을 위한 도구를 제공합니다. 그러나 벤치마킹 및 실험 평가

⁵에서는 SDV가 특정 단일 테이블 사용 사례에서 탁월하지만 더 크거나 복잡한 데이터 세트에서는 확장성 및 성능 제한에 직면할 수 있으며 수동 구성 또는 광범위한 매개 변수 조정이 필요할 수 있음을 보여줍니다. 이 분석을 복잡한 관계형 및 시간적 종속성이 있는 2개의 테이블 데이터 세트로 확장하면 SDV가 이러한 패턴을 캡처하는 데 어려움을 겪는 반면 SDK는 이러한 패턴을 보다 효과적으로 처리하여 이러한 조건 ⁶에서 더 높은 충실도와 유용성을 달성한다는 사실을

⁵SDV vs. SDK: <https://mostly.ai/blog/a-comparison-of-synthetic-data-vault-and-mostly-ai-part-1-single-table-scenarios>의 단일 테이블 시나리오

⁶SDV vs. SDK: Sequential Scenario at <https://mostly.ai/blog/a-comparison-of-synthetic-data-vault-and-mostly-ai-part-2-sequential-scenarios>

관찰했습니다.

C. 커뮤니티 채택

SDK는 2025년 1월 23일 출시된 이후 GitHub에서의 참여가 증가하면서 빠르게 채택되었습니다. Figure 5는 출시 일부터 7월 31일까지 GitHub 스타의 증가를 추적하며 이는 강력한 관심 지표입니다. 또한 Figure 6에는 MOSTLY AI 조직에 속하지 않은 사용자가 생성한 주당 생성기 수가 표시 됩니다. 중요한 것은 이 수치는 클라우드 서비스에서 생성된 생성기만 나타내므로 로컬에서 생성된 생성기를 포함하는 실제 사용량의 하한으로 사용된다는 것입니다. 이는 툴킷에 대한 커뮤니티의 실질적인 참여를 강조합니다.

이미 실제 적용을 추진하는 열정이 커지고 있습니다. 최근 사례로는 기업과 기관이 데이터 서비스 및 분석을 제공하여 데이터에서 실행 가능한 지식을 추출할 수 있도록 하는 것을 목표로 하는 유럽 조직인 Moderate Project에서 개발한 에너지 성능 인증서용 시각화 도구가 있습니다.⁷ Moderate 팀은 SDK를 지오 클러스터링 도구에 통합하여 이탈리아 피에몬테 지역의 에너지 성능 인증서를 분석하기 위한 시각화 도구를 개발할 수 있었습니다. 기본 데이터는 공개적으로 사용할 수 없으므로 합성 데이터를 활용하여 이 도구를 공개적으로 사용할 수 있도록 합니다.⁸

a) 추가 리소스: SDK의 모든 주요 기능을 다루는 사용 지침과 광범위한 튜토리얼도 제공되어 모든 수준의 사용자가 SDK를 빠르게 시작하고 전체 기능⁹을 탐색할 수 있도록 돕습니다.

VII. 결론

본 논문에서는 MOSTLY AI 합성 데이터 SDK의 아키텍처와 주요 기능을 소개했습니다. 직관적인 인터페이스는 실무자에게 광범위한 실제 사용 사례를 다룰 수 있는 전체적인 솔루션을 제공합니다. SDK는 개인 정보 보호 합성 데이터 생성을 위한 확장 가능한 솔루션을 제공하여 다양한 표 형식 데이터 토폴로지와 혼합 데이터 유형을 지원합니다.

모듈식 설계와 풍부한 구성 옵션 세트를 갖춘 SDK를 통해 사용자는 액세스 가능하고 사용하기 쉬운 Python API 내에서 클래스 불균형, 누락된 값, 공정성 요구 사항과 같은 일반적인 데이터 문제를 해결할 수 있습니다. 학습 및 생성의 주요 측면을 조정하는 기능과 간단한 로컬 배포가 결합되어 개인 정보 보호를 준수하는 데이터 액세스에 더 쉽게 접근할 수 있게 되고 실제로 합성 데이터의 채택을 가속화합니다. SDK는 로컬로 배포 가능한 개방형 솔루션을 제공함으로써 안전한 데이터 기반 혁신도 가능하게 합니다. 향후 작업에

⁷Moderate의 기본 웹사이트: <https://moderate-project.eu/in-a-nutshell/>

⁸시각화 도구는 https://tools.eeb.eurac.edu/epc_clustering/piemonte/에서 사용할 수 있습니다.

⁹<https://mostly-ai.github.io/mostlyai/tutorials/>

서는 모델 기능을 더욱 강화하고 추가 데이터 형식에 대한 지원을 확장할 것입니다.

완료

SDK 개발에 귀중한 기여를 해주신 Kerem Erdem, Michael Druk, Alex Ichim, Andr Jonasson, Lukasz Kolodziejczyk, Duygu Okcu, Dmitry Parshenkov, Michael Platzer, Radu Rogojanu, Paul Tiwald 및 Shuang Wu에게 감사드립니다. 이들의 집단적 전문 지식과 헌신은 SDK의 기능을 발전시키는 데 중추적인 역할을 하여 고품질 합성 데이터 생성을 보장하는 동시에 정보 유출에 대한 엄격한 보호 조치를 유지했습니다. 이들의 노력은 SDK를 표 형식의 합성 데이터 합성을 위한 효율적이고 강력하며 유연하고 사용자 친화적인 솔루션으로 만드는 데 중요한 역할을 했습니다.

References

- [1] C. Shani, J. Zarecki, and D. Shahaf, "The lean data scientist: Recent advances toward overcoming the data bottleneck," *Communications of the ACM*, vol. 66, no. 2, p. 92–102, Jan. 2023. [Online]. Available: <http://dx.doi.org/10.1145/3551635>
- [2] J. Drechsler, *Synthetic datasets for statistical disclosure control: theory and implementation*. Springer Science & Business Media, 2011, vol. 201.
- [3] J. Jordon, L. Szpruch, F. Houssiau, M. Bottarelli, G. Cherubin, C. Maple, S. N. Cohen, and A. Weller, "Synthetic data – what, why and how?" *arXiv preprint arXiv:2205.03257*, 2022.
- [4] UNECE, *Synthetic Data for Official Statistics*. United Nations, 2023. [Online]. Available: <https://www.un-ilibrary.org/content/books/9789210021708>
- [5] Y. Hu, F. Wu, Q. Li, Y. Long, G. M. Garrido, C. Ge, B. Ding, D. Forsyth, B. Li, and D. Song, "Sok: Privacy-preserving data synthesis," 2023. [Online]. Available: <https://arxiv.org/abs/2307.02106>
- [6] M. van der Schaar, B. van Breugel, T. Kyono, and J. Berrevoets, "Decaf: Generating fair synthetic data using causally-aware generative networks," in *Advances in Neural Information Processing Systems*, M. Ranzato, A. Beygelzimer, Y. Dauphin, P. Liang, and J. W. Vaughan, Eds., vol. 34. Curran Associates, Inc., 2021, pp. 22 221–22 233.
- [7] B. van Breugel and M. van der Schaar, "Beyond privacy: Navigating the opportunities and challenges of synthetic data," 2023. [Online]. Available: <https://arxiv.org/abs/2304.03722>
- [8] A. Bauer, S. Trapp, M. Stenger, R. Leppich, S. Kounev, M. Leznik, K. Chard, and I. Foster, "Comprehensive exploration of synthetic data generation: A survey," 2024. [Online]. Available: <https://arxiv.org/abs/2401.02524>
- [9] R. Shi, Y. Wang, M. Du, X. Shen, Y. Chang, and X. Wang, "A comprehensive survey of synthetic tabular data generation," 2025. [Online]. Available: <https://arxiv.org/abs/2504.16506>
- [10] P. Tiwald, I. Krchova, A. Sidorenko, M. V. Vieyra, M. Scriminaci, and M. Platzer, "Tabularargn: A flexible and efficient autoregressive framework for generating high-fidelity synthetic data," 2025. [Online]. Available: <https://arxiv.org/abs/2501.12012>
- [11] C. Dwork, A. Roth et al., "The algorithmic foundations of differential privacy," *Foundations and Trends® in Theoretical Computer Science*, vol. 9, no. 3–4, pp. 211–407, 2014.
- [12] I. Krchova, M. Platzer, and P. Tiwald, "Strong statistical parity through fair synthetic data," 2023. [Online]. Available: <https://arxiv.org/abs/2311.03000>

- [13] A. Sidorenko, M. Platzer, M. Scriminaci, and P. Tiwald, "Benchmarking synthetic tabular data: A multi-dimensional evaluation framework," 2025. [Online]. Available: <https://arxiv.org/abs/2504.01908>
- [14] I. Krchova, M. Platzer, and P. Tiwald, "Improving predictions on highly unbalanced data using open source synthetic data upsampling," 2025. [Online]. Available: <https://arxiv.org/abs/2507.16419>
- [15] scikit-learn, "RandomOverSampler documentation for randomoversampler," https://imbalanced-learn.org/stable/references/generated/imblearn.over_sampling.RandomOverSampler.html, 2011.
- [16] —, "SMOTENC documentation for smotenc," https://imbalanced-learn.org/stable/references/generated/imblearn.over_sampling.SMOTENC.html, 2011.
- [17] M. Platzer and T. Reutterer, "Holdout-based empirical assessment of mixed-type synthetic data," *Frontiers in big Data*, vol. 4, p. 679939, 2021.
- [18] MOSTLY AI, "MOSTLY AI – Quality Assurance," 2024. [Online]. Available: <https://github.com/mostly-ai/mostlyai-qa>
- [19] L. Xu, M. Skoularidou, A. Cuesta-Infante, and K. Veeramachaneni, "Modeling tabular data using conditional gan," *Advances in neural information processing systems*, vol. 32, 2019.
- [20] J. Kim, C. Lee, and N. Park, "Stasy: Score-based tabular data synthesis," in *The Eleventh International Conference on Learning Representations*, 2023.
- [21] H. Zhang, J. Zhang, B. Srinivasan, Z. Shen, X. Qin, C. Faloutsos, H. Rangwala, and G. Karypis, "Mixed-type tabular data synthesis with score-based diffusion in latent space," in *The Twelfth International Conference on Learning Representations*, 2024.
- [22] M. Gulati and P. Roysdon, "Tabmt: Generating tabular data with masked transformers," in *Advances in Neural Information Processing Systems*, A. Oh, T. Naumann, A. Globerson, K. Saenko, M. Hardt, and S. Levine, Eds., vol. 36. Curran Associates, Inc., 2023, pp. 46 245 – 46 254.
- [23] C. McCarter, "Unmasking trees for tabular data," *arXiv preprint arXiv:2407.05593*, 2024.
- [24] A. V. Solatorio and O. Dupriez, "Realtabformer: Generating realistic relational and tabular data using transformers," *arXiv preprint arXiv:2302.02041*, 2023.
- [25] M. Gueye, Y. Attabi, and M. Dumas, "Row conditional-tgan for generating synthetic relational databases," in *ICASSP 2023–2023 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. IEEE, 2023, pp. 1 – 5.
- [26] W. Pang, M. Shafieinejad, L. Liu, S. Hazlewood, and X. He, "Clavaddpm: Multi-relational data synthesis with cluster-guided diffusion models," 2024. [Online]. Available: <https://arxiv.org/abs/2405.17724>
- [27] N. Patki, R. Wedge, and K. Veeramachaneni, "The synthetic data vault," in *IEEE International Conference on Data Science and Advanced Analytics (DSAA)*, Oct 2016, pp. 399 – 410.