

PRAGMA: Revolut의 멀티 소스 बैं킹 이벤트 시퀀스용 파운데이션 모델

(PRAGMA: Revolut Foundation Model — 한국어 번역본)

Maxim Ostroukhov¹ Ruslan Mikhailov¹ Vladimir Iashin¹
Artem Sokolov¹ Andrei Akshonov¹ Vitaly Protasov¹ Dmitrii Beloborodov¹
Vince Mullin² Roman Y. Enzmann² Georgios Kolovos² Jason Renders²
Pavel Nesterov¹ Anton Repushko¹

¹Revolut Research ²NVIDIA

한국어 번역: Compendium (<https://yoon-gu.github.io/compendium/>)

현대 금융 시스템은 풍부한 경제적 신호를 담고 있는 대규모 거래(transactional) 데이터와 이벤트 수준(event-level) 데이터를 생성한다. 이 논문은 멀티 소스 बैं킹 이벤트 시퀀스(multi-source banking event sequences)를 위한 파운데이션 모델(foundation model) 계열인 PRAGMA를 제시한다. 저자들은 금융 레코드의 이산적이고 가변 길이인 성격에 맞춘 자기지도(self-supervised) 목적함수와 함께, 마스킹 모델링(masked modelling)으로 트랜스포머(Transformer) 기반 아키텍처를 대규모 이질적 बैं킹 이벤트 코퍼스 위에서 사전학습(pre-training)한다. 이렇게 얻어진 모델은 신용 평가(credit scoring), 사기 탐지(fraud detection), 라이프타임 밸류(lifetime value) 예측 같은 다양한 다운스트림 과제(downstream task)를 지원한다. 추출된 임베딩(embedding) 위에 단순한 선형 모델만 학습해도 강한 성능을 얻을 수 있고, 가벼운 파인튜닝(fine-tuning)을 더하면 성능은 더 올라간다. 폭넓은 다운스트림 평가를 통해, 저자들은 PRAGMA가 원시 이벤트 시퀀스로부터 여러 도메인에서 우수한 성능을 보이며 금융 응용을 위한 범용 표현 계층(representation layer)을 제공함을 보인다.

고지: 절대 지표는 상업적으로 민감하므로, 본 논문은 상대 개선폭만 보고한다.

모든 예시는 합성 데이터이며 실제 운영 데이터가 아니다.

1 서론

파운데이션 모델은 넓은 데이터 분포 위에서 대규모로 학습된 뒤 다양한 다운스트림 과제로 적응되는 범용 모델이다 (Bommasani et al., 2021). 이런 모델은 자연어 처리(natural language processing) (Devlin et al., 2019; Brown et al., 2020)와 컴퓨터 비전(computer vision) (Kirillov et al., 2023; Caron et al., 2021)을 크게 바꾸어 놓았지만, 멀티 소스 बैं킹 사용자 이력(multi-source banking user history)에 대한 적용은 상대적으로 거의 탐구되지 않았다. 현대의 은행과 핀테크는 카드 결제·송금 거래, 상품 사용, 인앱 내비게이션, 고객 커뮤니케이션 같은




그림 1: 10M에서 1B 파라미터까지 확장되는 단일 아키텍처가 과제별 모델을 일관되게 능가한다.

이벤트 스트림(event stream)과 더불어, 계정 보유 기간이나 플랜 같은 정적·일반화된 프로필 상태(profile state)까지 방대한 양의 데이터를 축적한다. 이런 이벤트 스트림에는 리스크 관리, 상품 분석, 운영에 중요한 신호가 담겨 있지만, 기성 언어모델 토큰화(tokenisation)와 아키텍처로는 이를 효율적으로 모델링하기 어렵다. 구조화된 레코드를 텍스트로 직렬화해서 표준 트랜스포머에 넣는 방식은 하나의 베이스라인이 될 수는 있지만, 각 필드 이름과 구분자가 여러 서브워드 토큰(subword token)으로 쪼개지기 때문에 시퀀스 길이를 크게 부풀린다. 또한 수치값은 숫자 조각으로 분해되면서 크기와 순서 정보가 사라지는데, 이 둘은 금융 추론에서 핵심적이다. 이런 한계 때문에 단순 텍스트 직렬화는 길고 이질적인 banking 사용자 이력에는 실용적이지 않다.

멀티 소스 banking 사용자 이력은 텍스트와 세 가지 점에서 다르다. 첫째, 각 이벤트는 범주형(categorical), 수치형(numerical), 자유 텍스트(free-text) 필드가 섞인 가변 길이 레코드(variable-length record)다. 둘째, 이력 길이는 롱테일(long-tail) 분포를 보이고, 시간적으로 불규칙하며, 강한 일간 및 주간 주기를 가진다. 셋째, 실제 배포는 엄격한 개인정보 및 규제 제약 아래 이뤄지므로, 무엇을 보고할 수 있는지와 어떤 피처(feature)를 특정 결정에 사용할 수 있는지가 제한된다. 이 세 문제를 동시에 처리하는 기성 아키텍처가 없기 때문에, 실무자는 보통 광범위한 피처 엔지니어링(feature engineering)이 들어간 과제별 파이프라인을 구축하게 되고, 그 결과 도메인과 상품 사이에서 통계적 강점을 공유하기가 어렵다.

기존 연구는 이 문제의 일부 단면만 다뤘다. TabTransformer와 FT-Transformer (Huang et al., 2020; Gorishniy et al., 2021) 같은 표 형식(tabular) 트랜스포머는 고정 스키마(fixed-schema) 행을 모델링하고, SASRec와 BERT4Rec (Kang et al., 2018; Sun et al., 2019) 같은 순차 추천(sequential recommendation) 모델은 아이템형 상호작용 이력을 다룬다. 금융 파운데이션 모델은 대체로 텍스트나 일반 시계열 토큰화에 집중해 왔으며 (Yang et al., 2020; Wu et al., 2023; Yang et al., 2023; Jin et al., 2024; Ansari et al., 2024), nuFormer와 TransactionGPT (Braithwaite et al., 2025; Dou et al., 2025) 같은 최근 거래 원장(transaction-ledger) 모델은 본 논문의 설정에 더 가깝다. 그러나 이런 모델들은 보통 단일 이벤트 소스만 입력받고 정적 프로필 상태를 생략하며, 좁은 과제 집합에서만 평가된다. 즉, nuFormer는 상품 추천을, TransactionGPT는 이상 탐지와 궤적 생성에 집중한다. 명시적 프로필 상태를 포함하면서 폭넓은 판별적 banking 과제로 전이되는 멀티 소스 인코더 백본은 여전히 문헌에서 비어 있는 자리다.

이 논문에서 저자들은 멀티 소스 banking 사용자 이력을 위한 인코더형 파운데이션 모델 계열인 PRAGMA를 제시한다. PRAGMA는 멀티 소스 이벤트와 정적 프로필 상태를 함께 담은 대규모 사용자 이력 코퍼스 위에서

마스킹 모델링으로 사전학습된다 (§ 2.1). 이질성을 처리하기 위해 수치형·범주형·텍스트형 필드에 맞는 타입별 값 인코딩(value encoding)을 포함한 키-값-시간 토큰화(key-value-time tokenisation) 방식을 적용한다 (§ 2.2). 이렇게 얻어지는 백본(backbone)은 프로필 상태와 이벤트를 각각 처리하는 두 개의 인코더(encoder) 가지(branch)를 두고, 그 출력을 히스토리 인코더(history encoder)가 융합하는 구조다 (§ 2.3).

저자들이 인코더 전용·양방향(encoder-only, bidirectional) 설계를 택한 이유는, 목표가 개방형 생성(open-ended generation)이 아니라 판별적(discriminative) 금융 과제를 위한 전이 가능한 표현(transferable representation)이기 때문이다. 마스킹 모델링은 각 토큰(token)이 과거와 미래 맥락 모두에 어텐션(attention)을 줄 수 있게 해 주며 (Devlin et al., 2019), 부분적으로만 관측된 이벤트 레코드를 복원하고 전체 이력으로부터 레코드 수준 표현을 학습하는 데 특히 유용하다. 사전학습 이후 PRAGMA는 두 가지 상보적인 방식으로 효율적으로 적용될 수 있다 (§ 3.1). 임베딩 프로브(embedding probe) 설정에서는 백본을 고정한 채, 추출된 임베딩 위에 가벼운 헤드만 학습한다. LoRA 파인튜닝 설정에서는 Low-Rank Adaptation(LoRA) (Hu et al., 2022)을 적용해 소수의 파라미터만 갱신함으로써, 대부분의 백본을 과제 간 공유하면서도 빠른 특화를 가능하게 한다.

저자들은 신용 평가, 사기 탐지, 커뮤니케이션 인게이지먼트(communication engagement), 정기 거래 탐지(recurrent transaction detection), 라이프타임 밸류 예측 등 폭넓은 도메인을 포함하는 내부 다운스트림 벤치마크 위에서 PRAGMA를 평가한다 (§ 3.2). 평가된 도메인 전반에서, PRAGMA는 강한 과제별 베이스라인을 일관되게 능가하면서 수작업 피쳐(hand-crafted feature)의 필요성을 줄인다(그림 1). 또한 시퀀스 패킹(sequence packing)과 동적 배치(dynamic batching)를 포함해, 길고 변동성이 큰 사용자 이력 위에서 PRAGMA를 효율적으로 학습시키기 위한 엔지니어링 선택들도 함께 기술한다 (§ 2.4).

저자들의 기여는 다음과 같다.

- 멀티 소스 बैं킹 사용자 이력을 위한 인코더형 파운데이션 모델 계열 PRAGMA를 제안한다. 10 M부터 1 B 파라미터까지 확장되며, 저자들이 아는 한 소비자 बैं킹 이벤트 시퀀스용으로 공개된 인코더 백본 중 가장 크다. 본 아키텍처는 키-값-시간 토큰화 방식과, 이질적 금융 레코드를 위한 두 가지(branch) 설계를 결합한다. 즉, 프로필 상태 인코더와 이벤트 인코더가 각각 입력을 처리하고 그 결과를 히스토리 인코더가 받는다.
- 마스킹 모델링, 시퀀스 패킹, 동적 배치에 기반해 길고 불규칙한 बैं킹 사용자 이력을 위한 효율적 사전학습 레시피를 기술하고, 사전학습 백본 위에서 LoRA 파인튜닝을 하는 것이 처음부터의 전체 학습과 일관되게 맞먹거나 그 이상임을 보인다.
- 단일 사전학습 백본을 여섯 개의 다양한 다운스트림 과제(신용 평가, 사기 탐지, 라이프타임 밸류, 커뮤니케이션 인게이지먼트, 정기 거래 탐지, 상품 추천)에 걸쳐 평가한다. 이는 보통 한두 과제에 한정되었던 기존 거래 원장 모델보다 훨씬 넓은 과제 범위이며, PRAGMA는 강한 과제별 베이스라인을 일관되게 능가하면서 수작업 피쳐의 필요성을 줄인다.

2 Pre-training




그림 2: 이벤트 타임라인 개요. 계정이 생성된 이후, 사용자들은 시간이 흐르며 거래, 인앱 내비게이션, 커뮤니케이션 등 플랫폼 상호작용 시퀀스를 만들어낸다. 저자들은 지정된 평가 시점까지의 이벤트 이력을 모은다. 이런 순차적 이벤트 외에, 그 시점에서의 레코드 상태를 기술하는 맥락 속성(예: 멤버십 플랜이나 서비스 지역)도 함께 담는다. 이벤트와 속성 모두 동일한 표현을 공유한다 — 타임스탬프와 키-값 쌍 집합(예: Type: card_payment, Channel: email)이다. 그림에 표시된 모든 값은 합성 데이터이며 예시일 뿐이다.

2.1 데이터셋

저자들의 목표는 다양한 이벤트 수준 신호를 인코딩하고 폭넓은 다운스트림 과제로 전이되는 파운데이션 모델을 만드는 것이다. 저자들의 데이터셋은 레코드 수준(record-level)으로 구조화되어 있으며, 각 관측은 평가 시점(evaluation point)과 연결된 가명화(pseudonymised) 이벤트 이력(event history)을 나타낸다. 그림 2에서 보듯이, 저자들은 이벤트 이력을 맥락 속성(contextual attribute)과 함께 고려한다. 이 접근은 모델이 순차적 패턴(sequential pattern)과 시간 불변(time-invariant) 피처(예: 계정 통화)를 동시에 반영할 수 있게 해 준다.

본 연구에서 사용된 모든 데이터는 완전 익명화되어 있으며 개인 식별 정보를 포함하지 않는다. 저자들은 사전 학습 데이터셋을 111개국에 걸친 26M 사용자 레코드로 구성하며, 이는 24B 이벤트와 207B 토큰을 누적한다.

2.1.1 이벤트 이력

표준 플랫폼 사용은 계정 충전, 결제, 인앱 내비게이션, 서비스 커뮤니케이션 등 다양한 서비스에 걸쳐 이벤트 스트림을 생성한다. 이렇게 집계된 이벤트 이력은 다양한 분석·예측 과제를 뒷받침할 수 있는 인구 수준 패턴을 담아낸다. 하나의 이벤트는 생성 타임스탬프와 키-값 쌍 집합으로 정의된다(예: Direction: out). 저자들은 거래(transactions), 앱(app), 트레이딩(trading), 커뮤니케이션(communication)으로 느슨하게 묶을 수 있는 폭넓은 소스 타입에서 이벤트를 가져오며, 이들은 다운스트림 과제에 미칠 기대 영향이 큰 것을 기준으로 선정되었다. 이벤트 스키마는 소스 타입별로 다르며 서로 다른 키 집합을 갖는다(예: Symbol 키는 트레이딩 이벤트에만 있다). 익명화·비식별화와 표준 자격 기준 외에는, 운영 환경에서 발견되는 이질성을 모델이 온전히 포착할 수 있도록 이상치 제거나 어휘 가지치기 같은 추가적인 통계 필터링이나 전처리를 이벤트 스트림에 적용하지 않는다.

2.1.2 프로필 상태

이벤트 이력에 더해, 저자들은 잔고 분위(balance quantile), 플랜, 보험 상태, 서비스 지역 등 일반적인 맥락 속성을 함께 포함한다. 이 속성들은 이벤트 이력만으로는 빠지기 쉬운 유용한 맥락을 제공한다. 프로필 상태는 이벤트와 비슷한 형식의 기술적 키-값 쌍 집합이며(예: Plan: metal), 지정된 평가 시점(또는 사전학습에서는 컷오프 날짜)으로 타임스탬프가 찍힌다.

활동량이 매우 큰 사용자는 흔히 수만 건의 상호작용을 만들어내 계산 자원의 한계를 넘어선다. 저자들은 이를 고정 컨텍스트 창(context window)으로 잘라내어(truncation) 처리한다 (§ 2.3.5). 그러나 이런 절단은 계정 연령처럼 유용한 신호를 담은 초기 역사적 이정표(milestone)를 잘라낼 위험이 있다. 이를 보완하기 위해 저자들은 프로필 상태에 라이프롱 이벤트(life-long events)를 덧붙인다. 일반 프로필 속성과 달리, 이 키-값 쌍들은 각각 최초 발생 시각을 기록하는 개별 타임스탬프를 갖는다(예: Lifelong: first_topup at 20-11-02 12:09:04). 이 타임스탬프는 평가 시점까지의 시간 거리를 계산하는 데 쓰이며, 모델이 역사적 이정표의 시점 정보를 인코딩할 수 있게 해 준다.

2.1.3 사전학습 시간 범위

견고하고 일반화되는 모델을 만들려면 역사적 커버리지를 극대화하는 것과 데이터의 관련성(relevance)을 유지하는 것 사이에서 섬세한 균형이 필요하다. 즉, 사전학습에 쓸 최적 시간 범위를 결정하는 일은 이벤트 다양성, 분포 변화(distribution shift), 계산 효율성 사이의 여러 트레이드오프(trade-off)를 풀어내는 작업이다.

첫째, 사용 가능한 전체 데이터셋의 모든 이벤트를 그대로 포함하는 것은 비실용적이며 최적이지 않은 경우가 많다. 오래된 이벤트는 추론 시점에는 더 이상 유효하지 않은 과거 패턴, 상품 기능, 시스템 동역학을 반영할 수 있다. 이런 불일치는 분포 어긋남(distribution mismatch)을 만들어내고, 결과적으로 진부한 과거 사례에서 배포 환경의 진화하는 행동 양상으로 일반화하기 어렵게 만든다. 또한 매우 긴 시간 범위에서 매우 이질적인 이벤트를 포함시키면 사전학습 과제 자체가 어려워지고 수렴이 느려질 수 있다. 둘째, 다운스트림 응용은 사전학습에 사용된 범위보다 훨씬 이전 또는 훨씬 이후 시점에 발생한 이벤트에 대해 예측해야 할 수 있다. 모델이 최근 패턴과 덜 흔한 과거 패턴 양쪽 모두에서 충분한 다양성을 보지 못했다면, 이런 분포 외(out-of-distribution) 입력에서 성능이 떨어질 수 있다. 마지막으로, 트랜스포머 아키텍처의 유효 컨텍스트 길이는 모델 설계와 하드웨어 제약에 의해 제한된다.

이런 점들을 종합해, 저자들은 사전학습용으로 2023년부터 2025년에 걸친 25개월 시간 범위를 선택하며, 이는 충분한 이벤트 커버리지, 최근성, 분포 일관성, 그리고 다룰 수 있는 시퀀스 모델링 사이의 균형을 맞춘 것이다.

2.2 토큰화

모든 것을 텍스트로 다루는 표준 LLM과 달리, 금융 파운데이션 모델은 표 형식(tabular) 데이터의 구조적 성격과 이질성을 보존해야 한다. 저자들은 이 문제를, 입력 토큰의 의미 구성요소가 분리된(disentangled) 임베딩 공간을 도입해 해결한다.

그림 3에서 볼 수 있듯, 저자들은 표 형식 이벤트 데이터의 일반 표준에 따라 (Braithwaite et al., 2025) 각 데이터 포인트를 세 가지 구성요소로 표현한다 — 의미 타입(키), 값, 시간 좌표. 예를 들어, Channel: email at 24-04-07




그림 3: 토큰화 개요. 원시 이벤트 레코드는 시간 좌표, 의미 타입(키), 값으로 분해된다. 키는 항상 하나의 토큰으로 표현되고, 값은 타입별 토큰화를 따른다 — 수치값은 백분위 버킷으로, 범주값은 하나의 토큰으로, 텍스트 값은 서브워드 토큰들로 분해된다. 따라서 어떤 키는 여러 개의 값 토큰으로 펼쳐지기도 한다(예: Description → met, al, plan). 시간은 직전 이벤트까지의 로그-초(log-seconds)와, 타임스탬프에서 유도된 달력·시간 피처로 함께 인코딩된다. 프로필 상태는 이벤트 레코드와 비슷하게 인코딩된다.

19:20:18은 각각 키, 값, 시간 좌표로 매핑된다. 이는 모델이 필드의 의미와 값을 구분해서 다루도록 보장하면서, 이벤트의 시간 순서까지 함께 인코딩한다. 이어서 세 구성요소가 어떻게 토큰화되는지 차례로 설명한다.

의미 타입(키). 의미 타입 임베딩은 모델이 각 필드의 의미를 학습하고 그 값을 맥락에 맞게 해석할 수 있도록 해 준다. 저자들은 모든 의미 타입(키)을 단일 토큰으로 토큰화하며, 이벤트와 프로필 상태의 의미 타입을 동일한 방식으로 인코딩한다. 그 결과 약 60개 토큰 규모의 어휘가 만들어진다.

값. 저자들은 값의 다양성을 수치형, 범주형, 텍스트형의 세 가지 값 타입으로 다룬다. 수치값은 백분위(percentile) 버킷으로 매핑되며, 버킷 경계는 학습 데이터에서 학습되고 0을 위한 별도 버킷이 추가되며, 각 버킷마다 토큰을 하나씩 할당한다. 범주형과 텍스트형의 구분은 카디널리티 임계화(cardinality thresholding)로 정해진다 — 고유 값 개수가 미리 정한 임계 미만인 문자열 필드는 범주형으로, 그보다 큰 필드는 텍스트형으로 다룬다. 범주값은 가맹점 카테고리 코드(MCC) 같이 자주 등장하는 값이 여러 토큰으로 쪼개지지 않도록 모든 텍스트 필드에서 수동으로 선정되며, 마찬가지로 단일 토큰으로 표현된다. 텍스트 필드의 값은 BPE(Byte-Pair Encoding) 스타일 서브워드 토큰라이저(subword tokeniser)로 토큰화되며 (Sennrich et al., 2016), 드문 미관측 조각을 위해 [UNK] 토큰이 따로 예약된다. 값 전체 어휘 크기는 약 28k 토큰이다.

시간 정보. 저자들은 시간을 두 가지 방식으로 인코딩한다. 첫째, 가장 최근 이벤트로부터 경과한 시간을 초 단위로 계산한다. 이어서 부드러운 로그 변환 $8 \cdot \ln(1 + t/8)$ 을 적용해, 라이프로그 이벤트의 동적 범위를 압축하면서도 최근 이벤트에 대해서는 고해상도의 선형 세분성을 유지한다. 이는 극단적인 시간 간격 때문에 위치 임베딩(positional embedding)에서 발생할 수 있는 앨리어싱(aliasing)을 막으면서도, 가까운 이벤트의 순서 정밀도는 희생하지 않게 해 준다. 둘째, 일간·주간 시간 주기를 포착하기 위해, 각 이벤트 타임스탬프를 시각의 시(hour of day), 요일(day of week), 일자(day of month)로 분해하고, Gorishniy et al. (2022)와 비슷한 주기 함수로 임베딩한다. 다만 주기는 학습되는 대신 알려진 달력 주기로 고정한다. 달력 피치는 이벤트 이력 항목에만 적용된다. 일회성 라이프로그 이벤트에서는 로그-초 인코딩만으로도 관련 시간 신호를 충분히 담을 수 있어, 주기 패턴이 덜 중요하기 때문이다.




그림 4: PRAGMA 백본 개요. 각 사용자 레코드는 시간순 이벤트 이력과 프로파일 상태로 표현되며, 모든 필드는 의미 타입(키), 하나 이상의 값, 그리고 시간 좌표로 분해된다. 키와 값은 공유 록업 테이블에서 임베딩되며, 값 토큰에는 필드 내(within-field) 위치 임베딩이 더해진다. 프로파일 상태 인코더는 프로파일 상태 x_a 를, 라이프롱 이벤트로부터의 시간 t_a 를 RoPE로 인코딩하며 [USR] 임베딩 z_a 로 매핑한다. 한편 이벤트 인코더는 각 이벤트의 토큰 x_e 를 독립적으로 [EVT] 임베딩 z'_e 로 매핑하고 달력 피쳐 z_t 를 더한다. 그 다음, 히스토리 인코더가 직전 이벤트까지의 시간 t_e 를 RoPE로 인코딩하면서 시퀀스 $z = [z_a : z_e]$ 를 맥락화하여 사용자 레코드 표현 z_h 를 만들어낸다.

2.3 모델 아키텍처

PRAGMA는 인코더 전용 트랜스포머로서, 이벤트 이력과 맥락 속성을 입력받아 레코드 수준의 밀집(dense) 임베딩을 출력한다. 이 모델은 마스킹된 입력 토큰을 복원하는 마스킹 모델링(masked modelling, MLM) 목적함수(objective)로, 대규모이면서 다양성이 큰 데이터셋 위에서 학습된다. 사전학습이 끝나면 백본 역할을 하며, 다양한 다운스트림 과제에 대해 모델 파라미터의 2-4%만 갱신하는 소규모 파인튜닝으로 적용시킬 수 있다. PRAGMA의 개요는 그림 4에 제시되어 있다.

PRAGMA는 10 M, 100 M, 1 B 파라미터의 모델 계열로 파라미터화되어 있어, 운영 예산과 제약에 따라 선택할 수 있다. 아키텍처 계열의 세부 사항은 표 1에 제시되어 있다. 모든 사이즈 변형은 GELU 활성화 함수(activation function) (Hendrycks et al., 2016), 사전 정규화(pre-norm) 레이어 정규화(layer normalisation) (Xiong et al., 2020), 0.1의 드롭아웃(dropout) (Srivastava et al., 2014)을 사용한다.

모델은 세 개의 주요 블록으로 구성된다 — 프로파일 상태 인코더, 이벤트 인코더, 히스토리 인코더. 첫째, 프로파일 상태 토큰은 프로파일 상태 인코더가 처리한다. 둘째, 프로파일 상태와 마찬가지로 각 이벤트는 이벤트 인코더에서 독립적으로 인코딩된다. 마지막으로, 프로파일 상태 인코더와 이벤트 인코더의 출력을 연결한 뒤 히스토리 인코더에 통과시켜 출력을 만든다. 단계에 따라 최종 출력은 사전학습 시 MLM 헤드(head), 파인튜닝 시 분류 헤드(classification head), 또는 임베딩 프로브(embedding probe)에서 그대로 사용된다.

모델	파라미터	Width		Depth			
		d_{model}	d_{ffn}	Profile	Event	History	Heads
PRAGMA-S	10 M	192	768	1	5	2	3
PRAGMA-M	100 M	512	2048	3	16	6	8
PRAGMA-L	1 B	1024	4096	9	45	18	16

표 1: PRAGMA 모델 계열. PRAGMA는 모델 폭(d_{model} , d_{ffn}), 프로파일 상태·이벤트·히스토리 인코더의 깊이, 그리고 어텐션 헤드 수를 함께 키우면서 10 M, 100 M, 1 B 파라미터의 세 변형으로 확장된다.

2.3.1 토큰 임베딩

프로파일 상태와 이벤트 토큰은 동일한 방식으로 임베딩된다. 다중값을 갖는 필드(예: Description)에서는, 키토큰이 각 값에 맞춰 복제되어 총 n 개의 키-값 쌍이 만들어진다. 공유된 단일 임베딩 테이블 E 가 각 키와 값을 d 차원 벡터로 매핑하며, 두 임베딩은 합산된 뒤 정적 사인/코사인 위치 인코딩(PosEmb) (Vaswani et al., 2017)으로 보강된다:

$$x = \text{PosEmb}(E(k) + E(v)), \quad x \in \mathbb{R}^{n \times d}. \quad (1)$$

위치 인덱스는 필드 사이가 아니라 필드 안에서의 값 위치를 가리킨다 — 예컨대, Currency의 값 eur은 위치 0을, Description의 세 값 토큰 (met, al, plan)은 위치 (0, 1, 2)를 받는다(그림 3 참조). 저자들은 사용자(프로파일) 임베딩을 $x_a \in \mathbb{R}^{n_a \times d}$, 이벤트 임베딩을 $x_e \in \mathbb{R}^{n_e \times d}$ 로 표기한다. 인코더 전용 트랜스포머의 일반 관행을 따라 (Devlin et al., 2019; Dosovitskiy et al., 2021), 학습 가능한 [USR](또는 [EVT]) 토큰을 각 시퀀스 앞에 붙인다(그림 4).

2.3.2 프로파일 상태 인코더

프로파일 상태 인코더는 양방향 트랜스포머다. 입력은 프로파일 상태 토큰 $x_a \in \mathbb{R}^{n_a \times d}$ 와 이에 대응하는 시간 좌표 $t_a \in \mathbb{R}^{n_a}$ 이며, 각 항목은 해당 라이프로그 이벤트로부터의 로그-초를 담는다(라이프로그이 아닌 쌍은 0). t_a 는 RoPE (Su et al., 2024)로 인코딩한다. 이 위치 임베딩은 § 2.3.1에서 다룬 값 수준 위치 임베딩과 분리(disentangle)해, 의미적·스케일적 불일치를 피한다. 출력은 프로파일 상태 임베딩 시퀀스 $z_a \in \mathbb{R}^{n_a \times d}$ 이다. [USR] 토큰에 해당하는 첫 원소를 히스토리 인코더로 전달하며, 표기 단순화를 위해 이를 $z_a \in \mathbb{R}^{1 \times d}$ 로 부른다.

2.3.3 이벤트 인코더

이벤트 인코더는 프로파일 상태 인코더와 비슷한 양방향 트랜스포머다. 입력은 이벤트 이력 $x_e = (x_{e,1}, x_{e,2}, \dots, x_{e,n_e})$ 이며, 각 원소는 서로 다른 수의 토큰 임베딩을 갖고($x_{e,i} \in \mathbb{R}^{n_i \times d}$), 이력 안의 다른 모든 이벤트와 독립적으로 처리된다. 이 모듈은 각 이벤트에 대해 토큰 수준의 임베딩 시퀀스 $\hat{z}_e$ 를 출력하며, 이 출력은 사전학습 시 MLM 헤드가 사용한다. 프로파일 상태 인코더와 마찬가지로, 각 이벤트의 [EVT] 토큰에 해당하는 첫 토큰을 그 이벤트의 집계 표현 $z'_e \in \mathbb{R}^{n_e \times d}$ 으로 선택한다.

달력 피쳐(시각의 시, 요일, 일자) $x_t \in \mathbb{R}^{n_e \times 3}$ 는 사인·코사인 라디안으로 변환된 뒤 두 개의 MLP 층으로 임베딩되어 $z_t \in \mathbb{R}^{n_e \times d}$ 가 된다. 그 다음, 이 임베딩된 달력 피쳐를 이벤트 인코더 출력에 더한다 — $z_e = z'_e + z_t$.

2.3.4 히스토리 인코더

히스토리 인코더는 다른 두 인코더와 비슷한 양방향 트랜스포머다. 입력은 프로필 상태와 달력 피처가 더해진 이벤트의 집계 표현을 이은 시퀀스 $z = [z_a : z_e] \in \mathbb{R}^{(1+n_e) \times d}$, 그리고 대응하는 시간 좌표 $t_e \in \mathbb{R}^{1+n_e}$ 이며, 각 항목은 이력 안에서 가장 최근 이벤트까지의 로그-초를 담는다(z_a 자리는 0). 프로필 상태 인코더와 마찬가지로, 위치 정보 인코딩에는 RoPE를 사용한다. 출력은 임베딩 시퀀스 $z_h \in \mathbb{R}^{(1+n_e) \times d}$ 이며, $z_{h,0}$ 은 [USR]에, $z_{h,1}, \dots, z_{h,n_e}$ 는 [EVT] 토큰들에 해당한다. z_h 는 사전학습 시 MLM 헤드, 그리고 다운스트림 프로브에 사용된다.

2.3.5 학습

사전학습 목적함수. PRAGMA는 BERT (Devlin et al., 2019)를 따라 MLM 목적함수로 사전학습된다 — 이벤트 입력 토큰의 임의 부분집합을 마스킹하고, 모델은 원래 토큰을 복원한다. 각 마스킹된 토큰에 대해, MLM 헤드는 세 개의 d 차원 벡터를 이어붙인 입력을 받는다 — $\hat{z}_e$ 안에서 그 토큰 위치에 해당하는 이벤트 인코더 출력(이벤트 내 지역적 맥락), 대응되는 [EVT] 위치의 히스토리 인코더 출력 $z_{h,i}$ (이벤트 간 맥락), 그리고 [USR] 위치의 히스토리 인코더 출력 $z_{h,0}$ (사용자 수준 맥락). 이 $3d$ 차원 표현은 다시 d 차원으로 사영된 뒤, 임베딩 테이블과의 매칭을 통해 logit으로 만들어진다. 학습 손실은 라벨 스무딩(label smoothing)이 적용된 교차 엔트로피(cross entropy)이다 (Szegedy et al., 2016).

마스킹 전략. 마스킹 전략은 세 가지 경로를 결합한다 — 표준적인 토큰 단위 마스킹(15% 확률), 모델이 이벤트 전체를 복원하게 하는 이벤트 단위 마스킹(10%), 그리고 선택된 키의 모든 값을 마스킹하여 키와 맥락이 주어졌을 때 값을 예측하게 하는 의미 타입(키) 단위 마스킹(10%). 사전학습 동안에는, 선택된 위치 중 일부를 [MASK] 대신 [UNK]로 바꾼다. [UNK] 위치는 MLM 목적함수에서 제외되어 그라디언트를 받지 않으므로, 사실상 입력 드롭아웃의 한 형태로 작동한다. 이는 더 강한 변형(corruption) 아래에서도 원래 값을 복원하도록 학습시키고, 추론 시에는 등장하지 않는 [MASK]에 대한 의존을 줄여 준다.

다운스트림 적용. PRAGMA는 두 가지 다운스트림 적용 모드를 지원한다. **임베딩 프로브 모드**에서는 히스토리 인코더가 만들어 낸 레코드 수준 표현을 고정된 피쳐 벡터로 추출한 뒤, 그 위에 가벼운 선형 프로브를 학습한다. **LoRA 파인튜닝 모드**에서는 모델 가중치(어텐션과 피드포워드 사영(projection))의 작은 일부(약 2–4%)를 Low-Rank Adaptation (Hu et al., 2022)으로 갱신한다. 이는 사전학습 백본을 거의 그대로 동결시켜 파국적 망각(catastrophic forgetting)의 위험을 줄여 준다.

2.4 학습 인프라

24B 사용자 이벤트에 걸친 207B 토큰으로 PRAGMA를 사전학습하는 일은 몇 가지 엔지니어링 과제를 동반한다. 데이터의 이질적이고 테이블 구조적인 성격은, 그에 맞춘 저장·배치·절단 전략을 요구한다. 저자들은 아래에서 각 항목을 차례로 기술한다.

데이터 저장. 사전학습 코퍼스는 2단계 구조로 저장된다 — **사용자 인덱스(user index)**(각 사용자를 그 사용자의 토큰화된 프로필 상태와 사용자별 토큰 통계로 매핑하는 LMDB 기반 키-값(key-value) 저장소)와, **이벤트 샤드(shard)** 모음(이벤트 개수로 파티셔닝(partitioning)된 Parquet 파일들로, 각 파일에는 동일한 이벤트 개수를 가진

사용자만 들어 있다). 이 레이아웃은 워커가 이벤트 샤드를 독립적으로 스트리밍하면서 프로필 상태는 필요할 때만 조회하도록 해 준다.

배치. 각 학습 샘플은 완전한 이벤트 이력과 그에 대응되는 프로필 상태 토큰으로 구성된다. 이벤트 이력 길이는 몇 건에서 수천 건까지 크게 변동하므로, 패딩 기반 배치를 단순히 적용하면 대부분의 연산이 패딩 토큰에 낭비될 것이다. 이벤트 개수로 레코드를 샤딩하면 로딩 단계에서 디스크 임의접근이 줄고, 한 배치 안의 이벤트 시퀀스 길이가 균일해진다. 결과적으로 히스토리 인코더는 들쭉날쭉하거나 패딩된 차원이 없는 직사각 텐서 위에서 작동한다. 저자들은 GPU 메모리에 들어맞는 고정 토큰 예산을 갖는 동적 배치(dynamic batching)를 사용한다 — 같은 샤드의 레코드를 예산이 찰 때까지 그리디하게 채워 넣는 방식이다.

시퀀스 패킹. 한 배치 안에서도 개별 이벤트의 토큰 수는 여전히 다르다. 저자들은 가장 긴 이벤트에 맞춰 모든 이벤트를 패딩(padding)하는 대신, 모든 이벤트 토큰을 평탄(flat) 버퍼에 패킹하고 가변 길이(varlen) 어텐션 커널(kernel) (Dao et al., 2022)로 처리해, 이 단계에서는 서로 다른 이벤트의 토큰이 서로 어텐션하지 않도록 한다. 샤드 기반 배치와 결합하면, 이는 이벤트 축과 토큰 축 양쪽의 패딩 오버헤드를 모두 제거한다. 패딩된 베이스라인과 비교했을 때, 시퀀스 패킹과 동적 배치를 함께 쓰면 데이터셋의 시퀀스 길이 분포에 따라 2–5×의 처리량 향상이 나타난다.

절단. 고정 컨텍스트 길이에서 메모리 소비를 제한하기 위해, 저자들은 패킹 전에 두 단계의 절단을 적용한다. 이벤트 단계에서는 각 개별 이벤트를 최대 24개 토큰으로 자르며, 이는 전체 이벤트의 0.01%에만 영향을 준다. 프로필 상태 단계에서는 정적 프로필 상태 시퀀스를 최대 200개 토큰으로 자른다. 이벤트가 0인 사용자는 폐기하고, 6,500개 이벤트를 초과하는 사용자는 가장 최근 이벤트들을 남기는 방식으로 서브샘플링하여 시간 최근성(temporal recency)을 보존한다.

사전학습 컴퓨트. 세 모델 변형은 모두 bf16 혼합정밀도(mixed precision)와, Muon 옵티마이저(optimizer)를 AdamW와 결합한 설정으로 학습되었다 (Loshchilov et al., 2019; Jordan, 2024; Liu et al., 2025). PRAGMA-S(10M 파라미터)와 PRAGMA-M(100M)은 16× NVIDIA H100 GPU에서, PRAGMA-L(1B)은 32× NVIDIA H100 GPU에서 학습되었다. 가장 작은 변형은 약 2일 만에 수렴한 반면, 100M와 1B 모델은 각각 약 2주의 벽시계 시간을 필요로 했다.

3 Evaluation

상업적 민감성 때문에, 저자들은 다운스트림 절대 지표를 보고하지 않고 모든 결과를 과제별 기준 대비 상대 변화로 표기한다. 본 논문 전반에서 상대 성능은 $(x/\text{baseline} - 1)\%$ 로 계산되며, 여기서 x 는 평가 대상 방법의 점수다.

3.1 평가 프로토콜

저자들은 PRAGMA를 주로 다운스트림 과제에 대한 임베딩 프로빙(embedding probing)과 Low-Rank Adaptation(LoRA) (Hu et al., 2022) 파인튜닝으로 평가한다.

3.1.1 임베딩 프로빙

임베딩 프로빙은 LoRA 파인튜닝까지 가지 않고도 실험 반복을 빠르게 돌릴 수 있게 해 준다 — 예컨대 새 피처가 기대만큼 이득을 가져다주는지 가늠하거나, 사전학습 실행 후 추가 평가를 위한 체크포인트를 고르거나, 어떤 과제를 다운스트림 타겟으로 탐색할 가치가 있는지 결정하는 데 쓰인다. 임베딩은 히스토리 인코더 출력(z_h)에서 추출한다.

프로빙 분석에서 저자들은 [USR] 토큰, 마지막 [EVT] 토큰, 그리고 둘의 결합을 표준 선형 프로브로 평가한다. 미리 정의된 학습/검증/테스트 분할(train/validation/test split)이 있는 다운스트림 과제에서, 먼저 각 레코드를 동결된(frozen) 인코더로 통과시켜 고정 크기 표현을 얻고, 학습 분할에서 선형 프로브(linear probe; 로지스틱 또는 선형 회귀)를 학습한다. 프로브 성능은 하이퍼파라미터(hyper-parameter) 선택에 강건(robust)하기 때문에, 프로브 적합은 보통 수 분이면 끝난다. 저자들의 아키텍처가 본질적으로 “pre-norm”이므로, 프로브 적합 전에 임베딩에 표준 스케일링을 적용한다. 프로브 학습에는 L-BFGS 옵티마이저 (Liu et al., 1989)가 가장 좋은 결과를 내고 빠르게 수렴함을 확인했다.

참고로, 차원이 낮은 임베딩(예: 192차원)에서는 그래디언트 부스팅 결정 트리(Gradient Boosted Decision Trees, GBDT)도 잘 작동하지만, 과제별 하이퍼파라미터 튜닝이 필요하고 적합 시간이 더 길어, 빠른 모델 평가용으로는 선형 프로빙보다 덜 실용적이다.

3.1.2 LoRA를 이용한 다운스트림 적응

PRAGMA 백본을 다운스트림 과제에 특화시키기 위해, 저자들은 단지 2–4%의 파라미터 오버헤드만 추가하는 Low-Rank Adaptation(LoRA)을 사용한다. 이 설정에서는 사전학습된 가중치를 과제별 목적함수에 맞춰 파인 튜닝함으로써, 일반 표현 학습과 다운스트림 요구 사이의 간극을 메운다.

LoRA는 일반 관행을 따라 인코더 레이어 안의 QKV 사영과 MLP 레이어에 적용한다 (Hu et al., 2022; Dettmers et al., 2023). 모든 실험에서 기본값으로 $\text{rank} = 8$, $\alpha = 8$ 을 쓰지만, 더 작은 데이터셋에서는 {4, 8, 16} 범위로 rank를 스위칭한다. LoRA 파인튜닝에는 Adam 옵티마이저 (Kingma et al., 2015)를 사용하며, 학습은 보통 사전학습 벽시계 시간의 약 1/8을 쓰고, 데이터셋 크기에 따라 12 시간에서 며칠 사이에 수렴한다.

3.1.3 다운스트림 데이터셋 준비

각 다운스트림 과제에 대해 저자들은 고유 식별자를 얻는다 — 보통 프로필 id와 평가 시점으로 구성된다. 다음으로, 평가 시점 직전까지의 이벤트 이력과 프로필 속성을 모은다. 각 다운스트림 과제에 대해 미리 정해진 폴드와 분할을 따른다. 다운스트림 데이터셋 수집 절차는 사전학습 데이터셋의 절차를 그대로 반영한다.

3.2 다운스트림 과제

신용 평가(Credit Scoring). 사용 첫 12개월 안에 채무 불이행(default)이 발생할 확률을 예측해 리테일 신청에 대한 신용 위험(credit risk)을 평가하는 과제다. 다운스트림 데이터셋은 여러 해에 걸쳐 있으며 레코드가 다양하다. 이 과제는 소수 클래스(minority class)가 있는 이진 분류(binary classification) 문제로 정식화되며, 오프라인 지표로 ROC-AUC와 PR-AUC를 사용한다.

커뮤니케이션 인게이지먼트(Communication Engagement). 신용 신청을 도중에 중단한 사용자에게 발송된 재인게이지먼트(re-engagement) 커뮤니케이션을 사용자가 열지 여부를 예측하는 과제다. 이 행동은 신청 재개와 궁극적인 대출 실행으로 이어지는 깔때기(funnel)의 상단 대리 지표(proxy) 역할을 한다. 이 과제의 두드러진 점은 표본 크기가 매우 제한적이라는 것이며, 그래서 모델은 극히 적은 데이터에서 미묘한 이벤트 수준 신호를 잡아내야 한다. 이 과제는 이진 분류 문제로 정식화되며, 주된 오프라인 지표는 ROC-AUC와 PR-AUC이다.

외부 사기(External Fraud). 이는 이진 분류 문제로 정식화된 대표적인 사기 탐지 사용 사례다. 주된 오프라인 지표로 정밀도(precision)와 재현율(recall)을 사용해 성능을 평가한다.

상품 추천(Product Recommendation). 사용자가 특정 커뮤니케이션(예: 이메일 또는 푸시 알림)을 받은 조건에서 가까운 미래에 어떤 상품을 채택할 가능성이 있는지 예측하는 과제다. 핵심 난점은 커뮤니케이션의 맥락적 영향을 함께 고려하면서, 여러 상품에 대한 전환 성향(conversion propensity)을 동시에 모델링하는 것이다. 이 과제는 다중 라벨 분류(multilabel classification) 문제로 정식화되며, 모델은 포트폴리오 내 각 상품에 대해 독립적인 전환 확률을 출력한다. 성능은 평균 정밀도 평균(mean average precision, mAP)을 주요 오프라인 지표로 평가한다.

정기 거래(Recurrent Transactions). 주어진 거래가 다음 달에 반복될 정기 구독에 해당하는지 예측하는 과제다. 핵심 난점은 제한된 과거 신호 안에서 진짜 반복 패턴과 불규칙·일회성 결제를 구분해 내는 것이다. 이 문제는 이진 분류 과제로 정식화되며, 클래스 불균형을 반영하고 클래스 간 성능 균형을 맞추기 위해 매크로 평균 F_1 -score로 성능을 평가한다.

라이프타임 밸류(Lifetime Value, LTV). LTV 과제는 사용자가 양()의 매출총이익(gross profit)을 발생시킬 확률을 평가하는 것으로, 이진 분류 문제로 정식화된다. LTV 데이터셋의 두드러진 특징은 사용자들의 이벤트 이력이 짧다는 점이다(예: 몇 주). 반면 예측 지평(prediction horizon)은 보통 6개월 이상이다. 주된 오프라인 지표는 ROC-AUC와 PR-AUC이다.

3.3 주요 결과

표 2에 제시된 결과는, 대부분의 파라미터를 과제 간 공유함에도 불구하고 PRAGMA가 평가된 거의 모든 도메인에서 기존 과제별 베이스라인(baseline)을 일관되게 능가함을 보여준다. 가장 두드러진 향상은 영향이 큰 과제들의 정밀도-재현율(precision-recall) 지표에서 관찰된다 — 신용 평가에서 PR-AUC가 130.2% 증가했고, 커뮤니케이션 인게이지먼트에서 79.4% 증가했다. 이는 PRAGMA가 전통 모델이 어려워하는 저빈도·고가치 신호를 식별하는 데 매우 효과적임을 시사한다. ROC-AUC 이득은 더 점진적이지만, 같은 두 과제에서 각각 +12.4%와 +20.4%로 여전히 상당하다. 라이프타임 밸류와 정기 거래 같은 과제에서는 성능 차이가 더 좁혀지지만, 전체 추세는 PRAGMA가 고립된 과제별 모델의 성능과 맞먹거나 그 이상의 우수한 범용 표현을 제공함을 확인해 준다.

3.3.1 모델 스케일의 효과

표 3의 결과는, PRAGMA 아키텍처를 Small (S, 10 M) 변형에서 Medium (M, 100 M)과 Large (L, 1 B) 변형으로 확장했을 때의 성능 영향을 보여준다. 스케일링 이득은 과제별로 크게 다르며, 특히 신용 평가에 가장 크게 집중된다 — Large 모델은 Small 기준 대비 PR-AUC에서 +35.2%, ROC-AUC에서 +5.8% 이득을 낸다.

과제	지표	베이스라인 (기준)	PRAGMA
신용 평가	PR-AUC	–	+130.2 %
	ROC-AUC	–	+12.4 %
커뮤니케이션 인게이지먼트	PR-AUC	–	+79.4 %
	ROC-AUC	–	+20.4 %
외부 사기	Precision	–	+16.7 %
	Recall	–	+64.7 %
상품 추천	mAP	–	+40.5 %
정기 거래	F_1	–	+5.8 %
라이프타임 밸류	PR-AUC	–	+1.8 %
	ROC-AUC	–	+2.6 %

표 2: PRAGMA는 과제 간 대부분의 파라미터를 공유하면서도 내부 과제별 모델을 큰 폭으로 능가한다. 상대 성능은 $(\text{PRAGMA}/\text{baseline} - 1)$ 로 계산한다. PRAGMA는 LoRA 파인튜닝을 적용한 Large 변형을 사용한다.

과제	지표	PRAGMA		
		S (기준)	M	L
외부 사기	Precision	–	+12.0 %	+16.4 %
	Recall	–	+24.8 %	+23.5 %
상품 추천	mAP	–	+18.9 %	+27.0 %
신용 평가	PR-AUC	–	+16.3 %	+35.2 %
	ROC-AUC	–	+3.6 %	+5.8 %
라이프타임 밸류	PR-AUC	–	+1.5 %	+3.0 %
	ROC-AUC	–	+1.7 %	+3.4 %
커뮤니케이션 인게이지먼트	PR-AUC	–	+0.1 %	+1.6 %
	ROC-AUC	–	–1.8 %	+0.7 %
정기 거래	F_1	–	+0.6 %	+0.4 %

표 3: 모델 성능은 파라미터 수에 따라 스케일링된다. 성능은 LoRA로 파인튜닝한 PRAGMA-S 대비이며, $(\text{model}/\text{PRAGMA-S} - 1)$ 로 계산한다.

특이하게도, 커뮤니케이션 인게이지먼트의 스케일링 거동은 단조롭지 않다 — Medium 변형은 ROC-AUC에서 약간의 회귀(–1.8%)를 보이고, Large 변형은 +0.7%로 회복된다. 정기 거래나 LTV처럼 더 안정적인 지표에서는 성능 이득이 더 작아서, 보통 +3.5% 이내에 머문다. 이 결과는 파라미터 수를 늘리면 일반적으로 예측력이 향상되지만, 거래성·라이프타임 밸류 예측에서는 Small 모델이 이미 매우 경쟁력 있는 표현을 제공한다는 것을 시사한다. 따라서 그러한 운영 사용 사례에 대해서는 Small이 잠재적인 효율성 스위트 스폿이 될 수 있다.

과제	지표	PRAGMA-M	
		Scratch (기준)	LoRA
커뮤니케이션 인게이지먼트	PR-AUC	–	+18.6 %
	ROC-AUC	–	+5.0 %
신용 평가	PR-AUC	–	+13.0 %
	ROC-AUC	–	+1.6 %
상품 추천	mAP	–	+10.3 %
정기 거래	F_1	–	+0.6 %
라이프타임 밸류	PR-AUC	–	+0.4 %
	ROC-AUC	–	+0.3 %

표 4: LoRA 파인튜닝과 처음부터 학습한 과제별 모델의 성능 비교. 상대 성능은 $(\text{LoRA}/\text{Scratch} - 1)$ 로 계산한다. LoRA는 처음부터의 전체 파라미터 학습 성능과 일관되게 맞먹거나 그 이상이다.

3.3.2 사전학습의 효과

표 4의 결과는, 평가된 모든 과제에서 LoRA 파인튜닝이 처음부터의 전체 파라미터 학습 성능과 일관되게 맞먹거나 그 이상임을 보여 줌으로써 본 논문의 접근을 검증해 준다. 가장 큰 이득은 커뮤니케이션 인게이지먼트에서 관찰되는데, LoRA가 PR-AUC에서 +18.6 %, ROC-AUC에서 +5.0 %를 달성한다. 이는 사전학습된 PRAGMA 백본이, 단일 다운스트림 과제에서 처음부터 학습할 때는 배우기 힘든 풍부하고 다양한 이벤트 패턴을 포착하고 있음을 시사한다. 신용 평가도 비슷한 패턴을 따라, LoRA가 PR-AUC에서 +13.0 %, ROC-AUC에서 +1.6 %의 향상을 보인다. 상품 추천도 mAP에서 +10.3 %의 큰 이득을 본다. 정기 거래와 라이프타임 밸류에서는 향상폭이 더 작으며(각각 F_1 +0.6 %, PR-AUC / ROC-AUC +0.4 % / +0.3 %), 이는 처음부터 학습한 베이스라인이 이미 해당 목적에 관련된 구조를 대부분 포착했음을 의미한다. 이런 경우 LoRA 파인튜닝은 회귀 없이 동등한 성능을 유지한다. 이 결과들은 운영 환경에서 특히 의미가 크다. 즉, PRAGMA가 여러 독립적이고 유지보수 비용이 큰 모델들을 단일 공유 시스템으로 통합하면서도 예측 정확도를 희생하지 않고, 학습 가능한 파라미터 풋프린트는 훨씬 작게 유지할 수 있음을 확인해 주기 때문이다.

3.4 추가 실험과 절제 분석

3.4.1 Low-Rank Adaptation의 효과

표 5이 보여 주듯, 평가된 모든 과제와 모델 스케일에서 LoRA 튜닝 변형은 임베딩 전용 베이스라인을 일관되게 능가한다. 이는 고정 임베딩이 놓칠 수 있는 과제별 미묘한 신호를 파라미터 효율적 파인튜닝이 잘 포착함을 보여준다. 가장 두드러진 향상은 커뮤니케이션 인게이지먼트에서 관찰되며, Small 모델에서 LoRA가 PR-AUC를 +72.9 % 끌어올리고, Medium·Large 변형에서도 큰 차이를 유지한다. 신용 평가에서는 Medium 모델의 PR-AUC가 +20.4 %로 가장 큰 상대 향상을 기록한다. 이는 복잡한 분류 과제에서 그 스케일의 LoRA 레이어가 특히 효과적임을 시사한다. 정기 거래와 LTV의 이득은 더 작아, 보통 +2.3 %에서 +4.7 % 범위에 있다.

과제	지표	PRAGMA-S		PRAGMA-M		PRAGMA-L	
		Emb.	LoRA	Emb.	LoRA	Emb.	LoRA
상품 추천	mAP	–	+57.2 %	–	+68.4 %	–	+68.1 %
외부 사기	Precision	–	+30.8 %	–	+29.8 %	–	+23.8 %
	Recall	–	+27.4 %	–	+24.5 %	–	+13.3 %
커뮤니케이션 인게이지먼트	PR-AUC	–	+72.9 %	–	+49.7 %	–	+54.1 %
	ROC-AUC	–	+16.9 %	–	+11.2 %	–	+13.5 %
신용 평가	PR-AUC	–	+18.0 %	–	+20.4 %	–	+10.3 %
	ROC-AUC	–	+0.2 %	–	+2.4 %	–	+1.5 %
정기 거래	F_1	–	+4.5 %	–	+3.2 %	–	+2.3 %
라이프타임 밸류	PR-AUC	–	+3.6 %	–	+2.4 %	–	+2.9 %
	ROC-AUC	–	+4.7 %	–	+3.4 %	–	+3.9 %

표 5: 스케일별로 본 LoRA 튜닝 모델의 임베딩 전용 베이스라인 대비 상대 향상. 각 모델 크기(S, M, L)에서 임베딩 전용 변형을 기준(Emb)으로 사용한다. 성능 이득은 $(\text{LoRA}/\text{Emb} - 1)$ 로 계산한다.

3.4.2 프로필 상태의 효과

표 6는, 전체 PRAGMA-S 모델과 프로필 상태 가지(branch)를 완전히 제거하고 이벤트 수준 표현에만 의존하는 변형을 비교함으로써 프로필 상태 인코더 (§ 2.3)의 기여를 분리해 보여 준다. 영향은 과제에 따라 강하게 달라진다. 신용 평가는 큰 이득을 본다 — PR-AUC에서 +31.8%, ROC-AUC에서 +4.9%의 상대 이득. PR-AUC가 유난히 크게 오른 것은, 계정 보유 기간이나 온보딩 특성 같은 정적 신호가 소수 클래스인 채무 불이행을 식별하는데 특히 유용한 변별적 맥락을 제공한다는 것을 의미한다 — 이는 이벤트 시퀀스만으로는 충분히 잡아내기 어렵다. 대조적으로, 라이프타임 밸류에서는 PR-AUC +2.2%, ROC-AUC +2.0%로 이득이 더 적어, 매출총이익 가능성은 예측 지평에 걸친 거래 패턴만으로도 상당 부분 추론 가능함을 시사한다. 커뮤니케이션 인게이지먼트는 PR-AUC가 살짝 회귀(−3.0%)하면서 ROC-AUC는 미미하게 상승(+1.3%)한다. 이는 재인게이지먼트 성향이 정적 사용자 특성보다는 이탈 직전 이벤트 패턴에 거의 전적으로 좌우됨을 가리킨다. 이 결과들은 PRAGMA의 두 가지 가지(branch) 설계를 검증한다 — 정적 프로필 상태가 정보적인 과제에서는 전용 프로필 상태 인코더가 의미 있는 가치를 더해 주고, 그 신호가 덜 관련된 과제에서는 아키텍처가 우아하게 성능을 유지한다.

3.4.3 커뮤니케이션 인게이지먼트(Uplift)

이 과제는 단순한 전환 예측을 넘어, 중단된 신용 신청 사용자를 다시 끌어들이는 데 어떤 메시징 전략이 가장 효과적인지를 식별하는 *최적 처치 선택(optimal treatment selection)*으로 나아간다. 데이터셋은 다른 다운스트림 벤치마크보다 작지만, 이 과제에서는 대규모 사전학습이 결정적인 역할을 한다 — 제한된 인-도메인 데이터만으로 학습된 베이스라인을 큰 폭으로 능가한다. 업리프트(uptift) 과제이기에 평가의 각도도 다르다 — PRAGMA는 파인튜닝되지 않고 동결된 피쳐 추출기로 사용되어 메타러너에 입력되며, 따라서 과제별 적응 없이 표현 자체의 품질을 분리해 평가할 수 있다.

과제	지표	PRAGMA-S	
		Event-only (기준)	Full
외부 사기	Precision	–	+46.8 %
	Recall	–	+85.6 %
신용 평가	PR-AUC	–	+31.8 %
	ROC-AUC	–	+4.9 %
상품 추천	mAP	–	+3.5 %
라이프타임 밸류	PR-AUC	–	+2.2 %
	ROC-AUC	–	+2.0 %
정기 거래	F_1	–	+2.4 %
커뮤니케이션 인게이지먼트	PR-AUC	–	–3.0 %
	ROC-AUC	–	+1.3 %

표 6: 프로필 상태는 정적 사용자 특성이 변별적인 과제에 큰 기여를 한다. 상대 성능은 $(\text{Full}/\text{Event-only} - 1)$ 로 계산한다.

과제	지표	베이스라인 (기준)	PRAGMA
커뮤니케이션 인게이지먼트 (uplift)	AUUC	–	+163.7 %
	SNIPS	–	+10.8 %

표 7: 동일한 메타러너 프레임워크에서 PRAGMA-L과 내부 업리프트 베이스라인의 성능 비교. 상대 성능은 $(\text{PRAGMA-L}/\text{Baseline} - 1)$ 로 계산한다.

구체적으로, 저자들은 이질적 처치 효과(heterogeneous treatment effect)를 추정하는 메타러너(meta-learner) 프레임워크 (Kunzel et al., 2019)를 채택하며, 모델이 이탈 직전 이벤트 신호, 프로필 상태, 처치 할당(treatment assignment) 사이의 복잡한 상호작용을 포착하도록 요구한다. PRAGMA와 베이스라인 모두 동일한 메타러너를 사용하며, 차이는 그 안의 표현(representation)뿐이다.

표 7는 Area Under the Uplift Curve(AUUC)와 SNIPS (Swaminathan et al., 2015)를 사용한 결과를 정리한다. 잠재된 이벤트 수준 패턴을 포착하는 PRAGMA-L의 능력은 매우 효과적인 처치 할당으로 이어져, 내부 베이스라인 대비 AUUC를 163.7 % 상대 증가시킨다.

3.4.4 사전학습된 텍스트 인코더의 효과

표준 PRAGMA 아키텍처에서는 텍스트 값이 다른 모든 표 형식 피처와 함께 임베딩 룩업 테이블(lookup table)을 통해 공동 학습된다 (§ 2.3.1 참조). 모델이 희소하거나(sparse) 잡음이 많거나(noisy) 매우 불규칙한 금융 텍스트 (예: 잘린 거래 설명)에 과소적합(underfit)되지 않도록, 저자들은 텍스트 이해를 별도의 사전학습된 텍스트 임베딩 모델(예: Nemotron-1B-v2 (de Souza P. Moreira et al., 2024))로 분리하는 안을 검토한다. 이 분리된(decoupled) 접근은 더 풍부한 즉시 사용 의미 표현을 제공하면서, 주된 이벤트 트랜스포머 (§ 2.3.3)가 피처 간




그림 5: PRAGMA의 텍스트 임베딩(왼쪽)과 사전학습 Nemotron-1B-v2 텍스트 임베딩 사용 버전(오른쪽) 비교. 자체 학습 BPE 토크나이저와 학습 가능한 임베딩 룩업 테이블 대신, 사전학습된 “동결” Nemotron이 텍스트 값 전체를 단일 텍스트 임베딩 벡터로 매핑하고, 학습 가능한 사영으로 트랜스포머의 기본 차원에 투영한다.

상호작용에 집중할 수 있게 해 준다. 이 변형을 일반화된 코어 아키텍처의 기본으로 채택하지는 않지만, 도메인 특화 통찰을 주는 선택적 확장으로 보고한다.

구현 세부. 사전학습된 텍스트 인코더의 추가는 PRAGMA 아키텍처에 여러 구조적 변경을 동반한다. 첫째, 보통 자체 학습된 BPE 토크나이저와 학습 가능한 임베딩 룩업 테이블로 인코딩되던 의미 타입(키)들의 값에 대해, 대신 동결된 사전학습 모델로 전체 텍스트 문자열을 단일 벡터로 매핑한 뒤, 한 층(one-layer)의 학습 가능한 사영을 통해 적응시킨다(그림 5 참조). 둘째, MLM 최적화(§ 2.3.5 참조) 동안 이 텍스트 필드의 정확한 토큰 라벨을 복원하는 대신, 사전학습된 텍스트 인코더가 만들어 내는 연속(continuous) 텍스트 임베딩을 평균제곱오차(mean squared error, MSE)로 복원하도록 PRAGMA를 학습시킨다.

결과 및 논의. 결과는 표 8에 제시한다. 다운스트림 효과는, 자유 텍스트와 범주형·행동 구조 가운데 어느 쪽에 라벨 관련 신호가 더 많이 들어 있는지에 따라 갈린다. 신용 평가는 가장 명확한 상승을 보인다 — Nemotron 사용 시 PR-AUC가 상대 +16.1%, ROC-AUC가 +2.8% 향상된다. 반면 상품 추천은 손실을 본다 — mAP가 상대 6.4% 떨어지는데, 이는 희소한 텍스트가 구조적 채널이 이미 인코딩하고 있는 정보 위에 별 추가 정보를 주지 않기 때문으로 보인다. 외부 사기는 정밀도(+3.8%)와 재현율(−0.7%)에서 작은 폭으로 반대 방향으로 움직이고, LTV와 정기 거래는 보고된 지표상 거의 변동이 없다. 이 변형은 또한 PRAGMA-M 학습 지연을 약 18% 늘리기 때문에, 저자들은 이를 기본 아키텍처에 포함시키는 대신 텍스트 비중이 큰 과제에서 옵트인하는 모듈로 유지한다.

3.4.5 높은 관계성을 가진 과제의 한계: 자금세탁방지(AML)

저자들은 자금세탁방지(Anti-Money Laundering, AML)를 이진 분류 과제로 정식화한다. 표 9에서 보이듯, 이 과제는 PRAGMA가 운영 베이스라인보다 크게 뒤지는 설정이다.

저자들은 이 성능 격차를 두 가지 주된 요인으로 본다. 첫째, AML 다운스트림 데이터셋은 베이스라인 모델이 파운데이션 수준의 사전학습 없이도 견고한 과제별 표현을 학습하기에 충분히 크다. 둘째, 그리고 더 결정적으로, AML 탐지는 본질적으로 *관계적(relational)* 이다 — 베이스라인은 네트워크 수준 신호를 포착하는 레코드 간

과제	지표	PRAGMA-M	
		기준	+Nemotron
신용 평가	PR-AUC	-	+16.1 %
	ROC-AUC	-	+2.8 %
정기 거래	F_1	-	+0.1 %
라이프타임 밸류	PR-AUC	-	+0.8 %
	ROC-AUC	-	+0.6 %
외부 사기	Precision	-	+3.8 %
	Recall	-	-0.7 %
상품 추천	mAP	-	-6.4 %

표 8: 사전학습된 텍스트 임베딩의 다운스트림 영향은 텍스트 비중이 큰 도메인에 집중된다. 성능은 LoRA 튜닝된 PRAGMA-M 대비 추정된 값이다.

과제	지표	베이스라인 (기준)	PRAGMA
자금세탁방지(AML)	$F_{0.5}$	-	-47.1 %

표 9: 자금세탁방지 과제에서 PRAGMA와 베이스라인의 성능 비교. 상대 성능은 PRAGMA-L 임베딩 위 선형 프로브로 $(\text{PRAGMA}/\text{Baseline} - 1)$ 으로 계산한다.

(cross-record) 피처를 활용한다. PRAGMA는 이벤트 이력을 고립된 단위로 처리하므로, 만들어진 임베딩은 이 과제에 결정적인 레코드 간 의존 구조를 본질적으로 담지 못한다.

성능은 정밀도를 강조하면서도 재현율을 함께 반영하는 $F_{0.5}$ 를 주된 지표로 평가한다. PRAGMA는 네트워크-인지 베이스라인 대비 $F_{0.5}$ 가 47.1 % 떨어지며, 이는 고립된 레코드 수준 표현이 이 강한 관계성 도메인에서는 충분하지 않을 수 있음을 보여준다. 이 한계를 해소하는 것은 향후 연구의 핵심 방향이다.

4 관련 연구

4.1 트랜스포머

시퀀스 모델링(sequence modelling)의 지형은 트랜스포머 아키텍처 (Vaswani et al., 2017)의 등장으로 근본적으로 다시 짜였다 — 트랜스포머는 순환 레이어(recurrent layer)를 버리는 대신 병렬화 가능한 셀프 어텐션(self-attention) 메커니즘을 도입했다. 이후 분야는 BERT (Devlin et al., 2019)처럼 판별적 과제에 최적화된 인코더 전용 모델과, GPT-3 (Brown et al., 2020)처럼 거대한 스케일링(scaling)과 창발적인 인-컨텍스트 학습(in-context learning)으로 현재의 생성형 AI 시대를 견인한 디코더 전용(decoder-only) 아키텍처로 갈라졌다. 이어진 연구는 시각 인식을 위한 Vision Transformer(ViT) (Dosovitskiy et al., 2021)와, 텍스트-투-텍스트 처리의 통일을 시도한 T5 프레임워크 (Raffel et al., 2020) 등으로 아키텍처의 적용 범위를 넓혀 왔다. 최근의 진전은 계산 효율성과 멀티모달리티(multimodality)에 무게를 두며, 특히 FlashAttention (Dao et al., 2022) 같은 하드웨어

인지 최적화와, Mixtral 8×7B (Jiang et al., 2024)처럼 Mixture-of-Experts(MoE) (Fedus et al., 2022)를 채택한 모델에서 두드러진다. 현재 패러다임에서는 Gemini 1.5 (Gemini Team, 2024)와 GPT-4o (Hurst et al., 2024) 같은 모델이 합성형(compositional) 아키텍처를 넘어 네이티브 멀티모달리티(native multimodality)로 옮겨 가, 이질적인 데이터 스트림을 가로지르는 매끄러운 추론을 가능하게 했다.

이 지형 안에서 PRAGMA는 이질적 표 형식 이벤트 스트림을 위한 인코더형 파운데이션 모델로 이해될 수 있다. 금융 거래에서 출발한 동기이지만, 엔티티가 시간을 따라 불규칙하고 다중 필드 레코드를 누적하는 어떤 도메인에도 자연스럽게 확장된다. PRAGMA는 인코더 전용 트랜스포머의 확장성과 양방향 맥락화를 그대로 물려받으면서, 이를 이질적 필드, 명시적 시간 신호, 재사용 가능한 레코드 수준 표현에 맞춰 변형해 적용한다.

4.2 마스크 모델링

생성형 디코더의 스케일링과 나란히, 마스크 모델링은 자기지도 표현 학습(self-supervised representation learning)의 지배적 패러다임으로 자리잡았다. 이는 양방향 맥락을 포착하는 마스크 언어 모델링(masked language modelling, MLM) 목적함수를 도입한 BERT (Devlin et al., 2019)로 시작되었으며, RoBERTa (Liu et al., 2019)는 동적 마스크(dynamic masking)와 최적화된 학습 레시피(recipe)로 이를 한층 다듬었다. 이후 MLM의 성공은 시각 도메인의 마스크 이미지 모델링(masked image modelling, MIM)으로 옮겨졌고, BEiT (Bao et al., 2021)와 Masked Autoencoders(MAE) (He et al., 2022)는 가려진 이미지 패치(image patch)를 복원하는 과정이 모델로 하여금 전체 구조적 표현을 학습하게 만든다는 것을 보였다. 최근에는 Data2Vec (Baeviski et al., 2022)처럼 모달 간 통합(cross-modal unification)으로, 그리고 Joint-Embedding Predictive Architecture(I-JEPA) (Assran et al., 2023)처럼 원시 신호 복원에서 잠재 피쳐 예측(latent feature prediction)으로 이동하는 흐름이 나타나고 있다.

PRAGMA는 이 흐름에서 직접 영감을 받지만, 마스크 모델링을 텍스트와 이미지에서 이질적 금융 레코드로 확장한다. 저자들의 목적함수는 개별 토큰, 이벤트 전체, 의미 타입(키)을 마스크하며, 부분 관측 이벤트의 복원과 전체 거래 이력으로부터의 전이 가능한 표현 학습을 함께 유도한다.

4.3 표 형식 데이터를 위한 트랜스포머

구조화 데이터(structured data)에서는 그동안 그래디언트 부스팅 결정 트리(GBDT)가 지배적이었지만, 트랜스포머는 새로운 부류의 “표 형식 딥러닝(Tabular Deep Learning)” 아키텍처를 촉발했다. TabTransformer (Huang et al., 2020)와 FT-Transformer (Gorishniy et al., 2021) 같은 초기 모델은 셀프 어텐션으로 피쳐 간 의존을 모델링하는 데 집중해, 고차원 데이터셋에서 GBDT와 동등한 성능을 보였다. SAINT (Somepalli et al., 2021)는 피쳐와 행 상호작용을 모두 다루는 이중 어텐션을 도입했고, Trompt (Chen et al., 2023)는 표의 본질 속성과 표본별 변동을 분리하기 위한 프롬프트 튜닝을 제안했다. TabPFN (Hollmann et al., 2023)은 베이스 추론을 근사하도록 합성 데이터로 사전학습된 파운데이션 모델로 패러다임 전환을 가져왔다. 인-컨텍스트 학습을 활용해, TabPFN은 단일 순전파만으로 예측을 만들어 내며 반복 학습의 필요를 제거한다. 원래 모델은 1,000개 표본으로 제한되었지만, TabPFN-v2와 TabPFN-v2.5 (Hollmann et al., 2025; Grinsztajn et al., 2025)는 100,000개 표본과 실제 데이터의 복잡성을 다루도록 아키텍처를 확장하고, 범주형 피쳐·결측값·이상치를 기본 지원한다. 가장 최근의 Mitra (Zhang et al., 2025)는 SAINT의 이중 어텐션을 채택하면서도, 거대한 합성 사전(prior) 혼합으로만 사전학습되는 TabPFN의 파운데이션 모델 패러다임을 따른다.

PRAGMA는 필드 정체성을 보존하고 어텐션으로 필드 간 상호작용을 모델링한다는 점에서 표 형식 트랜스포머와 정신적으로 가깝지만, TabTransformer·FT-Transformer·SAINT와 달리 고정 스키마의 단일 행 위에서 작동하지 않는다. 합성된 지도(supervised) 과제로 학습되는 TabPFN류 표 형식 파운데이션 모델과 비교하면, PRAGMA는 실제 금융 원장 위에서 자기지도로 사전학습되며 계층형 인코더로 이질적 이벤트의 가변 길이 사용자 이력을 모델링한다.

4.4 추천 시스템 모델링

순차 추천 모델은 풍부한 부가 정보를 동반한 시간순 이벤트 시퀀스를 다룬다는 점에서, 거래 모델링과 구조적 유사성을 갖는다. 트랜스포머 기반 추천 모델은 사용자 상호작용 이력을 토큰 시퀀스로 다룬다 — SASRec (Kang et al., 2018)는 순환 대신 셀프 어텐션으로 장거리 의존(long-range dependency)을 포착했고, BERT4Rec (Sun et al., 2019)는 마스킹된 아이템 예측을 통한 양방향 맥락화(bidirectional contextualisation)가 더 견고한 표현을 만들어 냈을 보였다. 이후 분야는 LLM 패러다임으로 수렴했다 — P5 (Geng et al., 2022)는 다양한 추천 과제를 T5 기반의 통일된 텍스트-투-텍스트(text-to-text) 프레임워크로 환원했고, TALLRec (Bao et al., 2023)은 명령 튜닝(instruction tuning)을 도입해 범용 LLM을 추천 로직에 정렬(aligned)했다.

더 최근의 산업적 흐름은, 양성 상호작용만 모델링하는 데에서 더 풍부한 이벤트 스트림을 인코딩하는 쪽으로 이동했다. Generative Recommenders (Zhai et al., 2024)는 인과 시퀀스(causal sequence) 안에 아이템 토큰과 액션 토큰을 교차 배치해, 멱법칙(power-law)에 가까운 품질 향상으로 수조 파라미터 규모로 확장한다. ARGUS (Khrylchenko et al., 2025)는 자기회귀(autoregressive) 학습을 피드백 예측과 다음 아이템 예측으로 분해하여, 추천 트랜스포머를 10억 파라미터 규모로 키운다. TransAct 계열 연구 (Xia et al., 2023; 2025)는 각 사용자 행동을 콘텐츠·행동 유형·맥락의 조합으로 임베딩해 CTR(click-through rate) 예측을 수행하고, 평생(lifelong) 행동 시퀀스로 확장한다.

PRAGMA는 시간순 이벤트 이력과 자기지도 사전학습을 사용한다는 점에서 이 문헌과 가깝다. 다만 각 상호작용을 흔히 아이템 토큰으로 환원하는 추천 모델과 달리, PRAGMA는 타입이 있는 필드, 금액, 자유 텍스트, 시간 좌표를 갖춘 더 풍부한 금융 이벤트를 모델링하며, 랭킹을 넘어선 폭넓은 बैंकिंग 과제에 적용된다.

4.5 금융을 위한 파운데이션 모델

금융 파운데이션 모델 패러다임은 특화된 텍스트 인코더에서 다양한 데이터 모달리티를 통합하는 종합 추론 엔진으로 빠르게 성숙해 왔다. 이런 진화는 인코더 전용 아키텍처를 금융 코퍼스에 적용시킨 FinBERT (Yang et al., 2020)로 시작되어, 감성 분석(sentiment analysis)이나 ESG 분류 같은 판별적 과제의 엄격한 베이스라인을 제시했다. 이후 분야는 BloombergGPT (Wu et al., 2023)와 함께 거대한 생성형 스케일로 옮겨 갔는데, 이는 독점 금융 데이터셋과 일반 웹 코퍼스를 교차해 학습하면 도메인 특화 벤치마크에서 우월한 성능을 낸다는 점을 보였다. 이런 거대 모델의 접근성 장벽을 다루기 위해, FinGPT (Yang et al., 2023)는 데이터 중심의 가벼운 적응 프레임워크를 제안하며, 오픈소스 모델의 효율적 LoRA 파인튜닝 (Hu et al., 2022)을 통해 금융 LLM의 접근성을 민주화했다. 가장 최근에는 텍스트의 경계를 넘어 시장 데이터의 구조적 성격을 다루는 연구가 나타났으며, Time-LLM (Jin et al., 2024)과 Chronos (Ansari et al., 2024) 같은 모델은 수치 시계열(numerical time series)을 토큰 시퀀스로 다루어, 트랜스포머가 제로샷 예측(zero-shot forecasting)을 수행할 수 있게 한다.

이런 구조적 전환을 소비자 금융으로 확장하면서, 최근의 파운데이션 모델은 대규모 사용자 거래 원장 위에서 직접 학습되고 있다. 예컨대, nuFormer (Braithwaite et al., 2025)는 토큰화된 거래 시퀀스를 전통적인 표 형식 피쳐와 결합하면 실제 위험 예측에서 수작업 피쳐 엔지니어링을 효과적으로 대체할 수 있음을 보인다. 같은 흐름에서 TransactionGPT (Dou et al., 2025)는 십억 단위 결제 궤적의 멀티모달, 시간, 표 형식 차원을 명시적으로 모델링하기 위한 특화 3D-Transformer 아키텍처를 도입해, 다운스트림 이상 탐지와 궤적 생성에서 최첨단 성능을 달성한다.

PRAGMA는 주로 금융 언어를 다루는 FinBERT, BloombergGPT, FinGPT 같은 텍스트 중심 금융 파운데이션 모델, 그리고 수치 시계열을 토큰화해 예측에 쓰는 Time-LLM과 Chronos와는 다르다. nuFormer와 TransactionGPT 같은 거래 원장 모델에 더 가깝지만, PRAGMA는 명시적 프로필 상태가 있는 멀티 소스 बैं킹 이벤트 위의 재사용 가능한 인코더 백본을 지향하며, 다양한 판별적 과제에 대해 가벼운 적응을 제공한다.

5 결론

저자들은 멀티 소스 बैं킹 사용자 이력을 위한 인코더형 파운데이션 모델 계열인 PRAGMA를 제시했다. PRAGMA는 키-값-시간 토큰화 방식을, 프로필 상태와 이벤트를 각각 처리하는 두 인코더 가지(branch) 그리고 그 출력을 융합하는 히스토리 인코더와 결합하며, 대규모 이질적 금융 레코드 위에서 마스킹 모델링으로 사전학습된다. 다양한 다운스트림 과제 — 신용 평가, 사기 탐지, 커뮤니케이션 인게이지먼트, 상품 추천, 정기 거래 탐지, 라이프타임 밸류 예측 등 — 에 걸쳐, 단일 사전학습 백본이 원시 बैं킹 이벤트 시퀀스로부터 곧바로 우수한 성능을 달성하며, 금융 응용을 위한 범용 표현 계층을 제공한다.

저자들의 실험은 몇 가지 실용적 통찰을 드러낸다. LoRA 파인튜닝은 일관되게 처음부터의 전체 학습과 맞먹거나 그 이상의 성능을 내면서도 갱신되는 파라미터는 일부에 그치며, 이는 사전학습 표현이 과제 간에 효과적으로 전이됨을 확인해 준다. 10M에서 1B 파라미터로의 스케일링은 신용 평가 같은 더 어려운 과제에서 큰 이득을 가져오는 반면, 라이프타임 밸류 예측 같은 과제에서는 더 작은 모델만으로도 경쟁력 있는 표현을 제공하므로 실용적인 효율성 트레이드오프가 가능하다. 전용 프로필 상태 인코더는 신용 평가나 사기 탐지처럼 정적 맥락 속성이 변별적인 과제에 특히 유용하며, 그런 신호가 덜 관련된 과제에서는 아키텍처가 우아하게 성능을 유지한다. 또한 사전학습된 텍스트 인코더의 통합은 텍스트 비중이 큰 도메인의 성능을 끌어올리지만, 텍스트가 희박한 과제에서는 학습 오버헤드를 정당화하지 못하는 것으로 나타났다. 마지막으로, AML 사례 연구는 한 가지 분명한 한계를 부각한다 — 레코드 간 관계 구조에 의존하는 과제는, 이벤트 이력을 고립된 단위로 처리하는 모델로는 도달하기 어렵다.

이 결과들은, 이질적 구조(heterogeneous structure), 불규칙한 시간성(irregular timing), 운영적 제약(operational constraint)에도 불구하고 멀티 소스 बैं킹 이벤트 시퀀스가 텍스트나 비전과 같은 방식으로 전이 가능한 표현을 허용함을 시사한다. 자금세탁방지 같은 관계적 과제를 위해 모델을 레코드 간 상호작용까지 포착하도록 확장하는 것은 향후 연구의 유망한 방향이다.

감사의 글

저자들은 이 연구에 기여해 준 Dmitry Mittov, Ian Iakobsen, Aleksandr Pushin, Muhammad Anas, Viacheslav Karpov, Nathalie Skrzypek, Leyla Sultanova, Francisco Sanz Estevez, Nikita Kravchuk, Tadas Krisciunas,

Amey Baokar, Hanna Danilovich, Jyoti Prakash Bal, Vitalii Radchenko, Kade Main, Nic Hatia, 그리고 그 밖의 Revoluter 동료들에게 감사를 전한다.

References

- Abdul Fatir Ansari, Lorenzo Stella, Caner Turkmen, Xiyuan Zhang, Pedro Mercado, Huibin Shen, Oleksandr Shchur, Syama Sundar Rangapuram, Sebastian Pineda Arango, Shubham Kapoor, et al. Chronos: Learning the language of time series. *Transactions on Machine Learning Research*, 2024.
- Mahmoud Assran, Quentin Duval, Ishan Misra, Piotr Bojanowski, Pascal Vincent, Michael Rabbat, Yann LeCun, and Nicolas Ballas. Self-supervised learning from images with a joint-embedding predictive architecture. In *Conference on Computer Vision and Pattern Recognition*, 2023.
- Alexei Baevski, Wei-Ning Hsu, Qiantong Xu, Arun Babu, Jiatao Gu, and Michael Auli. Data2vec: A general framework for self-supervised learning in speech, vision and language. In *International Conference on Machine Learning*, 2022.
- Hangbo Bao, Li Dong, Songhao Piao, and Furu Wei. BEiT: BERT pre-training of image transformers. *arXiv preprint arXiv:2106.08254*, 2021.
- Keqin Bao, Jizhi Zhang, Yang Zhang, Wenjie Wang, Fuli Feng, and Xiangnan He. TALLRec: An effective and efficient tuning framework to align large language model with recommendation. In *ACM Conference on Recommender Systems*, 2023.
- Rishi Bommasani, Drew A. Hudson, Ehsan Adeli, Russ Altman, Simran Arora, Sydney von Arx, Michael S. Bernstein, Jeannette Bohg, Antoine Bosselut, Emma Brunskill, Erik Brynjolfsson, S. Buch, Dallas Card, Rodrigo Castellon, Niladri S. Chatterji, Annie S. Chen, Kathleen A. Creel, Jared Davis, Dora Demszky, Chris Donahue et al. On the opportunities and risks of foundation models. *ArXiv*, 2021.
- DT Braithwaite, Misael Cavalcanti, R Austin McEver, Hiroto Udagawa, Daniel Silva, Rohan Ramanath, Felipe Meneses, Arissa Yoshida, Evan Wingert, Matheus Ramos, et al. Your spending needs attention: Modeling financial habits with transformers. *arXiv preprint arXiv:2507.23267*, 2025.
- Tom Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared D Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, et al. Language models are few-shot learners. *Advances in Neural Information Processing Systems*, 2020.
- Mathilde Caron, Hugo Touvron, Ishan Misra, Herve Jegou, Julien Mairal, Piotr Bojanowski, and Armand Joulin. Emerging properties in self-supervised vision transformers. In *International Conference on Computer Vision*, 2021.
- Kuan-Yu Chen, Ping-Han Chiang, Hsin-Rung Chou, Ting-Wei Chen, and Darby Tien-Hao Chang. Trompt: Towards a better deep neural network for tabular data. In *International Conference on Machine Learning*, 2023.

- Tri Dao, Dan Fu, Stefano Ermon, Atri Rudra, and Christopher Re. FlashAttention: Fast and memory-efficient exact attention with io-awareness. *Advances in Neural Information Processing Systems*, 2022.
- Gabriel de Souza P. Moreira, Radek Osmulski, Mengyao Xu, Ronay Ak, Benedikt Schifferer, and Even Oldridge. Nv-retriever: Improving text embedding models with effective hard-negative mining. *arXiv preprint arXiv:2407.15831*, 2024. doi: 10.48550/arXiv.2407.15831.
- Tim Dettmers, Artidoro Pagnoni, Ari Holtzman, and Luke Zettlemoyer. QLoRA: Efficient finetuning of quantized llms. *Advances in Neural Information Processing Systems*, 2023.
- Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. Bert: Pre-training of deep bidirectional transformers for language understanding. In *North American Association for Computational Linguistics – Human Language Technologies*, 2019.
- Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit, and Neil Houlsby. An image is worth 16x16 words: Transformers for image recognition at scale. In *International Conference on Learning Representations*, 2021.
- Yingtong Dou, Zhimeng Jiang, Tianyi Zhang, Mingzhi Hu, Zhichao Xu, Shubham Jain, Uday Singh Saini, Xiran Fan, Jiarui Sun, Menghai Pan, et al. Transactiongpt. *arXiv preprint arXiv:2511.08939*, 2025.
- William Fedus, Barret Zoph, and Noam Shazeer. Switch Transformers: Scaling to trillion parameter models with simple and efficient sparsity. *Journal of Machine Learning Research*, 2022.
- Gemini Team. Gemini 1.5: Unlocking multimodal understanding across millions of tokens of context. *arXiv preprint arXiv:2403.05530*, 2024.
- Shijie Geng, Shuchang Liu, Zuohui Fu, Yingqiang Ge, and Yongfeng Zhang. Recommendation as language processing (RLP): A unified pretrain, personalized prompt & predict paradigm (P5). In *ACM Conference on Recommender Systems*, 2022.
- Yury Gorishniy, Ivan Rubachev, Valentin Khrulkov, and Artem Babenko. Revisiting deep learning models for tabular data. *Advances in Neural Information Processing Systems*, 2021.
- Yury Gorishniy, Ivan Rubachev, and Artem Babenko. On embeddings for numerical features in tabular deep learning. *Advances in Neural Information Processing Systems*, 2022.
- Leo Grinsztajn, Klemens Floge, Oscar Key, Felix Birkel, Philipp Jund, Brendan Roof, Benjamin Jager, Dominik Safaric, Simone Alessi, Adrian Hayler, et al. TabPFN-2.5: Advancing the state of the art in tabular foundation models. *arXiv preprint arXiv:2511.08667*, 2025.
- Kaiming He, Xinlei Chen, Saining Xie, Yanghao Li, Piotr Dollar, and Ross Girshick. Masked autoencoders are scalable vision learners. In *Computer Vision and Pattern Recognition*, 2022.

- Dan Hendrycks and Kevin Gimpel. Gaussian error linear units (gelus). *arXiv preprint arXiv:1606.08415*, 2016.
- Noah Hollmann, Samuel Muller, Katharina Eggenberger, and Frank Hutter. TabPFN: A transformer that solves small tabular classification problems in a second. In *International Conference on Learning Representations*, 2023.
- Noah Hollmann, Samuel Muller, Lennart Purucker, Arjun Krishnakumar, Max Korfer, Shi Bin Hoo, Robin Tibor Schirrmeyer, and Frank Hutter. Accurate predictions on small data with a tabular foundation model. *Nature*, 2025.
- Edward J Hu, yelong shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang, and Weizhu Chen. LoRA: Low-rank adaptation of large language models. In *International Conference on Learning Representations*, 2022.
- Xin Huang, Ashish Khetan, Milan Cvitkovic, and Zohar Karnin. TabTransformer: Tabular data modeling using contextual embeddings. *arXiv preprint arXiv:2012.06678*, 2020.
- Aaron Hurst, Adam Lerer, Adam P Goucher, Adam Perelman, Aditya Ramesh, Aidan Clark, AJ Ostrow, Akila Welihinda, Alan Hayes, Alec Radford, et al. GPT-4o system card. *arXiv preprint arXiv:2410.21276*, 2024.
- Albert Q Jiang, Alexandre Sablayrolles, Antoine Roux, Arthur Mensch, Blanche Savary, Chris Bamford, Devendra Singh Chaplot, Diego de las Casas, Emma Bou Hanna, Florian Bressand, et al. Mixtral of experts. *arXiv preprint arXiv:2401.04088*, 2024.
- Ming Jin, Shiyu Wang, Lintao Ma, Zhixuan Chu, James Y Zhang, Xiaoming Shi, Pin-Yu Chen, Yuxuan Liang, Yuan-Fang Li, Shirui Pan, and Qingsong Wen. Time-LLM: Time series forecasting by reprogramming large language models. In *International Conference on Learning Representations*, 2024.
- Keller Jordan. Muon: An optimizer for hidden layers in neural networks, 2024. URL <https://kellerjordan.github.io/posts/muon/>.
- Wang-Cheng Kang and Julian McAuley. Self-attentive sequential recommendation. In *International Conference on Data Mining*, 2018.
- Kirill Khrylchenko, Artem Matveev, Sergei Makeev, and Vladimir Baikalov. Scaling recommender transformers to one billion parameters. *arXiv preprint arXiv:2507.15994*, 2025.
- Diederik P Kingma and Jimmy Ba. Adam: A method for stochastic optimization. In *International Conference on Learning Representations*, 2015.
- Alexander Kirillov, Eric Mintun, Nikhila Ravi, Hanzi Mao, Chloe Rolland, Laura Gustafson, Tete Xiao, Spencer Whitehead, Alexander C Berg, Wan-Yen Lo, et al. Segment anything. In *Computer Vision and Pattern Recognition*, 2023.

- Soren R Kunzel, Jasjeet S Sekhon, Peter J Bickel, and Bin Yu. Metalearners for estimating heterogeneous treatment effects using machine learning. *Proceedings of the national academy of sciences*, 2019.
- Dong C Liu and Jorge Nocedal. On the limited memory bfgs method for large scale optimization. *Mathematical programming*, 1989.
- Jingyuan Liu, Jianlin Su, Xingcheng Yao, Zhejun Jiang, Guokun Lai, Yulun Du, Yidao Qin, Weixin Xu, Enzhe Lu, Junjie Yan, et al. Muon is scalable for LLM training. *arXiv preprint arXiv:2502.16982*, 2025.
- Yinhan Liu, Myle Ott, Naman Goyal, Jingfei Du, Mandar Joshi, Danqi Chen, Omer Levy, Mike Lewis, Luke Zettlemoyer, and Veselin Stoyanov. RoBERTa: A robustly optimized bert pretraining approach. *arXiv preprint arXiv:1907.11692*, 2019.
- Ilya Loshchilov and Frank Hutter. Decoupled weight decay regularization. In *International Conference on Learning Representations*, 2019.
- Colin Raffel, Noam Shazeer, Adam Roberts, Katherine Lee, Sharan Narang, Michael Matena, Yanqi Zhou, Wei Li, and Peter J Liu. Exploring the limits of transfer learning with a unified text-to-text transformer. *Journal of Machine Learning Research*, 2020.
- Rico Sennrich, Barry Haddow, and Alexandra Birch. Neural machine translation of rare words with subword units. In *Annual Meeting of the Association for Computational Linguistics*, 2016.
- Gowthami Somepalli, Micah Goldblum, Avi Schwarzschild, C Bayan Bruss, and Tom Goldstein. SAINT: Improved neural networks for tabular data via row attention and contrastive pre-training. *arXiv preprint arXiv:2106.01342*, 2021.
- Nitish Srivastava, Geoffrey Hinton, Alex Krizhevsky, Ilya Sutskever, and Ruslan Salakhutdinov. Dropout: a simple way to prevent neural networks from overfitting. *Journal of Machine Learning Research*, 2014.
- Jianlin Su, Murtadha Ahmed, Yu Lu, Shengfeng Pan, Wen Bo, and Yunfeng Liu. RoFormer: Enhanced transformer with rotary position embedding. *Neurocomputing*, 2024.
- Fei Sun, Jun Liu, Jian Wu, Changhua Pei, Xiao Lin, Wenwu Ou, and Peng Jiang. BERT4Rec: Sequential recommendation with bidirectional encoder representations from transformer. In *International Conference on Information and Knowledge Management*, 2019.
- Adith Swaminathan and Thorsten Joachims. The self-normalized estimator for counterfactual learning. In *NeurIPS*, 2015.
- Christian Szegedy, Vincent Vanhoucke, Sergey Ioffe, Jon Shlens, and Zbigniew Wojna. Rethinking the inception architecture for computer vision. In *Computer Vision and Pattern Recognition*, 2016.
- Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. *Advances in Neural Information Processing Systems*, 2017.

- Shijie Wu, Ozan Irsoy, Steven Lu, Vadim Dabravolski, Mark Dredze, Sebastian Ghaffari, Binyam Gebre, Abraham Ittycheriah, and Gideon Mann. BloombergGPT: A large language model for finance. *arXiv preprint arXiv:2303.17564*, 2023.
- Xue Xia, Pong Eksombatchai, Nikil Pancha, Dhruvil Deven Badani, Po-Wei Wang, Neng Gu, Saurabh Vishwas Joshi, Nazanin Farahpour, Zhiyuan Zhang, and Andrew Zhai. TransAct: Transformer-based realtime user action model for recommendation at Pinterest. In *ACM SIGKDD*, 2023.
- Xue Xia, Saurabh Vishwas Joshi, Kousik Rajesh, Kangnan Li, Yangyi Lu, Nikil Pancha, Dhruvil Deven Badani, Jiajing Xu, and Pong Eksombatchai. TransAct V2: Lifelong user action sequence modeling on Pinterest recommendation. *arXiv preprint arXiv:2506.02267*, 2025.
- Ruibin Xiong, Yunchang Yang, Di He, Kai Zheng, Shuxin Zheng, Chen Xing, Huishuai Zhang, Yanyan Lan, Liwei Wang, and Tieyan Liu. On layer normalization in the transformer architecture. In *International Conference on Machine Learning*, 2020.
- Hongyang Yang, Xiao-Yang Liu, and Christina Dan Wang. FinGPT: Open-source financial large language models. In *International Joint Conference on Artificial Intelligence (IJCAI) Symposium on Financial Large Language Models*, 2023.
- Yi Yang, Mark Christopher Siy Uy, and Allen Huang. FinBERT: A pretrained language model for financial communications. *arXiv preprint arXiv:2006.08097*, 2020.
- Jiaqi Zhai, Lucy Liao, Xing Liu, Yueming Wang, Rui Li, Xuan Cao, Leon Gao, Zhaojie Gong, Fangda Gu, Michael He, Yinghai Lu, and Yu Shi. Actions speak louder than words: Trillion-parameter sequential transducers for generative recommendations. *arXiv preprint arXiv:2402.17152*, 2024.
- Xiyuan Zhang, Danielle C. Maddix, Junming Yin, Nick Erickson, Abdul Fatir Ansari, Boran Han, Shuai Zhang, Leman Akoglu, Christos Faloutsos, Michael W. Mahoney, Cuixiong Hu, Huzefa Rangwala, George Karypis, and Bernie Wang. Mitra: Mixed synthetic priors for enhancing tabular foundation models. *Advances in Neural Information Processing Systems*, 2025.