
τ^2 -Bench: 이중 제어 환경에서의 대화형 에이전트 평가

Victor Barres *
Sierra
victor@sierra.ai

Honghua Dong *†
Sierra & University of Toronto & Vector Institute
honghuad@cs.toronto.edu

Soham Ray
Sierra
soham@sierra.ai

Xujie Si
University of Toronto & Vector Institute
six@cs.toronto.edu

Karthik Narasimhan
Sierra
karthik@sierra.ai

Abstract

대화형 AI 에이전트를 위한 기존 벤치마크는 단일 제어(*single-control*) 환경을 시뮬레이션한다. 여기서는 AI 에이전트만 도구를 사용해 세계와 상호작용할 수 있고, 사용자는 수동적인 정보 제공자로 남는다. 이는 기술 지원처럼 사용자가 (공유된) 세계의 상태를 수정하는 데 능동적으로 참여해야 하는 실제 시나리오와 다르다. 이 간극을 해결하기 위해 우리는 τ^2 -bench 를 소개하며, 네 가지 핵심 기여를 제시한다: 1) Dec-POMDP 로 모델링한 새로운 Telecom 이중 제어 도메인으로, 에이전트와 사용자 모두 도구를 사용해 공유되고 동적인 환경에서 행동하며 에이전트의 조정과 의사소통을 함께 시험한다, 2) 원자적 구성 요소로부터 다양하고 검증 가능한 과제를 프로그램적으로 생성하여 도메인 포괄성과 제어된 복잡성을 보장하는 조합적 과제 생성기, 3) 도구와 관찰 가능한 상태로 행동이 제약되어 시뮬레이션 충실도를 높이는, 환경과 긴밀히 결합된 신뢰할 수 있는 사용자 시뮬레이터, 4) 추론에서 비롯된 오류와 의사소통/조정에서 비롯된 오류를 분리하는 것을 포함한 여러 절제를 통한 에이전트 성능의 세분화된 분석. 특히 우리의 실험은 에이전트가 no-user에서 이중 제어로 전환될 때 성능이 크게 하락함을 보여 주며, 사용자를 안내하는 일이 갖는 어려움을 부각한다. 전반적으로 τ^2 -bench 는 효과적으로 추론하면서 동시에 사용자의 행동을 안내해야 하는 에이전트를 위한 통제된 테스트베드를 제공한다.¹

1 서론

대화형 AI 에이전트를 위한 기존 벤치마크는 사용자와 효과적으로 소통하고 과제를 해결하기 위해 올바른 행동 순서를 수행하는 능력을 시험하도록 설계되어 있다 [26, 14, 23, 19]. 이러한 벤치마크는 본질적으로 단일 제어(*single-control*) 환경이다. AI 에이전트는 세계와 상호작용할 수 있지만, (시뮬레이션된) 사용자는 신호와 목표에 관한 정보를 제공하는 데 제한된다. 예를

*동등 기여.

†인턴십 기간 중 수행한 작업.

¹코드와 데이터는 다음에서 이용할 수 있다: <https://github.com/sierra-research/tau2-bench>.




그림 1: τ^2 -bench 에서 지원하는 dual-control 환경. 에이전트는 데이터베이스와 상호작용하는 도구 집합에 접근할 수 있으며, 도메인 정책을 준수하면서 Tool-Agent-User (TAU) 상호작용을 통해 사용자의 요청을 해결해야 한다. 실제 시나리오를 시험하기 위해, 사용자는 시나리오 기반 지시와 자체 데이터베이스와 상호작용하는 도구 집합을 받은 또 다른 AI 에이전트로 시뮬레이션된다. 시뮬레이션 사용자는 TAU 상호작용을 이중 형식(Tool-User-Agent)으로 처리하는 더 쉬운 버전을 수행한다고 볼 수 있는데, 이때 사용자는 지시만 따르면 되며 과제 해결책을 추론할 필요는 없다.

들어 τ -bench [26]에서 retail 및 airline 도메인은 제약 충족(constraint satisfaction) 과제를 해결하는 에이전트의 능력을 시험한다. 여기서 제약은 에이전트가 따라야 하는 도메인 정책과, 믿음, 목표, 선호를 포함한 사용자의 인지 상태가 결합되어 발생한다.

이러한 설정에서 에이전트의 환경(에이전트가 취할 수 있는 행동 집합 포함)에 대한 사용자의 이해는 제약 충족 문제에 대해 하나의 해결 가능한 경로를 보장하도록 돕는 세심하게 작성된 자연어 지시문을 통해 제공된다. 이는 과제 명세를 더 쉽게 만들지만, 사용자는 의사소통을 통해서만 에이전트의 행동을 인지할 수 있고 초기 지시문에만 근거하여 환경 상태를 추론할 수 있다. 이는 기술 고객 지원과 같은 실제 시나리오와 상당히 다르다. 그런 경우 사용자는 요청을 받으면 문제를 진단하고 해결하기 위해 **휴대전화를 재시작하기** 또는 **비행기 모드 끄기** 같은 일부 행동을 능동적으로 수행해야 한다.

이러한 추가적인 실제 복잡성을 포착하기 위해 우리는 이중 제어(dual-control) 환경을 갖춘 τ^2 -bench 를 소개한다. 여기서는 (LLM으로 시뮬레이션된) 사용자가 에이전트와 의사소통하는 것에 더해 행동을 취하고 도구를 호출할 수 있다. 이중 제어 모델은 선택적 정보 은닉, 환경의 비언어적 조작, 사용자의 과제나 시나리오를 더 쉽게 명세하는 것 등 사용자 시뮬레이션을 개선하는 여러 장점을 제공한다. 특히 도구의 구조화된 형식이 비구조화된 자연어보다 선호되는 경우에 그렇다.

이중 제어 설정의 주된 과제는 도구를 통해 사용자 시뮬레이터에 의미 있는 행위 주체성(agency)을 부여하면서도 에이전트와 사용자 시뮬레이터 사이의 "복잡성 비대칭성"을 유지하는 데 있다. 즉 사용자의 어포던스(affordance)가 제한되어 있고, 사용자가 문제를 해결하려면 여전히 에이전트의 지원을 필요로 하도록 보장해야 한다. 사용자 시뮬레이터용 도구는 그 능력을 높여 이러한 균형을 깨뜨릴 수 있지만, 우리는 도구를 신중하게 설계하면 사용자 행동을 제약하여 더 신뢰할 수 있는 시뮬레이션으로 이어질 수 있음을 발견했다. 우리는 사용자 도구가 사람이 읽을 수 있는 출력만 산출하도록 보장하고, 사용자 계획을 에이전트 요청에 기반한 반응적 도구 사용으로 제한하며, 환경을 통해 사용자 행동을 긴밀하게 제약함으로써 이를 달성한다. 그 결과, 생각하는 동시에 사용자가 올바른 행동을 취하도록 효과적으로 안내해야 하는 에이전트를 위한 통제된 테스트베드가 만들어진다.

전반적으로 τ^2 -bench 는 네 가지 핵심 기여를 한다:

Telecom 이중 제어 도메인. 우리는 τ^2 -bench 안에 새로운 이중 제어 telecom 도메인을 도입한다. 여기서는 이전 벤치마크와 달리 AI 에이전트와 사용자 모두 공유되고 동적인 환경의 상태를 관찰하고, 그 위에서 행동하며, 검증하기 위한 서로 다른 도구를 가진다. 이는 분산 부분 관찰 가능 마르코프 의사결정 과정(Decentralized Partially Observable Markov Decision Process, Dec-POMDP) [15]을 사용해 정식화된다. 이 이중 제어 설정은 실제 협업 시나리오를 정확히 나타내도록 설계되었으며, 사용자에게 제한된 행위 주체성만 있는 평가에는 없는 중요한 에이전트 조정 및 의사소통 과제를 드러낸다. 실험은 최첨단 LLM도 이 도메인에서 상당히 고전함을 보여준다(예: 새 과제에서 gpt-4.1 [16]는 pass¹ 34%, o4-mini [17]는 42%, claude-3.7-sonnet [2]는 49%).

조합적 과제 생성기. τ^2 -bench 는 작은 원자적 기본 시나리오 집합(조기화, 해결, 검증 함수로 정의됨)으로부터 방대하고 다양한 검증 가능한 과제 집합을 자동으로 조합하는 프로그램적 과제 생성기를 통합한다. 이 방법은 과제의 증명 가능한 정확성을 보장하고, 완전한 도메인 포괄성을 제공하며, 과제 복잡도(예: 해결 단계 수 또는 문제 유형)에 대한 명시적 제어를 가능하게 하고, 손으로 만든 과제 모음과 관련된 수작업과 잠재적 취약성을 제거한다.

신뢰할 수 있는 사용자 시뮬레이터. 우리는 사용자 시뮬레이터를 환경과 긴밀히 결합하여 사용자 시뮬레이션의 신뢰성을 높인다. 사용자 행동은 이용 가능한 도구와 관찰 가능한 환경 상태에 의해 제약되며, 더 예측 가능하고 일관된 상호작용으로 이어진다. 이 접근은 사용자 시뮬레이터를 안내하기 위한 복잡한 자연어 프롬프팅의 필요성을 크게 줄이고, 훨씬 더 높은 신뢰성을 낳는다(예: telecom 도메인의 사용자 시뮬레이터는 오류율 16%, 치명적 오류 6%를 보였는데, 이는 τ -bench 의 retail 도메인에서 오류율 40%, 치명적 오류 12%였던 것과 대비된다).

에이전트 실패의 세분화된 진단. τ^2 -bench 는 서로 다른 모드에서 과제 성공을 평가함으로써 에이전트 성능을 분해하여 진단할 수 있게 한다. (i) 에이전트가 모든 도구를 제어하여 추론 능력을 분리하는 완전 자율 모드("no-user mode"), (ii) 의사소통 및 조정 요구사항을 도입하는 표준 이중 제어 모드가 그것이다. 우리의 결과는 에이전트가 자율 동작에서 사용자를 안내하는 방식으로 전환해야 할 때 성능이 크게 감소함(약 20% pass¹)을 드러낸다. 이는 순수 추론 실패와 의사소통 및 분산 제어에서 비롯된 실패를 명확히 구분하며, 후자가 현재 에이전트의 중요한 병목임을 정확히 지목한다.

2 관련 연구

대화형 AI 에이전트를 위한 벤치마크. 언어 에이전트(language agent) [25, 27, 10, 13, 21], LLM 도구 사용 [24, 20, 9], 과제 지향 대화(task-oriented dialog) [5, 4, 1, 22, 6, 7, 8]에 관한 긴 연구 흐름을 따라, τ -bench [26]는 도메인 규칙을 준수하면서 고객 서비스 워크플로와 같은 다중 턴 과제 지향 대화에서 언어 에이전트의 신뢰성을 측정하기 위해 최근 도입된 벤치마크다. τ -bench 의 각 과제는 사용자 시뮬레이터와 언어 에이전트 사이의 실시간 대화를 인스턴스화 하며, 과제는 retail 및 airline 두 도메인에 걸쳐 있다. 신뢰성을 정량화하기 위해 이 논문은 pass^k 지표, 즉 k개의 독립 실행 중 성공한 비율을 도입한다.

τ -bench 의 여러 후속 연구는 기본 설정의 변형을 탐구했다. FlowBench [23]는 자연어, python 유사 의사코드 또는 mermaid 플로차트를 사용해 명시적 워크플로 지식을 프롬프트에 주입함으로써 도구 사용 에이전트의 계획 단계를 분리한다. IntellAgent [12]는 도메인 규칙과 그 동시 발생 통계를 인코딩한 구조화된 정책 그래프로부터 합성 테스트 스위트를 프로그램적으로 구축하는 평가 파이프라인을 제공한다. IntellAgent는 τ -bench 를 외부 골드 스탠더드로 명시적으로 사용하며, 두 점수 분포 사이의 높은 Spearman 상관을 보고하고 빠른 합성 프록시 과제로 기능한다. APIGen-MT [19]는 τ -bench 를 위해 도구 호출 에이전트를 파인튜닝(fine-tuning) 하는 아이디어를 탐구한다. 이들은 서로 의존하는 도구 호출의 시퀀스인 대화 청사진을 만들고, 각 청사진에 기반해 대화 추적을 시뮬레이션함으로써 데이터를 생성한다. ToolSandbox [14]

는 에이전트 진행 상황을 더 세분화된 방식으로 평가하기 위해 상태를 갖는 도구를 만드는 데 초점을 맞춘다.

우리 연구는 τ -bench 패러다임을 확장하고, 사용자와 에이전트가 모두 공유 세계 위에서 (도구 호출을 통해) 상태를 바꾸는 능력을 가질 수 있도록 일반화한다. 결과에서 보이듯이 이는 대화형 에이전트를 시험하기 위한 더 복잡한 도메인을 구축할 수 있게 하며, 개선 가능한 에이전트 실패 지점의 세분화된 분석 기회도 제공한다.

대화형 에이전트를 위한 사용자 시뮬레이션. 사용자 시뮬레이션의 신뢰성은 τ -bench [26]와 같은 벤치마크의 핵심 관심사였다. 대부분의 노력은 예컨대 범용 LLM을 사용해 사용자 응답을 생성하거나 검증하는 방식 [19]으로 사용자 시뮬레이터에 감독 신호를 도입하는 데 초점을 맞추어 왔다. 반면 환경 자체를 사용해 사용자 시뮬레이터의 행동을 제약하고 형성하여 신뢰성을 높일 가능성에는 상대적으로 적은 관심이 주어졌는데, 이는 우리 접근의 핵심 원칙이다. 이러한 우려는 과제 지향 대화 시스템의 맥락에서 폭넓게 연구되어 왔으며, 초기 연구인 [18]은 사용자 시뮬레이션 평가 지표에 대한 포괄적 조사를 제공했다. 더 최근에는 [11]가 과제 지향 대화 시스템 평가를 위한 사용자-에이전트로 LLM을 효과적으로 사용할 수 있음을 보였고, 신중한 프롬프팅과 상태 추적이 더 신뢰할 수 있고 문맥을 인식하는 사용자 시뮬레이션으로 이어질 수 있음을 보여 주었다.

다중 에이전트 벤치마크. 우리 연구는 다중 에이전트 프레임워크를 구축하고 평가하려는 노력 [28]과도 관련이 있다. 우리 논문의 사용자와 에이전트를 다중 에이전트 시스템을 형성하는 것으로 볼 수 있지만, 우리 경우의 핵심 차이는 최종 평가가 여전히 사용자로부터 올바른 정보를 이끌어 내고 과제를 해결하기 위해 올바른 행동을 수행하는 에이전트의 능력에 초점을 둔다는 점이다. 이는 에이전트와 사용자 사이에 내재적 비대칭성을 도입한다. 우리의 초점은 순수한 다중 에이전트 문제를 해결하는 것이 아니라, 역시 행위 주체성을 가진 사용자를 효과적으로 안내하고 협업하는 에이전트의 역량에 있다. 이런 의미에서 이 프레임워크는 협력적(예: 문제 해결), 경쟁적(예: 구독 협상), 또는 하이브리드일 수 있으며, 에이전트가 사용자 실수나 오류까지 고려하여 시나리오를 적절히 식별하고 헤쳐 나갈 것을 요구한다.

3 τ^2 -bench: 이중 제어 환경에서의 에이전트 평가

τ^2 -bench는 대화형 AI 에이전트와 시뮬레이션된 사용자 사이의 다중 턴 상호작용을 체계적으로 연구하기 위한 플랫폼 역할을 한다. 이중 제어 상호작용은 에이전트와 사용자가 모두 의사소통하고, 도구를 사용하며, 관찰을 받을 수 있는 분산 부분 관찰 가능 마르코프 의사결정 과정 (Dec-POMDP) [15]으로 모델링된다. 이를 통해 에이전트와 사용자가 과제를 해결하기 위해 행동을 조정해야 하는 기술 문제 해결과 같은 복잡한 시나리오를 시뮬레이션할 수 있다.

3.1 Dec-POMDP 정식화

Figure 1에 보인 것처럼, τ^2 -bench의 Dec-POMDP에는 두 플레이어, 즉 에이전트와 사용자가 포함된다. 전체 과정은 튜플 $(\mathcal{S}, \{\mathcal{A}_i\}, \{\mathcal{O}_i\}, \mathcal{T}, \mathcal{R}, \mathcal{U}, \mathcal{M})$ 로 형식적으로 정의된다. 여기서 $i \in \{agent, user\}$ 는 플레이어를 나타내며, 튜플의 각 구성 요소는 아래에서 자세히 설명한다. 예시는 새 telecom 도메인에서 가져왔다.

메시지 공간 ($\mathcal{M}$): 에이전트와 사용자 사이에 교환될 수 있는 모든 가능한 (자연어) 메시지의 집합이다. 예를 들어 사용자는 “I cannot use mobile data.”라고 말할 수 있고, 에이전트는 “Could you check whether your airplane mode is on?”라고 응답할 수 있다.

상태 공간 ($\mathcal{S}$): 전역 상태 $\mathcal{S} = \mathcal{S}_{world} \otimes \mathcal{S}_{history}$ 이며, 여기서 $\mathcal{S}_{world} = \mathcal{S}_{db,agent} \otimes \mathcal{S}_{db,user}$ 는 에이전트와 사용자의 기저 데이터베이스 상태를 나타내고, $\mathcal{S}_{history}$ 는 모든 상호작용 이벤트

표 1: τ^2 -bench 도메인의 핵심 통계.

	retail	airline	telecom
에이전트 데이터베이스	사용자 500명, 제품 50개, 주문 1,000건	사용자 500명, 항공편 300편, 예약 2,000건	요금제 5개, 회선 9개, 고객 4명
에이전트 도구	write 7개, read 6개	write 6개, read 6개	write 6개, read 7개
사용자 도구	-	-	write 15개, read 15개
과제	115	50	114 (full: 2285)

(행동, 관찰, 메시지)를 기록한다. 예를 들어 telecom 도메인에서 $\mathcal{S}_{db,agent}$ 는 CRM 데이터(고객 프로필, 회선)일 수 있고, $\mathcal{S}_{db,user}$ 는 휴대전화 상태일 수 있다.

행동 공간 ($\mathcal{A}_i$): 플레이어 i 의 행동 $a_i \in \mathcal{A}_i$ 는 도구 호출 $a_{i,tool} \in \mathcal{A}_{i,tool}$ (`tool_name(**kwargs)` 같은 함수 호출을 통해 $\mathcal{S}_{db,i}$ 와 상호작용) 또는 메시지 $m_i \in \mathcal{M}$ 중 하나다. 한 턴에는 한 플레이어만 행동한다. telecom 도메인에서 에이전트는 `get_customer_by_id(id)` 같은 도구에 접근할 수 있고, 사용자는 `toggle_airplane_mode()` 같은 도구에 접근할 수 있다.

관찰 공간 ($\mathcal{O}_i$): 플레이어 i 의 관찰 $o_i \in \mathcal{O}_i$ 는 도구 관찰 $o_{i,tool}$ (예: $a_{i,tool}$ 에서 온 데이터, 메시지 또는 오류) 또는 플레이어 $j \neq i$ 가 보낸 메시지 $m_j \in \mathcal{M}$ 중 하나다. 한 턴에는 한 플레이어만 관찰을 받는다. telecom 도메인에서 에이전트는 `get_customer_by_id`로부터 고객 세부 정보를 관찰할 수 있고, 사용자는 `toggle_airplane_mode`로부터 비행기 모드가 꺼졌음을 나타내는 메시지를 관찰할 수 있다.

전이 함수 ($\mathcal{T}$): $\mathcal{T} : \mathcal{S} \times \mathcal{A} \rightarrow \mathcal{S} \times \mathcal{O}$ 를 통해 시스템 동역학을 정의한다. 현재 상태 $s \in \mathcal{S}$ 와 결합 행동 $a = (a_{agent}, a_{user})$ 가 주어지면, 새 상태 $s' \in \mathcal{S}$ 와 결합 관찰 $o = (o_{agent}, o_{user})$ 를 산출한다. 도구 $a_{i,tool} \in \mathcal{A}_{i,tool}$ 를 호출하면 $\mathcal{S}_{world}$ 가 바뀔 수 있고 $o_i \in \mathcal{O}_{i,tool}$ 가 산출될 수 있다. 메시지 $m_i \in \mathcal{M}$ 를 보내면 $j \neq i$ 에 대해 $o_j = m_i$ 가 산출된다. 두 경우 모두 s' 에는 갱신된 $\mathcal{S}_{world}$ 와 $\mathcal{S}_{history}$ 가 포함된다. 예를 들어 에이전트의 행동 `enable_roaming(customer_id, line_id)`는 세계 상태(특정 회선 번호의 로밍 서비스가 활성화됨)를 갱신하고, 사용자의 행동 `toggle_airplane_mode`는 모의 휴대전화의 상태를 갱신한다.

보상 함수 ($\mathcal{R}$): $\mathcal{R} : \mathcal{S} \rightarrow [0, 1]$ 인 함수로, 전체 상태 $s \in \mathcal{S}$ (데이터베이스 상태, 이력)에 기반해 전역 보상을 제공하여 과제 성공 또는 실패를 신호한다. 예를 들어 telecom에서는 사용자의 데이터베이스 상태로 검증했을 때 사용자 문제("no mobile data")가 해결되면 에이전트가 보상을 받는다.

지시 공간 ($\mathcal{U}$): 지시 공간 $\mathcal{U}$ 는 현실적인 사용자 시뮬레이션을 안내하는 시나리오와, 사용자를 지원할 때 에이전트가 준수해야 하는 도메인 정책을 정의한다.

Dec-POMDP 정식화는 복잡하고 상호작용적인 시나리오를 시뮬레이션하는 데 핵심적인 장점을 제공한다(상호작용 궤적의 예시는 Figure 2 참조). 이는 기술 지원처럼 사용자가 에이전트의 안내에 따라 도구 행동을 실행하는 협업 환경의 현실적인 시뮬레이션을 가능하게 한다. 이는 에이전트에게 중요한 조정 및 의사소통 과제를 제시한다. 또한 이 정식화는 사용자 시뮬레이션의 신뢰성과 제어 가능성을 높인다. 사용자 도구와 그것이 사용자 상태에 미치는 효과를 정의함으로써 사용자 행동은 더 예측 가능해지고 광범위한 자연어 프롬프팅에 덜 의존하게 된다.

3.2 도메인과 과제 생성

τ -bench와 유사하게, 우리는 새 도메인에 대한 도메인별 자료를 구축하기 위해 단계적 생성 과정을 채택했다. telecom 도메인을 예로 들면, 이 과정은 다음 단계로 이루어진다:

1단계: 에이전트의 데이터베이스 스키마와 도구 생성. 우리는 먼저 대규모 언어 모델(LLM)에 도메인의 핵심 비즈니스 로직을 개괄하는 제품 요구사항 문서(Product Requirements Document, PRD)를 생성하도록 프롬프트한다. 이 PRD는 데이터베이스 스키마와 필요한 함수를 명세한다. telecom 도메인에서는 고객과 회선을 위한 스키마 및 이를 관리하는 함수를 갖춘 고객 CRM




그림 2: telecom 도메인에서 τ^2 -bench 의 에이전트-사용자 상호작용 trajectory($S_{history}$) 예시. 사용자 도구(모의 전화)의 구현을 제어함으로써, 기저 데이터베이스 상태를 바탕으로 “상태 표시줄 확인”과 “데이터 전환” 같은 에이전트의 실행 가능한 지시에 대한 사용자의 응답을 안정적으로 시뮬레이션할 수 있다. 오른쪽 절반에서는 에이전트의 도구 호출이 사용자의 데이터베이스 상태에 미치는 영향을 모델링할 수 있음을 보여주며, 여기서는 사용자에게 대한 roaming 서비스가 에이전트 쪽에서 활성화되어 사용자의 전화가 roaming할 수 있게 된다.

시스템을 정의하는 일이 포함되었다. 그런 다음 LLM은 PRD에 기반해 함수 구현, 모의 데이터베이스, 단위 테스트를 생성한다. 우리는 모든 단위 테스트가 통과할 때까지 생성된 코드를 수동으로 정제한다.

2단계: 사용자의 데이터베이스 스키마와 도구 생성. 문제 해결 시나리오의 경우, 우리는 마찬가지로 LLM을 사용해 사용자의 데이터베이스 스키마와 도구를 정의한다. telecom 도메인에서는 상태(예: 신호 강도)와 함수(예: 비행기 모드 토글)를 갖춘 모의 사용자 휴대전화 장치를 구현하는 일이 포함되었다. 여기서도 LLM은 구현, 모의 데이터베이스, 단위 테스트를 생성하고, 이후 모든 테스트가 통과할 때까지 이를 수동으로 정제한다.

3단계: 프로그램적 과제 생성. 우리는 원자적 빌딩 블록으로부터 다양하고 검증 가능한 과제를 생성하기 위해 조합적 접근을 사용한다.

각 원자적 하위과제 t 는 해결해야 할 특정 문제에 관한 것이다. 예를 들어 비행기 모드가 켜져 있어 모바일 데이터가 작동하지 않는 경우가 있다. 구체적으로 각 하위과제 t 는 $(\{f_{t,k}^{init}\}, \{f_{t,k}^{sol}\}, \{f_{t,k}^{assert}\})$ 로 정의된다. 여기서 $f_{t,k}$ 는 에이전트 또는 사용자의 데이터베이스와 상호작용하는 하위과제 t 의 k 번째 함수 호출이다:

- 초기화 함수 $f_{t,k}^{init}$ 는 일반적으로 데이터베이스 값을 갱신하여 초기 과제 상태를 설정하는 호출을 명세한다. 예를 들어 telecom에서 초기화는 `set_airplane_mode(True)`일 수 있다.
- 해결 함수 $f_{t,k}^{sol}$ 는 초기화로 도입된 문제를 해결하기 위한 도구 호출을 명세한다. 예를 들어 `toggle_airplane_mode()`는 위에 제시한 초기화 예시에 대한 해결책일 수 있다. 이들은 에이전트나 사용자가 이용할 수 있는 도구여야 함에 유의하라.
- 검증 함수 $f_{t,k}^{assert}$ 는 과제가 해결된 것으로 간주되기 위해 최종 상태 S 가 만족해야 하는 조건을 명세한다. 예를 들어 `assert_service_status("connected")`는 telecom에서 사용자의 서비스가 활성 상태인지 확인한다.

해결 함수 $f_{t,k}^{sol}$ 는 에이전트 또는 사용자 도구로 제한되지만, 초기화 및 검증 함수는 관련 데이터베이스의 어떤 함수도 될 수 있다.

원자적 하위과제는 상호 배타적이거나 대안적인 하위과제들이 같은 그룹에 속하도록 묶인다. 복합 과제는 각 그룹에서 최대 하나의 하위과제를 선택하고, 각각의 함수 호출을 이어 붙여 생성

된다. 과제 정확성은 초기화 함수를 적용한 뒤 해결 함수를 적용했을 때 최종 상태 $s \in \mathcal{S}$ 가 모든 검증 함수를 만족하는지 확인하여 자동으로 검증된다. 또한 모든 해결 함수가 적용되기 전에는 과제가 해결되지 않음을 검증한다.

telecom 도메인에서 우리는 복잡도가 증가하는 3개의 사용자 의도, 즉 `service_issue`, `mobile_data_issue`, `mms_issue`에 대해 15개의 원자적 하위과제 그룹을 개발했다. 이 하위과제들을 프로그램적으로 조합하면 2285개의 과제가 생성된다. 그런 다음 서로 다른 의도와 하위과제 수에 걸쳐 균형 잡힌 분포를 이루도록 114개 과제를 서브샘플링했다(자세한 내용은 Appendix A). 과제의 하위과제 수는 더 많은 진단 및 해결 단계가 필요하므로 난이도의 대리 지표로 쓰인다.

4단계: 도메인별 에이전트 정책 생성. 선별된 과제와 그 해결책에 기반해, 우리는 LLM에 에이전트를 위한 도메인별 정책을 생성하도록 프롬프트한다. 문제 해결의 경우 이러한 정책은 사용자 문제를 진단하고 해결하도록 에이전트를 안내하며, 각 사용자 의도와 관련된 일반적인 문제에 대한 단계별 절차를 개괄하는 경우가 많다. 자세한 내용은 Appendix D.2에 있다.

5단계: 수동 정제. 우리는 도구, 정책, 원자적 하위과제를 포함한 모든 도메인 자료를 공동으로 정제하여 도메인의 품질을 높인다.

또한 원래 τ -bench와 비교해 τ^2 -bench는 개발자가 과제를 페르소나(Persona, 사용자의 정체성에 대한 간단한 설명)와 구체적으로 연결할 수 있게 한다. 우리는 새 도메인에서 이를 활용했다. 각 telecom 도메인 과제에는 다음 페르소나 중 하나가 무작위로 할당되었다: None, Easy, Hard. None 페르소나는 사용자 시뮬레이터에 특정 페르소나가 제공되지 않음을 의미한다. Easy 페르소나는 도메인에 상당히 익숙한 사용자의 프로필을 설명하고, Hard 페르소나는 기술 지식이 낮아 더 까다로운 사용자를 나타낸다(Appendix A.1 참조).

3.3 과제 평가

과제 성공은 DB 검사, 상태 검증, 자연어 검증, 의사소통 정보 검사, 행동 매칭이라는 서로 다른 기준으로 정의될 수 있다. DB 검사와 의사소통 정보 검사는 원래 τ -bench와 동일하다. 상태 검증은 미리 정의된 검증 함수(예: 서비스가 연결되어 있는지 확인)를 사용해 최종 세계 상태 S_{world} 의 특정 조건을 검증하는 것을 포함한다. 자연어 검증은 “the agent diagnosed the cause of the issue.”와 같은 자연어 설명을 사용해 최종 이력 상태 $S_{history}$ 의 특정 조건을 검증하는 것을 포함한다. 행동 매칭은 실제 에이전트-사용자 상호작용 궤적 안에 모든 해결 함수 $f_{t,k}^{sol}$ 가 존재하는지 검증하는 것을 포함한다. 실제로 각 과제는 그 특징에 따라 이러한 기준의 부분집합을 명세할 수 있다. telecom에서는 과제 성공을 평가하는 데 검증 함수만 사용한다.

4 실험

4.1 에이전트 설정

모든 LLM API 호출은 Litellm 패키지 [3]를 사용해 구현했다. 우리는 네 개의 대규모 언어 모델, 즉 gpt-4.1-mini-2025-04-14, gpt-4.1-2025-04-14, o4-mini-2025-04-16, claude-3-7-sonnet-20250219을 평가했다. 사용자 시뮬레이터는 gpt-4.1-2025-04-14을 사용해 구현했다. 각 과제는 네 번 실행되며, 결정적 출력을 촉진하기 위해 일관되게 LLM temperature 0을 유지했다. 에이전트와 사용자 시뮬레이터는 모두 함수 호출 에이전트(function-calling agent)로 구현되었다. 모든 도구는 OpenAI tools 형식으로 LLM에 제공된다. 에이전트 프롬프트는 도메인별 정책과 함께 일반 지침을 포함한다. 마찬가지로 사용자 프롬프트는 과제별 지시문으로 보강된 일반 지침을 포함한다. 도메인 정책과 프롬프트는 모두 Appendices C and D에서 확인할 수 있다.




그림 3: 평가한 모든 도메인(airline, retail, telecom)에 걸친 pass^k 지표. 왼쪽 위: gpt-4.1, 오른쪽 위: o4-mini, 왼쪽 아래: gpt-4.1-mini, 오른쪽 아래: claude-3.7-sonnet.

gpt-4.1-2025-04-14 에이전트가 gpt-4.1-2025-04-14 사용자 시뮬레이터와 짝지어질 때, 과제당 평균 에이전트/사용자 시뮬레이션 비용은 각각 \$0.086/\$0.059이다. 모든 도메인을 과제당 1회 시행으로 실행하는 비용은 약 \$40이다.

4.2 결과

Pass^k 점수. 우리는 검증된 τ^2 -bench 도메인(retail 및 airline)과 새 telecom 도메인에서 성능 지표를 계산했다(Figure 3 참조). 우리의 결과는 telecom 도메인이 더 큰 도전을 제시하며, 다른 도메인에 비해 전반적으로 더 낮은 성공률을 보임을 나타낸다. gpt-4.1의 pass^1 은 retail 및 airline에서 각각 74%/56%였으나 telecom에서는 34%로 떨어진다. gpt-4.1-mini, o4-mini, claude-3.7-sonnet는 telecom에서 약 50%의 pass^1 으로 더 나은 성능을 보인다. claude-3.7-sonnet의 경우 telecom의 pass^1 점수(49%)는 airline과 비슷하다. 그러나 k 가 증가함에 따라 telecom의 pass^k 점수는 airline에 비해 더 빠르게 감소하며, 이는 telecom 도메인에서 성능이 덜 일관적임을 시사한다.

절제 분석. τ^2 -bench에서 에이전트의 성공은 두 가지에 달려 있다. 1) 문제를 해결하기 위해 사용자와 얼마나 잘 의사소통하고 협업할 수 있는가, 2) 정책 문서에 명시된 도메인 지침을 얼마나 잘 추론하고 적용할 수 있는가. 이러한 구성 요소 각각, 즉 이중 제어에서의 추론과 의사소통의 영향을 이해하기 위해 우리는 절제 연구를 수행한다. 구체적으로 telecom 도메인에서 세 가지 서로 다른 설정에 걸쳐 성능을 평가한다:

- **Default:** 에이전트와 사용자가 이중 제어 설정에서 협업하는 기본 에이전트 및 사용자 시뮬레이터 구성이다.
- **No-User:** 에이전트에는 사용자의 문제와 성공 기준을 요약한 티켓이 제공된다. 에이전트는 일반적으로 사용자가 조작하는 도구를 포함해 모든 도구를 제어하며, 문제 해결을 전적으로 담당한다. 이 설정은 사용자와 상호작용하는 능력과 독립적으로 에이전트의 추론 및 도구 호출 능력을 시험한다.
- **Oracle Plan:** 에이전트에는 문제 해결에 필요한 도구 호출 시퀀스가 제공되며, 여기에는 에이전트와 사용자 양쪽의 행동이 모두 포함된다. 이 설정은 에이전트의 추론 부담을 완화하고, 알려진 계획을 실행하기 위해 사용자와 협업하는 능력에 초점을 맞춘다.

Figure 4(왼쪽)는 gpt-4.1와 o4-mini에 대해 이러한 설정 전반의 성능을 보고하며, 핵심 통찰을 드러낸다. Oracle Plan와 Default 구성의 차이는 추론 부담이 에이전트 성능에 미치는




그림 4: Default 사용자 시뮬레이션을 사용했을 때, 서로 다른 운영 모드(Default, No-User, Oracle Plan)에 걸친 Telecom 도메인의 pass@1 지표. 왼쪽: 원래 정책. 오른쪽: workflow 기반 정책. 이 그림은 추론 부하와 분산 제어가 에이전트 성능에 미치는 영향을 보여 준다.




그림 5: telecom의 다양한 과제에 대한 pass@1 점수. 해결에 필요한 행동 수(왼쪽) 또는 처리해야 할 서로 다른 문제 수(오른쪽)에 따라 구간화했다. transfer는 사람에게 이관해야 하며 에이전트 단독으로는 해결할 수 없는 과제의 특수한 경우를 가리킨다. (회색 막대는 해당 구간에 속하는 과제의 비율을 나타낸다.)

영향을 강조한다. 당연히 정답 정보를 제공하면 Default 설정보다 더 나은 성능으로 이어진다. 그러나 이 효과가 gpt-4.1 보다 o4-mini 에서 더 크다는 점은 주목할 만하며, o4-mini 가 정답 정보를 더 잘 활용할 수 있음을 시사한다.

No-User 와 Default 모드의 비교는 이중 제어와 그에 수반되는 의사소통 오버헤드가 에이전트 오류율과 전체 성공에 미치는 영향을 보여 준다. 두 모델 모두에서, 사용자 없는 동작(No-User)에서 에이전트가 사용자를 안내해야 하는 협업 설정(Default)으로 전환하면 pass@1 이 크게 하락한다(gpt-4.1 는 18% 하락, o4-mini 는 25% 하락). 이는 LLM이 환경의 제어를 공유하는 능동적 사용자와 함께 문제를 해결할 때 여전히 상당한 어려움에 직면함을 강조한다.

정책 문서가 성능에 미치는 영향. Figure 4는 정책 문서가 과제 성공에 미치는 영향도 분석할 수 있게 한다. 구체적으로 우리는 각 유형의 과제를 해결하는 데 필요한 워크플로에 대해 더 구체적인 세부 정보를 제공하는 대체 정책 문서를 만들었다. 이는 워크플로가 있으면 에이전트에 더 구체적인 안내를 제공한다는 근거에 따른 것이다(Appendices D.2.2 and D.2.3 참조). 실제로 그런 경향이 관찰되었으며, Default 및 No-User 모드에서 워크플로 정책(오른쪽)을 사용하면 원래 정책(왼쪽)에 비해 에이전트 성능이 약간 향상된다. 놀랍게도 워크플로 정책 문서는 gpt-4.1 와 o4-mini 모두에서 Oracle Plan 성능을 해친다. 여기서 우리의 가설은 에이전트가 이미 정답 행동 시퀀스를 가지고 있기 때문에, 워크플로를 제공하면 도움이 되기보다 혼란을 일으켜 성능을 해칠 수 있다는 것이다.

행동 수와 하위과제 수의 영향. Figure 5는 telecom의 다양한 과제에 대한 pass@1 점수를, 해결에 필요한 행동 수(왼쪽) 또는 처리해야 하는 서로 다른 하위과제 수(오른쪽)별로 구간화하여 분해해 보여 준다. transfer는 인간에게 이관되어야 하며 에이전트만으로는 해결할 수 없는 과제의 특수한 경우를 가리킨다.




그림 6: telecom 도메인에서 문제 유형별 gpt-4.1 (왼쪽 위), o4-mini (오른쪽 위), gpt-4.1-mini (왼쪽 아래), claude-3.7-sonnet (오른쪽 아래)의 pass@k . service_issue, mobile_data_issue, mms_issue 문제 유형에 대한 성능을 보여 주며, 서로 다른 문제 유형이 성공률에 어떤 영향을 미치는지 강조한다.

예상대로 기본 모델이 gpt-4.1 이든 o4-mini 이든, 행동 수가 증가함에 따라 에이전트 성능은 떨어지며 Default 모드에서 > 7개 행동의 경우 거의 0에 도달한다. No-User 모드는 전반적으로 더 높은 점수를 낳지만, 행동 수가 증가함에 따라 격차는 (약 0.3-0.4에서 <0.2로) 줄어든다. 이는 더 긴 지평의 과제에서 신뢰성을 유지하는 것이 두 설정 모두에서 여전히 도전이며, 사용자와의 의사소통만이 유일한 병목은 아님을 암시한다. 흥미롭게도 No-User 에서는 꼬리 부분(10개 이상 행동)에서 gpt-4.1 가 o4-mini 보다 더 잘 수행한다.

과제당 서로 다른 하위과제 수가 증가할 때도 유사한 경향을 관찰한다. 두 기본 모델 모두에서 성능은 하락 추세를 보이며, no-user 모드는 일반적으로 default 모드보다 높다. 이 두 결과는 우리의 도메인 설계와 과제 생성 과정이 행동 길이를 늘리거나 서로 다른 하위과제를 단일 과제로 결합함으로써 복잡도를 확장하는 자연스러운 경로를 제공함을 검증한다.

문제 유형의 영향. telecom 도메인은 마주칠 수 있는 세 가지 서로 다른 문제를 반영하는 세 가지 주요 사용자 의도, 즉 service_issue, mobile_data_issue, mms_issue 를 중심으로 구성되며, 각각은 도메인 정책이 제시한 특정 절차를 포함한다. 이러한 문제 유형은 내재적인 난이도 위계를 갖도록 설계되었다. 예를 들어 service_issue 과제는 일반적으로 간단한 행동 시퀀스를 통해 독립적으로 해결될 수 있다. 반면 mobile_data_issue 또는 mms_issue 를 성공적으로 처리하려면 먼저 기저의 service_issue 문제를 확인하고 잠재적으로 해결해야 하는 경우가 많다. 이러한 의존성은 과제 난이도에 자연스러운 순서를 만들며, service_issue 가 가장 쉽고 mobile_data_issue 및 mms_issue 는 더 복잡한 다단계 문제를 나타낸다.

Figure 6는 문제 유형별 성능 분해 분석을 제공한다. 우리는 모든 LLM(gpt-4.1, o4-mini, claude-3.7-sonnet, gpt-4.1-mini)의 pass@k 점수가 더 복잡한 문제 유형(mobile_data_issue 및 mms_issue)에서의 더 높은 실패율에 의해 좌우됨을 관찰한다. 이는 더 어려운 문제 유형에 필요한 다단계 추론과 조건부 논리가 에이전트에게 상당한 도전을 제기함을 시사한다. 또한 문제 유형 전반의 분포가 모델별로 약간 다르다는 점도 발견했다. 예를 들어 claude-3.7-sonnet 는 mobile_data_issue 에서 o4-mini 보다 더 잘하지만 service_issue 에서는 더 못한다.

사용자 페르소나의 영향. Figure 7는 사용자 페르소나별 성능 분해 분석을 제공한다. 결과는 에이전트가 Hard 페르소나와 관련된 과제보다 Easy 페르소나와 관련된 과제에서 더 잘 수행하는 경향이 있음을 확인한다. 흥미롭게도 페르소나 정보가 없는 과제(None)에서의 에이전트 성능은 Hard 페르소나와 관련된 과제의 성능과 비슷하거나 더 낮은 경향이 있다. 이는 실제 배포 전에 잘 정의된 사용자 페르소나로 AI 시스템을 시험하는 일이 매우 중요함을 강조한다.




그림 7: telecom 도메인에서 페르소나 유형별 gpt-4.1 (왼쪽 위), o4-mini (오른쪽 위), gpt-4.1-mini (왼쪽 아래), claude-3.7-sonnet (오른쪽 아래)의 pass^k . 서로 다른 사용자 특성이 성공률에 어떤 영향을 미치는지 강조하여, 다양한 페르소나 유형 전반의 성능을 보여 준다.

4.3 이중 제어는 벤치마크 신뢰성에 어떤 영향을 미치는가?

대화형 에이전트 벤치마크의 신뢰성을 보장하는 것은 무엇보다 중요하다. 세 가지 주요 불확실성 원천이 벤치마크 신뢰성에 영향을 줄 수 있다: **구현 오류**, **과제 명세 오류**, **사용자 시뮬레이터 오류**. 사용자 시뮬레이터는 신중한 평가가 필요한 핵심 구성 요소로 자주 언급되지만, 그 평가는 벤치마크 구현이나 과제 정의의 문제로 인해 교란될 수 있다. 따라서 우리는 사용자 시뮬레이터 자체를 평가하기 전에 먼저 이러한 잠재적 오류 원천을 다룬다. 이는 Appendix B에 자세히 설명되어 있다.

사용자 시뮬레이터 품질 평가. 벤치마크 구현과 과제 명세의 오류를 최소화한 뒤, 우리는 사용자 시뮬레이터 품질을 평가했다.

도메인 전반에서 사용자 시뮬레이터의 품질을 평가하기 위해, 우리는 사용자 시뮬레이터와 에이전트 모두에 gpt-4.1 를 사용해 생성한 상호작용 궤적을 수동으로 주석 처리했다.

각 대화는 사용자 시뮬레이터 오류를 식별하는 임무를 받은 두 명의 독립 주석자가 검토했다. 주석자에게는 사용자 시뮬레이터 지침, 해당 대화의 구체적인 사용자 지시문(Appendix C.2 참조), 이용 가능한 사용자 도구(있는 경우)에 대한 설명, 그리고 전체 대화 궤적(메시지와 도구 호출)이 제공되었다. 주석자는 각 사용자 턴을 네 가지 기준에 따라 평가했다: **사용자 시뮬레이터 지침 준수**, **사용자 지시문 준수**, **사용자 도구의 올바른 사용**, **자연스럽고 일관된 대화 이어가기** 생성.

오류는 (1) **과제 치명적 오류**: 과제 완료를 불가능하게 하는 고심각도 실패(예: 사용자 목표와 모순되는 의도 생성 또는 복구 불가능한 상태 전이 유발), 또는 (2) **과제 무해 오류**: 과제 완료를 방해하지 않는 오류로 분류되었다.

사용자 시뮬레이터의 신뢰성. Table 2에 보인 것처럼, 사용자 시뮬레이터 행동에 대한 우리의 분석은 새 telecom 도메인에서 신뢰성이 크게 향상되었음을 드러낸다. retail 및 airline 도메인에서는 사용자 시뮬레이터 오류율이 각각 40%와 47%였고(이 중 과제 완료를 방해하는 치명적 오류가 각각 12%와 13%), telecom 도메인에서는 이 비율이 훨씬 낮아 보고된 오류율이 16%, 치명적 오류가 6%에 불과했다. 이러한 신뢰성의 상당한 향상은 환경과 이용 가능한 어포던스를 통해 사용자 행동을 형성하고 긴밀히 제약하는 도메인 설계에 기인할 수 있다. 행동을 안내하기 위해 자연어 명세에 크게 의존하기보다, telecom 도메인의 구조화된 인터페이스와 명확한 행동

표 2: 도메인별 사용자 시뮬레이터 오류 수(비율). 치명 사용자 오류는 에이전트가 과제를 해결하지 못하게 하지만, 경미 오류는 과제 완료에 영향을 주지 않는다. 새로운 telecom 도메인은 오류율이 훨씬 낮으며, 치명 오류가 보고되지 않았다. (추가 세부 사항은 Appendix E 참조).

도메인	대화 수	치명 오류	경미 오류	전체 오류
airline	100	13 (13%)	34 (34%)	47 (47%)
retail	50	6 (12%)	14 (28%)	20 (40%)
telecom	50	3 (6%)	5 (10%)	8 (16%)

공간은 사용자 시뮬레이터를 올바른 상호작용으로 자연스럽게 안내하여 더 일관되고 예측 가능한 행동을 낳는다.

5 결론

우리는 이중 제어 설정을 도입하여 τ -bench 를 일반화한 τ^2 -bench 를 제시했으며, 조정과 의사소통 요구사항 때문에 LLM의 성능이 크게 하락함을 발견했다. 이는 사용자 요청을 해결하는데 있어 순수 추론 능력보다 이러한 요소들이 중요한 병목임을 강조한다.

사용자 시뮬레이터를 개선하기 위해서는 아직 해야 할 일이 남아 있다. 선별된 도구로 사용자를 보강하면 치명적 오류를 피하는 데 도움이 될 수 있음을 보였지만, 이 방법을 기존 airline 및 retail 도메인에 어떻게 적용할 수 있을지는 아직 조사하지 않았다. 이를 수행하면 고품질 사용자 시뮬레이터를 보장하기 위한 더 일반적인 해법으로 나아갈 길이 열릴 것이다.

벤치마크의 도메인 포괄성을 확장하는 일은 여전히 인간 전문가에 크게 의존한다. 벤치마킹 방법이 산업계에 채택되어 절실히 필요한 표준을 제공하려면, 도메인 큐레이션 과정을 자동화하는 방법을 더 깊이 조사하는 것이 중요하다.

τ^2 -bench 의 중요한 한계 중 하나는 대부분의 고객 지원 과제에 내재한 전문가-초보자 간극을 명시적으로 모델링하지 않는다는 점이다. 순진한 사용자와 상호작용할 때 전문가는 사용자의 멘탈 모델을 이해하고 그에 맞게 설명을 조정해야 한다. 이 간극을 메우는 AI 에이전트의 능력을 평가하고 개선하는 것은 향후 연구의 유망한 방향이며, τ^2 -bench 는 그러한 탐구를 위한 강력한 출발점을 제공한다.

감사의 말

이 연구를 강화하는 데 도움이 된 유익한 논의와 피드백을 제공한 Noah Shinn, Dongxu Zhou, Ola Zytek, Keshav Dhandhanian에게 감사한다. 또한 실험을 위해 서로 다른 LLM API를 설정하는 데 도움을 준 Kevin Gao, Nate White, Kimberly Patron에게, 그리고 변함없는 지원을 해준 Clay Bavor에게 감사한다.

References

- [1] Jacob Andreas, John Bufe, David Burkett, Charles Chen, Josh Clausman, Jean Crawford, Kate Crim, Jordan DeLoach, Leah Dornier, Jason Eisner, et al. Task-oriented dialogue as dataflow synthesis. *Transactions of the Association for Computational Linguistics*, 8:556–571, 2020.
- [2] Anthropic. Claude 3.7 Sonnet, 2025. Model release: 2025-02-24.

- [3] BerriAI. litellm, 2025.
- [4] Paweł Budzianowski, Tsung-Hsien Wen, Bo-Hsiang Tseng, Inigo Casanueva, Stefan Ultes, Osman Ramadan, and Milica Gasic. Multiwoz – a large-scale multi-domain wizard-of-oz dataset for task-oriented dialogue modelling. *arXiv preprint arXiv:1810.00278*, 2018.
- [5] Derek Chen, Howard Chen, Yi Yang, Alex Lin, and Zhou Yu. Action-based conversations dataset: A corpus for building more in-depth task-oriented dialogue systems. *arXiv preprint arXiv:2104.00783*, 2021.
- [6] Izzeddin Gür, Dilek Hakkani-Tür, Gokhan Tür, and Pararth Shah. User modeling for task oriented dialogues. In *2018 IEEE Spoken Language Technology Workshop (SLT)*, pages 900 – 906, 2018.
- [7] He He, Derek Chen, Anusha Balakrishnan, and Percy Liang. Decoupling strategy and generation in negotiation dialogues. *arXiv preprint arXiv:1808.09637*, 2018.
- [8] Zhiyuan Hu, Yue Feng, Anh Tuan Luu, Bryan Hooi, and Aldo Lipani. Unlocking the potential of user feedback: Leveraging large language model as user simulators to enhance dialogue system. In *Proceedings of the 32nd ACM International Conference on Information and Knowledge Management, CIKM ’23*. ACM, October 2023.
- [9] Yue Huang, Jiawen Shi, Yuan Li, Chenrui Fan, Siyuan Wu, Qihui Zhang, Yixin Liu, Pan Zhou, Yao Wan, Neil Zhenqiang Gong, et al. Metatool benchmark for large language models: Deciding whether to use tools and which to use. *arXiv preprint arXiv:2310.03128*, 2023.
- [10] Carlos E Jimenez, John Yang, Alexander Wettig, Shunyu Yao, Kexin Pei, Ofir Press, and Karthik Narasimhan. Swe-bench: Can language models resolve real-world github issues? *arXiv preprint arXiv:2310.06770*, 2023.
- [11] Taaha Kazi, Ruiliang Lyu, Sizhe Zhou, Dilek Hakkani-Tür, and Gokhan Tür. Large Language Models as User-Agents for Evaluating Task-Oriented-Dialogue Systems, November 2024. *arXiv:2411.09972*.
- [12] Elad Levi and Ilan Kadar. Intellagent: A multi-agent framework for evaluating conversational ai systems. *arXiv preprint arXiv:2501.11067*, 2025.
- [13] Xiao Liu, Hao Yu, Hanchen Zhang, Yifan Xu, Xuanyu Lei, Hanyu Lai, Yu Gu, Hangliang Ding, Kaiwen Men, Kejuan Yang, et al. Agentbench: Evaluating llms as agents. *arXiv preprint arXiv:2308.03688*, 2023.
- [14] Jiarui Lu, Thomas Holleis, Yizhe Zhang, Bernhard Aumayer, Feng Nan, Felix Bai, Shuang Ma, Shen Ma, Mengyu Li, Guoli Yin, et al. Toolsandbox: A stateful, conversational, interactive evaluation benchmark for llm tool use capabilities. *arXiv preprint arXiv:2408.04682*, 2024.
- [15] Frans A Oliehoek, Christopher Amato, et al. *A concise introduction to decentralized POMDPs*, volume 1. Springer, 2016.
- [16] OpenAI. gpt-4.1, 2025. Model release: 2025-04-14.
- [17] OpenAI. o4-mini, 2025. Model release: 2025-04-16.
- [18] Olivier Pietquin and Helen Hastie. A survey on metrics for the evaluation of user simulations. *The knowledge engineering review*, 28(1):59 – 73, 2013. Publisher: Cambridge University Press.

- [19] Akshara Prabhakar, Zuxin Liu, Weiran Yao, Jianguo Zhang, Ming Zhu, Shiyu Wang, Zhiwei Liu, Tulika Awalganekar, Haolin Chen, Thai Hoang, et al. Apigen-mt: Agentic pipeline for multi-turn data generation via simulated agent-human interplay. *arXiv preprint arXiv:2504.03601*, 2025.
- [20] Yujia Qin, Shihao Liang, Yining Ye, Kunlun Zhu, Lan Yan, Yaxi Lu, Yankai Lin, Xin Cong, Xiangru Tang, Bill Qian, et al. Toolllm: Facilitating large language models to master 16000+ real-world apis. In *ICLR*, 2024.
- [21] Yangjun Ruan, Honghua Dong, Andrew Wang, Silviu Pitis, Yongchao Zhou, Jimmy Ba, Yann Dubois, Chris J Maddison, and Tatsunori Hashimoto. Identifying the risks of lm agents with an lm-emulated sandbox. *arXiv preprint arXiv:2309.15817*, 2023.
- [22] Jost Schatzmann, Daniel Jurafsky, Michael Galley, and David Trevillian. Evaluating agenda-based user simulation for reinforcement learning of dialogue management. In *Speech Communication*, volume 47, pages 95 – 121, 2007.
- [23] Ruixuan Xiao, Wentao Ma, Ke Wang, Yuchuan Wu, Junbo Zhao, Haobo Wang, Fei Huang, and Yongbin Li. Flowbench: Revisiting and benchmarking workflow-guided planning for llm-based agents. *arXiv preprint arXiv:2406.14884*, 2024.
- [24] Fanjia Yan, Huanzhi Mao, Charlie Cheng-Jie Ji, Tianjun Zhang, Shishir G. Patil, Ion Stoica, and Joseph E. Gonzalez. Berkeley function calling leaderboard. https://gorilla.cs.berkeley.edu/blogs/8_berkeley_function_calling_leaderboard.html, 2024.
- [25] Shunyu Yao, Howard Chen, John Yang, and Karthik Narasimhan. Webshop: Towards scalable real-world web interaction with grounded language agents. *Advances in Neural Information Processing Systems*, 35:20744 – 20757, 2022.
- [26] Shunyu Yao, Noah Shinn, Pedram Razavi, and Karthik Narasimhan. τ -bench: A benchmark for tool-agent-user interaction in real-world domains. *arXiv preprint arXiv:2406.12045*, 2024.
- [27] Shuyan Zhou, Frank F Xu, Hao Zhu, Xuhui Zhou, Robert Lo, Abishek Sridhar, Xianyi Cheng, Yonatan Bisk, Daniel Fried, Uri Alon, et al. WebArena: A Realistic Web Environment for Building Autonomous Agents. *arXiv preprint arXiv:2307.13854*, 2023.
- [28] Kunlun Zhu, Hongyi Du, Zhaochen Hong, Xiaocheng Yang, Shuyi Guo, Zhe Wang, Zhenhailong Wang, Cheng Qian, Xiangru Tang, Heng Ji, et al. Multiagent-bench: Evaluating the collaboration and competition of llm agents. *arXiv preprint arXiv:2503.01935*, 2025.

더 넓은 영향

대규모 언어 모델(Large Language Models, LLMs)과 AI 에이전트를 위한 표준화된 벤치마크의 개발은 빠르게 발전하는 기술 속에서 사회적 통제를 보장하고 공정성을 촉진하는 데 매우 중요하다. 이러한 벤치마크는 투명한 평가를 위한 프레임워크를 제공할 뿐 아니라, 연구 그룹들이 공통 과제를 중심으로 노력을 조율할 수 있게 하여 해당 분야의 전반적 진전을 가속한다. 본 연구 자체가 직접적인 부정적 사회적 함의를 갖지는 않을 수 있지만, 현실 세계 에이전트의 개발에 기여하며, 이러한 에이전트는 필연적으로 다양한 경제적·사회적 결과를 낳을 것이다. 따라서 AI 에이전트가 인간 사용자와 효과적이고 안전하게 협업하도록 설계되는 것 또한 매우 중요하며, 이는 에이전트를 상업적 환경과 일상생활에 책임 있게 통합하기 위한 전제 조건이다.

부록

A 통신 도메인

서로 다른 사용자 의도에 걸친 과제 수와 전체 과제 수는 Table 3에 제시되어 있다.

표 3: 각 의도와 하위 과제 수별로 표본 추출된 과제 수.

하위 과제 수	service_issue	mobile_data_issue	mms_issue	합계
2	9	8	8	25
3	9	8	9	26
4	9	6	6	21
5	2	6	5	13
6	—	5	6	11
7	—	3	5	8
8	—	—	4	4
9	—	—	6	6
합계	29	36	49	114

통신 도메인에는 service_issue, mobile_data_issue, mms_issue 의 3가지 서로 다른 의도가 있다. 문제를 해결하는 데 필요한 행동 수가 의도별로 어떻게 달라지는지는 Table 4에 제시되어 있다.

표 4: 문제를 해결하는 데 필요한 행동 수.

의도	평균	표준편차	최소	최대
service_issue	2.31	2.25	1	8
mobile_data_issue	4.31	1.79	2	8
mms_issue	6.00	2.85	2	12

A.1 사용자 페르소나

기술 전문성과 기술에 대한 편안함의 서로 다른 수준을 나타내기 위해 두 가지 구별되는 사용자 페르소나를 정의한다:

Persona 1: Easy 41세의 사무 관리자이며, 업무와 개인 용도 모두에 휴대전화를 매일 사용한다. 일반적인 휴대전화 기능에는 익숙하지만 스스로를 기술 애호가라고 부르는 것을 싫어한다.

기술 역량은 평균적이다. 통화, 문자, 이메일, 기본 앱 같은 표준 스마트폰 기능은 쉽게 다룬다. 기본 설정은 이해하지만, 새로운 것을 시도할 때에는 명확한 단계별 안내를 선호한다.

상호작용에서는 자연스럽게 친절하고 인내심이 있다. 도움을 받을 때에는 주의 깊게 듣고 질문하는 것을 두려워하지 않는다. 자신이 이해한 바를 확인하고, 받은 각 지시에 대해 자세한 피드백을 제공하려고 한다.

Persona 2: Hard 64세이며 은퇴한 사서로, 휴대전화 사용은 주로 통화, 문자, 손주 사진 촬영 정도로 단순하게 유지한다. 기술 전반에 대해 불안하고 압도되는 느낌을 받는다.

기술 지식은 상당히 제한적이다. 단계별 지시도 종종 혼란스럽고, "VPN"이나 "APN" 같은 기술 용어는 외국어처럼 느껴질 수 있다. 구체적으로 요청받을 때에만 정보를 공유한다.

기술을 다룰 때에는 쉽게 당황하는 경향이 있다. 지속적인 안심이 필요하고, 불안한 질문으로 자주 끼어든다. "휴대전화를 재부팅하세요" 같은 간단한 요청도 소중한 사진을 잃을까 하는 걱정을 유발할 수 있다.

A.2 예시 과제

과제 세부사항

ID

[service_issue]airplane_mode_on[unseat_sim_card]

설명

- ****목적****: 해결 경로 테스트: 서비스 없음/연결 문제.

사용자 시나리오

- ****지시사항****:

- ****도메인****: telecom

- ****전화 이유****: 지난 몇 시간 동안 휴대전화에 'No Service'가 표시되고 있습니다.

- ****알려진 정보****: 당신은 John Smith이며 전화번호는 555-123-2002입니다.

- ****알 수 없는 정보****: null

- ****과제 지시사항****: 에이전트가 문제를 즉시 해결하지 못하는 조치를 제안하면, 그 안내를 따르되 첫 번째 실패한 시도 이후에는 약간의 답답함을 표현하세요.

상태 표시줄에 신호가 있다고 표시되면 문제가 해결된 것으로 간주합니다.

도구 호출이 업데이트된 상태 정보를 반환하지 않으면, 업데이트된 상태를 얻기 위해

다른 도구 호출을 수행해야 할 수도 있습니다.

티켓

사용자가 휴대전화 서비스 문제를 겪고 있습니다. 전화를 걸거나 받을 수 없고,

상태 표시줄에는 'No Service'가 표시됩니다. 고객 이름: John Smith, 전화번호:

555-123-2002. 상태 표시줄에 신호가 있다고 표시되면 문제가 해결된 것으로 간주합니다.

초기 상태

- ****초기화 데이터****: null

- ****초기화 작업****:

1. ****작업****: set_user_info

```

- **환경 유형**: user
- **인수**:
  - name: John Smith
  - phone_number: 555-123-2002
2. **작업**: turn_airplane_mode_on
  - **환경 유형**: user
  - **인수**: {}
3. **작업**: unseat_sim_card
  - **환경 유형**: user
  - **인수**: {}

## 평가 기준
### 작업
1. **작업 ID**: toggle_airplane_mode_0
  - **요청자**: user
  - **이름**: toggle_airplane_mode
  - **인수**: {}

2. **작업 ID**: reseat_sim_card_1
  - **요청자**: user
  - **이름**: reseat_sim_card
  - **인수**: {}

### 환경 단언
- **환경 유형**: user
- **함수**: assert_service_status
- **인수**:
  - expected_status: connected
- **단언 값**: true

```

A.3 예시 궤적 1: Default 모드

Appendix A.2의 과제를 Default 모드에서 수행한 궤적.

어시스턴트: 안녕하세요! 오늘 무엇을 도와드릴까요?

사용자: 안녕하세요! 지난 몇 시간 동안 휴대폰에 "No Service"가 표시되고 있습니다. 전화를 걸 수도 없고 모바일 데이터도 사용할 수 없습니다. 해결을 도와주실 수 있나요?

어시스턴트: "No Service" 문제를 도와드리려면 먼저 계정을 식별해야 합니다. 다음 중 하나를 알려주시겠습니까?

- 계정에 연결된 전화번호
- 고객 ID
- 성명과 생년월일

이 정보를 받으면 문제 해결을 시작할 수 있습니다.

사용자: 네! 제 전화번호는 555-123-2002이고 이름은 John Smith입니다. 진행하는 데 더 필요한 것이 있으면 알려주세요.

어시스턴트: [시스템이 고객 정보를 검색함]

도 구 : [Tool call: get_customer_by_phone(phone_number: "555-123-2002")]

```
{
  "customer_id": "C1001",
  "full_name": "John Smith",
  "date_of_birth": "1985-06-15",
  "email": "john.smith@example.com",
  "phone_number": "555-123-2002",
  "address": {
    "street": "123 Main St",
    "city": "Anytown",
    "state": "CA",
    "zip_code": "90210"
  },
  "account_status": "Active",
  "payment_methods": [{
    "method_type": "Credit Card",
    "account_number_last_4": "1235",
    "expiration_date": "12/2026"
  }],
  "line_ids": ["L1001", "L1002", "L1003"],
  "bill_ids": ["B1001", "B1002", "B1003"],
  "created_at": "2025-01-15 10:30:00",
  "last_extension_date": null,
  "goodwill_credit_used_this_year": 25.0
}
```

어시스턴트: 정보를 제공해 주셔서 감사합니다. "No Service" 문제 해결을 시작하기 위해 휴대폰의 연결 상태를 확인해 주시겠습니까? 구체적으로 다음을 알려주세요.

- 현재 비행기 모드가 켜져 있나요, 꺼져 있나요?
- 신호 막대나 네트워크 이름이 표시되나요?

이 정보는 문제 해결을 위한 다음 단계를 정하는 데 도움이 됩니다.

사용자: [시스템이 네트워크 상태를 확인함]

도구: [Tool call: get_network_status()]

Airplane Mode: ON
SIM Card Status: invalid
Cellular Connection: no_service
Cellular Signal: none
Cellular Network Type: none
Mobile Data Allowed: Yes
Roaming: No
Data Roaming Allowed: No
Wi-Fi Radio: OFF
Wi-Fi Connected: No

사용자: 비행기 모드가 현재 켜져 있고, 신호 막대나 네트워크 이름이 표시되지 않는 것 같습니다. 다음에는 무엇을 해야 하나요?

어시스턴트: 휴대폰에서 비행기 모드를 꺼 주세요. 그런 다음 네트워크 연결이 복구되었는지 확인해 주세요(신호 막대나 통신사 이름이 나타나는지 확인). 이것으로 문제가 해결되는지, 아니면 여전히 "No Service"가 보이는지 알려주세요.

사용자: [시스템이 비행기 모드를 전환함]

도구: [Tool call: toggle_airplane_mode()]

Airplane Mode is now OFF.

Status Bar: [No Signal] | [Battery 80%]

사용자: 비행기 모드를 껐지만 휴대폰 상태 표시줄에는 여전히 "No Signal"이 표시됩니다. 다음에는 무엇을 시도해야 하나요?

어시스턴트: 확인해 주셔서 감사합니다. 다음으로 휴대폰에서 SIM 카드 상태를 확인해 주세요. SIM 카드가 인식되는지, 없거나 잘못되었거나 잠겨 있는 것 같은 문제가 있는지 판단하는 데 도움이 됩니다.

SIM 상태를 확인하고 무엇이라고 표시되는지 알려주시겠습니까?

사용자: [시스템이 SIM 상태를 확인함]

도구: [Tool call: get_sim_status()]

SIM 카드가 유효하지 않거나 인식되지 않습니다.

사용자: SIM 카드가 유효하지 않거나 휴대폰에서 인식되지 않는 것 같습니다. 이를 해결하려면 어떻게 해야 하나요?

어시스턴트: 휴대폰에서 SIM 카드를 제거한 다음 단단히 다시 삽입해 보세요. 완료한 뒤 휴대폰이 이제 SIM 카드를 인식하는지, 네트워크 신호가 돌아오는지 확인해 주세요.

SIM 상태가 개선되는지, 아니면 문제가 지속되는지 알려주세요.

사용자: [시스템이 SIM 카드를 다시 삽입함]

도구: [Tool call: reseat_sim_card()]

SIM card re-seated successfully.

Status Bar: [Signal 4] Excellent | 5G | [Data] Enabled | [Battery 80%]

사용자: SIM 카드를 다시 삽입했더니 이제 상태 표시줄에 5G 연결과 함께 신호 강도가 가득 표시됩니다. 문제가 해결된 것 같습니다! 감사합니다!

어시스턴트: SIM 카드를 다시 삽입해서 문제가 해결되었고 휴대폰에 이제 5G 연결과 가득 찬 신호 강도가 표시된다니 다행입니다.

추가 문제가 있거나 다른 질문이 있으면 언제든지 연락해 주세요. 좋은 하루 보내세요!

사용자: 도와주셔서 정말 감사합니다! 이제 모든 것이 완벽하게 작동하는 것 같습니다. 멋진 하루 보내세요! [STOP]

A.4 예시 쿼리 2: No-User 모드

Appendix A.2의 과제를 No-User 모드에서 수행한 쿼리.

어시스턴트: [시스템이 고객 정보를 검색함]

도 구 : [Tool call: get_customer_by_phone(phone_number: "555-123-2002")]

```
{
  "customer_id": "C1001",
  "full_name": "John Smith",
  "date_of_birth": "1985-06-15",
  "email": "john.smith@example.com",
  "phone_number": "555-123-2002",
  "address": {
    "street": "123 Main St",
    "city": "Anytown",
    "state": "CA",
    "zip_code": "90210"
  },
  "account_status": "Active",
  "payment_methods": [{
    "method_type": "Credit Card",
    "account_number_last_4": "1235",
    "expiration_date": "12/2026"
  }],
  "line_ids": ["L1001", "L1002", "L1003"],
  "bill_ids": ["B1001", "B1002", "B1003"],
  "created_at": "2025-01-15 10:30:00",
  "last_extension_date": null,
  "goodwill_credit_used_this_year": 25.0
}
```

어시스턴트: [시스템이 회선 세부 정보를 검색함]

도구: [Tool call: get_details_by_id(id: "L1001")]

```
{
  "line_id": "L1001",
  "phone_number": "555-123-2001",
  "status": "Active",
  "plan_id": "P1001",
  "device_id": "D1001",
  "data_used_gb": 3.2,
  "data_refueling_gb": 0.0,
  "roaming_enabled": false,
  "contract_end_date": "2026-12-31",
  "last_plan_change_date": "2025-01-10",
  "last_sim_replacement_date": null,
  "suspension_start_date": null
}
```

어시스턴트: [시스템이 추가 회선 세부 정보를 검색함]

도구: [Tool call: get_details_by_id(id: "L1002")]

```
{
  "line_id": "L1002",
  "phone_number": "555-123-2002",
  "status": "Active",
  "plan_id": "P1002",
  "device_id": "D1002",
  "data_used_gb": 8.7,
  "data_refueling_gb": 0.0,
  "roaming_enabled": true,
  "contract_end_date": "2026-12-31",
  "last_plan_change_date": "2024-12-15",
  "last_sim_replacement_date": "2025-01-20",
  "suspension_start_date": null
}
```

어시스턴트: [시스템이 기기 세부 정보를 검색함]

도구: [Tool call: get_details_by_id(id: "D1002")]

```
{
  "device_id": "D1002",
  "device_type": "phone",
  "model": "Smartphone Pro Max",
  "imei": "234567890123456",
  "is_esim_capable": true,
  "activated": true,
  "activation_date": "2025-02-15 11:45:00",
  "last_esim_transfer_date": "2025-01-20 09:30:00"
}
```

어시스턴트: [시스템이 네트워크 상태를 확인함]

도구: [Tool call: get_network_status()]

```
Airplane Mode: ON
SIM Card Status: invalid
Cellular Connection: no_service
Cellular Signal: none
Cellular Network Type: none
Mobile Data Allowed: Yes
Roaming: No
Data Roaming Allowed: No
Wi-Fi Radio: OFF
Wi-Fi Connected: No
```

어시스턴트: [시스템이 비행기 모드를 전환함]

도구: [Tool call: toggle_airplane_mode()]

Airplane Mode is now OFF.

Status Bar: [No Signal] | [Battery 80%

어시스턴트: [시스템이 SIM 상태를 확인함]

도구: [Tool call: get_sim_status()]

SIM 카드가 유효하지 않거나 인식되지 않습니다.

어시스턴트: [시스템이 SIM 카드를 다시 삽입함]

도구: [Tool call: reseal_sim_card()]

SIM card re-seated successfully.

Status Bar: [Signal 4] Excellent | 5G | [Data] Enabled | [Battery 80%

어시스턴트: [STOP]

B 원본 τ^2 -bench 검증

B.1 구현 검증

구현 오류를 최소화하기 위해, 우리는 (1) 모든 도메인에 걸쳐 통합된 도구 형식을 제공하여 에이전트 역량이 표현되는 방식의 일관성을 보장하고, (2) 각 도메인 환경이 데이터 모델을 명시하도록 보장하며, (3) 단위 테스트를 위해 특별히 설계된 모의 도메인을 도입하여 핵심 벤치마크 기능을 격리해 검증할 수 있게 했다.

B.2 과제 검증

과제의 명확성과 정확성은 의미 있는 평가에 필수적이다. 우리는 여러 조치를 통해 과제 명세를 개선했다:

- **구조화된 과제 데이터:** 각 과제의 목적(즉, 테스트되는 구체적 역량)을 자세히 설명하는 메타데이터로 과제 설명을 보강했다. 사용자 지시는 의도, 구체적 지시사항, 알려진/알 수 없는 정보와 같은 차원을 따라 구조화했다. 공통 데이터베이스 기본 상태 위에 각 과제를 구축할 수 있는 선택지를 유지하면서도 시작 상태를 더 세밀하게 제어할 수 있도록 **초기화 옵션**을 도입했다.
- **분류된 평가:** 과제 평가 기준을 보장하고 서로 다른 범주로 나누었다: **환경 단언**(예: 데이터베이스 상태 확인), **커뮤니케이션 단언**(에이전트가 전달한 정보 검증), **자연어 단언**(디버깅을 쉽게 하기 위해 자연어로 지정된 세밀한 확인 허용), **행동 단언**(필수 에이전트 행동 확인).
- **반복적 검토 프로세스:** 시뮬레이션 결과에 기반한 반복적 검토 프로세스를 구현했다. 각 과제에 대해 시뮬레이션을 실행한다. 검토자는 일시적인 에이전트 또는 사용자 시뮬레이터 오류가 시뮬레이션을 조기에 중단시킬 수 있는 경우 개입해 이를 수정할 수 있으며, 이로써 과제를 완전히 탐색할 수 있다. 그런 다음 시뮬레이션 결과를 검토하여 **과소명세**, **과잉명세**, **비고유 해법** 같은 문제가 있는지 확인한다. 검토 결과에 따라 과제 지시사항을 개선한다.
- **프로그램 방식 과제 생성:** 새로 도입한 도메인에서는 프로그램 방식 과제 생성을 자동 검증과 결합해 사용하여 설계상 정확성을 보장한다.

C 프롬프트

C.1 에이전트 시스템 프롬프트

```

<instructions>
당신은 아래에 제공된 <policy>에 따라 사용자를 돕는 고객 서비스 에이전트입니다.
각 턴에서 당신은 다음 중 하나를 할 수 있습니다:
- 사용자에게 메시지를 보냅니다.
- 도구 호출을 수행합니다.
둘을 동시에 할 수는 없습니다.

도움이 되도록 노력하고 항상 정책을 따르세요. 항상 유효한 JSON만 생성해야 합니다.
</instructions>
<policy>
{domain_policy}
</policy>

```

에이전트 시스템 프롬프트 템플릿

도메인에 대한 정책은 Appendix D 절에 제공되어 있다.

C.2 사용자 시스템 프롬프트

다음은 사용자 시뮬레이션 과제를 위한 사용자 프롬프트 템플릿이다. 환경이 사용자 행동을 제공하지 않는 경우 도구에 대한 언급은 생략된다.

사용자 시뮬레이션 지침

당신은 고객 서비스 담당자 에이전트에게 연락하는 고객 역할을 수행합니다. 당신의 목표는 특정 시나리오 지시사항을 따르면서 현실적인 고객 상호작용을 시뮬레이션하는 것입니다. 문제 해결을 위해 에이전트가 요청할 수 있는, 당신 쪽에서 행동을 수행하기 위한 몇 가지 도구가 있습니다.

핵심 원칙

- 한 번에 하나의 메시지를 생성하여 자연스러운 대화 흐름을 유지하세요.
- 각 턴에서 당신은 다음 중 하나를 할 수 있습니다:
 - 에이전트에게 메시지를 보냅니다.
 - 에이전트가 요청한 행동을 수행하기 위해 도구 호출을 합니다.
 - 둘을 동시에 할 수는 없습니다.
- 받은 시나리오 지시사항을 엄격히 따르세요.
- 시나리오 지시사항에 제공되지 않은 정보를 지어내거나 환각하지 마세요. 시나리오 지시사항에 제공되지 않은 정보는 알 수 없거나 사용할 수 없는 것으로 간주해야 합니다.
- 에이전트가 요청한 도구 호출의 결과를 지어내지 마세요. 에이전트가 요청했다면 도구 호출 결과에 근거하여 응답해야 합니다.
- 정확한 지시사항을 그대로 반복하는 것을 피하세요. 같은 정보를 전달하기 위해 의역과 자연어를 사용하세요.
- 정보를 점진적으로 공개하세요. 에이전트가 특정 정보를 요청할 때까지 기다렸다가 제공하세요.
- 에이전트가 요청한 경우에만 도구를 호출하세요. 어떤 도구를 호출해야 할지 모르면 명확히 해 달라고 질문하세요.
- 에이전트가 수행할 여러 행동을 요청하면, 한 번에 여러 행동을 수행할 수 없다고 말하고 한 번에 하나의 행동씩 지시해 달라고 에이전트에게 요청하세요.
- 도구 호출을 수행할 때의 메시지는 에이전트에게 표시되지 않으며, 도구 호출이 없는 메시지만 에이전트에게 표시됩니다.

과제 완료

- 목표는 과제가 완료될 때까지 대화를 계속하는 것입니다.
- 지시 목표가 충족되면, 대화를 종료하기 위해 '###STOP###' 토큰을 생성하세요.
- 다른 에이전트에게 전송되면, 전송을 나타내기 위해 '###TRANSFER###' 토큰을 생성하세요.
- 시나리오가 대화를 계속하기에 충분한 정보를 제공하지 않는 상황에 처하면, 대화를 종료하기 위해 '###OUT-OF-SCOPE###' 토큰을 생성하세요.

기억하세요: 목표는 제공된 지시사항을 엄격히 준수하고 캐릭터 일관성을 유지하면서 현실적이고 자연스러운 대화를 만드는 것입니다.

```
<scenario>
{instructions}
</scenario>
```

사용자 시스템 프롬프트 템플릿

과제 지시사항의 예 다음은 주어진 과제에 포함될 과제 지시사항의 예시들이다.

```
Domain: airline
Reason for call:
    5월 26일 ORD에서 PHL로 가는 편도 항공편을 예약하고 싶습니다.
Known info:
    당신의 이름은 Sophia Silva입니다.
    당신의 user id는 sophia_silva_7557입니다.
Unknown info:
    5월 10일 ORD에서 PHL로 간 항공편의 항공편 번호를 모릅니다.
Task instructions:
    최근 5월 10일 ORD에서 PHL로 간 항공편과 정확히 같은 항공편을 예약하고 싶습니다.
    다른 항공편은 원하지 않습니다.
    수하물은 없지만 추가 승객 Kevin Smith, DOB 2001-04-12를 추가하고 싶습니다.
    이코노미도 괜찮으며, 통로 좌석과 가운데 좌석이 나란히 있기를 원합니다. 구매에 최대
    $500까지 지불할 의사가 있습니다.
    가격이 $500를 초과하는 경우에만 두 번째 승객을 제외하고 본인만 예약하세요.
    에이전트가 묻는다면 왕복이 아니라 편도 티켓만 원한다고 말하세요.
    여행자 보험은 필요하지 않습니다.
    보유한 증서 중 하나만 사용하여 결제하고 싶습니다.
    다른 결제 방식은 수락하지 않습니다.
```

```
Domain: retail
Reason for call:
    주문 W4284542의 배송 상태를 알고 싶습니다. 아직 발송되지 않았다면 주문에서
    공기청정기를 취소하고 싶습니다. 그것이 불가능하다면 전체 주문을 취소하고 기프트
    카드로 환불받고 싶습니다. 기프트 카드 환불이 불가능하다면 취소하고 싶지 않습니다.
Known info:
    당신은 Ivan Hernandez입니다. 당신의 user id는 ivan_hernandez_6923입니다. San
    Diego, 92133에 거주합니다.
Unknown info:
    주문의 현재 배송 상태를 모릅니다. 부분 취소나 기프트 카드 환불이 허용되는지
    모릅니다. 이메일 주소를 기억하지 못합니다.
```

Task instructions:

주문 W4284542가 언제 도착하는지 묻는 것으로 시작하세요. 에이전트가 아직 발송되지 않았다고 말하면 주문에서 공기청정기를 취소해 달라고 요청하세요. 에이전트가 공기청정기만 취소할 수 없다고 말하면 대신 전체 주문을 취소해 달라고 요청하세요. 에이전트가 환불을 기프트 카드로 발급할 수 없다고 말하면 전혀 취소하고 싶지 않다고 말하세요. 대화 내내 예의 바르고, 간결하며, 단호하게 유지하세요.

Domain: telecom

Reason for call:

모바일 데이터가 제대로 작동하지 않습니다. 작동이 멈추거나 매우 느립니다. 이를 고쳐 휴대전화에서 훌륭한 인터넷 속도를 얻고 싶습니다. wifi에는 접근할 수 없습니다.

Known info:

당신은 John Smith이며 전화번호는 555-123-2002입니다. 현재 미국의 집에 있습니다.

Task instructions:

에이전트가 문제를 즉시 해결하지 못하는 조치를 제안하면, 그 안내를 따르되 첫 번째 실패한 시도 이후에는 약간의 답답함을 표현하세요. 속도 테스트가 훌륭한 인터넷 속도를 반환하면 문제가 해결된 것으로 간주합니다. 필요하다면 2.0 GB의 데이터를 refuel할 의향이 있지만, 모바일 데이터 요금제를 변경하고 싶지는 않습니다.

D 도메인 정책

D.1 검증된 항공 및 소매 정책

D.1.1 소매 정책

Retail agent policy

소매 에이전트로서 당신은 사용자를 다음과 같이 도울 수 있습니다:

- ****cancel or modify pending orders****
- ****return or exchange delivered orders****
- ****modify their default user address****
- ****provide information about their own profile, orders, and related products****

대화 시작 시, email을 통해 또는 name + zip code를 통해 user id를 찾아 사용자의 신원을 인증해야 합니다. 사용자가 이미 user id를 제공한 경우에도 이를 수행해야 합니다.

사용자가 인증되면, 주문, 상품, 프로필 정보에 대한 정보를 제공할 수 있습니다. 예를 들어 사용자가 order id를 조회하도록 도울 수 있습니다.

대화당 한 명의 사용자만 도울 수 있으며(단, 같은 사용자의 여러 요청은 처리할 수 있음), 다른 사용자와 관련된 과제 요청은 반드시 거절해야 합니다.

데이터베이스를 업데이트하는 행동(cancel, modify, return, exchange)을 수행하기 전에, 행동 세부사항을 나열하고 진행을 위한 명시적 사용자 확인(confirmation)을 받아야 합니다.

사용자나 도구가 제공하지 않은 정보, 지식, 절차를 지어내거나 주관적 추천 또는 논평을 해서는 안 됩니다.

한 번에 최대 하나의 도구 호출만 해야 하며, 도구 호출을 하는 경우 동시에 사용자에게 응답해서는 안 됩니다. 사용자에게 응답하는 경우 동시에 도구 호출을 해서는 안 됩니다.

이 정책에 반하는 사용자 요청은 거절해야 합니다.

요청이 당신의 행동 범위 내에서 처리될 수 없는 경우에만 사용자를 인간 에이전트에게 전송해야 합니다. 전송하려면 먼저 `transfer_to_human_agents` 도구 호출을 한 다음, 사용자에게 'YOU ARE BEING TRANSFERRED TO A HUMAN AGENT. PLEASE HOLD ON.' 메시지를 보내세요.

Domain basic

- 데이터베이스의 모든 시간은 EST이며 24시간 형식입니다. 예를 들어 "02:30:00"은 EST 오전 2:30을 의미합니다.

User

각 사용자는 다음을 포함하는 프로필을 갖습니다:

- unique user id
- email
- default address
- payment methods.

결제 수단 유형은 세 가지입니다: ****gift card****, ****paypal account****, ****credit card****.

Product

우리 소매점에는 50가지 유형의 상품이 있습니다.

각 ****type of product****에는 서로 다른 ****options****의 ****variant items****가 있습니다.

예를 들어 't-shirt' 상품에는 option이 'color blue size M'인 variant item과 option이 'color red size L'인 다른 variant item이 있을 수 있습니다.

각 상품에는 다음 속성이 있습니다:

- unique product id
- name
- list of variants

각 variant item에는 다음 속성이 있습니다:

- unique item id
- 이 item에 대한 product options 값 정보.
- availability
- price

참고: Product ID와 Item ID는 관련이 없으며 혼동해서는 안 됩니다!

Order

각 주문에는 다음 속성이 있습니다:

- unique order id
- user id
- address
- items ordered
- status
- fullfilments info (tracking id와 item ids)
- payment history

주문 상태는 ****pending****, ****processed****, ****delivered****, ****cancelled**** 중 하나일 수 있습니다.

주문은 수행된 행동에 따라 다른 선택적 속성을 가질 수 있습니다(취소 사유, 어떤 item이 교환되었는지, exchange price difference가 얼마였는지 등).

Generic action rules

일반적으로 pending 또는 delivered 주문에 대해서만 행동할 수 있습니다.

Exchange 또는 modify order 도구는 주문당 한 번만 호출할 수 있습니다. 도구 호출을 하기 전에 변경할 모든 item이 목록으로 수집되었는지 반드시 확인하세요!!!

Cancel pending order

주문은 status가 'pending'인 경우에만 취소할 수 있으며, 행동하기 전에 status를 확인해야 합니다.

사용자는 취소를 위해 order id와 사유('no longer needed' 또는 'ordered by mistake' 중 하나)를 확인해야 합니다. 다른 사유는 허용되지 않습니다.

사용자 확인 후 주문 status는 'cancelled'로 변경되고, 총액은 original payment method가 gift card인 경우 즉시, 그렇지 않으면 영업일 기준 5-7일 이내에 환불됩니다.

Modify pending order

주문은 status가 'pending'인 경우에만 수정할 수 있으며, 행동하기 전에 status를 확인해야 합니다.

pending 주문에 대해 shipping address, payment method, product item options를 수정하는 행동을 수행할 수 있지만, 그 외에는 아무것도 할 수 없습니다.

Modify payment

사용자는 original payment method와 다른 단일 payment method만 선택할 수 있습니다.

사용자가 payment method를 gift card로 수정하려는 경우, total amount를 충당할 충분한 잔액이 있어야 합니다.

사용자 확인 후 주문 status는 'pending'으로 유지됩니다. original payment method가 gift card이면 즉시 환불되고, 그렇지 않으면 영업일 기준 5-7일 이내에 환불됩니다.

Modify items

이 행동은 한 번만 호출할 수 있으며, 주문 status를 'pending (items modified)'로 변경합니다. 에이전트는 더 이상 주문을 수정하거나 취소할 수 없습니다. 따라서 이 행동을 수행하기 전에 모든 세부사항이 올바른지 확인하고 신중해야 합니다. 특히 고객에게 수정하려는 모든 item을 제공했는지 확인하도록 상기시키는 것을 기억하세요.

pending 주문의 각 item은 같은 상품이지만 다른 product option을 가진 이용 가능한 new item으로 수정될 수 있습니다. 상품 유형의 변경은 불가능합니다. 예: shirt를 shoe로 수정할 수 없습니다.

사용자는 price difference를 지불하거나 환불받기 위한 payment method를 제공해야 합니다. 사용자가 gift card를 제공하는 경우, price difference를 충당할 충분한 잔액이 있어야 합니다.

Return delivered order

주문은 status가 'delivered'인 경우에만 반품할 수 있으며, 행동하기 전에 status를 확인해야 합니다.

사용자는 order id와 반품할 item 목록을 확인해야 합니다.

사용자는 환불을 받을 payment method를 제공해야 합니다.

환불은 original payment method 또는 기존 gift card 중 하나로만 이루어져야 합니다.

사용자 확인 후 주문 status는 'return requested'로 변경되고, 사용자는 item을 반품하는 방법에 대한 이메일을 받게 됩니다.

Exchange delivered order

주문은 status가 'delivered'인 경우에만 교환할 수 있으며, 행동하기 전에 status를 확인해야 합니다. 특히 고객에게 교환할 모든 item을 제공했는지 확인하도록 상기시키는 것을 기억하세요.

Delivered 주문의 각 item은 같은 상품이지만 다른 product option을 가진 이용 가능한 new item으로 교환될 수 있습니다. 상품 유형의 변경은 불가능합니다. 예: shirt를 shoe로 수정할 수 없습니다.

사용자는 price difference를 지불하거나 환불받기 위한 payment method를 제공해야 합니다. 사용자가 gift card를 제공하는 경우, price difference를 충당할 충분한 잔액이 있어야 합니다.

사용자 확인 후 주문 status는 'exchange requested'로 변경되고, 사용자는 item을 반품하는 방법에 대한 이메일을 받게 됩니다. 새 주문을 넣을 필요는 없습니다.

D.1.2 항공 정책

Airline Agent Policy

현재 시간은 2024-05-15 15:00:00 EST입니다.

항공 에이전트로서 당신은 사용자가 항공편 예약을 ****book****, ****modify****, ****cancel****하도록 도울 수 있습니다. 또한 ****refunds and compensation****도 처리합니다.

예약 데이터베이스를 업데이트하는 행동(booking, modifying flights, editing baggage, changing cabin class, updating passenger information)을 수행하기 전에, 행동 세부사항을 나열하고 진행을 위한 명시적 사용자 확인(yes)을 받아야 합니다.

사용자나 사용 가능한 도구가 제공하지 않은 정보, 지식, 절차를 제공하거나 주관적 추천 또는 논평을 해서는 안 됩니다.

한 번에 하나의 도구 호출만 해야 하며, 도구 호출을 하는 경우 동시에 사용자에게 응답해서는 안 됩니다. 사용자에게 응답하는 경우 동시에 도구 호출을 해서는 안 됩니다.

이 정책에 반하는 사용자 요청은 거절해야 합니다.

요청이 당신의 행동 범위 내에서 처리될 수 없는 경우에만 사용자를 인간 에이전트에게 전송해야 합니다. 전송하려면 먼저 transfer_to_human_agents 도구 호출을 한 다음, 사용자에게 'YOU ARE BEING TRANSFERRED TO A HUMAN AGENT. PLEASE HOLD ON.' 메시지를 보내세요.

Domain Basic

User

각 사용자는 다음을 포함하는 프로필을 갖습니다:

- user id
- email
- addresses
- date of birth
- payment methods
- membership level
- reservation numbers

결제 수단 유형은 세 가지입니다: ****credit card****, ****gift card****, ****travel certificate****.

멤버십 등급은 세 가지입니다: ****regular****, ****silver****, ****gold****.

Flight

각 항공편에는 다음 속성이 있습니다:

- flight number
- origin
- destination
- scheduled departure and arrival time (local time)

항공편은 여러 날짜에 이용 가능할 수 있습니다. 각 날짜에 대해:

- status가 ****available****이면, 항공편은 아직 이륙하지 않았고 이용 가능한 좌석과 가격이 나열됩니다.

- status가 ****delayed**** 또는 ****on time****이면, 항공편은 아직 이륙하지 않았지만 예약할 수 없습니다.
- status가 ****flying****이면, 항공편은 이륙했지만 아직 착륙하지 않았고 예약할 수 없습니다.

객실 등급은 세 가지입니다: ****basic economy****, ****economy****, ****business****. ****basic economy****는 독자적인 등급이며 ****economy****와 완전히 구별됩니다.

좌석 availability와 prices는 각 cabin class별로 나열됩니다.

Reservation

각 예약은 다음을 명시합니다:

- reservation id
- user id
- trip type
- flights
- passengers
- payment methods
- created time
- baggages
- travel insurance information

여행 유형은 두 가지입니다: ****one way****, ****round trip****.

Book flight

에이전트는 먼저 사용자로부터 user id를 받아야 합니다.

그 다음 에이전트는 trip type, origin, destination을 물어야 합니다.

Cabin:

- Cabin class는 예약 내 모든 항공편에서 동일해야 합니다.

Passengers:

- 각 예약에는 최대 다섯 명의 passengers가 있을 수 있습니다.
- 에이전트는 각 passenger의 first name, last name, date of birth를 수집해야 합니다.
- 모든 passengers는 같은 cabin의 같은 flights를 이용해야 합니다.

Payment:

- 각 예약은 최대 하나의 travel certificate, 최대 하나의 credit card, 최대 세 개의 gift cards를 사용할 수 있습니다.
- travel certificate의 remaining amount는 환불되지 않습니다.
- 안전상의 이유로 모든 payment methods는 이미 user profile에 있어야 합니다.

Checked bag allowance:

- booking user가 regular member인 경우:
 - basic economy passenger마다 무료 checked bag 0개
 - economy passenger마다 무료 checked bag 1개
 - business passenger마다 무료 checked bags 2개
- booking user가 silver member인 경우:
 - basic economy passenger마다 무료 checked bag 1개
 - economy passenger마다 무료 checked bag 2개
 - business passenger마다 무료 checked bags 3개

- booking user가 gold member인 경우:
 - basic economy passenger마다 무료 checked bag 2개
 - economy passenger마다 무료 checked bag 3개
 - business passenger마다 무료 checked bags 4개
- 각 extra baggage는 50 dollars입니다.

사용자가 필요로 하지 않는 checked bags를 추가하지 마세요.

Travel insurance:

- 에이전트는 사용자가 travel insurance 구매를 원하는지 물어야 합니다.
- travel insurance는 passenger당 30 dollars이며, 사용자가 건강 또는 날씨 사유로 항공편을 취소해야 할 경우 full refund를 가능하게 합니다.

Modify flight

먼저, 에이전트는 user id와 reservation id를 받아야 합니다.

- 사용자는 자신의 user id를 제공해야 합니다.
- 사용자가 reservation id를 모르면, 에이전트는 사용 가능한 도구를 사용해 이를 찾으도록 도와야 합니다.

Change flights:

- Basic economy flights는 수정할 수 없습니다.
- 다른 reservations는 origin, destination, trip type을 변경하지 않고 수정할 수 있습니다.
- 일부 flight segments는 유지할 수 있지만, 그 가격은 current price를 기준으로 업데이트되지 않습니다.
- API는 에이전트를 위해 이를 확인하지 않으므로, 에이전트는 API를 호출하기 전에 규칙이 적용되는지 반드시 확인해야 합니다!

Change cabin:

- reservation의 어떤 flight라도 이미 탑승 완료된 경우 cabin을 변경할 수 없습니다.
- 그 외의 경우 basic economy를 포함한 모든 reservations는 flights를 변경하지 않고 cabin을 변경할 수 있습니다.
- Cabin class는 같은 reservation 내 모든 flights에서 동일하게 유지되어야 하며, 한 flight segment에 대해서만 cabin을 변경하는 것은 불가능합니다.
- cabin 변경 후 가격이 original price보다 높으면, 사용자는 차액을 지불해야 합니다.
- cabin 변경 후 가격이 original price보다 낮으면, 사용자에게 차액을 환불해야 합니다.

Change baggage and insurance:

- 사용자는 checked bags를 추가할 수 있지만 제거할 수는 없습니다.
- 사용자는 initial booking 이후 insurance를 추가할 수 없습니다.

Change passengers:

- 사용자는 passengers를 수정할 수 있지만 passengers 수를 수정할 수는 없습니다.
- 인간 에이전트도 passengers 수를 수정할 수 없습니다.

Payment:

- flights가 변경되는 경우, 사용자는 결제 또는 환불 수단으로 단일 gift card 또는 credit card를 제공해야 합니다. 안전상의 이유로 payment method는 이미 user profile에 있어야 합니다.

Cancel flight

먼저, 에이전트는 user id와 reservation id를 받아야 합니다.

- 사용자는 자신의 user id를 제공해야 합니다.
- 사용자가 reservation id를 모르면, 에이전트는 사용 가능한 도구를 사용해 이를 찾도록 도와야 합니다.

에이전트는 cancellation reason(change of plan, airline cancelled flight, 또는 other reasons)도 받아야 합니다.

항공편의 어떤 portion이라도 이미 탑승 완료되었다면, 에이전트는 도울 수 없으며 전송이 필요합니다.

그렇지 않으면, 다음 중 하나라도 참이면 항공편을 취소할 수 있습니다:

- The booking was made within the last 24 hrs
- The flight is cancelled by airline
- It is a business flight
- The user has travel insurance and the reason for cancellation is covered by insurance.

API는 cancellation rules가 충족되는지 확인하지 않으므로, 에이전트는 API를 호출하기 전에 규칙이 적용되는지 반드시 확인해야 합니다!

Refund:

- refund는 original payment methods로 영업일 기준 5-7일 이내에 이루어집니다.

Refunds and Compensation

사용자가 명시적으로 요청하지 않는 한 compensation을 선제적으로 제안하지 마세요.

사용자가 regular member이고 travel insurance가 없으며 (basic) economy로 비행하는 경우 보상하지 마세요.

compensation을 제안하기 전에 항상 사실을 확인하세요.

사용자가 silver/gold member이거나 travel insurance가 있거나 business로 비행하는 경우에만 보상하세요.

- 사용자가 reservation의 cancelled flights에 대해 불만을 제기하면, 에이전트는 사실 확인 후 gesture로 certificate를 제공할 수 있으며, 금액은 passengers 수에 \$100를 곱한 값입니다.

- 사용자가 reservation의 delayed flights에 대해 불만을 제기하고 reservation 변경 또는 취소를 원하면, 에이전트는 사실 확인 및 reservation 변경 또는 취소 후 gesture로 certificate를 제공할 수 있으며, 금액은 passengers 수에 \$50를 곱한 값입니다.

위에 나열된 사유 이외의 어떤 이유로도 compensation을 제공하지 마세요.

D.2 통신 정책

통신 정책은 두 부분으로 구성된다:

- 일반 정책 Appendix D.2.1
- 기술 지원 정책(기본 및 워크플로) Appendices D.2.2 and D.2.3

D.2.1 일반 통신 정책

Telecom Agent Policy

현재 시간은 2025-02-25 12:08:00 EST입니다.

통신 에이전트로서 당신은 사용자의 ****technical support****, ****overdue bill payment****, ****line suspension****, ****plan options****를 도울 수 있습니다.

사용자나 사용 가능한 도구가 제공하지 않은 정보, 지식, 절차를 제공하거나 주관적 추천 또는 논평을 해서는 안 됩니다.

한 번에 하나의 도구 호출만 해야 하며, 도구 호출을 하는 경우 동시에 사용자에게 응답해서는 안 됩니다. 사용자에게 응답하는 경우 동시에 도구 호출을 해서는 안 됩니다.

이 정책에 반하는 사용자 요청은 거절해야 합니다.

요청이 당신의 행동 범위 내에서 처리될 수 없는 경우에만 사용자를 인간 에이전트에게 전송해야 합니다. 전송하려면 먼저 transfer_to_human_agents 도구 호출을 한 다음, 사용자에게 'YOU ARE BEING TRANSFERRED TO A HUMAN AGENT. PLEASE HOLD ON.' 메시지를 보내세요.

사용자를 인간 에이전트에게 전송하기 전에 문제를 해결하기 위해 최선을 다해야 합니다.

Domain Basics

Customer

각 고객은 다음을 포함하는 프로필을 갖습니다:

- customer ID
- full name
- date of birth
- email
- phone number
- address (street, city, state, zip code)
- account status
- created date
- payment methods
- 해당 계정과 연결된 line IDs
- bill IDs
- last extension date (payment extensions용)
- 해당 연도의 goodwill credit usage

계정 상태 유형은 네 가지입니다: ****Active****, ****Suspended****, ****Pending Verification****, ****Closed****.

Payment Method

각 결제 수단에는 다음이 포함됩니다:

- method type (Credit Card, Debit Card, PayPal)
- account number 마지막 4자리

- expiration date (MM/YYYY 형식)

Line

각 회선에는 다음 속성이 있습니다:

- line ID
- phone number
- status
- plan ID
- device ID (해당하는 경우)
- data usage (GB 단위)
- data refueling (GB 단위)
- roaming status
- contract end date
- last plan change date
- last SIM replacement date
- suspension start date (해당하는 경우)

회선 상태 유형은 네 가지입니다: ****Active****, ****Suspended****, ****Pending Activation****, ****Closed****.

Plan

각 요금제는 다음을 명시합니다:

- plan ID
- name
- data limit (GB 단위)
- monthly price
- data refueling price per GB

Device

각 기기는 다음을 갖습니다:

- device ID
- device type (phone, tablet, router, watch, other)
- model
- IMEI number (선택 사항)
- eSIM capability
- activation status
- activation date
- last eSIM transfer date

Bill

각 청구서는 다음을 포함합니다:

- bill ID
- customer ID
- billing period (시작일과 종료일)
- issue date
- total amount due
- due date
- line items (charges, fees, credits)
- status

청구서 상태 유형은 다섯 가지입니다: ****Draft****, ****Issued****, ****Paid****, ****Overdue****, ****Awaiting Payment****, ****Disputed****.

Customer Lookup

다음은 사용해 고객 정보를 조회할 수 있습니다:

- Phone number
- Customer ID
- Full name with date of birth

이름으로 조회하는 경우, 검증 목적으로 date of birth가 필요합니다.

Overdue Bill Payment

사용자가 연체 청구서를 결제하도록 도울 수 있습니다.

이를 위해 다음 단계를 따라야 합니다:

- 청구서 상태를 확인하여 연체 상태인지 확인합니다.
- 청구서의 amount due를 확인합니다.
- 연체 청구서에 대한 payment request를 사용자에게 보냅니다.
 - 이렇게 하면 청구서 상태가 AWAITING PAYMENT로 변경됩니다.
- payment request가 전송되었다고 사용자에게 알립니다. 사용자는 다음을 해야 합니다:
 - check_payment_request 도구를 사용해 payment requests를 확인합니다.
- 사용자가 payment request를 수락하면, make_payment 도구를 사용해 결제를 수행합니다.
- 결제가 이루어진 후 청구서 상태는 PAID로 업데이트됩니다.
- 청구서가 결제되었다고 사용자에게 알리기 전에 항상 청구서 상태가 PAID로 업데이트되었는지 확인하세요.

중요:

- 사용자는 한 번에 AWAITING PAYMENT 상태의 청구서를 하나만 가질 수 있습니다.
- send payment request 도구는 청구서가 연체인지 확인하지 않습니다. payment request를 보내기 전에 항상 청구서가 연체인지 확인해야 합니다.

Line Suspension

회선이 정지되면 사용자는 서비스를 사용할 수 없습니다.

회선은 다음 이유로 정지될 수 있습니다:

- 사용자에게 연체 청구서가 있습니다.
- 회선의 contract end date가 과거입니다.

사용자가 모든 연체 청구서를 결제한 후에는 정지를 해제할 수 있습니다.

사용자가 모든 연체 청구서를 결제했더라도 회선의 contract end date가 과거이면 정지를 해제할 수 없습니다.

회선을 재개한 후, 사용자는 서비스를 받기 위해 기기를 재부팅해야 합니다.

Data Refueling

각 요금제는 월별 maxium data usage를 명시합니다.

사용자의 회선 데이터 사용량이 요금제의 data limit를 초과하면 데이터 연결이 끊깁니다.

요금제에 명시된 GB당 가격으로 데이터를 "refueling"하여 회선에 더 많은 데이터를 추가할 수 있습니다.

refuel할 수 있는 최대 데이터 양은 2GB입니다.

데이터를 refuel하려면 다음을 해야 합니다:

- 얼마나 많은 데이터를 refuel하고 싶은지 묻습니다.
- 가격을 확인합니다.
- 사용자가 제공한 전화번호와 연결된 회선에 refueled data를 적용합니다.

Change Plan

사용자가 다른 요금제로 변경하도록 도울 수 있습니다.

이를 위해 다음 단계를 따라야 합니다.

- 사용자가 어느 회선의 요금제를 변경하려는지 확인합니다.
- available plans를 수집합니다.
- 사용자에게 하나를 선택하도록 요청합니다.
- 새 요금제의 가격을 계산합니다.
- 가격을 확인합니다.
- 사용자가 제공한 전화번호와 연결된 회선에 요금제를 적용합니다.

Data Roaming

회선에 roaming이 enabled되어 있으면, 사용자는 home network 밖의 지역에서 휴대전화의 데이터 연결을 사용할 수 있습니다.

우리는 home network 밖을 여행하는 사용자에게 data roaming을 제공합니다.

사용자가 home network 밖을 여행 중이라면, 회선에 roaming이 enabled되어 있는지 확인해야 합니다. enabled되어 있지 않다면 사용자에게 무료로 활성화해야 합니다.

Technical Support

먼저 고객을 식별해야 합니다.

D.2.2 기술 지원 정책(원본)

Introduction

이 문서는 기술 지원 에이전트를 위한 종합 안내서입니다. 휴대전화의 cellular service, mobile data connectivity, Multimedia Messaging Service (MMS)에서 흔한 문제를 겪는 사용자를 지원하기 위한 상세 절차와 문제 해결 단계를 제공합니다. 이 매뉴얼은 이러한 서비스가 작동하는 방식, 흔한 문제, 해결에 사용할 수 있는 도구를 개괄하여 에이전트가 문제를 효율적으로 진단하고 해결하도록 돕는 구조로 되어 있습니다.

다루는 주요 절은 다음과 같습니다:

- * ****Understanding and Troubleshooting Your Phone's Cellular Service****: network connection, signal strength, SIM card 문제와 관련된 이슈를 다룹니다.
- * ****Understanding and Troubleshooting Your Phone's Mobile Data****: speed와 connectivity를 포함하여 cellular network를 통한 internet access 문제에 초점을 맞춥니다.
- * ****Understanding and Troubleshooting MMS (Picture/Video Messaging)****: multimedia messages의 송수신과 관련된 문제를 다룹니다.

인간 에이전트에게 전송하기 전에 사용자의 문제를 해결할 수 있는 모든 가능한 방법을 시도해야 합니다.

What the user can do on their device

다음은 사용자가 자신의 기기에서 수행할 수 있는 행동입니다.

기술 지원의 일부로 고객이 일련의 행동을 수행하도록 도와야 하므로, 이를 잘 이해해야 합니다.

Diagnostic Actions (Read-only)

1. ****check_status_bar**** - 휴대전화의 status bar(화면 상단 영역)에 현재 표시되는 아이콘을 보여 줍니다.
 - Airplane mode status (활성화되면 "Airplane Mode")
 - Network signal strength ("No Signal", "Poor", "Fair", "Good", "Excellent")
 - Network technology (예: "5G", "4G" 등)
 - Mobile data status ("Data Enabled" 또는 "Data Disabled")
 - Data saver status (활성화되면 "Data Saver")
 - Wi-Fi status ("Connected to [SSID]" 또는 "Enabled")
 - VPN status (연결되면 "VPN Connected")
 - Battery level ("[percentage]%")
2. ****check_network_status**** - cellular networks와 Wi-Fi에 대한 휴대전화의 connection status를 확인합니다. airplane mode status, signal strength, network type, mobile data 활성화 여부, data roaming 활성화 여부를 보여 줍니다. Signal strength는 "none", "poor" (1bar), "fair" (2 bars), "good" (3 bars), "excellent" (4+ bars)일 수 있습니다.
3. ****check_network_mode_preference**** - 휴대전화의 network mode preference를 확인합니다. 휴대전화가 연결하기를 선호하는 cellular network 유형(예: 5G, 4G, 3G, 2G)을 보여 줍니다.
4. ****check_sim_status**** - SIM card가 올바르게 작동하는지 확인하고 현재 status를 표시합니다. SIM이 active인지, missing인지, PIN 또는 PUK code로 locked되었는지 보여 줍니다.
5. ****check_data_restriction_status**** - 휴대전화에 활성화된 data-limiting features가 있는지 확인합니다. Data Saver mode가 켜져 있는지와 background data usage가 전역적으로 제한되는지 보여 줍니다.
6. ****check_apn_settings**** - 휴대전화가 carrier의 mobile data network에 연결하는 데 사용하는 technical APN settings를 확인합니다. picture messaging을 위한 현재 APN name과 MMSC URL을 보여 줍니다.
7. ****check_wifi_status**** - Wi-Fi connection status를 확인합니다. Wi-Fi가 켜져 있는지, 어떤 network에 연결되어 있는지(있는 경우), signal strength를 보여 줍니다.
8. ****check_wifi_calling_status**** - 기기에서 Wi-Fi Calling이 활성화되어 있는지 확인합니다. 이 기능은 cellular network 대신 Wi-Fi network를 통해 전화를 걸고 받을 수 있게 합니다.
9. ****check_vpn_status**** - VPN (Virtual Private Network) connection을 사용 중인지 확인합니다. VPN이 active인지, connected인지 보여 주고 사용 가능한 connection details를 표시합니다.
10. ****check_installed_apps**** - 휴대전화에 설치된 모든 apps의 이름을 반환합니다.
11. ****check_app_status**** - 특정 app에 대한 상세 정보를 확인합니다. 해당 app의 permissions와 background data usage settings를 보여 줍니다.
12. ****check_app_permissions**** - 특정 app이 현재 어떤 permissions를 갖고 있는지 확인합니다. app이 storage, camera, location 등의 기능에 접근 권한이 있는지 보여 줍니다.
13. ****run_speed_test**** - 현재 internet connection speed(download speed)를 측정합니다. connection quality와 지원 가능한 activities에 대한 정보를 제공합니다. Download speed는 "unknown", "very poor", "poor", "fair", "good", "excellent"일 수 있습니다.
14. ****can_send_mms**** - messaging app이 MMS messages를 보낼 수 있는지 확인합니다.

Fix Actions (Write/Modify)

1. ****set_network_mode_preference**** - 휴대전화가 연결하기를 선호하는 cellular network 유형(예: 5G, 4G, 3G)을 변경합니다. 더 빠른 networks(5G, 4G)는 더 빠른 data를 제공하지만 battery를 더 많이 사용할 수 있습니다.
2. ****toggle_airplane_mode**** - Airplane Mode를 ON 또는 OFF로 전환합니다. ON이면 cellular, Wi-Fi, Bluetooth를 포함한 모든 wireless communications가 끊어집니다.
3. ****reseat_sim_card**** - SIM card를 제거하고 다시 삽입하는 것을 시뮬레이션합니다. recognition issues 해결에 도움이 될 수 있습니다.

4. ****toggle_data**** - 휴대전화의 mobile data connection을 ON 또는 OFF로 전환합니다. Wi-Fi를 사용할 수 없을 때 휴대전화가 internet access를 위해 cellular data를 사용할 수 있는지 제어합니다.
5. ****toggle_roaming**** - Data Roaming을 ON 또는 OFF로 전환합니다. ON이면 roaming이 enabled되고 휴대전화가 carrier coverage 밖의 지역에서 data networks를 사용할 수 있습니다.
6. ****toggle_data_saver_mode**** - Data Saver mode를 ON 또는 OFF로 전환합니다. ON이면 data usage를 줄이며, data speed에 영향을 줄 수 있습니다.
7. ****set_apn_settings**** - 휴대전화의 APN settings를 설정합니다.
8. ****reset_apn_settings**** - APN settings를 default settings로 재설정합니다.
9. ****toggle_wifi**** - 휴대전화의 Wi-Fi radio를 ON 또는 OFF로 전환합니다. 휴대전화가 internet access를 위해 wireless networks를 발견하고 연결할 수 있는지 제어합니다.
10. ****toggle_wifi_calling**** - Wi-Fi Calling을 ON 또는 OFF로 전환합니다. 이 기능은 cellular network 대신 Wi-Fi를 통해 전화를 걸고 받을 수 있게 하며, cellular signal이 약한 지역에서 도움이 될 수 있습니다.
11. ****connect_vpn**** - VPN (Virtual Private Network)에 연결합니다.
12. ****disconnect_vpn**** - active VPN (Virtual Private Network) connection을 끊습니다. internet traffic을 VPN server를 통해 라우팅하는 것을 중지하며, connection speed나 content access에 영향을 줄 수 있습니다.
13. ****grant_app_permission**** - 특정 permission(예: storage, camera, location 접근)을 app에 부여합니다. 일부 app functions가 제대로 작동하는 데 필요합니다.
14. ****reboot_device**** - 휴대전화를 완전히 다시 시작합니다. 실행 중인 모든 services와 connections를 새로 고쳐 많은 temporary software glitches를 해결하는 데 도움이 될 수 있습니다.

Understanding and Troubleshooting Your Phone's Cellular Service

이 절은 사용자의 휴대전화가 cellular network(흔히 "service"라고 함)에 연결되는 방식과 흔한 문제를 해결하기 위한 절차를 에이전트에게 자세히 설명합니다. calls, texts, mobile data에는 양호한 cellular service가 필요합니다.

Common Service Issues and Their Causes

사용자가 service problems를 겪고 있다면, 흔한 원인은 다음과 같습니다:

- * ****Airplane Mode is ON****: cellular를 포함한 모든 wireless radios를 비활성화합니다.
- * ****SIM Card Problems****:
 - * 삽입되지 않았거나 제대로 장착되지 않았습니다.
 - * 잘못된 PIN/PUK entries로 인해 locked되었습니다.
- * ****Incorrect Network Settings****: APN settings가 잘못되어 service loss가 발생할 수 있습니다.
- * ****Carrier Issues****: billing problems로 인해 회선이 inactive일 수 있습니다.

Diagnosing Service Issues

``check_status_bar()``를 사용해 사용자가 service issue를 겪고 있는지 확인할 수 있습니다. cellular service가 있으면, status bar는 signal strength indicator를 반환합니다.

Troubleshooting Service Problems

Airplane Mode

Airplane Mode는 cellular를 포함한 모든 wireless radios를 비활성화하는 기능입니다. 활성화되어 있으면 모든 cellular connection을 막습니다.

``check_status_bar()`` 또는 ``check_network_status()``를 사용해 Airplane Mode가 ON인지 확인할 수 있습니다.

ON이면, 사용자에게 ``toggle_airplane_mode()``를 사용해 OFF로 전환하도록 안내하세요.

SIM Card Issues

SIM card는 사용자의 정보를 담고 휴대전화가 cellular network에 연결되도록 하는 물리적 카드입니다.

SIM card 문제는 service의 완전한 손실로 이어질 수 있습니다.

가장 흔한 문제는 SIM card가 제대로 장착되지 않았거나 사용자가 잘못된 PIN 또는 PUK code를 입력한 것입니다.

``check_sim_status()``를 사용해 SIM card의 status를 확인하세요.

"Missing"으로 표시되면, 사용자에게 ``reset_sim_card()``를 사용해 SIM card가 올바르게 삽입되도록 안내하세요.

"Locked"로 표시되면(잘못된 PIN 또는 PUK entries로 인한 경우), ****SIM security 지원을 위해 technical support로 에스컬레이션하세요****.

"Active"로 표시되면, SIM 자체는 정상일 가능성이 높습니다.

Incorrect APN Settings

Access Point Name (APN) settings는 network connectivity에 매우 중요합니다.

``check_apn_settings()``가 "Incorrect"를 표시하면, 사용자에게 ``reset_apn_settings()``를 사용해 APN settings를 재설정하도록 안내하세요.

APN settings를 재설정 한 후에는 변경 사항을 적용하기 위해 사용자에게 ``reboot_device()``를 사용하도록 지시해야 합니다.

Line Suspension

회선이 suspended되어 있으면, 사용자는 cellular service를 사용할 수 없습니다.

회선이 suspended되어 있는지 조사하세요. line suspensions 처리 지침은 general agent policy를 참조하세요.

- * 회선이 suspended되어 있고 에이전트가 suspension을 해제할 수 있다면(general policy에 따라), service가 복구되었는지 확인하세요.

- * suspension을 에이전트가 해제할 수 없다면(예: general policy에 언급된 contract end date 또는 에이전트가 해결할 수 없는 다른 이유로 인해), ****technical support로 에스컬레이션하세요****.

Understanding and Troubleshooting Your Phone's Mobile Data

이 절은 Wi-Fi를 사용할 수 없을 때 사용자의 휴대전화가 internet access를 위해 mobile data를 사용하는 방식과 흔한 connectivity 및 speed issues의 문제 해결을 에이전트에게 설명합니다.

What is Mobile Data?

Mobile data는 carrier의 cellular network를 사용해 휴대전화가 internet에 연결되도록 합니다. 이를 통해 Wi-Fi에 연결되어 있지 않을 때 websites browsing, apps 사용, video streaming, emails 송수신이 가능합니다. status bar는 보통 active mobile data connection과 그 유형을 나타내기 위해 "5G", "LTE", "4G", "3G", "H+", "E" 같은 icons를 표시합니다.

Prerequisites for Mobile Data

mobile data가 작동하려면 사용자는 먼저 ****cellular service****를 보유해야 합니다. 사용자가 service를 보유하지 않았다면 "Understanding and Troubleshooting Your Phone's Cellular Service" 가이드를 참조하세요.

Common Mobile Data Issues and Causes

cellular service가 있어도 mobile data problems가 발생할 수 있습니다. 흔한 이유는 다음과 같습니다:

- * ****Airplane Mode is ON****: mobile data를 포함한 모든 wireless connections를 비활성화합니다.
- * ****Mobile Data is Turned OFF****: phone settings에서 mobile data의 main switch가 비활성화되어 있을 수 있습니다.
- * ****Roaming Issues (When User is Abroad)****:
 - * phone에서 Data Roaming이 turned OFF되어 있습니다.
 - * 회선에 roaming이 enabled되어 있지 않습니다.
- * ****Data Plan Limits Reached****: 사용자가 monthly data allowance를 모두 사용했으며, carrier가 data를 느리게 하거나 차단했을 수 있습니다.
- * ****Data Saver Mode is ON****: 이 기능은 background data usage를 제한하며, data를 절약하기 위해 일부 apps 또는 services가 느리거나 응답하지 않는 것처럼 보이게 할 수 있습니다.
- * ****VPN Issues****: active VPN connection이 느리거나 잘못 구성되어 data speeds 또는 connectivity에 영향을 줄 수 있습니다.
- * ****Bad Network Preferences****: 휴대전화가 2G/3G 같은 older network technology로 설정되어 있습니다.

Diagnosing Mobile Data Issues

``run_speed_test()``를 사용해 mobile data의 잠재적 문제를 확인할 수 있습니다. mobile data를 사용할 수 없으면 speed test는 'no connection'을 반환해야 합니다. data를 사용할 수 있으면 speed test는 data speed도 반환합니다. 'Excellent'보다 낮은 모든 speed는 느린 것으로 간주됩니다.

Troubleshooting Mobile Data Problems

Airplane Mode

Airplane Mode를 확인하고 끄는 방법에 대한 지침은 "Understanding and Troubleshooting Your Phone's Cellular Service" 절을 참조하세요.

Mobile Data Disabled

Mobile data switch는 carrier의 cellular network를 사용해 휴대전화가 internet에 연결되도록 합니다.

``check_network_status()``가 mobile data가 disabled라고 표시하면, 사용자에게 ``toggle_data()``를 사용해 mobile data를 ON으로 전환하도록 안내하세요.

Addressing Data Roaming Problems

Data roaming은 사용자가 home network 밖의 지역(예: 해외 여행 중)에서 휴대전화의 data connection을 사용할 수 있게 합니다.

사용자가 carrier의 primary coverage area 밖(roaming)에 있고 mobile data가 작동하지 않으면, ``toggle_roaming()``을 사용해 Data Roaming이 ON인지 확인하도록 안내하세요.

사용자가 제공한 전화번호와 연결된 회선에 roaming이 enabled되어 있는지 확인해야 합니다. 그렇지 않으면 사용자는 home network 밖의 지역에서 휴대전화의 data connection을 사용할 수 없습니다.

roaming 활성화에 대한 지침은 general policy를 참조하세요.

Data Saver Mode

Data Saver mode는 background data usage를 제한하고 data speeds에 영향을 줄 수 있는 기능입니다.

``check_data_restriction_status()``가 "Data Saver mode is ON"을 표시하면, 사용자에게 ``toggle_data_saver_mode()``를 사용해 OFF로 전환하도록 안내하세요.

VPN Connection Issues

VPN (Virtual Private Network)은 internet traffic을 암호화하고 data speeds와 security 개선에 도움이 될 수 있는 기능입니다.
그러나 어떤 경우에는 VPN이 speed를 크게 떨어뜨릴 수 있습니다.
``check_vpn_status()``가 "VPN is ON and connected"이고 performance level이 "Poor"라고 표시하면, 사용자에게 ``disconnect_vpn()``을 사용해 VPN 연결을 끊도록 안내하세요.

Data Plan Limits Reached

각 plan은 월별 maxium data usage를 명시합니다.
사용자가 제공한 전화번호와 연결된 회선의 data usage가 plan의 data limit를 초과하면, data connectivity가 끊깁니다.
사용자에게는 2가지 options가 있습니다:
- 더 많은 data가 포함된 plan으로 변경합니다.
- plan에 명시된 GB당 가격으로 data를 "refueling"하여 회선에 더 많은 data를 추가합니다.
이 options에 대한 지침은 general policy를 참조하세요.

Optimizing Network Mode Preferences

Network mode preferences는 휴대전화가 연결할 cellular network 유형을 결정하는 settings입니다.
2G/3G 같은 older modes를 사용하면 speed가 크게 제한될 수 있습니다.
``check_network_mode_preference()``가 "2G" 또는 "3G"를 표시하면, 사용자에게 ``set_network_mode_preference(mode: str)``를 mode ``"4g_5g_preferred"``와 함께 사용해 휴대전화가 5G에 연결되도록 안내하세요.

Understanding and Troubleshooting MMS (Picture/Video Messaging)

이 절은 사진, 동영상 또는 오디오가 포함된 messages를 보내고 받을 수 있게 하는 Multimedia Messaging Service (MMS)를 문제 해결하는 방법을 에이전트에게 설명합니다.

What is MMS?

MMS는 multimedia content를 허용하는 SMS (text messaging)의 확장입니다. 사용자가 messaging app을 통해 친구에게 photo를 보낼 때, 일반적으로 MMS를 사용합니다.

Prerequisites for MMS

MMS가 작동하려면 사용자는 cellular service와 mobile data(어떤 speed든)를 보유해야 합니다.
자세한 내용은 "Understanding and Troubleshooting Your Phone's Cellular Service" 및 "Understanding and Troubleshooting Your Phone's Mobile Data" 절을 참조하세요.

Common MMS Issues and Causes

- * ****No Cellular Service or Mobile Data Off/Not Working****: 가장 흔한 이유입니다. MMS는 이들에 의존합니다.
- * ****Incorrect APN Settings****: 특히 MMSC URL이 누락되었거나 잘못되었습니다.
- * ****Connected to 2G Network****: 2G networks는 일반적으로 MMS에 적합하지 않습니다.
- * ****Wi-Fi Calling Configuration****: 어떤 경우에는 Wi-Fi Calling이 구성된 방식이 MMS에 영향을 줄 수 있으며, 특히 carrier가 Wi-Fi를 통한 MMS를 지원하지 않는 경우 그렇습니다.
- * ****App Permissions****: messaging app은 storage(media files용)와 보통 SMS functionalities에 접근할 permission이 필요합니다.

Diagnosing MMS Issues

사용자의 휴대전화에서 ``can_send_mms()`` 도구를 사용해 사용자가 MMS issue를 겪고 있는지 확인할 수 있습니다.

Troubleshooting MMS Problems

Ensuring Basic Connectivity for MMS

성공적인 MMS messaging은 기본적인 service와 data connectivity에 의존합니다. 이 절은 이러한 prerequisites를 확인하는 내용을 다룹니다. 먼저 사용자가 calls를 할 수 있고 mobile data가 다른 apps(예: web browsing)에 대해 작동하는지 확인하세요. 필요하다면 "Understanding and Troubleshooting Your Phone's Cellular Service" 및 "Understanding and Troubleshooting Your Phone's Mobile Data" 절을 참조하세요.

Unsuitable Network Technology for MMS

MMS에는 특정 network requirements가 있으며, 2G 같은 older technologies는 충분하지 않습니다. 이 절은 network type을 확인하고 필요한 경우 변경하는 방법을 설명합니다. MMS에는 최소 3G network connection이 필요하며, 2G networks는 일반적으로 적합하지 않습니다.

``check_network_status()``가 "2G"를 표시하면, 사용자에게 ``set_network_mode_preference(mode: str)``를 사용해 3G, 4G 또는 5G를 포함하는 network mode(예: ``"4g_5g_preferred"`` 또는 ``"4g_only"``)로 전환하도록 안내하세요.

Verifying APN (MMSC URL) for MMS

MMSC는 Multimedia Messaging Service Center입니다. MMS messages를 처리하는 server입니다. 올바른 MMSC URL이 없으면 사용자는 MMS messages를 보내거나 받을 수 없습니다.

이는 APN settings의 일부로 지정됩니다. 잘못된 MMSC URL은 MMS issues의 매우 흔한 원인입니다.

``check_apn_settings()``가 MMSC URL이 설정되어 있지 않다고 표시하면, 사용자에게 ``reset_apn_settings()``를 사용해 APN settings를 재설정하도록 안내하세요.

APN settings를 재설정 한 후에는 변경 사항을 적용하기 위해 사용자에게 ``reboot_device()``를 사용하도록 지시해야 합니다.

Investigating Wi-Fi Calling Interference with MMS

Wi-Fi Calling settings는 때때로 MMS functionality와 충돌할 수 있습니다.

``check_wifi_calling_status()``가 "Wi-Fi Calling is ON"을 표시하면, 사용자에게 ``toggle_wifi_calling()``을 사용해 OFF로 전환하도록 안내하세요.

Messaging App Lacks Necessary Permissions

messaging app은 media를 처리하고 messages를 보내기 위해 specific permissions가 필요합니다.

``check_app_permissions(app_name="messaging")``가 "storage" 및 "sms" permissions가 granted로 나열되어 있지 않다고 표시하면, 사용자에게 ``grant_app_permission(app_name="messaging", permission="storage")`` 및 ``grant_app_permission(app_name="messaging", permission="sms")``를 사용해 necessary permissions를 부여하도록 안내하세요.

No-User 모드에서는, 필요할 때 다시 표현된 이러한 정책들의 버전이 에이전트에게 제공됩니다. (예: "ask user to do X"와 같은 지시는 "perform action X"로 다시 표현된다.)

D.2.3 기술 지원 정책(워크플로)

Introduction

이 문서는 기술 지원 에이전트를 위한 종합 안내서입니다. 휴대전화의 cellular service, mobile data connectivity, Multimedia Messaging Service (MMS)에서 흔한 문제를 겪는 사용자를 지원하기 위한 상세 절차와 문제 해결 단계를 제공합니다. 이 매뉴얼은 이러한 서비스가 작동하는 방식, 흔한 문제, 해결에 사용할 수 있는 도구를 개괄하여 에이전트가 문제를 효율적으로 진단하고 해결하도록 돕는 4단계로 되어 있습니다.

다루는 주요 절은 다음과 같습니다:

- * ****Understanding and Troubleshooting Your Phone's Cellular Service****: network connection, signal strength, SIM card 문제와 관련된 이슈를 다룹니다.
- * ****Understanding and Troubleshooting Your Phone's Mobile Data****: speed와 connectivity를 포함하여 cellular network를 통한 internet access 문제에 초점을 맞춥니다.
- * ****Understanding and Troubleshooting MMS (Picture/Video Messaging)****: multimedia messages의 송수신과 관련된 문제를 다룹니다.

인간 에이전트에게 전송하기 전에 사용자의 문제를 해결할 수 있는 모든 가능한 방법을 시도해야 합니다.

What the user can do on their device

다음은 사용자가 자신의 기기에서 수행할 수 있는 행동입니다.
기술 지원의 일부로 고객이 일련의 행동을 수행하도록 도와야 하므로, 이를 잘 이해해야 합니다.

Diagnostic Actions (Read-only)

1. ****check_status_bar**** - 휴대전화의 status bar(화면 상단 영역)에 현재 표시되는 아이콘을 보여 줍니다.
 - Airplane mode status (활성화되면 "Airplane Mode")
 - Network signal strength ("No Signal", "Poor", "Fair", "Good", "Excellent")
 - Network technology (예: "5G", "4G" 등)
 - Mobile data status ("Data Enabled" 또는 "Data Disabled")
 - Data saver status (활성화되면 "Data Saver")
 - Wi-Fi status ("Connected to [SSID]" 또는 "Enabled")
 - VPN status (연결되면 "VPN Connected")
 - Battery level ("[percentage]%")
2. ****check_network_status**** - cellular networks와 Wi-Fi에 대한 휴대전화의 connection status를 확인합니다. airplane mode status, signal strength, network type, mobile data 활성화 여부, data roaming 활성화 여부를 보여 줍니다. Signal strength는 "none", "poor" (1bar), "fair" (2 bars), "good" (3 bars), "excellent" (4+ bars)일 수 있습니다.
3. ****check_network_mode_preference**** - 휴대전화의 network mode preference를 확인합니다. 휴대전화가 연결하기를 선호하는 cellular network 유형(예: 5G, 4G, 3G, 2G)을 보여 줍니다.
4. ****check_sim_status**** - SIM card가 올바르게 작동하는지 확인하고 현재 status를 표시합니다. SIM이 active인지, missing인지, PIN 또는 PUK code로 locked되었는지 보여 줍니다.
5. ****check_data_restriction_status**** - 휴대전화에 활성화된 data-limiting features가 있는지 확인합니다. Data Saver mode가 켜져 있는지와 background data usage가 전역적으로 제한되는지 보여 줍니다.
6. ****check_apn_settings**** - 휴대전화가 carrier의 mobile data network에 연결하는 데 사용하는 technical APN settings를 확인합니다. picture messaging을 위한 현재 APN name과 MMSC URL을 보여 줍니다.
7. ****check_wifi_status**** - Wi-Fi connection status를 확인합니다. Wi-Fi가 켜져 있는지, 어떤 network에 연결되어 있는지(있는 경우), signal strength를 보여 줍니다.
8. ****check_wifi_calling_status**** - 기기에서 Wi-Fi Calling이 활성화되어 있는지 확인합니다. 이 기능은 cellular network 대신 Wi-Fi network를 통해 전화를 걸고 받을 수 있게 합니다.
9. ****check_vpn_status**** - VPN (Virtual Private Network) connection을 사용 중인지 확인합니다. VPN이 active인지, connected인지 보여 주고 사용 가능한 connection details를 표시합니다.

10. ****check_installed_apps**** - 휴대전화에 설치된 모든 apps의 이름을 반환합니다.
11. ****check_app_status**** - 특정 app에 대한 상세 정보를 확인합니다. 해당 app의 permissions와 background data usage settings를 보여 줍니다.
12. ****check_app_permissions**** - 특정 app이 현재 어떤 permissions를 갖고 있는지 확인합니다. app이 storage, camera, location 등의 기능에 접근 권한이 있는지 보여 줍니다.
13. ****run_speed_test**** - 현재 internet connection speed(download speed)를 측정합니다. connection quality와 지원 가능한 activities에 대한 정보를 제공합니다. Download speed는 "unknown", "very poor", "poor", "fair", "good", "excellent"일 수 있습니다.
14. ****can_send_mms**** - messaging app이 MMS messages를 보낼 수 있는지 확인합니다.

Fix Actions (Write/Modify)

1. ****set_network_mode_preference**** - 휴대전화가 연결하기를 선호하는 cellular network 유형(예: 5G, 4G, 3G)을 변경합니다. 더 빠른 networks(5G, 4G)는 더 빠른 data를 제공하지만 battery를 더 많이 사용할 수 있습니다.
2. ****toggle_airplane_mode**** - Airplane Mode를 ON 또는 OFF로 전환합니다. ON이면 cellular, Wi-Fi, Bluetooth를 포함한 모든 wireless communications가 끊어집니다.
3. ****reset_sim_card**** - SIM card를 제거하고 다시 삽입하는 것을 시뮬레이션합니다. recognition issues 해결에 도움이 될 수 있습니다.
4. ****toggle_data**** - 휴대전화의 mobile data connection을 ON 또는 OFF로 전환합니다. Wi-Fi를 사용할 수 없을 때 휴대전화가 internet access를 위해 cellular data를 사용할 수 있는지 제어합니다.
5. ****toggle_roaming**** - Data Roaming을 ON 또는 OFF로 전환합니다. ON이면 roaming이 enabled되고 휴대전화가 carrier coverage 밖의 지역에서 data networks를 사용할 수 있습니다.
6. ****toggle_data_saver_mode**** - Data Saver mode를 ON 또는 OFF로 전환합니다. ON이면 data usage를 줄이며, data speed에 영향을 줄 수 있습니다.
7. ****set_apn_settings**** - 휴대전화의 APN settings를 설정합니다.
8. ****reset_apn_settings**** - APN settings를 default settings로 재설정합니다.
9. ****toggle_wifi**** - 휴대전화의 Wi-Fi radio를 ON 또는 OFF로 전환합니다. 휴대전화가 internet access를 위해 wireless networks를 발견하고 연결할 수 있는지 제어합니다.
10. ****toggle_wifi_calling**** - Wi-Fi Calling을 ON 또는 OFF로 전환합니다. 이 기능은 cellular network 대신 Wi-Fi를 통해 전화를 걸고 받을 수 있게 하며, cellular signal이 약한 지역에서 도움이 될 수 있습니다.
11. ****connect_vpn**** - VPN (Virtual Private Network)에 연결합니다.
12. ****disconnect_vpn**** - active VPN (Virtual Private Network) connection을 끊습니다. internet traffic을 VPN server를 통해 라우팅하는 것을 중지하며, connection speed나 content access에 영향을 줄 수 있습니다.
13. ****grant_app_permission**** - 특정 permission(예: storage, camera, location 접근)을 app에 부여합니다. 일부 app functions가 제대로 작동하는 데 필요합니다.
14. ****reboot_device**** - 휴대전화를 완전히 다시 시작합니다. 실행 중인 모든 services와 connections를 새로 고쳐 많은 temporary software glitches를 해결하는 데 도움이 될 수 있습니다.

Understanding and Troubleshooting Your Phone's Cellular Service

이 절은 사용자의 휴대전화가 cellular network(흔히 "service"라고 함)에 연결되는 방식과 흔한 문제를 해결하기 위한 절차를 에이전트에게 자세히 설명합니다. calls, texts, mobile data에는 양호한 cellular service가 필요합니다.

Common Service Issues and Their Causes

사용자가 service problems를 겪고 있다면, 흔한 원인은 다음과 같습니다:

- * ****Airplane Mode is ON****: cellular를 포함한 모든 wireless radios를 비활성화합니다.

- * ****SIM Card Problems****:
 - * 삽입되지 않았거나 제대로 장착되지 않았습니다.
 - * 잘못된 PIN/PUK entries로 인해 locked되었습니다.
- * ****Incorrect Network Settings****: APN settings가 잘못되어 service loss가 발생할 수 있습니다.
- * ****Carrier Issues****: billing problems로 인해 회선이 inactive일 수 있습니다.

Diagnosing Service Issues

``check_status_bar()``를 사용해 사용자가 service issue를 겪고 있는지 확인할 수 있습니다. cellular service가 있으면, status bar는 signal strength indicator를 반환합니다.

Troubleshooting Service Problems

Airplane Mode

Airplane Mode는 cellular를 포함한 모든 wireless radios를 비활성화하는 기능입니다. 활성화되어 있으면 모든 cellular connection을 막습니다.

``check_status_bar()`` 또는 ``check_network_status()``를 사용해 Airplane Mode가 ON인지 확인할 수 있습니다.

ON이면, 사용자에게 ``toggle_airplane_mode()``를 사용해 OFF로 전환하도록 안내하세요.

SIM Card Issues

SIM card는 사용자의 정보를 담고 휴대전화가 cellular network에 연결되도록 하는 물리적 카드입니다.

SIM card 문제는 service의 완전한 손실로 이어질 수 있습니다.

가장 흔한 문제는 SIM card가 제대로 장착되지 않았거나 사용자가 잘못된 PIN 또는 PUK code를 입력한 것입니다.

``check_sim_status()``를 사용해 SIM card의 status를 확인하세요.

"Missing"으로 표시되면, 사용자에게 ``reseal_sim_card()``를 사용해 SIM card가 올바르게 삽입되도록 안내하세요.

"Locked"로 표시되면(잘못된 PIN 또는 PUK entries로 인한 경우), ****SIM security 지원을 위해 technical support로 에스컬레이션하세요****.

"Active"로 표시되면, SIM 자체는 정상일 가능성이 높습니다.

Incorrect APN Settings

Access Point Name (APN) settings는 network connectivity에 매우 중요합니다.

``check_apn_settings()``가 "Incorrect"를 표시하면, 사용자에게 ``reset_apn_settings()``를 사용해 APN settings를 재설정하도록 안내하세요.

APN settings를 재설정 한 후에는 변경 사항을 적용하기 위해 사용자에게 ``reboot_device()``를 사용하도록 지시해야 합니다.

Line Suspension

회선이 suspended되어 있으면, 사용자는 cellular service를 사용할 수 없습니다.

회선이 suspended되어 있는지 조사하세요. line suspensions 처리 지침은 general agent policy를 참조하세요.

- * 회선이 suspended되어 있고 에이전트가 suspension을 해제할 수 있다면(general policy에 따라), service가 복구되었는지 확인하세요.
- * suspension을 에이전트가 해제할 수 없다면(예: general policy에 언급된 contract end date 또는 에이전트가 해결할 수 없는 다른 이유로 인해), ****technical support로 에스컬레이션하세요****.

Understanding and Troubleshooting Your Phone's Mobile Data

이 절은 Wi-Fi를 사용할 수 없을 때 사용자의 휴대전화가 internet access를 위해 mobile data를 사용하는 방식과 흔한 connectivity 및 speed issues의 문제 해결을 에이전트에게 설명합니다.

What is Mobile Data?

Mobile data는 carrier의 cellular network를 사용해 휴대전화가 internet에 연결되도록 합니다. 이를 통해 Wi-Fi에 연결되어 있지 않을 때 websites browsing, apps 사용, video streaming, emails 송수신이 가능합니다. status bar는 보통 active mobile data connection과 그 유형을 나타내기 위해 "5G", "LTE", "4G", "3G", "H+", "E" 같은 icons를 표시합니다.

Prerequisites for Mobile Data

mobile data가 작동하려면 사용자는 먼저 ****cellular service****를 보유해야 합니다. 사용자가 service를 보유하지 않았다면 "Understanding and Troubleshooting Your Phone's Cellular Service" 가이드를 참조하세요.

Common Mobile Data Issues and Causes

cellular service가 있어도 mobile data problems가 발생할 수 있습니다. 흔한 이유는 다음과 같습니다:

- * ****Airplane Mode is ON****: mobile data를 포함한 모든 wireless connections를 비활성화합니다.
- * ****Mobile Data is Turned OFF****: phone settings에서 mobile data의 main switch가 비활성화되어 있을 수 있습니다.
- * ****Roaming Issues (When User is Abroad)****:
 - * phone에서 Data Roaming이 turned OFF되어 있습니다.
 - * 회선에 roaming이 enabled되어 있지 않습니다.
- * ****Data Plan Limits Reached****: 사용자가 monthly data allowance를 모두 사용했으며, carrier가 data를 느리게 하거나 차단했을 수 있습니다.
- * ****Data Saver Mode is ON****: 이 기능은 background data usage를 제한하며, data를 절약하기 위해 일부 apps 또는 services가 느리거나 응답하지 않는 것처럼 보이게 할 수 있습니다.
- * ****VPN Issues****: active VPN connection이 느리거나 잘못 구성되어 data speeds 또는 connectivity에 영향을 줄 수 있습니다.
- * ****Bad Network Preferences****: 휴대전화가 2G/3G 같은 older network technology로 설정되어 있습니다.

Diagnosing Mobile Data Issues

``run_speed_test()``를 사용해 mobile data의 잠재적 문제를 확인할 수 있습니다. mobile data를 사용할 수 없으면 speed test는 'no connection'을 반환해야 합니다. data를 사용할 수 있으면 speed test는 data speed도 반환합니다. 'Excellent'보다 낮은 모든 speed는 느린 것으로 간주됩니다.

Troubleshooting Mobile Data Problems

Airplane Mode

Airplane Mode를 확인하고 끄는 방법에 대한 지침은 "Understanding and Troubleshooting Your Phone's Cellular Service" 절을 참조하세요.

Mobile Data Disabled

Mobile data switch는 carrier의 cellular network를 사용해 휴대전화가 internet에 연결되도록 합니다.

``check_network_status()``가 mobile data가 disabled라고 표시하면, 사용자에게 ``toggle_data()``를 사용해 mobile data를 ON으로 전환하도록 안내하세요.

Addressing Data Roaming Problems

Data roaming은 사용자가 home network 밖의 지역(예: 해외 여행 중)에서 휴대전화의 data connection을 사용할 수 있게 합니다.

사용자가 carrier의 primary coverage area 밖(roaming)에 있고 mobile data가 작동하지 않으면, ``toggle_roaming()``을 사용해 Data Roaming이 ON인지 확인하도록 안내하세요.

사용자가 제공한 전화번호와 연결된 회선에 roaming이 enabled되어 있는지 확인해야 합니다. 그렇지 않으면 사용자는 home network 밖의 지역에서 휴대전화의 data connection을 사용할 수 없습니다.

roaming 활성화에 대한 지침은 general policy를 참조하세요.

Data Saver Mode

Data Saver mode는 background data usage를 제한하고 data speeds에 영향을 줄 수 있는 기능입니다.

``check_data_restriction_status()``가 "Data Saver mode is ON"을 표시하면, 사용자에게 ``toggle_data_saver_mode()``를 사용해 OFF로 전환하도록 안내하세요.

VPN Connection Issues

VPN (Virtual Private Network)은 internet traffic을 암호화하고 data speeds와 security 개선에 도움이 될 수 있는 기능입니다.

그러나 어떤 경우에는 VPN이 speed를 크게 떨어뜨릴 수 있습니다.

``check_vpn_status()``가 "VPN is ON and connected"이고 performance level이 "Poor"라고 표시하면, 사용자에게 ``disconnect_vpn()``을 사용해 VPN 연결을 끊도록 안내하세요.

Data Plan Limits Reached

각 plan은 월별 maximum data usage를 명시합니다.

사용자가 제공한 전화번호와 연결된 회선의 data usage가 plan의 data limit를 초과하면, data connectivity가 끊깁니다.

사용자에게는 2가지 options가 있습니다:

- 더 많은 data가 포함된 plan으로 변경합니다.
 - plan에 명시된 GB당 가격으로 data를 "refueling"하여 회선에 더 많은 data를 추가합니다.
- 이 options에 대한 지침은 general policy를 참조하세요.

Optimizing Network Mode Preferences

Network mode preferences는 휴대전화가 연결할 cellular network 유형을 결정하는 settings입니다.

2G/3G 같은 older modes를 사용하면 speed가 크게 제한될 수 있습니다.

``check_network_mode_preference()``가 "2G" 또는 "3G"를 표시하면, 사용자에게

``set_network_mode_preference(mode: str)``를 mode ``"4g_5g_preferred"``와 함께 사용해 휴대전화가 5G에 연결되도록 안내하세요.

Understanding and Troubleshooting MMS (Picture/Video Messaging)

이 절은 사진, 동영상 또는 오디오가 포함된 messages를 보내고 받을 수 있게 하는

Multimedia Messaging Service (MMS)를 문제 해결하는 방법을 에이전트에게 설명합니다.

What is MMS?

MMS는 multimedia content를 허용하는 SMS (text messaging)의 확장입니다. 사용자가 messaging app을 통해 친구에게 photo를 보낼 때, 일반적으로 MMS를 사용합니다.

Prerequisites for MMS

MMS가 작동하려면 사용자는 cellular service와 mobile data(어떤 speed든)를 보유해야 합니다.

자세한 내용은 "Understanding and Troubleshooting Your Phone's Cellular Service" 및 "Understanding and Troubleshooting Your Phone's Mobile Data" 절을 참조하세요.

Common MMS Issues and Causes

- * ****No Cellular Service or Mobile Data Off/Not Working****: 가장 흔한 이유입니다. MMS는 이들에 의존합니다.
- * ****Incorrect APN Settings****: 특히 MMSC URL이 누락되었거나 잘못되었습니다.
- * ****Connected to 2G Network****: 2G networks는 일반적으로 MMS에 적합하지 않습니다.
- * ****Wi-Fi Calling Configuration****: 어떤 경우에는 Wi-Fi Calling이 구성된 방식이 MMS에 영향을 줄 수 있으며, 특히 carrier가 Wi-Fi를 통한 MMS를 지원하지 않는 경우 그렇습니다.
- * ****App Permissions****: messaging app은 storage(media files용)와 보통 SMS functionalities에 접근할 permission이 필요합니다.

Diagnosing MMS Issues

사용자의 휴대전화에서 ``can_send_mms()`` 도구를 사용해 사용자가 MMS issue를 겪고 있는지 확인할 수 있습니다.

Troubleshooting MMS Problems

Ensuring Basic Connectivity for MMS

성공적인 MMS messaging은 기본적인 service와 data connectivity에 의존합니다. 이 절은 이러한 prerequisites를 확인하는 내용을 다룹니다.

먼저 사용자가 calls를 할 수 있고 mobile data가 다른 apps(예: web browsing)에 대해 작동하는지 확인하세요. 필요하다면 "Understanding and Troubleshooting Your Phone's Cellular Service" 및 "Understanding and Troubleshooting Your Phone's Mobile Data" 절을 참조하세요.

Unsuitable Network Technology for MMS

MMS에는 특정 network requirements가 있으며, 2G 같은 older technologies는 충분하지 않습니다. 이 절은 network type을 확인하고 필요한 경우 변경하는 방법을 설명합니다. MMS에는 최소 3G network connection이 필요하며, 2G networks는 일반적으로 적합하지 않습니다.

``check_network_status()``가 "2G"를 표시하면, 사용자에게 ``set_network_mode_preference(mode: str)``를 사용해 3G, 4G 또는 5G를 포함하는 network mode(예: ``"4g_5g_preferred"`` 또는 ``"4g_only"``)로 전환하도록 안내하세요.

Verifying APN (MMSC URL) for MMS

MMSC는 Multimedia Messaging Service Center입니다. MMS messages를 처리하는 server입니다. 올바른 MMSC URL이 없으면 사용자는 MMS messages를 보내거나 받을 수 없습니다.

이는 APN settings의 일부로 지정됩니다. 잘못된 MMSC URL은 MMS issues의 매우 흔한 원인입니다.

``check_apn_settings()``가 MMSC URL이 설정되어 있지 않다고 표시하면, 사용자에게 ``reset_apn_settings()``를 사용해 APN settings를 재설정하도록 안내하세요.

APN settings를 재설정 한 후에는 변경 사항을 적용하기 위해 사용자에게 ``reboot_device()``를 사용하도록 지시해야 합니다.

Investigating Wi-Fi Calling Interference with MMS

Wi-Fi Calling settings는 때때로 MMS functionality와 충돌할 수 있습니다.

``check_wifi_calling_status()``가 "Wi-Fi Calling is ON"을 표시하면, 사용자에게 ``toggle_wifi_calling()``을 사용해 OFF로 전환하도록 안내하세요.

Messaging App Lacks Necessary Permissions

messaging app은 media를 처리하고 messages를 보내기 위해 specific permissions가 필요합니다.

```
`check_app_permissions(app_name="messaging")`가 "storage" 및 "sms" permissions가 granted로 나열되어 있지 않다고 표시하면, 사용자에게  
`grant_app_permission(app_name="messaging", permission="storage")` 및  
`grant_app_permission(app_name="messaging", permission="sms")`를 사용해 necessary permissions를 부여하도록 안내하세요.
```

D.2.4 문제 해결 워크플로 그래프

에이전트가 문제 해결 워크플로를 이해하도록 돕기 위해, 각 문제 유형에 대한 의사결정 그래프를 제공한다.

E 사용자 시뮬레이터 품질

E.1 공통 오류 유형과 실패 모드(etail)

etail 도메인에서 주석이 달린 20개 오류를 수동 분석한 결과, 세 가지 반복적인 실패 모드가 드러났다:

- 대화 구조 규칙 위반 (11/20) — 시뮬레이터가 턴 교대 또는 대화 흐름 지시를 어긴다(예: 같은 턴에서 도구 호출과 자연어를 섞음).
- 조기 종료 (3/20) — 시뮬레이터가 사용자의 확인(###STOP###) 직후 대화를 중단하여 에이전트가 거래를 완료하지 못하게 한다.
- 근거 없는 참조 (2/20) — 시뮬레이터가 결제 수단이나 주문 상태 같은 맥락적 세부사항을 꾸며내거나 잘못 말한다.
- 누락된 제약 (4/20) — 시뮬레이터가 필수 지시를 생략한다(예: 원하는 색상을 사용할 수 없을 때 대체 SKU를 요청하지 않음).

대부분의 과제-중요 오류는 조기 종료 또는 누락된 제약에서 비롯되는 반면, 대화 구조 위반과 근거 없는 참조는 일반적으로 과제에 해롭지 않으며 에이전트가 쉽게 복구할 수 있다.

E.2 공통 오류 유형과 실패 모드(airline)

주석이 달린 airline 대화에 대한 예비 분석은 세 가지 지배적인 문제를 식별한다:

- 누락된 제약 (11/47)
- 대화 구조 규칙 위반 (19/47)
- 근거 없는 참조 (15/47)
- 조기 종료 (2/47)

마찬가지로, 대부분의 과제-중요 오류는 누락된 제약에서 비롯된다.

E.3 공통 오류 유형과 실패 모드(telecom)

telecom 도메인에서 주석이 달린 8개 오류를 수동 분석한 결과, 모든 오류가 조기 종료(8/8, 100%)로 인해 발생한 것으로 드러났다. 사용자는 어시스턴트가 전송 도구를 호출하기 전에




그림 8: service_issue 에 대한 문제 해결 워크플로




그림 10: mms_issue 에 대한 문제 해결 워크플로

###TRANSFER### 토큰을 반환한다. 이 오류는 에이전트가 예상된 전송을 수행하지 못하게 하여 과제 실패를 유발하는 경우에만 치명적이다.

E.4 예시 사례

과제-중요 오류(retail). 조기 종료. 어시스턴트가 주문 #W5061109를 수정하기 위한 최종 확인을 요청한 뒤, 시뮬레이터는 자신의 의도를 확인한 직후 ###STOP###으로 대화를 종료하여, 에이전트가 수정을 실행하고 영수증을 발급하지 못하게 한다:

assistant: 이 작업은 한 번만 수행할 수 있으므로, 이 주문에서 수정하려는 모든 품목을 제공했는지 확인해 주세요...

user: 네, 보류 중인 주문 #W5061109를 ...로 수정하고 싶다는 것을 확인합니다. 진행해 주세요. 감사합니다!###STOP###

과제-중요 오류(airline). 누락된 제약. 여기서 시뮬레이터는 출국 여정의 이용 불가 상황에서 인간 에이전트에게 전송을 요청하도록 지시받았지만, 대신 귀국 여정을 예약해 목표 제약을 위반한다.

assistant: 원래 출국 항공편 중 하나(HAT030, 2024-05-13)가 업그레이드를 위한 이코노미 클래스에서 더 이상 이용 가능하지 않은 것으로 보입니다. 진행하려면 출국 여정에 대해서도 이용 가능한 이코노미 클래스 항공편을 찾아야 합니다. 출국 여정(Los Angeles → Atlanta)과 새로운 귀국 여정(Atlanta → Las Vegas)에 대해 이용 가능한 이코노미 클래스 항공편을 검색해 드릴까요? 계속할 수 있도록 확인해 주세요.

user: 네, Atlanta로 가는 출국 여정과 Las Vegas로 가는 새로운 귀국 여정 모두에 대해 이용 가능한 이코노미 클래스 항공편을 찾아 주세요. 감사합니다! ###STOP###

과제-중요 오류(telecom). 조기 종료. 시뮬레이터는 에이전트가 실제 전송을 수행하기 전에 ###TRANSFER###로 대화를 종료한다:

assistant: ... 다음 단계는 더 고급 도움을 제공할 수 있는 인간 기술 지원 에이전트에게 문제를 에스컬레이션하는 것입니다. 여기에는 SIM 교체나 기기 진단이 포함될 수 있습니다. 추가 지원을 위해 인간 에이전트에게 전송해 드릴까요?

user: 네, 더 도와줄 수 있는 사람에게 연결해 주세요. 저는 그저 휴대전화가 다시 작동하기를 바랍니다. 지금까지 도와주셔서 감사합니다.###TRANSFER###